论文深读与理论推导详解：《疫情监测中的病例规模收益边界：估计目标、环境随机性与外部验证》

论文全案理论推导详解 · sympy 数值核验 · 技术审计意见

目录

1 导读前言：应用统计研究生的“论文通透心法” 3

2 第一部分：宏观全景地图——这篇论文究竟讲了一个什么故事？ 4

2.1 1.1 一个违背直觉的现实科学矛盾 . . . 4

2.2 1.2 论文的核心破局点：“推断目标决定规模收益” . . . 4

2.3 1.3 内生平衡点 $m_\times$ 的物理意义 . . . 5

3 第二部分：全篇核心参数全景深度字典与流行病学物理直觉 5

3.1 2.1 全篇核心参数速查总表 . . . 5

3.2 2.2 核心参数的深度流行病学物理剖析 . . . 6

3.2.1 (1) 超传播参数 k 的生物学本质 . . . 6

3.2.2 (2) 报告抽样率 ρ 的折算逻辑 . . . 6

3.2.3 (3) 滞后卷积权重 $w = (0.65, 0.25, 0.10)$ 的依据 . . . 6

4 理论工具箱速查：推导中调用的 12 大经典数理统计原公式 7

5 第三部分：数学命题教学级逐行拆解与深入证明（保姆级代数展开） 7

5.1 3.1 命题 1 前置：Gamma–Poisson 混合积分逐行展开与“成功概率” p 的物理本质 . 7

5.1.1 3.1.0 成功概率 p 的反直觉物理顿悟 . . . 7

5.1.2 3.1.1 Gamma–Poisson 连续混合积分逐行演算 . . . 8

5.2 3.2 命题 1：条件似然、得分函数、无偏性与 Cramér–Rao 下界 . . . 8

5.2.1 3.2.1 PGF 复合律保族性逐行推导 . . . 9

5.2.2 3.2.2 负二项方差公式化简 . . . 10

5.2.3 3.2.3 对数似然与得分函数求解 . . . 10

5.2.4 3.2.4 无偏性验证（双层全期望展开） . . . 10

5.2.5 3.2.5 Fisher 信息量与 Cramér–Rao 下界确立 . . . 10

5.3 3.3 命题 2：跨期基础水平的边际方差分解与仿射式推导 . . . 11

5.3.1 3.3.1 特征规模平衡点 $m_\times$ 的导出 . . . 12

5.4 3.4 命题 3：监测杠杆的理论非对称性 . . . 12

5.5 3.5 命题 4 与推论 1：多期时间抽样、AR(1) 求和与 Cochran 对偶 13
5.5.1 3.5.1 独立环境下的预算恒常性 13
5.5.2 3.5.2 AR(1) 环境自相关的双重级数求和（错位相减法逐行展开） 14
5.5.3 3.5.3 离散可行设计集合 15
5.5.4 3.5.4 推论 1：成本约束下的最优单期规模与 Cochran 对偶 15
5.6 3.6 命题 5：增长判定的单调似然比（MLR）一阶差分与离散功效 15
5.6.1 3.6.1 MLR 一阶差分严格为正证明 15
5.6.2 3.6.2 离散临界值与精确功效 16
5.6.3 3.6.3 离散功效锯齿波（Sawtooth Wave）成因 16
5.7 3.7 命题 6：更新过程条件预测方差全分解与式 (29) 预测偏差项展开 17
5.7.1 3.7.1 两步全方差公式展开 17
5.7.2 3.7.2 相对预测误差均方分解（式 29 / 正文式 22） 17

6 第四部分：数值模拟的深层设计与三幅图的精读密码 18
6.1 4.1 图 1（理论方差分解与 50,000 次蒙特卡洛验证） 18
6.2 4.2 图 2（增长检测功效与 Wald 检验失真） 18
6.3 4.3 图 3（更新过程时序卷积与单步预测误差的双口径解密） 18

7 第五部分：全美流感真实数据实证全景复盘 18
7.1 5.1 实证中的样本量 N 是什么？怎么一步步筛选出来的？ 18
7.1.1 (1) N 的统计学定义：观测单位是“州—周（State-Week）” 18
7.1.2 (2) 总样本池的来源：16,218 个原始记录 19
7.1.3 (3) 核心客观筛选门槛：$D_t \geq 5$（全美总有效样本 $N = 10,303$） 19
7.1.4 (4) 各章节具体的 N 划分机制全景表 19
7.2 5.2 为什么必须用 FGLS（可行广义最小二乘法）？ 19
7.3 5.3 核心实证估计结果 20
7.4 5.4 达峰期震撼反转：88.9% 偏差 vs 15.5% 集成预测 20
7.5 5.5 欧洲 11 国 COVID-19 跨病种验证 20

8 第六部分：硕士中期答辩高频质询 Q&A 宝典（11 问 11 答） 20
8.0.1 Q1: 你的研究与现有的 EpiEstim (Cori) 和 Parag 的信息论下界有什么本质区别？ 20
8.0.2 Q2: 为什么一定要用负二项分支过程？用经典的泊松过程不行吗？ 21
8.0.3 Q3: 理论上的 $m_\times = A/v_R$ 与实证拟合得到的 $b/a \approx 22.6$ 能否直接画等号？ . 21

8.0.4　Q4: 你在局限性里提到 v_R 始终是拟合量而非测量量，如果让你来测，在实务中怎么才能把它测出来？ 21
8.0.5　Q5: 为什么推论 1 里的最优单期规模公式会和 Cochran 的两阶段抽样同构？ 21
8.0.6　Q6: 实证中为什么用 FGLS 而不用我们最熟悉的普通最小二乘法 (OLS)？ . . 22
8.0.7　Q7: 达峰期看似误差恒定在 0.3 左右，你凭什么说病例规模在达峰期依然有用？ 22
8.0.8　Q8: 滞后暴露权重取 $w = (0.65, 0.25, 0.10)$ 的依据是什么？换一组权重结论还成立吗？ 22
8.0.9　Q9: 为什么命题 3 说提高报告率 ρ 存在无法消除的方差下界？现实中疾控提高检测率没有意义吗？ 22
8.0.10　Q10: 这篇论文对国家公共卫生监测体系的建设，到底能提供什么实际建议？ 22
8.0.11　Q11: 你在实证里的样本量 N 是怎么确定的？有没有主观挑选样本或偷看未来数据？ 23

- **英文标题（原文）**: Boundaries of Surveillance Scale Returns in Epidemic Monitoring: Estimation Targets, Environmental Stochasticity, and External Validation
- **来源仓库**：https://github.com/wangchi2068/case-count-inference-bottleneck （最新定稿 commit `91ae6ab`，2026 年 10 月）
- **深读依据**：仓库内权威定稿正文 `paper/main.tex`（28 页）、理论附录 A.1–A.6、全美 NHSN 流感实证、CDC FluSight 前瞻集成验证与欧洲 11 国 COVID-19 扩展实验。
- **阅读对象**：应用统计专业硕士（MAS）及生物数学/动力学建模方向研究生。本文不仅讲清公式“是什么”，更深度拆解“为什么这样推”、“直觉怎么理解”、“用到某个结论时原文公式是什么”、“参数怎么设定与文献依据”、“实证样本量 N 是什么与怎么选的”以及“评委可能怎么问”。
- **本版新增**：全文每一个推导节点均完整标注 **【正文公式编号与原文表达式】**，凡调用某结论处一律回填原公式原文，做到不自洽不说、闭环引用。

1　导读前言：应用统计研究生的“论文通透心法”

阅读或答辩这篇论文时，首先要建立一个宏观全局认知：**本文是一篇高度典范的应用统计学顶刊风格论文**。它的行文与论证结构高度精密，由四根核心支柱环环相扣而成：

1. **微观概率论支柱**：从经典生灭分支过程（Galton–Watson 过程）出发，引入生物学超传播机制（Gamma 混合泊松分布，即负二项分布）与宏观观测不完全性（二项报告抽样过程），建立了双层随机生成机制；
2. **渐近统计推断支柱**：利用概率母函数（PGF）复合律证明了分布族闭包，计算得分函数与 Fisher 信息矩阵，严格证明了一致最小方差无偏估计（UMVUE）并达到 Cramér–Rao 下界；

3. **运筹与抽样设计支柱**：将理论方差分解与流行病学监测资源预算结合，推导了时间与样本规模的二维权衡闭式解，在数学形式上同构于经典两阶段抽样模型（Cochran 费用分配模型）；
4. **经验计量与实证支柱**：不满足于纯理论推导，而是采集全美 CDC NHSN 长达六年、涵盖 50 州及 DC 的 16,218 条真实住院周度记录，采用可行广义最小二乘法（FGLS）与聚类 Bootstrap 检验，破除了达峰期“样本量失效”的传统误读，并扩展至 CDC FluSight 与欧洲 COVID-19 多场景。

读懂这篇论文的秘诀在于：**时刻牢记“推断目标决定规模收益”这一灵魂红线**。

---

2 第一部分：宏观全景地图——这篇论文究竟讲了一个什么故事？

2.1 1.1 一个违背直觉的现实科学矛盾

在公共卫生监测实践与常规统计直觉中，人们往往预设：**“数据越多越好，样本量越大越准”**。大数定律告诉我们，只要不断扩大哨点医院覆盖面、增加报告确诊人数（即增大病例规模 m），随机噪声就会被迅速平均掉，估计精度就能无界提升。

然而，在应对流感大流行、COVID-19 等真实传染病爆发时，全球疾控机构频繁面临一个极其尴尬的困境：

- 为什么在疫情高峰期，即便每周捕获上万例患者，模型的短期预测误差依然居高不下？
- 为什么在投入巨资扩展检测网络后，对未来趋势的判断却很快遭遇“平台瓶颈”，再怎么加倍收集病例，预测精度的改善也极其微弱？

既有文献的局限：以往学者通常笼统地将这种现象归咎于“漏报太多”、“数据质量差”或“模型设定错误”。近年来 Parag 等人（Nature Physics, 2022）利用信息论推导了带噪疫情曲线的信息极限，但其核心结论依然是：信息量随病例数近似线性增长。这仍未回答：**究竟在什么时候，病例规模不再是推断的主要瓶颈？**

2.2 1.2 论文的核心破局点：“推断目标决定规模收益”

本文最惊艳的洞见，在于指出以往文献混淆了**两个截然不同的统计推断目标**：

- **目标 A（当期传播参数 R_t）**：估计特定当周环境下的瞬时传染数。此时，环境扰动是我们要测量的“信号”。定理证明：测量方差随期望报告规模 m 按 $O(1/m)$ 严格单调趋零！在此目标下，大数定律完全成立，样本确实越大越好。
- **目标 B（跨期平均基准 $\bar{R}$）**：估计消除单周偶然波动后的潜在基础趋势。此时，宏观气象、节假日人群流动等不可预测的环境扰动成了“噪声”。定理证明：单期横截面样本再大，也只能观测到该期环境的一次实现，因而必然残留一个**不可约环境方差下限** v_R！总方差呈现仿射结构：

$$\mathrm{Var} = v_R + \frac{A}{m}$$

2.3 1.3 内生平衡点 $m_\times$ 的物理意义

将上述两项方差联立，自然导出了一个不可逆转的临界规模：

$$m_\times \equiv \frac{A}{v_R}$$

- **当 $m \ll m_\times$ 时（微观噪声主导区）**：抽样方差远远大于环境方差，此时扩大病例捕获能够带来极其显著的方差下降（投入产出比极高）；
- **当 $m \gg m_\times$ 时（宏观环境饱和区）**：不可约环境方差占比超过 50%，误差曲线进入水平平台。此时继续依靠扩大病例报告数已无法改善预测精度，监测资源必须由“扩量”转向“提质”（控制环境协变量与推进多模型集成）。

---

3 第二部分：全篇核心参数全景深度字典与流行病学物理直觉

为了彻底搞懂论文的推导与实证，消除“参数天书感”，本部分系统梳理全篇 20 个核心数学与流行病学参数。

3.1 2.1 全篇核心参数速查总表

符号	参数中文名称	数学类型与定义域	流行病学/物理含义
R_t	当期瞬时再生数 / 传播强度	连续标量 $(0,\infty)$	给定当期环境下，平均每个感染者引发的二代数（目标 A）
$\bar{R}$	跨期平均传播基准	连续标量 $(0,\infty)$	消除单周偶然波动后的基线水平（目标 B）
k	生物学过度离散参数	连续标量 $(0,\infty)$	刻画传染力异质性（超传播强度）；$k\to 0$ 极端厚尾，$k\to\infty$
ρ	报告抽样率 / 报告率	连续比例 $(0,1]$	潜在真实感染者被医疗系统检测并上报的概率
n	上一代真实风险集规模	正整数 $\mathbb{N}_+$	上一传播代社会上真实存在的感染人数（潜变量）
m	期望报告规模	连续标量 $(0,\infty)$	$m=\rho n$，上一代风险集对应的期望被报告人数
C_t	观测报告病例数	非负整数 $\mathbb{N}$	医院或疾控系统实际记录到的报告计数（观测随机变量）
I_t	当期真实新发感染总数	非负整数 $\mathbb{N}$	当期全社会实际发生的新感染总人数（潜变量）
v_R	不可约环境方差	连续标量 $(0,\infty)$	天气、人群聚集、社会干预对全员的共同乘性扰动方差
A	规模相关方差标量系数	连续标量 $(0,\infty)$	$A\equiv\bar{R}+\frac{\rho(\bar{R}^2+v_R)}{k}$，微观抽样与超传播方差的综合系数
$m_\times$	特征规模平衡点 / 阈值	连续标量 $(0,\infty)$	抽样方差与环境方差相等的特征规模，$m_\times\equiv A/v_R$
D_t	有效暴露病例规模	连续标量 $(0,\infty)$	既往报告住院数的时序卷积平滑加权和，增长比分母
w	滞后暴露加权向量	离散向量 $\sum w_s=1$	传染代际分布与就诊确诊填报时滞的复合卷积权重
G_{t+1}	周度病例增长比	连续标量 $(0,\infty)$	下周新发报告数与当期有效暴露规模的比值 C_{t+1}/D_t
B	总病例人数预算	连续标量 $(0,\infty)$	命题 4 中各期期望被报告人数之和，$B=T\cdot m=T\rho n_T$
$\mathcal{B}$	总经费预算	货币标量 $(0,\infty)$	推论 1 中系统总运作经费预算，$\mathcal{B}=T(c_0+c_1 m)$
r	一阶环境自相关系数	连续标量 $[0,1)$	宏观环境冲击在相邻周度之间的自回归相关系数
T_{eff}	有效独立期数	连续标量 $(0,\infty)$	自相关折减后的等效独立期数，$T_{\text{eff}}\approx T\frac{1-r}{1+r}$
c_α	增长判定离散临界值	非负整数 $\mathbb{N}$	单侧假设检验 $H_0: R_t\le 1$ 在显著性水平 α 下的整数拒绝阈值
a,b	仿射损失模型拟合参数	连续标量	实证模型 $\text{Loss}=a+b/D_t+u$ 的截距与斜率

3.2 2.2 核心参数的深度流行病学物理剖析

3.2.1 (1) 超传播参数 k 的生物学本质

在负二项分支模型中，方差公式为 $\mathrm{Var}(X) = R_t + \frac{R_t^2}{k}$。

- 第一项 R_t 是纯 Poisson 计数方差（哪怕所有人传染力完全相同，随机相遇也会产生的泊松噪声）；
- 第二项 R_t^2/k 是个体生物学生殖数异质性方差。
- **文献依据**：Lloyd-Smith 等人（Nature, 2005）对全球 8 种传染病的历史流调数据进行了元分析，发现 SARS 的 $k \approx 0.16$，麻疹 $k \approx 0.1$（强超传播），而流感 $k \approx 0.3 \sim 0.5$（中度超传播）。本文数值模拟选取 $k = 0.35$ 作为流感基准，并在实证唯象分析中覆盖 $k \in [0.2, 0.5]$，完全建立在真实流行病学基石之上。

3.2.2 (2) 报告抽样率 ρ 的折算逻辑

在流感住院实证中，ρ 不是普通的核酸阳性检出率，而是 **“全社会有症状感染者最终转化为实验室确诊住院病例的复合比例”**。

- **文献依据**：
- Zhou 等（2012）测算全美流感年均住院负担约为 20 万 ~ 40 万例；
- Tokars 等（2018）基于血清抗体流调测算全美季节性流感平均有症状侵袭率（Symptomatic Attack Rate）约为 8% ~ 15%（即约 2500 万 ~ 5000 万有症状感染）；
- 两者相除：$\rho \approx \frac{20\text{万}}{3500\text{万}} \sim \frac{40\text{万}}{2500\text{万}} \in [0.0056, 0.021]$（千分之六至百分之二）。
- 这一极端小概率抽样特性，完美契合了二项报告抽样模型的物理现实。

3.2.3 (3) 滞后卷积权重 $w = (0.65, 0.25, 0.10)$ 的依据

流感病程由三段时滞复合而成：

1. **潜伏期**：感染到出现症状，平均 1.5 ~ 2 天；
2. **就诊时滞**：发病轻症到病情恶化办理入院，平均 3 ~ 5 天；
3. **填报确认时滞**：医院实验室检测并录入 CDC NHSN 系统，平均 2 ~ 3 天。

三者相加，流感住院的复合时滞为 8 ~ 11 天。权重向量加权时间为：

$$\bar{\tau} = 1 \times 0.65 + 2 \times 0.25 + 3 \times 0.10 = 1.45 \text{ 周} \approx 10.2 \text{ 天}$$

正好落在该临床生理窗口的正中心。此外，正文表 1 证明无论是单周滞后（7 天）还是三周等权（14 天），斜率 b 均高度显著为正，结论对权重选择完全稳健。

4 理论工具箱速查：推导中调用的 12 大经典数理统计原公式

为了保证全书推导的不跳步可读性，在展开命题证明前，本节集中列明全篇推导所反复调用的 12 个经典数理统计基础原公式：

序号	经典定理 / 原公式名称	标准数理统计原公式表达
(1)	**欧拉 Gamma 函数严格积分定义**	$\Gamma(\alpha) \equiv \int_0^\infty u^{\alpha-1}e^{-u}du$
(2)	**负二项分布标准 PGF 母函数**	$G_X(s) \equiv \mathbb{E}[s^X] = [p/(1-(1-p)s)]^r$
(3)	**复合随机和母函数复合定理**	若 $S = \sum_{i=1}^N X_i$，则 $G_S(s) = G_N(G_X(s))$
(4)	**负二项均值与方差标准公式**	$\mathbb{E}[X] = r(1-p)/p$, $\mathrm{Var}(X) = r(1-p)/p^2$
(5)	**条件全期望公式 (塔式法则)**	$\mathbb{E}[Y] = \mathbb{E}_X[\mathbb{E}[Y \mid X]]$
(6)	**条件全方差公式 (Law of Total Variance)**	$\mathrm{Var}(Y) = \mathrm{Var}(\mathbb{E}[Y \mid X]) + \mathbb{E}[\mathrm{Var}(Y \mid X)]$
(7)	**二阶原点矩与方差恒等式**	$\mathbb{E}[Y^2] = \mathrm{Var}(Y) + (\mathbb{E}[Y])^2$
(8)	**Fisher 信息量双套标准定义**	$\mathcal{I}(\theta) = \mathrm{Var}(\partial \ln L/\partial\theta) = \mathbb{E}[-\partial^2 \ln L/\partial\theta^2]$
(9)	**Cramér–Rao 不等式与 UMVUE 判据**	对任意无偏估计量 $\hat{\theta}$，$\mathrm{Var}(\hat{\theta}) \geq 1/\mathcal{I}(\theta)$
(10)	**有限等比数列求和公式**	$\sum_{s=1}^T q^s = q(1-q^T)/(1-q)$
(11)	**Cochran (1977) 两阶段费用分配模型**	$m_{\text{Cochran}} = \sqrt{c_1 S_2^2/[c_2(S_1^2 - S_2^2/M)]}$
(12)	**Karlin–Rubin 一致最优检验 (UMP) 定理**	若分布族具单调似然比 (MLR)，则上尾拒绝域在边界上确界控制水

---

5 第三部分：数学命题教学级逐行拆解与深入证明（保姆级代数展开）

本部分面向数学与统计学严格标准，将附录与正文中的每一个定理进行保姆级代数展开，绝不跳步。

凡调用某个已证结论时，均先回填【正文公式编号与原文表达式】，再展开。

5.1 3.1 命题 1 前置：Gamma–Poisson 混合积分逐行展开与“成功概率” p 的物理本质

5.1.1 3.1.0 成功概率 p 的反直觉物理顿悟

在负二项分布 $\mathrm{NB}(k,p)$ 的抛硬币定义中：

- 我们不断试验，直到累计看到第 k 次“成功”为止；
- 在此之前所经历的“失败总次数” X 服从负二项分布。
- **在传染病模型中**：
- **传染给一个人 $\Longrightarrow$ 数学上记为一次“失败”！**
- **传染链条中断（未传染）$\Longrightarrow$ 数学上记为一次“成功”！**
- 均值公式反解：

$$R_t = k\frac{1-p}{p} \implies pR_t = k - kp \implies p(k+R_t) = k \implies p = \frac{k}{k+R_t}$$

- **物理直觉**：病毒传染力越强（R_t 越大），“中断传染（成功）”的概率 p 越接近 0，于是在链条中断前就会发生大量的“传染事件（失败）”，造成超级暴发！

5.1.2 3.1.1 Gamma–Poisson 连续混合积分逐行演算

设个体传染力 $\nu \sim \text{Gamma}(k, \theta)$，其中形状参数为 k，尺度参数 $\theta = R_t/k$。概率密度为：

$$f_\nu(\nu) = \frac{1}{\theta^k \Gamma(k)} \nu^{k-1} e^{-\nu/\theta} = \frac{(k/R_t)^k}{\Gamma(k)} \nu^{k-1} e^{-k\nu/R_t}$$

给定个体传染力 ν，二代感染数条件服从泊松分布：$\Pr(X = x \mid \nu) = \frac{\nu^x e^{-\nu}}{x!}$。

对潜变量 ν 在 $(0, \infty)$ 上求全积分（边缘化）：

$$\Pr(X = x) = \int_0^\infty \frac{\nu^x e^{-\nu}}{x!} \cdot \frac{(k/R_t)^k}{\Gamma(k)} \nu^{k-1} e^{-k\nu/R_t} d\nu$$

提取所有不含积分变量 ν 的常数项，合并被积函数中的幂次与指数：

$$= \frac{(k/R_t)^k}{x!\Gamma(k)} \int_0^\infty \nu^{(x+k)-1} \exp\left\{-\nu\left(1 + \frac{k}{R_t}\right)\right\} d\nu$$

做变量代换：令 $u = \nu\left(1 + \frac{k}{R_t}\right) = \nu\frac{k+R_t}{R_t}$，则 $\nu = u\frac{R_t}{k+R_t}$，微元 $d\nu = \frac{R_t}{k+R_t} du$。

代入积分中：

$$\int_0^\infty \nu^{(x+k)-1} e^{-u} \frac{R_t}{k+R_t} du = \left(\frac{R_t}{k+R_t}\right)^{x+k} \int_0^\infty u^{(x+k)-1} e^{-u} du$$

由欧拉 Gamma 函数严格积分定义：$\int_0^\infty u^{(x+k)-1} e^{-u} du = \Gamma(x+k)!$

代回原式展开：

$$\Pr(X = x) = \frac{(k/R_t)^k}{x!\Gamma(k)} \cdot \left(\frac{R_t}{k+R_t}\right)^{x+k} \cdot \Gamma(x+k) = \frac{\Gamma(x+k)}{x!\Gamma(k)} \cdot \frac{k^k R_t^x}{(k+R_t)^{x+k}}$$

按幂次项拆分组合：

$$= \frac{\Gamma(x+k)}{x!\Gamma(k)} \cdot \left(\frac{k}{k+R_t}\right)^k \left(\frac{R_t}{k+R_t}\right)^x$$

令 $p \triangleq \frac{k}{k+R_t}$，则 $1 - p = 1 - \frac{k}{k+R_t} = \frac{R_t}{k+R_t}$。

代入即得：

$$\Pr(X = x) = \frac{\Gamma(x+k)}{x!\Gamma(k)} p^k (1-p)^x \equiv \text{NB}(k, p)$$

从微观连续混合积分到离散负二项 PMF 逐行证毕！

5.2 3.2 命题 1：条件似然、得分函数、无偏性与 Cramér–Rao 下界

【调用 1 · 正文式 (1)】

$$\mathbb{E}[X_{i,t} \mid R_t] = R_t, \qquad \mathrm{Var}(X_{i,t} \mid R_t) = R_t + \frac{R_t^2}{k} \tag{eq:nb_branching}$$

正文将个体继发感染的条件一阶矩与二阶矩合起来写为过离散负二项分支模型。

【调用 2 · 正文式 (2)】

$$C_t \mid I_t \sim \mathrm{Binomial}(I_t, \rho) \tag{eq:binomial_obs}$$

5.2.1 3.2.1 PGF 复合律保族性逐行推导

每个感染者独立以概率 ρ 上报，报告数 $C_t = \sum_{j=1}^{I_t} B_j$，其中 $B_j \sim \mathrm{Bernoulli}(\rho)$，其 PGF 为 $G_B(s) = (1-\rho) + \rho s$。

上一代 n 个人产生的感染总数 $I_t \sim \mathrm{NB}(nk, p)$，其 PGF 为：

$$G_{I_t}(s) = \left(\frac{p}{1-(1-p)s}\right)^{nk}$$

利用复合随机和 PGF 复合定理 $G_{C_t}(s) = G_{I_t}(G_B(s))$：

$$G_{C_t}(s) = \left(\frac{p}{1-(1-p)[(1-\rho)+\rho s]}\right)^{nk}$$

将分母完全展开：

$$1-(1-p)(1-\rho)-\rho(1-p)s = 1-(1-\rho-p+p\rho)-\rho(1-p)s = [p+\rho(1-p)]-\rho(1-p)s$$

分子分母同时除以提取因子 $[p+\rho(1-p)]$：

$$G_{C_t}(s) = \left(\frac{\frac{p}{p+\rho(1-p)}}{1-\frac{\rho(1-p)}{p+\rho(1-p)}s}\right)^{nk}$$

定义新成功概率 $p^* \triangleq \frac{p}{p+\rho(1-p)}$。代入 $p = \frac{k}{k+R_t}$ 与 $1-p = \frac{R_t}{k+R_t}$：

$$p^* = \frac{\frac{k}{k+R_t}}{\frac{k}{k+R_t} + \rho\frac{R_t}{k+R_t}} = \frac{k}{k+\rho R_t}$$

对比负二项标准 PGF 形式，直接证明了：**观测值** $C_t \mid n, R_t \sim \mathrm{NB}(nk, p^*)$ **严格保族封闭！**

【回填 3 · 正文式 (4)】

$$C_t \mid n, R_t \sim \mathrm{NB}\big(\text{均值} = \rho n R_t,\ \text{形状参数} = nk\big) \tag{eq:nb_thinning}$$

5.2.2 3.2.2 负二项方差公式化简

由负二项分布方差公式，形状参数为 nk，成功概率为 p^*：

$$\mathrm{Var}(C_t \mid n, R_t) = \frac{nk(1-p^*)}{(p^*)^2} = nk \cdot \frac{\frac{\rho R_t}{k+\rho R_t}}{\left(\frac{k}{k+\rho R_t}\right)^2} = nk \cdot \frac{\rho R_t}{k+\rho R_t} \cdot \frac{(k+\rho R_t)^2}{k^2}$$

分子分母对消 $k(k+\rho R_t)$：

$$= \frac{n\rho R_t(k+\rho R_t)}{k} = \frac{nk\rho R_t + n\rho^2 R_t^2}{k} = \rho n R_t + \frac{(\rho R_t)^2 n}{k}$$

清晰展示了泊松方差 $\rho n R_t$ 与个体超传播方差 $\frac{(\rho R_t)^2 n}{k}$ 的代数叠加！

5.2.3 3.2.3 对数似然与得分函数求解

$$\ln L(R_t) = \mathrm{const} - (nk + C_t)\ln(k+\rho R_t) + C_t \ln R_t$$

对 R_t 求偏导：

$$S(R_t) = \frac{\partial \ln L}{\partial R_t} = -\frac{\rho(nk+C_t)}{k+\rho R_t} + \frac{C_t}{R_t} = \frac{-\rho R_t(nk+C_t) + C_t(k+\rho R_t)}{R_t(k+\rho R_t)} = \frac{k(C_t - \rho n R_t)}{R_t(k+\rho R_t)}$$

令 $S(R_t)=0$，解得唯一极大似然估计量 $\widehat{R}_t^{\mathrm{MLE}} = \frac{C_t}{\rho n}$。

5.2.4 3.2.4 无偏性验证（双层全期望展开）

利用双层全期望公式：

$$\mathbb{E}[\widehat{R}_t \mid n, R_t] = \frac{1}{\rho n}\mathbb{E}[C_t \mid n, R_t] = \frac{1}{\rho n}\mathbb{E}_{I_t}\Big(\mathbb{E}_{C_t}[C_t \mid I_t] \,\Big|\, n, R_t\Big)$$

- 内层：二项报告抽样均值 $\mathbb{E}[C_t \mid I_t] = \rho I_t$；
- 外层：独立分支和均值 $\mathbb{E}[I_t \mid n, R_t] = \mathbb{E}\left[\sum_{i=1}^{n} X_{i,t}\right] = nR_t$；

代入：

$$\mathbb{E}[\widehat{R}_t \mid n, R_t] = \frac{1}{\rho n} \cdot \rho(nR_t) = R_t \quad (\text{严格无偏！})$$

5.2.5 3.2.5 Fisher 信息量与 Cramér–Rao 下界确立

$$\mathcal{I}(R_t \mid n) = \mathrm{Var}(S(R_t)) = \frac{k^2\,\mathrm{Var}(C_t)}{R_t^2(k+\rho R_t)^2} = \frac{k^2 \cdot \frac{n\rho R_t(k+\rho R_t)}{k}}{R_t^2(k+\rho R_t)^2} = \frac{k\rho n}{R_t(k+\rho R_t)} = \frac{n}{\frac{R_t}{\rho} + \frac{R_t^2}{k}}$$

【回填 4 · 正文式 (5)】

$$\mathcal{I}(R_t \mid n) = \frac{n}{\frac{R_t}{\rho} + \frac{R_t^2}{k}} \tag{eq:fisher_info}$$

取倒数得下界：

$$\mathcal{I}^{-1} = \frac{R_t}{\rho n} + \frac{R_t^2}{kn} \equiv \mathrm{Var}(\widehat{R}_t \mid n, R_t)$$

【回填 5 · 正文式 (6)】

$$\mathrm{Var}\left(\frac{C_t}{\rho n} \,\middle|\, n, R_t\right) = \mathcal{I}(R_t \mid n)^{-1} = \frac{R_t}{\rho n} + \frac{R_t^2}{kn} \tag{eq:var_prop1}$$

无偏估计量方差达到 Cramér–Rao 下界，确立其为 UMVUE!

5.3 3.3 命题 2：跨期基础水平的边际方差分解与仿射式推导

【核心观察 · 前置洞见：不可约环境方差 v_R 的双重身份】

在推导方差前，必须认清 v_R 的物理本质分化：

- **对目标 A（当期瞬态）而言**：环境波动正是待测对象本身，其跨期变异不构成误差，单期方差按 $O(1/m)$ 无界衰减；

- **对目标 B（跨期平稳）而言**：同一波动退化为不可消除的误差源，单期样本无论多大都无法消除全员共享的单次环境实现!

【调用 6 · 正文式 (3)】

$$\mathbb{E}[R_t \mid n] = \bar{R}, \qquad \mathrm{Var}(R_t \mid n) = v_R > 0 \tag{eq:env_conditional_moment}$$

应用全方差公式：

$$\mathrm{Var}\left(\frac{C_t}{\rho n} \,\middle|\, n\right) = \mathrm{Var}\left(\mathbb{E}\left[\frac{C_t}{\rho n} \,\middle|\, n, R_t\right] \,\middle|\, n\right) + \mathbb{E}\left[\mathrm{Var}\left(\frac{C_t}{\rho n} \,\middle|\, n, R_t\right) \,\middle|\, n\right]$$

- 第一项：由无偏性，$\mathbb{E}\left[\frac{C_t}{\rho n} \,\middle|\, n, R_t\right] = R_t$，故方差为 $\mathrm{Var}(R_t \mid n) = v_R$；
- 第二项：代入命题 1 条件方差：

$$\mathbb{E}\left[\frac{R_t}{\rho n}+\frac{R_t^2}{kn}\,\middle|\,n\right]=\frac{\mathbb{E}[R_t\mid n]}{\rho n}+\frac{\mathbb{E}[R_t^2\mid n]}{kn}$$

代入二阶矩恒等式 $\mathbb{E}[R_t^2\mid n]=\mathrm{Var}(R_t)+(\mathbb{E}[R_t])^2=v_R+\bar{R}^2$：

$$=\frac{\bar{R}}{\rho n}+\frac{\bar{R}^2+v_R}{kn}$$

两项相加，整理为仿射结构：

$$\mathrm{Var}=v_R+\frac{1}{\rho n}\left[\bar{R}+\frac{\rho(\bar{R}^2+v_R)}{k}\right]\equiv v_R+\frac{A}{m}$$

【回填 7 · 正文式 (7)】

$$\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\,n\right)=v_R+\frac{\bar{R}}{\rho n}+\frac{\bar{R}^2+v_R}{kn}\equiv v_R+\frac{A}{m}\tag{eq:var_prop2}$$

其中令 $m=\rho n$，标量系数 $A\equiv\bar{R}+\frac{\rho(\bar{R}^2+v_R)}{k}$。

5.3.1 3.3.1 特征规模平衡点 $m_\times$ 的导出

联立抽样方差与环境方差，解出两类方差各占 50% 的临界规模：

【回填 8 · 正文式 (8)】

$$\frac{A}{m_\times}=v_R\implies m_\times\equiv\frac{A}{v_R}=\frac{\bar{R}+\frac{\rho(\bar{R}^2+v_R)}{k}}{v_R}\tag{eq:crossover_def}$$

【记号注记】

标量系数 $A\equiv\bar{R}+\frac{\rho(\bar{R}^2+v_R)}{k}$ 自身仍显式依赖于报告率 ρ。因此两个监测系统即使处于相同的 $m=\rho n$，只要报告率 ρ 不同，A 与收益拐点 $m_\times$ 便不相同。A 依赖 ρ 的方式与依赖规模 m 的反比衰减完全不同，这正是命题 3 监测杠杆非对称性的数理根源。

5.4 3.4 命题 3：监测杠杆的理论非对称性

【调用 9 · 正文式 (9)】

$$V(n,\rho)=v_R+\frac{\bar{R}}{\rho n}+\frac{\bar{R}^2+v_R}{kn}\tag{eq:var_bivariate}$$

【调用 10 · 正文式 (10)】

$$\frac{\bar{R}}{\rho n} = \frac{\bar{R}}{n} + \frac{(1-\rho)\bar{R}}{\rho n} \tag{eq:rho_decomp}$$

将抽样项拆解后，总方差呈现三层结构：

$$V(n,\rho) = v_R + \underbrace{\frac{(1-\rho)\bar{R}}{\rho n}}_{\text{漏报抽稀噪声}} + \underbrace{\frac{\bar{R}}{n}}_{\text{有限人群泊松计数波动}} + \underbrace{\frac{\bar{R}^2 + v_R}{kn}}_{\text{超级传播子代抽样波动}}$$

极限一：报告率极限 $\rho \to 1$

$$\lim_{\rho\to 1} V(n,\rho) = v_R + 0 + \frac{\bar{R}}{n} + \frac{\bar{R}^2 + v_R}{kn} > v_R$$

【回填 11 · 正文式 (11)】

$$\lim_{\rho\to 1} V(n,\rho) = v_R + \frac{\bar{R}}{n} + \frac{\bar{R}^2 + v_R}{kn} > v_R \tag{eq:rho_limit}$$

极限二：人群基数极限 $n \to \infty$

$$\lim_{n\to\infty} V(n,\rho) = v_R + \lim_{n\to\infty} \frac{1}{n}\left[\frac{\bar{R}}{\rho} + \frac{\bar{R}^2 + v_R}{k}\right] = v_R + 0 = v_R$$

政策启示：完全消除漏报只能干掉第一项漏报抽稀噪声；人群内部固有的泊松相遇离散度 $\bar{R}/n$ 与超级传播重尾离散 $\frac{\bar{R}^2+v_R}{kn}$ 永远无法被 ρ 消除。唯有扩大监测的地理与人群基数 $n \to \infty$，大数定律才能统摄消除全部微观噪声。

5.5 3.5 命题 4 与推论 1：多期时间抽样、AR(1) 求和与 Cochran 对偶

5.5.1 3.5.1 独立环境下的预算恒常性

在总人数预算 $B = T \cdot m$ 约束下，跨期均值估计量的方差分解为：

$$\mathrm{Var}(\overline{\widehat{R}}_T) = \frac{1}{T^2}\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) + \frac{1}{T^2}\sum_{t=1}^{T}\mathrm{Var}(\widehat{R}_t \mid R_t)$$

代入单期条件抽样方差 $\frac{A}{m}$：

$$\text{抽样项} = \frac{1}{T^2}\cdot T\frac{A}{m} = \frac{A}{Tm} = \frac{A}{B} \quad (\text{恒为常数！})$$

【回填 12 · 正文式 (12)】

$$\mathrm{Var}(\overline{\widehat{R}}_T \mid n_T) = \frac{v_R}{T} + \frac{A}{B} \qquad \text{(eq:var_budget_indep)}$$

惊人结论：在固定总样本预算下，无论怎么分配 T 与 m，抽样误差项永远是常数 A/B！要想降低总方差，**唯一的方法是拉长观测期数 T 去平滑宏观不可约环境变异** v_R。

5.5.2 3.5.2 AR(1) 环境自相关的双重级数求和（错位相减法逐行展开）

在 AR(1) 自相关下，环境方差项展开为：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = Tv_R + 2v_R \sum_{s=1}^{T-1} (T-s) r^s$$

定义等差乘等比级数：

$$S \triangleq \sum_{s=1}^{T-1} (T-s) r^s = (T-1)r + (T-2)r^2 + \cdots + 1 \cdot r^{T-1}$$

两端同乘公比 r：

$$rS = (T-1)r^2 + (T-2)r^3 + \cdots + 1 \cdot r^T$$

两式相减：

$$(1-r)S = (T-1)r - \left[r^2 + r^3 + \cdots + r^{T-1}\right] - r^T = Tr - \sum_{s=1}^{T} r^s = Tr - \frac{r(1-r^T)}{1-r}$$

两端除以 $(1-r)$：

$$S = \frac{Tr}{1-r} - \frac{r(1-r^T)}{(1-r)^2}$$

代回环境总方差：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = Tv_R + 2v_R S = Tv_R + 2v_R \left[\frac{Tr}{1-r} - \frac{r(1-r^T)}{(1-r)^2}\right] = v_R T \left[1 + \frac{2r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right]$$

通分化简括号内前两项：$1 + \frac{2r}{1-r} = \frac{1-r+2r}{1-r} = \frac{1+r}{1-r}$：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = v_R T \left[\frac{1+r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right]$$

两端除以 T^2，得附录 A.4 精确双重级数求和闭式。当 $T \gg \frac{1}{1-r}$ 时，精确式良好近似为有效独立期数折减形式：

【回填 13 · 正文式 (13)：有效独立期数近似式】

$$\mathrm{Var}(\widehat{\overline{R}}_T \mid n_T) \approx \frac{v_R}{T_{\mathrm{eff}}(T,r)} + \frac{A}{B}, \qquad T_{\mathrm{eff}}(T,r) \triangleq T\frac{1-r}{1+r} \tag{eq:var_budget_ar1}$$

5.5.3 3.5.3 离散可行设计集合

当要求各期风险集相同且为正整数，并精确用尽总预算 B 时：

【回填 14 · 正文式 (14)】

$$\mathcal{T}(B,\rho) \triangleq \left\{ T \in \mathbb{N}_+ \ : \ \frac{B}{\rho T} \in \mathbb{N}_+ \right\} \tag{eq:feasible_T}$$

5.5.4 3.5.4 推论 1：成本约束下的最优单期规模与 Cochran 对偶

在总经费预算 $\mathcal{B} = T(c_0 + c_1 m)$ 约束下，代入 $T = \frac{\mathcal{B}}{c_0 + c_1 m}$，目标方差函数关于 m 严格凸。唯一内部最优单期规模直接给出：

【回填 15 · 正文式 (15)】

$$m^* = \sqrt{\frac{c_0}{c_1} \cdot \frac{A}{v_R}} = \sqrt{\frac{c_0}{c_1} m_\times} \tag{eq:optimal_scale}$$

Cochran (1977) 抽样对偶：推论 1 中的方差与总成本结构，在数学形式上同构于经典两阶段抽样（Two-stage Sampling）的费用分配模型：时间观测期数 T 对应初级抽样单元数，单期期望捕获规模 m 对应次级样本量。二阶导数 $\frac{2c_0 A}{\mathcal{B} m^3} > 0$ 严格保证了最优解的全局唯一性。

5.6 3.6 命题 5：增长判定的单调似然比（MLR）一阶差分与离散功效

5.6.1 3.6.1 MLR 一阶差分严格为正证明

单侧假设检验：

$$H_0 : R_t \le 1 \quad \text{vs} \quad H_1 : R_t > 1$$

【回填 18 · 正文式 (18)】

$$H_0 : R_t \le 1 \qquad \text{对} \qquad H_1 : R_t > 1 \tag{eq:hypo_growth}$$

对任意备择强度 $R_1 > R_0$，似然比对数形式为：

$$\ln \frac{\Pr_{R_1}(C_t = j)}{\Pr_{R_0}(C_t = j)} = nk \ln \frac{p^*(R_1)}{p^*(R_0)} + j \ln \frac{1 - p^*(R_1)}{1 - p^*(R_0)}$$

计算对计数值 j 的一阶差分：

$$\Delta(j) \triangleq \ln \frac{\Pr_{R_1}(j+1)}{\Pr_{R_0}(j+1)} - \ln \frac{\Pr_{R_1}(j)}{\Pr_{R_0}(j)} = \ln \frac{1 - p^*(R_1)}{1 - p^*(R_0)}$$

代入 $1 - p^*(R) = \frac{\rho R}{k + \rho R}$：

$$\frac{1 - p^*(R_1)}{1 - p^*(R_0)} = \frac{\frac{\rho R_1}{k + \rho R_1}}{\frac{\rho R_0}{k + \rho R_0}} = \frac{R_1(k + \rho R_0)}{R_0(k + \rho R_1)} = \frac{kR_1 + \rho R_0 R_1}{kR_0 + \rho R_0 R_1}$$

由于 $R_1 > R_0$，分子 $kR_1 + \rho R_0 R_1 > kR_0 + \rho R_0 R_1$ 分母，该比值严格大于 1！

取自然对数后，一阶差分 $\Delta(j) > 0$ 恒成立！

证明了似然比关于充分统计量 C_t **严格单调递增**，Karlin–Rubin 定理严格适用！

5.6.2 3.6.2 离散临界值与精确功效

临界值由使边界处超额拒绝概率受控的最小整数唯一确定：

【回填 19 · 正文式 (19)】

$$c_\alpha = \min \left\{ c \in \mathbb{N} \,:\, \Pr_{R_t = 1}(C_t \geq c) \leq \alpha \right\} \qquad \text{(eq:crit_val)}$$

【回填 20 · 正文式 (20)】

$$\pi(n, \delta) \triangleq \Pr_{R_t = 1+\delta}(C_t \geq c_\alpha) = 1 - F_{\mathrm{NB}}\left(c_\alpha - 1;\, nk,\, \frac{k}{k + \rho(1+\delta)} \right) \qquad \text{(eq:power_exact)}$$

5.6.3 3.6.3 离散功效锯齿波（Sawtooth Wave）成因

因为观测计数 C_t 只能取整数，临界值 $c_\alpha(n)$ 随样本量 n 呈阶梯状跳变：

- 当 n 在某个区间微增时，临界值 c_α 保持不变，由于样本量变大，功效连续上升；
- 一旦 n 跨过某个临界点，为了控制显著性水平 α，c_α 突然跳跃到 $c_\alpha + 1$，拒绝门槛突然拔高，导致统计功效瞬间出现向下跳跃！
- 这解释了图 2 模拟中为什么连续增加病例数，功效曲线会出现特有的锯齿波动，证实了离散枚举求解最小样本量的必要性。

5.7 3.7 命题 6：更新过程条件预测方差全分解与式 (29) 预测偏差项展开

5.7.1 3.7.1 两步全方差公式展开

在时间序列更新过程中，给定截至第 t 期的报告信息集 $\mathcal{F}_t^C$：

第一步：分解潜在真实感染数 I_{t+1} 的预测方差

$$\mathrm{Var}(I_{t+1} \mid \mathcal{F}_t^C) = \mathrm{Var}\left(\Lambda_{t+1} R_{t+1} \,\middle|\, \mathcal{F}_t^C\right) + \mathbb{E}\Big[\,\mathrm{Var}\left(I_{t+1} \,\middle|\, \Lambda_{t+1}, R_{t+1}, \mathcal{F}_t^C\right) \,\Big|\, \mathcal{F}_t^C\Big]$$

【回填 16 · 正文式 (16)】

$$\mathrm{Var}(I_{t+1} \mid \mathcal{F}_t^C) = \mathrm{Var}\left(\Lambda_{t+1} R_{t+1} \,\middle|\, \mathcal{F}_t^C\right) + \mathbb{E}\Big[\,\mathrm{Var}\left(I_{t+1} \,\middle|\, \Lambda_{t+1}, R_{t+1}, \mathcal{F}_t^C\right) \,\Big|\, \mathcal{F}_t^C\Big] \tag{eq:var_I_decomp}$$

第二步：分解报告病例数 C_{t+1} 的观测预测方差

以未观测的潜在真实感染 I_{t+1} 为条件再次应用全方差公式：

$$\mathrm{Var}(C_{t+1} \mid \mathcal{F}_t^C) = \mathbb{E}[\mathrm{Var}(C_{t+1} \mid I_{t+1}, \mathcal{F}_t^C) \mid \mathcal{F}_t^C] + \mathrm{Var}(\mathbb{E}[C_{t+1} \mid I_{t+1}, \mathcal{F}_t^C] \mid \mathcal{F}_t^C)$$

代入二项报告抽样条件分布 $C_{t+1} \mid I_{t+1} \sim \mathrm{Binomial}(I_{t+1}, \rho)$ 的条件方差 $I_{t+1}\rho(1-\rho)$ 与条件均值 ρI_{t+1}：

【回填 17 · 正文式 (17)】

$$\mathrm{Var}(C_{t+1} \mid \mathcal{F}_t^C) = \rho(1-\rho)\,\mathbb{E}[I_{t+1} \mid \mathcal{F}_t^C] + \rho^2\,\mathrm{Var}(I_{t+1} \mid \mathcal{F}_t^C) \tag{eq:var_C_decomp}$$

5.7.2 3.7.2 相对预测误差均方分解（式 29 / 正文式 22）

设 $\mu_{t+1|t} \triangleq \mathbb{E}[C_{t+1} \mid \mathcal{F}_t^C]$ 与 $\sigma^2_{t+1|t} \triangleq \mathrm{Var}(C_{t+1} \mid \mathcal{F}_t^C)$，在活跃周（$D_t > 0$）上有严格的条件预测均方误差正交分解：

【回填 22 · 正文式 (22)】

$$\mathbb{E}\left[(G_{t+1} - \bar{R})^2 \mid D_t > 0\right] = \mathbb{E}\left[\frac{\sigma^2_{t+1|t}}{D_t^2} + \left(\frac{\mu_{t+1|t}}{D_t} - \bar{R}\right)^2 \,\middle|\, D_t > 0\right] \tag{eq:exact_renewal_decomp}$$

- **关键物理机制**：

1. 第一项：随机分母 D_t 对条件方差的**倒数二次方重新加权**；
2. 第二项：用报告历史代理真实感染压力导致的**非负预测偏差项** $\left(\frac{\mu_{t+1|t}}{D_t} - \bar{R}\right)^2 \geq 0$。

- **对图 3 结果的终极解释**：这从代数上严格证明了：为什么在更新过程中，实际经验预测误差始终**严格不低于单代静态下界**！

6　第四部分：数值模拟的深层设计与三幅图的精读密码

6.1　4.1 图 1（理论方差分解与 50,000 次蒙特卡洛验证）

- **双对数坐标轴下的两条轨迹**：
- 蓝色曲线（估计当期 R_t）：斜率为 -1 的直线，随 m 增大单调趋零；
- 红色曲线（估计跨期 $\bar{R}$）：小样本时沿 -1 斜率下降，越过交叉点 $m_\times = 53.1$ 后，迅速弯曲变平，严丝合缝贴在水平渐近虚线 $v_R = 0.04$ 上；
- 散点与解析解比值处于 0.988–1.017 之间，证明理论代数推导 100% 紧致正确。

6.2　4.2 图 2（增长检测功效与 Wald 检验失真）

- 虚线（Wald 检验）：在小样本且强超传播（$k = 0.1$）时，实际一类错误率最高达到 8.1%（严重虚警）；
- 实线（离散精确负二项检验）：全域严格受控于 0.05 以下；
- 超传播的代价：达到 80% 功效所需的病例数，从轻度超传播（$k = 1.0$）的 142 例激增至重度超传播（$k = 0.1$）的 415 例，暴增近 3 倍！

6.3　4.3 图 3（更新过程时序卷积与单步预测误差的双口径解密）

- **为什么初始参数看是 0.75–0.98 倍？**模拟横轴标示的是第 0 周的初始规模 m。因为 $\bar{R} = 1.15 > 1$（疫情自发增长），到了第 4–29 周评估时，实际病例数自发增长至初始值的 1.7–2.4 倍（中位数口径，均值口径约 2.6–3.2 倍）！拿增长后的大病例数对比初始小规模理论值，表观比值自然偏低；
- **为什么实际规模看是不低于下界的 1.01–1.17 倍（按组 1.00–1.45 倍）？**按实际发生规模重核参照线，经验预测误差**严格不低于单代静态下界**，直接证实了命题 6 式 (29) 预言的额外预测偏差项 $(\mu/D - \bar{R})^2 \geq 0$！

7　第五部分：全美流感真实数据实证全景复盘

7.1　5.1 实证中的样本量 N 是什么？怎么一步步筛选出来的？

7.1.1　(1) N 的统计学定义：观测单位是“州—周（State-Week）”

在传染病面板数据（Panel Data）中，**1 个观测不是 1 个人，也不是 1 个州，而是 1 个具体的“辖区—周度”时间切片**！

7.1.2 (2) 总样本池的来源：16,218 个原始记录

- 全美 50 个州加上华盛顿特区（DC），共 51 个地理辖区；
- 样本时间跨度从 2020 年 8 月至 2026 年 9 月，涵盖整整 6 年（约 318 个自然周）；
- 51 个辖区 $\times$ 318 周 $=$ **16,218** 个原始“州—周”观测记录。

7.1.3 (3) 核心客观筛选门槛：$D_t \geq 5$（全美总有效样本 $N = 10,303$）

从 16,218 个记录筛选到 10,303 个主分析样本，依据单一客观规则：

- **门槛规则**：当周有效暴露规模 $D_t \geq 5$（加权暴露住院数不少于 5 例）；
- **为什么必须设为 5？**

增长比定义为 $G_{t+1} = C_{t+1}/D_t$。若 $D_t = 0$（连续多周零病例）或 D_t 仅有 1–2 例，增长比会出现剧烈的除零数值爆炸；在夏季非流行期，很多州连续数周无流感住院。设定 $D_t \geq 5$，既排除了无信息的静默周，又完整保留了真实的小规模样本（如 $[5, 20)$ 组）。

- **坚决避免选择性偏误（不设覆盖率门槛）**：

主分析**不设任何医院填报覆盖率硬门槛**（没有像早期做法那样要求覆盖率 $\geq 50\%$），防止系统性剔除低覆盖率的脆弱观测。最终获得 $N = 10,303$ **个活跃周主样本**。

7.1.4 (4) 各章节具体的 N 划分机制全景表

章节与分析模块	样本量 N	详细筛选逻辑与流行病学阶段界定
全美主分析总池	10,303	满足 $D_t \geq 5$ 的全部活跃州—周观测总和。
流行初期主拟合（表 1）	1,267	各流感季初期疫情上升波段（$\bar{R}_{\text{early}} \approx 1.67$）中满足 $D_t \geq 5$ 的记录。主回
达峰与回落反证（表 3）	1,220	全美各季达峰周及随后 7 周回落期（$\bar{R}_{\text{peak}} \approx 0.81$）满足 $D_t \geq 5$ 的记录。
前过渡高覆盖期（第一阶段）	6,009	2020 年 10 月至 2024 年 4 月 30 日（合并大流行初期与法定强制段），平
自愿过渡期（第二阶段）	420	2024 年 5 月至 10 月（紧急状态解除），夏季低发加自愿填报，仅 420 个
CMS 新规重制期（第三阶段）	3,874	2024 年 11 月至 2026 年 9 月，恢复医保强制上报，覆盖率回升至 91.8%。
阶段加和算术闭环	10,303	$6,009 + 420 + 3,874 = 10,303$，数据链条 100% 严密闭环！
全国空间汇总序列	28	51 辖区数据加总为全国单一时间序列后，初期上升波段共 28 个全国汇总
CDC FluSight 外部验证	1,177	CDC 官方多模型前瞻预测（2022–23 季），按纯事前预测值 $\widehat{Y} \geq 5$ 筛选的
欧洲 COVID-19 外部验证	404	欧洲 11 国早期暴发序列（2020 年 2–4 月），按事前历史规模 $D_t \geq 5, g >$

7.2 5.2 为什么必须用 FGLS（可行广义最小二乘法）？

- 普通 OLS 假定误差项具有同方差；
- 但实测发现：残差具有极端厚尾（偏度高达 8.63），且小规模组的方差–均值比高达 5.32，大规模组收缩至 0.99，存在剧烈的反比非齐次方差；
- 必须采用以拟合值平方倒数 $1/\hat{\mu}^2$ 加权的 FGLS，并配合 1,500 次按州聚类的 Bootstrap 估计标准误。

7.3 5.3 核心实证估计结果

- 规模斜率项 $\hat{b} = 2.2434$（95% CI $[1.50, 3.02]$），**1,500 次 Bootstrap 重抽无一次小于等于零**（$p < 10^{-4}$），强力证实了 b/D_t 递减项的真实存在；
- 经验拟合截距 $\hat{a} = 0.0991$；经验平衡点 $m_\times^{\text{emp}} = \hat{b}/\hat{a} \approx 22.6$ 例/周；
- **误差份额分解**：在流行初期平均 0.181 的总误差中，规模相关项占 45.1%，不可约经验下限占 54.6%（四至五成半）。

7.4 5.4 达峰期震撼反转：88.9% 偏差 vs 15.5% 集成预测

- **表象与传统误读**：在达峰期，各规模组的总相对误差恒定在 0.292–0.312，看起来不管怎么增大病例规模，误差完全不下降。很多人据此宣称“达峰期病例数失效了”。
- **论文的数学正交分解**：

$$\text{总误差} = \underbrace{\left(\frac{\bar{R}_{\text{peak}} - \bar{R}_{\text{early}}}{\bar{R}_{\text{early}}}\right)^2}_{\text{常数基准偏移项（占 88.9\%）}} + \underbrace{\text{条件方差项（占 11.1\%）}}_{\text{规模效应仍显著为正！}}$$

- 达峰期看似恒定的高误差，**整整 88.9% 是因为疫情达峰转向、历史平稳基准失灵导致的常数漂移**！
- 剥离常数漂移后，达峰期内部的纯条件方差依然显著随规模递减（$\hat{b} = 7.9272$）；
- **外部验证的终极呼应**：

在引入 CDC FluSight 官方真实多模型前瞻集成预测后，**达峰期的均值偏差占比从静态单模型的 88.9% 骤降至 15.5%**！

直接在实证上回答了：跨过规模平衡点后，单纯扩充样本量已经边际递减，必须依靠多模型自适应集成来消除均值漂移。

7.5 5.5 欧洲 11 国 COVID-19 跨病种验证

- 引入欧洲 11 国早期日度发病监测数据（$N = 404$）；
- 纯事前口径拟合得 $\hat{b} = 33.92$（95% CI $[14.60, 74.9873]$），显著为正，经验平衡点为 124.7 例/天；
- 证明了规模递减规律跨病种、跨地域的高度稳健性，同时证实特征平衡点随时间分辨率和监测尺度变动。

---

8 第六部分：硕士中期答辩高频质询 Q&A 宝典（11 问 11 答）

8.0.1 Q1：你的研究与现有的 EpiEstim (Cori) 和 Parag 的信息论下界有什么本质区别？

> **答**：Cori 等人的 EpiEstim 解决的是“如何在滑动窗口下估计时变再生数”，Parag 等人的研究确立了“以当期瞬态参数 R_t 为目标时信息量随病例数线性增长”的物理极限。

本文的本质区别在于**推断目标的切换**：我们证明，一旦将推断目标由当期瞬态参数 R_t 切换为跨期基础水平 $\bar{R}$，由于单期横截面样本无法消除全员共享的外生宏观环境扰动，方差标度律发生根本改变，出现不可约环境方差下限 v_R 与特征规模平衡点 $m_\times$。本文填补的是从“单期推断”跨越到“监测资源运筹设计”的理论空白。

8.0.2 Q2: 为什么一定要用负二项分支过程？用经典的泊松过程不行吗？

答：传染病学中普遍存在极强的超传播现象（Lloyd-Smith 等 2005），约 20% 的感染者引发 80% 的传播。

泊松分布强加了方差等于均值（$k \to \infty$），这在数学上会严重低估小计数阶段的重尾抽样风险，人为低估达到指定功效所需的样本量需求（如图 2 所示，强超传播下样本量需求暴增 3 倍）。引入负二项分布不仅具有流行病学真实性，更在数理上通过 PGF 复合运算保证了二项抽样下的分布族封闭性，为全方差分解提供了优雅的解析基准。

8.0.3 Q3: 理论上的 $m_\times = A/v_R$ 与实证拟合得到的 $b/a \approx 22.6$ 能否直接画等号？

答：不能直接等同，实证比值是理论平衡点的**经验映射物与量级参照**。

理论上的 $m_\times$ 是在单代已知参数下的解析临界点；而实证中的 $a = 0.0991$ 与 $b = 2.2434$ 是在真实流感周度时间序列中对 D_t 进行仿射拟合的参数，其中 a 既包含了宏观环境波动，也吸收了滞后卷积平滑失配的常数偏差。实证的核心价值在于**验证了理论预测的仿射递减与平台收敛形状**，而非点位精确物理测量。

8.0.4 Q4: 你在局限性里提到 v_R 始终是拟合量而非测量量，如果让你来测，在实务中怎么才能把它测出来？

答：正如我们在第 6.2 节方法学展望中所提出的，未来可以通过 **“双轨监测体系”** 实现纯外生环境方差 v_R 的解耦测度：

目前的医院住院监测混合了就医行为与填报时滞；如果能在代表性社区布设固定人群的前瞻性主动追踪队列（如定期家庭采样），直接测得无就医行为干扰的真实社区传播强度，就能将外生宏观环境方差 v_R 与监测系统的代理平滑偏差完全分离识别。

8.0.5 Q5: 为什么推论 1 里的最优单期规模公式会和 Cochran 的两阶段抽样同构？

答：这体现了数理统计深层的对偶之美。

在时间序列监测中，期数 T 本质上就是初级抽样单元（PSU），单期捕获病例数 m 就是次级抽样单元（SSU）。固定维持成本 c_0 发生于每一期，边际采集成本 c_1 发生于每个病例。这与 Cochran (1977) 调查抽样中“在有限预算下权衡抽取多少个群（群成本 c_0）与每群调查多少人（人均成本 c_1）”的数学优化模型完全同构，二阶导数 $\frac{2c_0A}{Bm^3} > 0$ 严格保证了最优解的全局唯一性。

8.0.6 Q6: 实证中为什么用 FGLS 而不用我们最熟悉的普通最小二乘法 (OLS)？

答：因为真实监测数据的残差具有极强的异方差与厚尾性。

流感住院损失的偏度高达 8.63，小规模段的方差–均值比高达 5.32，大规模段收缩至 0.99，表现出剧烈的反比非齐次方差。如果使用普通 OLS，小样本段的极大极端值会过度主导回归线，估计功效损失极大；FGLS 通过一阶拟合残差平方倒数进行迭代加权，在大样本下达到最优线性无偏估计（BLUE）。

8.0.7 Q7: 达峰期看似误差恒定在 0.3 左右，你凭什么说病例规模在达峰期依然有用？

答：凭严格的**均值–方差正交代数分解**。

我们证明了达峰期看似恒定的高误差中，整整 88.9% 来源于疫情转折导致的常数基准漂移 $(\bar{R}_{\text{peak}} - \bar{R}_{\text{early}})^2/\bar{R}^2_{\text{early}} = 0.2669$。真正反映推断波动的纯条件方差只占 11.1%。当我们使用达峰期自身均值剥离常数漂移后，规模相关项系数 $\hat{b} = 7.9272$ 依然高度显著为正。失效的是跨期平稳性假设，而不是病例规模本身。

8.0.8 Q8: 滞后暴露权重取 $w = (0.65, 0.25, 0.10)$ 的依据是什么？换一组权重结论还成立吗？

答：有两个依据：第一，加权平均回溯时间为 1.45 周（约 10.2 天），与流感临床从感染、潜伏（1–2 天）、发病就诊（3–5 天）到填报确认的复合特征时滞（约 10 天）完全吻合；

第二，正文第 5.1 节进行了严格的权重敏感性检验：无论换用单周滞后（7 天）还是三周等权（14 天），规模斜率 b 始终在 1.9 到 3.1 之间，聚类 Bootstrap 置信区间严格远离零点，1,500 次重抽无一次小于零，核心科学结论对权重设定高度稳健。

8.0.9 Q9: 为什么命题 3 说提高报告率 ρ 存在无法消除的方差下界？现实中疾控提高检测率没有意义吗？

答：提高报告率具有显著价值，但它的作用机制具有局限性。

全方差公式严格表明：提高报告率 $\rho \to 1$ 只能消除由于漏报产生的纯二项抽样方差 $\frac{(1-\rho)\bar{R}}{\rho n}$，但它无法消除人群中固有的微观计数随机性 $\frac{\bar{R}}{n}$，更无法消除个体超级传播引发的子代抽样方差 $\frac{\bar{R}^2+v_R}{kn}$。唯有扩大地理或人群基数 n，通过大数定律才能同时压低所有微观随机性。

8.0.10 Q10: 这篇论文对国家公共卫生监测体系的建设，到底能提供什么实际建议？

答：给出了两阶段“差异化资源配置”判据：

1. **在疫情初期与低发期（$m < m_\times$）**：系统处于微观噪声主导区，此时应集中资源扩建哨点、扩大病例捕获，能够迅速跨过平衡点，获得显著的方差收益；

2. **在疫情高峰期与常态化监测期（$m > m_\times$）**：系统跨过特征平衡点进入饱和区，此时继续单纯追求捕获更多病例已边际收益递减，监测资源应当果断由“扩量”转向“提质”——即转向引入多模型前瞻集成预测，并补充气象、人群流动等外部环境协变量以解释不可约环境方差。

8.0.11 Q11：你在实证里的样本量 N 是怎么确定的？有没有主观挑选样本或偷看未来数据？

答：实证中的 N 指的是“州—周”观测记录数。全美 51 辖区在 6 年内共有 16,218 个原始记录。我们采用单一、客观且纯事前的活跃周筛选门槛：$D_t \geq 5$，以过滤无流感病例时的除零数值爆炸，由此获得全美总样本池 10,303 个活跃观测。

在具体分析中：主拟合选取各季初期上升阶段（$N = 1,267$），达峰期选取转折周及随后回落周（$N = 1,220$）；三个报告制度期的样本量分别为 $6,009$、420 和 $3,874$，三者加和严格等于 $10,303$，数据链条绝对自洽；全部筛选仅依赖当期及既往已知数据，绝不利用未来信息；同时不设覆盖率门槛，确保不会因人为筛选引入选择性偏误。