论文深读与理论推导详解：《疫情监测中的病例规模收益边界：估计目标、环境随机性与外部验证》

论文全案理论推导详解 · sympy 数值核验 · 技术审计意见

目录

1 导读前言：应用统计研究生的“论文通透心法” 3

2 第一部分：宏观全景地图——这篇论文究竟讲了一个什么故事？ 3

2.1 1.1 一个违背直觉的现实科学矛盾 . . . 3

2.2 1.2 论文的核心破局点：“推断目标决定规模收益” . . . 4

2.3 1.3 内生平衡点 $m_\times$ 的物理意义 . . . 4

3 第二部分：核心概念与流行病学物理直觉通识 4

3.1 2.1 超传播与离散参数 k . . . 4

3.2 2.2 报告抽样率 ρ . . . 5

3.3 2.3 不可约环境方差 v_R . . . 5

3.4 2.4 有效暴露病例规模 D_t 与权重向量 w . . . 5

4 第三部分：数学命题教学级逐行拆解与深入证明（保姆级代数展开） 5

4.1 3.1 命题 1：条件似然、Fisher 信息与 Cramér–Rao 下界 . . . 5

4.1.1 3.1.1 定理陈述 . . . 5

4.1.2 3.1.2 逐步严密代数推导 . . . 5

4.2 3.2 命题 2：跨期基础水平的边际方差分解 . . . 8

4.2.1 3.2.1 定理陈述 . . . 8

4.2.2 3.2.2 逐步严密代数推导 . . . 8

4.3 3.3 命题 3：监测杠杆的理论非对称性 . . . 9

4.3.1 3.3.1 定理陈述 . . . 9

4.3.2 3.3.2 严密分步极限推导 . . . 9

4.4 3.4 命题 4 与推论 1：成本预算与监测设计运筹优化 . . . 10

4.4.1 3.4.1 命题 4（多期时间平均与 AR(1) 修正） . . . 10

4.4.2 3.4.2 推论 1（成本约束下的闭式解与 Cochran 对偶） . . . 10

4.5 3.5 命题 5：当期超临界增长判定的精确检验与离散功效锯齿 . . . 11

4.5.1 3.5.1 检验构建与单调似然比（MLR） . . . 11

4.5.2 3.5.2 为什么功效曲线呈现锯齿状（Sawtooth Wave）? 11

5 第四部分：数值模拟的深层设计与三幅图的精读密码 11

5.1 4.1 图 1（理论方差分解与 50,000 次蒙特卡洛验证） 11

5.2 4.2 图 2（增长检测功效与 Wald 检验失真） 12

5.3 4.3 图 3（更新过程时序卷积与单步预测误差的双口径解密） 12

6 第五部分：全美流感真实数据实证全景复盘 12

6.1 5.1 数据资产与计量模型设定 12

6.2 5.2 核心实证估计结果 13

6.3 5.3 达峰期震撼反转：88.9% 偏差 vs 15.5% 集成预测 13

6.4 5.4 欧洲 11 国 COVID-19 跨病种验证 13

7 第六部分：硕士中期答辩高频质询 Q&A 宝典（10 问 10 答） 13

7.0.1 Q1: 你的研究与现有的 EpiEstim (Cori) 和 Parag 的信息论下界有什么本质区别? 14

7.0.2 Q2: 为什么一定要用负二项分支过程? 用经典的泊松过程不行吗? 14

7.0.3 Q3: 理论上的 $m_\times = A/v_R$ 与实证拟合得到的 $b/a \approx 22.6$ 能否直接画等号? . 14

7.0.4 Q4: 你在局限性里提到 v_R 始终是拟合量而非测量量，如果让你来测，在实务中怎么才能把它测出来? 14

7.0.5 Q5: 为什么推论 1 里的最优单期规模公式会和 Cochran 的两阶段抽样同构? 14

7.0.6 Q6: 实证中为什么用 FGLS 而不用我们最熟悉的普通最小二乘法 (OLS)? . . 15

7.0.7 Q7: 达峰期看似误差恒定在 0.3 左右，你凭什么说病例规模在达峰期依然有用? 15

7.0.8 Q8: 滞后暴露权重取 $w = (0.65, 0.25, 0.10)$ 的依据是什么? 换一组权重结论还成立吗? 15

7.0.9 Q9: 为什么命题 3 说提高报告率 ρ 存在无法消除的方差下界? 现实中疾控提高检测率没有意义吗? 15

7.0.10 Q10: 这篇论文对国家公共卫生监测体系的建设，到底能提供什么实际建议? 15

- **英文标题（原文）**: Boundaries of Surveillance Scale Returns in Epidemic Monitoring: Estimation Targets, Environmental Stochasticity, and External Validation
- **来源仓库**：https://github.com/wangchi2068/case-count-inference-bottleneck （最新定稿 commit `80e7d39`，2026 年 10 月 10 日）
- **深读依据**：仓库内权威定稿正文 `paper/main.tex`（28 页）、理论附录 A.1–A.6、全美 NHSN 流感实证、CDC FluSight 前瞻集成验证与欧洲 11 国 COVID-19 扩展实验。

- **阅读对象**：应用统计专业硕士（MAS）及生物数学/动力学建模方向研究生。旨在不仅讲清公式“是什么”，更深度拆解“为什么这样推”、“直觉怎么理解”、“实证说明了什么”以及“评委可能怎么问”。

---

1 导读前言：应用统计研究生的“论文通透心法”

阅读或答辩这篇论文时，首先要建立一个宏观全局认知：**本文是一篇高度典范的应用统计学顶刊风格论文**。它的行文与论证结构高度精密，由四根核心支柱环环相扣而成：

1. **微观概率论支柱**：从经典生灭分支过程（Galton–Watson 过程）出发，引入生物学超传播机制（Gamma 混合泊松分布，即负二项分布）与宏观观测不完全性（二项报告抽样过程），建立了双层随机生成机制；
2. **渐近统计推断支柱**：利用概率母函数（PGF）复合律证明了分布族闭包，计算得分函数与 Fisher 信息矩阵，严格证明了一致最小方差无偏估计（UMVUE）并达到 Cramér–Rao 下界；
3. **运筹与抽样设计支柱**：将理论方差分解与流行病学监测资源预算结合，推导了时间与样本规模的二维权衡闭式解，在数学形式上同构于经典两阶段抽样模型（Cochran 费用分配模型）的深刻对偶；
4. **经验计量与实证支柱**：不满足于纯理论推导，而是采集全美 CDC NHSN 长达六年、涵盖 50 州及 DC 的 16,218 条真实住院周度记录，采用可行广义最小二乘法（FGLS）与聚类 Bootstrap 检验，破除了达峰期“样本量失效”的传统误读，并扩展至 CDC FluSight 与欧洲 COVID-19 多场景。

读懂这篇论文的秘诀在于：**时刻牢记“推断目标决定规模收益”这一灵魂红线**。

---

2 第一部分：宏观全景地图——这篇论文究竟讲了一个什么故事？

2.1 1.1 一个违背直觉的现实科学矛盾

在公共卫生监测实践与常规统计直觉中，人们往往预设：**“数据越多越好，样本量越大越准”**。大数定律告诉我们，只要不断扩大哨点医院覆盖面、增加报告确诊人数（即增大病例规模 m），随机噪声就会被迅速平均掉，估计精度就能无界提升。

然而，在应对流感大流行、COVID-19 等真实传染病爆发时，全球疾控机构频繁面临一个极其尴尬的困境：

- 为什么在疫情高峰期，即便每周捕获上万例患者，模型的短期预测误差依然居高不下？
- 为什么在投入巨资扩展检测网络后，对未来趋势的判断却很快遭遇“平台瓶颈”，再怎么加倍收集病例，预测精度的改善也极其微弱？

既有文献的局限：以往学者通常笼统地将这种现象归咎于“漏报太多”、“数据质量差”或“模型设定错误”。近年来 Parag 等人（Nature Physics, 2022）利用信息论推导了带噪疫情曲线的信息

极限，但其核心结论依然是：信息量随病例数近似线性增长。这仍未回答：**究竟在什么时候，病例规模不再是推断的主要瓶颈？**

2.2　1.2 论文的核心破局点："推断目标决定规模收益"

本文最惊艳的洞见，在于指出以往文献混淆了**两个截然不同的统计推断目标**：

- **目标 A（当期传播参数 R_t）**：估计特定当周环境下的瞬时传染数。此时，环境扰动是我们要测量的"信号"。定理证明：测量方差随期望报告规模 m 按 $O(1/m)$ 严格单调趋零！在此目标下，大数定律完全成立，样本确实越大越好。
- **目标 B（跨期平均基准 $\bar{R}$）**：估计消除单周偶然波动后的潜在基础趋势。此时，宏观气象、节假日人群流动等不可预测的环境扰动成了"噪声"。定理证明：单期横截面样本再大，也只能观测到该期环境的一次实现，因而必然残留一个**不可约环境方差下限** v_R！总方差呈现仿射结构：

$$\mathrm{Var} = v_R + \frac{A}{m}$$

2.3　1.3 内生平衡点 $m_\times$ 的物理意义

将上述两项方差联立，自然导出了一个不可逆转的临界规模：

$$m_\times \equiv \frac{A}{v_R}$$

- **当 $m \ll m_\times$ 时（微观噪声主导区）**：抽样方差远远大于环境方差，此时扩大病例捕获能够带来极其显著的方差下降（投入产出比极高）；
- **当 $m \gg m_\times$ 时（宏观环境饱和区）**：不可约环境方差占比超过 50%，误差曲线进入水平平台。此时继续依靠扩大病例报告数已无法改善预测精度，监测资源必须由"扩量"转向"提质"（控制环境协变量与推进多模型集成）。

3　第二部分：核心概念与流行病学物理直觉通识

在深入代数推导之前，必须彻底理解论文中反复出现的几个关键符号的物理内涵：

3.1　2.1 超传播与离散参数 k

- **流行病学现象**：传染病传播具有极强的个体异质性，即"二八定律"——20% 的感染者引发了 80% 的二代传播（超传播事件，Superspreading）。
- **数学建模**：个体的次级感染数服从负二项分布 $\mathrm{NB}(k,p)$，方差为 $R_t + R_t^2/k$。
- **参数 k 的物理直觉**：
- $k \in (0,\infty)$ 是生物学过度离散参数；
- 当 $k \to \infty$ 时，方差退化为均值 R_t，退化为经典泊松分布（所有个体传染力均匀）；
- 当 $k \to 0$ 时，异质性极强，极少数"超级传播者"引发超级暴发，分布具有极严重的厚尾特征。

3.2 2.2 报告抽样率 ρ

- **物理含义**：真实感染者中，最终被医疗系统检测并上报的概率。
- **观测机制**：潜在感染者独立以概率 ρ 被医院确诊上报，构成二项报告抽样过程 $C_t \mid I_t \sim \text{Binomial}(I_t, \rho)$。

3.3 2.3 不可约环境方差 v_R

- **物理含义**：外部宏观气象、人群自发聚集、交通政策变动等对整个地区所有感染者的“共同乘性冲击”。
- **不可约性**：无论你在当地测了 100 人还是 10 万人，由于他们处于同一个客观天气与社会环境中，单周横截面数据无法通过大数定律平均消除这一共同外生扰动。

3.4 2.4 有效暴露病例规模 D_t 与权重向量 w

- **为什么不直接用上周病例数？**流感病程具有持续性，前几天甚至两周前的住院患者依然具有传染风险，且就医确诊存在延迟。
- **数学卷积**：$D_t = \sum_{s=1}^{3} w_s C_{t+1-s}$，采用 3 周回溯卷积核 $w = (0.65, 0.25, 0.10)$。
- **加权平均回溯时滞**：$\bar{\tau} = 1 \times 0.65 + 2 \times 0.25 + 3 \times 0.10 = 1.45$ 周 ≈ 10.2 天。这与流感临床从感染、发病到住院填报的复合特征时滞（约 10 天）完全吻合。

---

4 第三部分：数学命题教学级逐行拆解与深入证明（保姆级代数展开）

本部分面向数学与统计学严格标准，将附录与正文中的每一个定理进行保姆级代数展开，绝不跳步。

4.1 3.1 命题 1：条件似然、Fisher 信息与 Cramér–Rao 下界

4.1.1 3.1.1 定理陈述

设已知上一代风险集真实规模 n、固定报告率 ρ 及离散参数 k：

1. 观测报告数 $C_t \mid n, R_t \sim \text{NB}$（均值 $= \rho n R_t$，形状参数 $= nk$）；
2. 矩估计量 $\widehat{R}_t = \frac{C_t}{\rho n}$ 恰为极大似然估计（MLE）；
3. 在内部参数空间 $R_t \in (0, \infty)$ 上，估计量 $\widehat{R}_t$ 严格无偏，且方差严格达到 Cramér–Rao 下界：

$$\text{Var}(\widehat{R}_t \mid n, R_t) = \mathcal{I}(R_t \mid n)^{-1} = \frac{R_t}{\rho n} + \frac{R_t^2}{kn}$$

4.1.2 3.1.2 逐步严密代数推导

第一步：单感染者的概率母函数（PGF）

个体二代感染数 $X_{i,t} \sim \text{NB}(k, p)$，其中成功概率 $p = \frac{k}{k+R_t}$。

负二项分布的标准 PGF 形式为：

$$G_X(s) \equiv \mathbb{E}[s^X] = \left(\frac{p}{1-(1-p)s}\right)^k$$

第二步：n 名独立感染者求和

当期真实新发感染总数 $I_t = \sum_{i=1}^{n} X_{i,t}$。由条件独立性，独立随机变量和的 PGF 等于各自 PGF 之积：

$$G_{I_t}(s) = \prod_{i=1}^{n} G_X(s) = \left(\frac{p}{1-(1-p)s}\right)^{nk}$$

因此，$I_t \mid n, R_t \sim \mathrm{NB}(nk, p)$，形状参数累加为 nk。

第三步：二项报告抽样下的 PGF 复合运算

每个感染者独立以概率 ρ 上报，则报告数可表示为复合随机和 $C_t = \sum_{j=1}^{I_t} B_j$，其中 $B_j \sim \mathrm{Bernoulli}(\rho)$。

伯努利分布的 PGF 为 $G_B(s) = (1-\rho) + \rho s$。

利用复合随机变量的 PGF 复合律 $G_{C_t}(s) = G_{I_t}(G_B(s))$：

$$G_{C_t}(s) = \left(\frac{p}{1-(1-p)[(1-\rho)+\rho s]}\right)^{nk}$$

展开分母：

$$1-(1-p)(1-\rho)-\rho(1-p)s = [p+\rho(1-p)] - \rho(1-p)s$$

分子分母同除以 $[p+\rho(1-p)]$：

$$G_{C_t}(s) = \left(\frac{\frac{p}{p+\rho(1-p)}}{1-\frac{\rho(1-p)}{p+\rho(1-p)}s}\right)^{nk}$$

定义新的成功概率 $p^* \triangleq \frac{p}{p+\rho(1-p)}$。将 $p = \frac{k}{k+R_t}$ 及 $1-p = \frac{R_t}{k+R_t}$ 代入：

$$p^* = \frac{\frac{k}{k+R_t}}{\frac{k}{k+R_t} + \rho\frac{R_t}{k+R_t}} = \frac{k}{k+\rho R_t}$$

对比负二项标准 PGF 形式，直接证明了：**观测值 C_t 严格服从负二项分布**：

$$C_t \mid n, R_t \sim \mathrm{NB}\left(\text{形状参数} = nk,\ \text{成功概率} = \frac{k}{k+\rho R_t}\right)$$

条件期望为 $\mathbb{E}[C_t] = nk\frac{1-p^*}{p^*} = \rho n R_t$。

第四步：对数似然方程与 `const` 拆解

观测样本 C_t 的概率质量函数为：

$$\Pr(C_t = c) = \frac{\Gamma(c+nk)}{c!\Gamma(nk)}(p^*)^{nk}(1-p^*)^c = \left[\frac{\Gamma(c+nk)}{c!\Gamma(nk)} \cdot k^{nk} \cdot \rho^c\right] \cdot \frac{R_t^c}{(k+\rho R_t)^{nk+c}}$$

两边取自然对数 ln：

$$\ln L(R_t) = \underbrace{\ln\left[\frac{\Gamma(c+nk)}{c!\Gamma(nk)}\right] + nk\ln k + c\ln\rho}_{\text{与未知参数}R_t\text{ 完全无关，简记为}\mathbf{const}} + c\ln R_t - (nk+c)\ln(k+\rho R_t)$$

对参数 R_t 求一阶导数（得分函数 Score Function）：

$$S(R_t) \triangleq \frac{\partial \ln L}{\partial R_t} = 0 - \frac{\rho(nk+C_t)}{k+\rho R_t} + \frac{C_t}{R_t}$$

通分展开：

$$S(R_t) = \frac{-\rho R_t(nk+C_t) + C_t(k+\rho R_t)}{R_t(k+\rho R_t)} = \frac{k(C_t - \rho n R_t)}{R_t(k+\rho R_t)}$$

令得分函数为零 $S(R_t) = 0$，解得唯一驻点（极大似然估计量）：

$$\widehat{R}_t^{\mathrm{MLE}} = \frac{C_t}{\rho n}$$

第五步：无偏性验证（双层全期望展开）

要求解 $\mathbb{E}[\widehat{R}_t \mid n, R_t]$：

$$\mathbb{E}[\widehat{R}_t \mid n, R_t] = \mathbb{E}\left[\frac{C_t}{\rho n} \,\middle|\, n, R_t\right] = \frac{1}{\rho n}\mathbb{E}[C_t \mid n, R_t]$$

利用双层全期望公式（塔式法则）：

$$\mathbb{E}[C_t \mid n, R_t] = \mathbb{E}_{I_t}\Big(\mathbb{E}_{C_t}[C_t \mid I_t] \,\Big|\, n, R_t\Big)$$

- 内层：已知真实感染 I_t，二项抽样均值为 $\mathbb{E}[C_t \mid I_t] = \rho I_t$；
- 外层：已知风险集 n 和传播率 R_t，各分支独立，感染总数期望为 $\mathbb{E}[I_t \mid n, R_t] = nR_t$；

代入得：

$$\mathbb{E}[C_t \mid n, R_t] = \mathbb{E}[\rho I_t \mid n, R_t] = \rho\mathbb{E}[I_t \mid n, R_t] = \rho n R_t$$

两端相除：

$$\mathbb{E}[\widehat{R}_t \mid n, R_t] = \frac{\rho n R_t}{\rho n} = R_t$$

无偏性证毕！

第六步：Fisher 信息量两套算法与 Cramér–Rao 下界

- **算法一（得分方差法）**：

$$\mathcal{I}(R_t \mid n) = \mathrm{Var}(S(R_t)) = \frac{k^2}{R_t^2(k+\rho R_t)^2}\,\mathrm{Var}(C_t \mid n, R_t)$$

代入负二项方差 $\mathrm{Var}(C_t) = \frac{\rho n R_t(k+\rho R_t)}{k}$：

$$\mathcal{I}(R_t \mid n) = \frac{k^2 \cdot \frac{\rho n R_t(k+\rho R_t)}{k}}{R_t^2(k+\rho R_t)^2} = \frac{k\rho n}{R_t(k+\rho R_t)} = \frac{n}{\frac{R_t}{\rho} + \frac{R_t^2}{k}}$$

- **算法二（负二阶导期望法）**：

对得分函数 $S(R_t) = -\frac{\rho(nk+C_t)}{k+\rho R_t} + \frac{C_t}{R_t}$ 再次求导：

$$\frac{\partial^2 \ln L}{\partial R_t^2} = \frac{\rho^2(nk+C_t)}{(k+\rho R_t)^2} - \frac{C_t}{R_t^2}$$

取负号并求期望，代入 $\mathbb{E}[C_t] = \rho n R_t$：

$$\mathcal{I}(R_t \mid n) = \mathbb{E}\left[\frac{C_t}{R_t^2} - \frac{\rho^2(nk+C_t)}{(k+\rho R_t)^2}\right] = \frac{\rho n R_t}{R_t^2} - \frac{\rho^2(nk+\rho n R_t)}{(k+\rho R_t)^2} = \frac{\rho n}{R_t} - \frac{\rho^2 n}{k+\rho R_t} = \frac{k\rho n}{R_t(k+\rho R_t)}$$

两套算法完全一致！计算其倒数：

$$\mathcal{I}(R_t \mid n)^{-1} = \frac{R_t}{\rho n} + \frac{R_t^2}{kn}$$

由于估计量无偏，Cramér–Rao 方差下界恰为 $\mathcal{I}^{-1}$，而估计量方差代数上严格等于该倒数。

证毕：估计量为 UMVUE。

4.2 3.2 命题 2：跨期基础水平的边际方差分解

4.2.1 3.2.1 定理陈述

估计跨期平均传播基准 $\bar{R} \equiv \mathbb{E}[R_t \mid n]$（存在宏观环境随机性 $\mathrm{Var}(R_t \mid n) = v_R > 0$），单期估计量 $\frac{C_t}{\rho n}$ 给定风险集 n 的条件边际方差为：

$$\mathrm{Var}\left(\frac{C_t}{\rho n} \,\middle|\, n\right) = v_R + \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn} \equiv v_R + \frac{A}{m}$$

其中期望报告规模 $m \equiv \rho n$，标量系数 $A \equiv \bar{R} + \frac{\rho(\bar{R}^2+v_R)}{k}$。

4.2.2 3.2.2 逐步严密代数推导

应用**全方差公式（Law of Total Variance）**：

$$\mathrm{Var}\left(\frac{C_t}{\rho n} \,\middle|\, n\right) = \underbrace{\mathrm{Var}\left(\mathbb{E}\left[\frac{C_t}{\rho n} \,\middle|\, n, R_t\right] \,\middle|\, n\right)}_{\text{宏观环境方差贡献}} + \underbrace{\mathbb{E}\left[\mathrm{Var}\left(\frac{C_t}{\rho n} \,\middle|\, n, R_t\right) \,\middle|\, n\right]}_{\text{微观抽样方差贡献}}$$

第一项计算：

由命题 1 的无偏性结论，$\mathbb{E}\left[\frac{C_t}{\rho n} \,\middle|\, n, R_t\right] = R_t$。因此：

$$\mathrm{Var}(R_t \mid n) = v_R$$

第二项计算：

代入命题 1 导出的条件方差式：

$$\mathbb{E}\left[\frac{R_t}{\rho n} + \frac{R_t^2}{kn} \,\middle|\, n\right] = \frac{\mathbb{E}[R_t \mid n]}{\rho n} + \frac{\mathbb{E}[R_t^2 \mid n]}{kn}$$

由二阶矩与方差的基本代数关系：$\mathbb{E}[R_t^2 \mid n] = \mathrm{Var}(R_t \mid n) + (\mathbb{E}[R_t \mid n])^2 = v_R + \bar{R}^2$。

代入得：

$$= \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn}$$

两项相加，得到定稿核心方差公式：

$$\mathrm{Var}\left(\frac{C_t}{\rho n} \,\middle|\, n\right) = v_R + \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn} = v_R + \frac{1}{\rho n}\left[\bar{R} + \frac{\rho(\bar{R}^2 + v_R)}{k}\right] = v_R + \frac{A}{m}$$

物理含义：单期方差呈现严格的仿射结构 $v_R + A/m$。当 $m \to \infty$ 时，后项抽样方差消失，但前项宏观环境方差 v_R 永远保留！

4.3 3.3 命题 3：监测杠杆的理论非对称性

4.3.1 3.3.1 定理陈述

将单期方差中的抽样项展开：

$$\frac{\bar{R}}{\rho n} = \frac{\bar{R}}{n} + \frac{(1-\rho)\bar{R}}{\rho n}$$

总方差二元函数 $V(n, \rho)$ 满足：

1. 报告率极限（$\rho \to 1$）：$\lim_{\rho \to 1} V(n, \rho) = v_R + \frac{\bar{R}}{n} + \frac{\bar{R}^2 + v_R}{kn} > v_R$；
2. 风险集基数极限（$n \to \infty$）：$\lim_{n \to \infty} V(n, \rho) = v_R$。

4.3.2 3.3.2 严密分步极限推导

- **对报告率 $\rho \to 1$ 求极限**：

$$\lim_{\rho \to 1} V(n, \rho) = v_R + \lim_{\rho \to 1} \frac{(1-\rho)\bar{R}}{\rho n} + \frac{\bar{R}}{n} + \frac{\bar{R}^2 + v_R}{kn} = v_R + 0 + \frac{\bar{R}}{n} + \frac{\bar{R}^2 + v_R}{kn} > v_R$$

解释：完全消除漏报只能干掉 $\frac{(1-\rho)\bar{R}}{\rho n}$，但人群内部固有的完全报告泊松计数波动 $\bar{R}/n$ 和超级传播子代抽样波动 $\frac{\bar{R}^2 + v_R}{kn}$ 均依赖于有限样本量 n，无法靠提升报告率解决。

- **对人群基数 $n \to \infty$ 求极限**：

$$\lim_{n\to\infty} V(n,\rho) = v_R + \lim_{n\to\infty} \frac{1}{n}\left[\frac{\bar{R}}{\rho} + \frac{\bar{R}^2 + v_R}{k}\right] = v_R + 0 = v_R$$

解释：扩大基数 n 分母趋于无穷大，利用大数定律将所有微观层面的抽样波动彻底消除。

4.4 3.4 命题 4 与推论 1：成本预算与监测设计运筹优化

4.4.1 3.4.1 命题 4（多期时间平均与 AR(1) 修正）

设总样本输入规模预算为 $B = T \cdot m = T\rho n_T$。设计方案为 $\mathcal{D}_T = (T, n_T)$。

对跨期样本均值 $\overline{\widehat{R}}_T = \frac{1}{T}\sum_{t=1}^{T} \widehat{R}_t$ 求方差：

$$\mathrm{Var}(\overline{\widehat{R}}_T) = \frac{1}{T^2}\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) + \frac{1}{T^2}\sum_{t=1}^{T}\mathrm{Var}(\widehat{R}_t \mid R_t) = \frac{1}{T^2}\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) + \frac{1}{T^2}\cdot T\frac{A}{m}$$

代入 $Tm = B$：

$$\text{第二项（抽样项）} = \frac{A}{Tm} = \frac{A}{B} \quad \text{（恒为常数！）}$$

惊人结论：在固定总样本预算下，无论你分多少期，抽样误差项永远是常数 A/B！

要想降低总方差，**唯一的方法是拉长期数 T 去压制第一项（环境项）**！

- 独立环境下：第一项为 $\frac{v_R}{T}$，方差以 $O(1/T)$ 严格递减；
- AR(1) 自相关环境下（相关系数 r）：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = Tv_R + 2v_R\sum_{s=1}^{T-1}(T-s)r^s = v_R T\left[\frac{1+r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right]$$

当观测期远大于环境自相关记忆时长（$T \gg \frac{1}{1-r}$）时，有效独立期数退化为 $T_{\text{eff}} \approx T\frac{1-r}{1+r}$。

4.4.2 3.4.2 推论 1（成本约束下的闭式解与 Cochran 对偶）

设每期固定运转维持成本为 c_0，每报告一例边际成本为 c_1。总经费预算为 $\mathcal{B} = T(c_0 + c_1 m)$。

代入 $T = \frac{\mathcal{B}}{c_0 + c_1 m}$ 到目标方差函数：

$$f(m) = \mathrm{Var}(\overline{\widehat{R}}_T) = \frac{v_R}{\frac{\mathcal{B}}{c_0+c_1 m}} + \frac{A}{\frac{\mathcal{B}}{c_0+c_1 m}m} = \frac{c_0 + c_1 m}{\mathcal{B}}\left(v_R + \frac{A}{m}\right) = \frac{1}{\mathcal{B}}\left[c_0 v_R + c_1 v_R m + \frac{c_0 A}{m} + c_1 A\right]$$

求一阶导数：

$$f'(m) = \frac{1}{\mathcal{B}}\left[c_1 v_R - \frac{c_0 A}{m^2}\right] = 0 \implies m^2 = \frac{c_0 A}{c_1 v_R} = \frac{c_0}{c_1}m_\times \implies m^* = \sqrt{\frac{c_0}{c_1}m_\times}$$

求二阶导数：

$$f''(m) = \frac{2c_0 A}{\mathcal{B}m^3} > 0 \quad (\text{对一切} m > 0 \text{ 恒正，函数严格凸！})$$

学术高度：这在数学结构上与抽样调查鼻祖 Cochran (1977) 第 10 章的两阶段抽样最优次级样本量公式完全同构！初级抽样单元对应期数 T，次级抽样单元对应单期病例 m。

4.5　3.5 命题 5：当期超临界增长判定的精确检验与离散功效锯齿

4.5.1　3.5.1 检验构建与单调似然比（MLR）

单侧假设检验：$H_0 : R_t \le 1 \quad \text{vs} \quad H_1 : R_t > 1$。

对任意 $R_1 > R_0$，似然比为：

$$\frac{\Pr_{R_1}(C_t = j)}{\Pr_{R_0}(C_t = j)} = \left(\frac{p^*(R_1)}{p^*(R_0)}\right)^{nk} \left(\frac{1 - p^*(R_1)}{1 - p^*(R_0)}\right)^{j}$$

由于 $1 - p^*(R) = \frac{\rho R}{k + \rho R}$ 关于 R 严格单调递增，底数 $\frac{1-p^*(R_1)}{1-p^*(R_0)} > 1$。

因此，似然比关于充分统计量 C_t **严格单调递增**（满足 MLR 性质）。

由经典统计推断理论（Karlin–Rubin 定理），上尾拒绝域 $\{C_t \ge c_\alpha\}$ 在复合原假设下，一类错误率严格在上确界点（边界点 $R_t = 1$）达到最大：

$$\sup_{R_t \le 1} \Pr_{R_t}(C_t \ge c_\alpha) = \Pr_{R_t = 1}(C_t \ge c_\alpha) \le \alpha$$

离散临界值由 $c_\alpha = \min\{c \in \mathbb{N} : \Pr_{R_t=1}(C_t \ge c) \le \alpha\}$ 唯一确定。

4.5.2　3.5.2 为什么功效曲线呈现锯齿状（Sawtooth Wave）？

因为观测计数 C_t 只能取整数，临界值 $c_\alpha(n)$ 随样本量 n 呈阶梯状跳变：

- 当 n 在某个区间连续微增时，临界值 c_α 保持不变，由于样本量变大，功效连续上升；
- 一旦 n 跨过某个临界点，为了控制显著性水平 α，c_α 突然跳跃到 $c_\alpha + 1$，拒绝门槛突然拔高，导致统计功效瞬间出现向下跳跃！
- 这解释了图 2 模拟中为什么连续增加病例数，功效曲线会出现特有的锯齿波动，证实了离散枚举求解最小样本量的必要性。

5　第四部分：数值模拟的深层设计与三幅图的精读密码

5.1　4.1 图 1（理论方差分解与 50,000 次蒙特卡洛验证）

- **验证目的**：直接在无时序延迟的单代分支模型下，用 50,000 次完全随机模拟，核验命题 1 与命题 2 的代数解析式是否准确无误。
- **图面精读**：

- 蓝色曲线（估计当期 R_t）：在双对数坐标轴下是一条斜率为 -1 的直线，随着 m 增大一路单调趋于零；
- 红色曲线（估计跨期 $\bar{R}$）：在小样本时沿 -1 斜率下降，越过交叉点 $m_\times = 53.1$ 后，迅速弯曲变平，严丝合缝地贴在水平渐近虚线 $v_R = 0.04$ 上；
- 散点（仿真值）与实线（解析解）比值处于 0.988–1.017 之间，证明理论代数推导 100% 紧致正确。

5.2　4.2 图 2（增长检测功效与 Wald 检验失真）

- **验证目的**：检验常规渐近正态 Wald 检验在传染病暴发早期小计数时的失效，并展示超传播对样本量需求的惩罚。
- **图面精读**：
- 虚线（Wald 检验）：在小样本且强超传播（$k = 0.1$）时，实际一类错误率最高达到 8.1%（严重虚警）；
- 实线（离散精确负二项检验）：全域严格压在 0.05 以下；
- 超传播的代价：达到 80% 功效所需的病例数，从轻度超传播（$k = 1.0$）的 142 例激增至重度超传播（$k = 0.1$）的 415 例，暴增近 3 倍！

5.3　4.3 图 3（更新过程时序卷积与单步预测误差的双口径解密）

- **核心争议与双口径彻底搞通**：
- **为什么按初始规模看是 0.75–0.98 倍？**模拟生成时横轴标示的是第 0 周的初始规模 m。因为设定了 $\bar{R} = 1.15 > 1$（疫情处于增长态势），到了第 4–29 周评估时，实际的周病例数已经自发增长到了初始值的 1.7–2.4 倍（中位数口径）！拿增长后的大病例数去对比初始小规模的理论值，表观比值自然显得略低；
- **为什么按实际规模看是不低于下界的 1.01–1.17 倍（按组 1.00–1.45 倍）？**只要按照评价周实际发生的病例暴露规模重核参照线，经验预测误差就**严格不低于单代静态下界**！
- **理论大获全胜**：这直接印证了命题 6 和式 (29) 的条件分解定理——更新过程因为只能用历史报告代替真实感染压力，必然叠合一个非负的预测偏差项 $(\mu/D - \bar{R})^2 \geq 0$！

6　第五部分：全美流感真实数据实证全景复盘

6.1　5.1 数据资产与计量模型设定

- **真实数据源**：美国 CDC NHSN 系统 50 个州加华盛顿特区自 2020 年 8 月至 2026 年 9 月共 16,218 条周度住院记录；
- **有效样本筛选**：$D_t \geq 5$（活跃周门槛），保留 10,303 个有效州周观测；
- **计量模型**：根据式 (7) 仿射理论形式，建立模型 $\text{Loss}_{s,t} = a + \frac{b}{D_{s,t}} + u_{s,t}$；
- **为什么必须用 FGLS（可行广义最小二乘法）？**
- 普通 OLS 假定误差项具有同方差；

- 但实测发现：残差具有极端厚尾（偏度高达 8.63），且小规模组的方差–均值比高达 5.32，大规模组收缩至 0.99，存在剧烈的反比非齐次方差；
- 必须采用以拟合值平方倒数 $1/\hat{\mu}^2$ 加权的 FGLS，并配合 1,500 次按州聚类的 Bootstrap 估计标准误。

6.2 5.2 核心实证估计结果

- 规模斜率项 $\hat{b} = 2.2434$（95% CI $[1.50, 3.02]$），**1,500 次 Bootstrap 重抽无一次小于等于零**（$p < 10^{-4}$），强力证实了 b/D_t 递减项的真实存在；
- 经验拟合截距 $\hat{a} = 0.0991$；经验平衡点 $m_{\times}^{\text{emp}} = \hat{b}/\hat{a} \approx 22.6$ 例/周；
- **误差份额分解**：在流行初期平均 0.181 的总误差中，规模相关项占 45.1%，不可约经验下限占 54.6%（四至五成半）。

6.3 5.3 达峰期震撼反转：88.9% 偏差 vs 15.5% 集成预测

- **表象与传统误读**：在达峰期，各规模组的总相对误差恒定在 0.292–0.312，看起来不管怎么增大病例规模，误差完全不下降。很多人据此宣称“达峰期病例数失效了”。
- **论文的数学正交分解**：

$$\text{总误差} = \underbrace{\left(\frac{\bar{R}_{\text{peak}} - \bar{R}_{\text{early}}}{\bar{R}_{\text{early}}}\right)^2}_{\text{常数基准偏移项（占 88.9\%）}} + \underbrace{\text{条件方差项（占 11.1\%）}}_{\text{规模效应仍显著为正！}}$$

- 达峰期看似恒定的高误差，**整整 88.9% 是因为疫情达峰转向、历史平稳基准失灵导致的常数漂移**！
- 剥离常数漂移后，达峰期内部的纯条件方差依然显著随规模递减（$\hat{b} = 7.9272$）；
- **外部验证的终极呼应**：

在引入 CDC FluSight 官方真实多模型前瞻集成预测后，**达峰期的均值偏差占比从静态单模型的 88.9% 骤降至 15.5%**！

直接在实证上回答了：跨过规模平衡点后，单纯扩充样本量已经边际递减，必须依靠多模型自适应集成来消除均值漂移。

6.4 5.4 欧洲 11 国 COVID-19 跨病种验证

- 引入欧洲 11 国早期日度发病监测数据（$N = 404$）；
- 纯事前口径拟合得 $\hat{b} = 33.92$（95% CI $[14.60, 74.9873]$），显著为正，经验平衡点为 124.7 例/天；
- 证明了规模递减规律跨病种、跨地域的高度稳健性，同时证实特征平衡点随时间分辨率和监测尺度变动。

---

7 第六部分：硕士中期答辩高频质询 Q&A 宝典（10 问 10 答）

本部分专为数学系、应用统计系教授评委的刁钻提问量身定制，掌握这 10 个回答，答辩即可稳操胜券。

7.0.1 Q1: 你的研究与现有的 EpiEstim (Cori) 和 Parag 的信息论下界有什么本质区别？

> **答**：Cori 等人的 EpiEstim 解决的是“如何在滑动窗口下估计时变再生数”，Parag 等人的研究确立了“以当期瞬态参数 R_t 为目标时信息量随病例数线性增长”的物理极限。

> 本文的本质区别在于**推断目标的切换**：我们证明，一旦将推断目标由当期瞬态参数 R_t 切换为跨期基础水平 $\bar{R}$，由于单期横截面样本无法消除全员共享的外生宏观环境扰动，方差标度律发生根本改变，出现不可约环境方差下限 v_R 与特征规模平衡点 $m_\times$。本文填补的是从“单期推断”跨越到“监测资源运筹设计”的理论空白。

7.0.2 Q2: 为什么一定要用负二项分支过程？用经典的泊松过程不行吗？

> **答**：传染病学中普遍存在极强的超传播现象（Lloyd-Smith 等 2005），约 20% 的感染者引发 80% 的传播。

> 泊松分布强加了方差等于均值（$k \to \infty$），这在数学上会严重低估小计数阶段的重尾抽样风险，人为低估达到指定功效所需的样本量需求（如图 2 所示，强超传播下样本量需求暴增 3 倍）。引入负二项分布不仅具有流行病学真实性，更在数理上通过 PGF 复合运算保证了二项抽样下的分布族封闭性，为全方差分解提供了优雅的解析基准。

7.0.3 Q3: 理论上的 $m_\times = A/v_R$ 与实证拟合得到的 $b/a \approx 22.6$ 能否直接画等号？

> **答**：不能直接等同，实证比值是理论平衡点的**经验映射物与量级参照**。

> 理论上的 $m_\times$ 是在单代已知参数下的解析临界点；而实证中的 $a = 0.0991$ 与 $b = 2.2434$ 是在真实流感周度时间序列中对 D_t 进行仿射拟合的参数，其中 a 既包含了宏观环境波动，也吸收了滞后卷积平滑失配的常数偏差。实证的核心价值在于**验证了理论预测的仿射递减与平台收敛形状**，而非点位精确物理测量。

7.0.4 Q4: 你在局限性里提到 v_R 始终是拟合量而非测量量，如果让你来测，在实务中怎么才能把它测出来？

> **答**：正如我们在第 6.2 节方法学展望中所提出的，未来可以通过 **“双轨监测体系”** 实现纯外生环境方差 v_R 的解耦测度：

> 目前的医院住院监测混合了就医行为与填报时滞；如果能在代表性社区布设固定人群的前瞻性主动追踪队列（如定期家庭采样），直接测得无就医行为干扰的真实社区传播强度，就能将外生宏观环境方差 v_R 与监测系统的代理平滑偏差完全分离识别。

7.0.5 Q5: 为什么推论 1 里的最优单期规模公式会和 Cochran 的两阶段抽样同构？

> **答**：这体现了数理统计深层的对偶之美。

> 在时间序列监测中，期数 T 本质上就是初级抽样单元（PSU），单期捕获病例数 m 就是次级抽样单元（SSU）。固定维持成本 c_0 发生于每一期，边际采集成本 c_1 发生于每个病例。这与 Cochran (1977) 调查抽样中“在有限预算下权衡抽取多少个群（群成本 c_0）与每群调查多少人（人均成本 c_1）”的数学优化模型完全同构，二阶导数 $\frac{2c_0A}{\mathcal{B}m^3} > 0$ 严格保证了最优解的全局唯一性。

7.0.6 Q6: 实证中为什么用 FGLS 而不用我们最熟悉的普通最小二乘法 (OLS)？

> **答**：因为真实监测数据的残差具有极强的异方差与厚尾性。

> 流感住院损失的偏度高达 8.63，小规模段的方差–均值比高达 5.32，大规模段收缩至 0.99，表现出剧烈的反比非齐次方差。如果使用普通 OLS，小样本段的极大极端值会过度主导回归线，估计功效损失极大；FGLS 通过一阶拟合残差平方倒数进行迭代加权，在大样本下达到最优线性无偏估计（BLUE）。

7.0.7 Q7: 达峰期看似误差恒定在 0.3 左右，你凭什么说病例规模在达峰期依然有用？

> **答**：凭严格的**均值–方差正交代数分解**。

> 我们证明了达峰期看似恒定的高误差中，整整 88.9% 来源于疫情转折导致的常数基准漂移 $(\bar{R}_{\text{peak}} - \bar{R}_{\text{early}})^2 / \bar{R}^2_{\text{early}} = 0.2669$。真正反映推断波动的纯条件方差只占 11.1%。当我们使用达峰期自身均值剥离常数漂移后，规模相关项系数 $\hat{b} = 7.9272$ 依然高度显著为正。失效的是跨期平稳性假设，而不是病例规模本身。

7.0.8 Q8: 滞后暴露权重取 $w = (0.65, 0.25, 0.10)$ 的依据是什么？换一组权重结论还成立吗？

> **答**：有两个依据：第一，加权平均回溯时间为 1.45 周（约 10.2 天），与流感临床从感染、潜伏（1–2 天）、发病就诊（3–5 天）到填报确认的复合特征时滞（约 10 天）完全吻合；

> 第二，正文第 5.1 节进行了严格的权重敏感性检验：无论换用单周滞后（7 天）还是三周等权（14 天），规模斜率 b 始终在 1.9 到 3.1 之间，聚类 Bootstrap 置信区间严格远离零点，1,500 次重抽无一次小于零，核心科学结论对权重设定高度稳健。

7.0.9 Q9: 为什么命题 3 说提高报告率 ρ 存在无法消除的方差下界？现实中疾控提高检测率没有意义吗？

> **答**：提高报告率具有显著价值，但它的作用机制具有局限性。

> 全方差公式严格表明：提高报告率 $\rho \to 1$ 只能消除由于漏报产生的纯二项抽样方差 $\frac{(1-\rho)\bar{R}}{\rho n}$，但它无法消除人群中固有的微观计数随机性 $\frac{\bar{R}}{n}$，更无法消除个体超级传播引发的子代抽样方差 $\frac{\bar{R}^2 + v_R}{kn}$。唯有扩大地理或人群基数 n，通过大数定律才能同时压低所有微观随机性。

7.0.10 Q10: 这篇论文对国家公共卫生监测体系的建设，到底能提供什么实际建议？

> **答**：给出了两阶段“差异化资源配置”判据：

> 1. **在疫情初期与低发期 ($m < m_\times$)**：系统处于微观噪声主导区，此时应集中资源扩建哨点、扩大病例捕获，能够迅速跨过平衡点，获得显著的方差收益；

> 2. **在疫情高峰期与常态化监测期 ($m > m_\times$)**：系统跨过特征平衡点进入饱和区，此时继续单纯追求捕获更多病例已边际收益递减，监测资源应当果断由“扩量”转向“提质”——即转向引入多模型前瞻集成预测，并补充气象、人群流动等外部环境协变量以解释不可约环境方差。