

疫情监测中的病例规模收益边界：估计目标、环境随机性与外部验证

摘要

准确识别疫情增长并预测短期病例负担是现代传染病预警的核心任务。常规直觉认为样本量越大推断精度越高，但在个体超传播、不完全检测与共同环境扰动并存时，样本规模与推断信息量不能简单等同。既有信息下界理论主要建立在瞬时再生数 R_t 一类估计目标上；本文证明更换估计目标后方差标度律随之改变，据此将病例规模何时不再主导推断误差转化为一个条件明确的监测设计问题。

主要理论结果表明：(1) 估计当期瞬态参数 R_t 时，测量方差随期望报告规模 m 严格单调趋零；(2) 以单期数据估计跨期平稳基准 $\bar{R}$ 时，单期推断留存不可消除的环境方差底板 v_R ，由此导出两类方差相等的收益拐点 $m_\times$ ；(3) 提高报告率 ρ 仅能消除漏报抽稀方差，唯有扩大真实感染基数 n 才能使各项方差同时衰减；(4) 时间序列中事后代理增长统计量与事前单步预测严格成比例，且误差在极小规模端受更新过程尾部方差二次放大。

实证方面，基于全美 CDC NHSN 流感住院真实监测数据 (16,218 个州周观测)：流行初期相对均方误差随规模呈理论预测的仿射衰减，经验拐点约为 23 例/周；约四至五成半的误差份额落在与规模无关的拟合底板上；在达峰期，常数均值偏移是误差平台的主要来源，剥离偏差后规模效应依然显著。本文进一步分析了 CDC FluSight 前瞻集成预测和欧洲 11 国 COVID-19 数据，两组数据中的规模相关误差项均为正，经验拐点随监测尺度和时间粒度变化。这些结果可用于比较扩大样本、延长观测期和采用多模型预测的相对收益。

关键词：疫情增长判定；分支过程；超传播；环境随机性；监测设计；误差预算分解；流感住院实证

1 引言

准确识别疫情由平稳或下降转为上升增长，并对随后数周的病例负担作出可靠预测，是现代传染病预警与公共卫生应急响应的核心支柱。在常规统计直觉中，大样本量通常意味着高推断精度，即增加捕获病例数能够持续压制随机计数波动的相对影响。然而，在传染病监测与动力学建模的真实场景下，这一直觉往往遭遇严峻挑战：病原体传播普遍具有高度个体异质性（超传播），导致继发感染数严重过离散 [1, 2]；监测系统普遍存在不同程度的不完全检测与报告延迟 [3, 4]；此外，处于同一地理辖区或时间窗口内的宿主群体共同受到气象条件、人群接触模式以及周期性社会流动等环境随机扰动 [5, 6]。超传播、漏报和共同环境波动同时存在时，病例数不再等同于有效信息量。

关于传染病监测数据中信息瓶颈与推断局限的研究，在既有文献中形成了数条清晰的发展脉络。其一源于对传播异质性与更新过程动力学的建模探索。开创性工作揭示了个体繁殖数偏

离泊松假设的负二项分布特征，阐明了均值推断低估爆发概率与灭绝风险的机制 [1, 7]。随后，基于发病时间间隔分布的代际更新过程模型确立了时变再生数推断的通用模型 [8, 9]，其中以 Cori et al. [10] 提出的基于更新方程的瞬态估计方法及其实用工具 (EpiEstim) 成为实时疫情追踪的主流基准 [11–13]。

其二聚焦于不完全观测、报告延迟与状态空间滤波。现实监测系统难以直接捕捉真实感染，往往只能观测到夹杂抽稀与迟滞的医院确诊或重症入院序列 [3, 14]。为了从带噪监测序列中恢复未观测感染压力，学者们构建了包含粒子滤波、更新过程与分层时空平滑的状态空间推断方法 [4, 15]，并揭示了报告率与传播强度的联合可识别性边界 [16]。

其三近年来利用信息论与 Fisher 信息量解析了带噪疫情曲线的信息极限 [17]，确立了检测疫情反弹的严格信息论下界及干预延迟边界 [18, 19]。然而，既有信息下界文献中信息量随病例数近似线性增长的标度律，主要建立在当期瞬态参数 R_t 这一类估计目标之上。本文与之形成理论对话：当推断目标由当期瞬态参数转换为跨期基础水平时，方差对病例规模的标度响应出现分水岭。对当期瞬态参数 R_t ，增加病例规模的边际方差收益恒为正，测量方差随规模扩大严格单调趋零（命题 1）；而对跨期平稳的潜在基础趋势 $\bar{R}$ ，单期推断必然留存不可消除的环境方差底板 v_R ，由此定义出两类方差相等的经验收益拐点 $m_\times$ （命题 2）。这一结果与生态动力学中人口统计随机性和环境随机性的区分一致 [5, 6, 20–23]，在应用统计中则对应测量误差模型与信度理论的方差分解 [24–27]。此外，大规模真实监测（如 CDC FluSight 挑战赛）的经验评估表明，随着监测覆盖面扩张，多模型前瞻预测精度的提升迅速呈现收益递减平台 [28–34]，而全美流感住院负担测算 [35] 为折算住院比例提供了经验参照。

因此，不能直接把单一模型中的规模规律外推到所有监测场景。本文针对这一具体监测设计问题，构建了条件明确的分层随机模型，系统实现以下五项贡献：

- (1) **明确估计目标与收益拐点**：严格区分当期瞬态传播参数 R_t 与跨期潜在基准 $\bar{R}$ ，证明二者对增加病例规模的边际方差响应截然不同；解析导出单期估计方差内部环境底板项与抽样方差项相等的收益拐点 $m_\times$ （对应信度比 0.5 的临界结构位置）。
- (2) **精确拆解监测杠杆的非对称性**：证明扩大真实感染捕获基数 n （人群/地理覆盖扩大）与提高检测报告率 ρ 存在数理非对称性——显式分解指出提高报告率仅能消除漏报抽稀方差 $\frac{(1-\rho)\bar{R}}{\rho n}$ ，无法消除完全报告时依然存在的计数方差与超传播内在抽样方差；唯有扩大真实基数 n 才能使各项方差同时衰减。
- (3) **分析理想设计下的监测维度权衡**：在理想化重复采样设计与总监测输入规模预算 $B = T \cdot m$ 约束下，严格推导拉长独立观测期数 T 削减环境方差 v_R 的精确表达式与 AR(1) 自相关闭式，并明确指出每期整数风险集约束下的离散可行设计集合。
- (4) **给出增长判定检验与预测基准评估**：导出基于负二项单调似然比的精确上尾超临界增长判定检验并证明其水平控制；在时间序列更新过程中清晰界定事后代理增长统计量与事前单步病例预测的内在代数关系与条件方差展开，并通过有限样本模拟检验理论基准的适用性与衰减形态。
- (5) **真实监测数据实证与误差预算分解**：采用美国疾控中心国家医疗保健安全网 (CDC NHSN) 2020–2026 年覆盖 50 个州及华盛顿特区周度流感住院真实数据 (16,218 个州周观测)，在

控制聚类不确定性的前提下，测得经验收益放缓平台的数量级与报告政策切换前后的离散度分化，识别出达峰期失效的是跨期平稳基准假定而非病例规模本身；进一步构建与 Cori 时变更新过程基线的竞争对照，开展预测偏差项分解与季节内独立两阶段最小二乘 (2SLS) 稳健性检验；并给出误差预算份额分解与时变经验交叉点：仿射拟合中约四至五成半 (39%–55%) 的误差份额落在与规模无关的拟合项上，样本中已实现的大规模观测误差约为全体平均的六成——这一份额结构本身，提示进一步评估环境协变量与多期信息的价值。

需要明确，本文的核心理论贡献在于揭示估计目标与环境随机性对监测规模收益的决定性制约，把估计目标、方差结构和监测设计放在同一分析框架中，而非提出新的动力学分布模型。

本文结构安排如下：第 2 节建立传播与报告模型并界定两类估计目标；第 3 节呈现核心理论结果、交叉点与监测杠杆非对称性推导；第 4 节报告增长判定离散功效与更新过程预测模拟；第 5 节利用全美流感住院真实监测数据展开系统实证检验与反证边界分析；第 6 节总结全文并探讨公共卫生监测设计的决策启示。

2 模型与估计目标

2.1 传播与报告模型

设上一传播代有 n 名真实感染者，第 i 名感染者产生的继发感染数为 $X_{i,t}$ 。在给定当期环境条件下的传播参数 R_t 后，假设个体继发感染数服从过离散负二项分支分布：

$$\mathbb{E}[X_{i,t} | R_t] = R_t, \quad \text{Var}(X_{i,t} | R_t) = R_t + \frac{R_t^2}{k}, \quad (1)$$

其中 $k > 0$ 为个体传播离散参数 ($k \rightarrow 0$ 对应极端超传播, $k \rightarrow \infty$ 退化为泊松分布)。假设在给定 (n, R_t) 条件下，个体继发感染数 $\{X_{i,t}\}_{i=1}^n$ 相互条件独立。当期真实新发感染总数为 $I_t = \sum_{i=1}^n X_{i,t}$ 。

观测过程采用固定报告率 $\rho \in (0, 1]$ 的基准二项抽稀模型：

$$C_t | I_t \sim \text{Binomial}(I_t, \rho). \quad (2)$$

理论基准设定：第 3 节的推导在已知真实风险集规模 n 的条件下建立理论基准，使各类方差分量的机制来源获得解析透明的对照参照系；第 3.7 节进一步给出仅报告数据可见时的条件预测方差分解，并说明单代基准不能直接移用。

2.2 两种不同的估计目标

在推导方差前，必须严格区分两类性质迥异的估计目标：

- **目标 A (当期传播参数)：**估计给定当期环境条件下的传播参数 R_t 。目标是测量当期环境（包含当周气象、人群接触模式等共同扰动）所决定的个体期望继发感染水平。注意：该参数不同于最终实现的感染比例 I_t/n ，后者还叠加了个体分支过程的抽样随机性。
- **目标 B (跨期基础水平)：**估计消除单周共同随机扰动后的潜在基础增长趋势 $\bar{R}$ 。

在单期基准设计中，给定风险集规模 n 后，假定当期环境满足条件矩设定：

$$\mathbb{E}[R_t | n] = \bar{R}, \quad \text{Var}(R_t | n) = v_R > 0. \quad (3)$$

这一条件可由固定试验设计的 n ，或 R_t 与 n 相互独立作为充分条件予以保证。

2.3 预测信息集

针对预测问题，其表现依赖于当前可用的信息集。本文严格区分两种信息集：

- **全历史信息集 $\mathcal{F}_t^I$** ： $\mathcal{F}_t^I = \sigma(I_1, \dots, I_t, C_1, \dots, C_t)$ 。在此理想信息集下，截至第 t 期的历史真实感染完全可知，未来的感染压力 Λ_{t+1} 是已确定的历史量。
- **仅报告序列信息集 $\mathcal{F}_t^C$** ： $\mathcal{F}_t^C = \sigma(C_1, C_2, \dots, C_t)$ 。这是现实监测中唯一可直接获取的信息，满足 $\mathcal{F}_t^C \subset \mathcal{F}_t^I$ 。由于二项漏报的存在， $I_1, \dots, I_t$ 未被完全观测，下一周的潜在感染压力 Λ_{t+1} 本身具有不确定性，成为随机变量。

3 理论结果

3.1 当期传播参数、Fisher 信息与条件方差

命题 1 (当期传播参数的条件似然、Fisher 信息与方差)。在个体继发感染条件独立且服从负二项模型 (1)、二项报告率 ρ 固定的基准条件下，当真实风险集 n 与报告率 ρ 已知时：

(i) 报告病例数 C_t 在给定 (n, R_t) 下的边缘分布严格服从负二项分布：

$$C_t | n, R_t \sim \text{NB}(\text{均值} = \rho n R_t, \text{形状参数} = nk); \quad (4)$$

(ii) 矩估计量 $\hat{R}_t = \frac{C_t}{\rho n}$ 恰为该条件似然模型下 R_t 的极大似然估计量 (MLE)；当观测值 $C_t = 0$ 时， $\hat{R}_t = 0$ 位于非负参数空间的边界；

(iii) 在内部参数点 $R_t \in (0, \infty)$ 上，该模型关于 R_t 的 Fisher 信息量为：

$$\mathcal{I}(R_t | n) = \frac{n}{\frac{R_t}{\rho} + \frac{R_t^2}{k}}; \quad (5)$$

(iv) 在内部参数空间 $R_t \in (0, \infty)$ 上，估计量 $\hat{R}_t$ 的条件方差严格达到 Cramér–Rao 下界：

$$\text{Var}\left(\frac{C_t}{\rho n} \middle| n, R_t\right) = \mathcal{I}(R_t | n)^{-1} = \frac{R_t}{\rho n} + \frac{R_t^2}{kn}. \quad (6)$$

解释：条件测量方差式 (6) 由两项构成：第一项 $\frac{R_t}{\rho n}$ 整合了微观 Poisson 计数随机性与二项报告抽稀噪声；第二项 $\frac{R_t^2}{kn}$ 则源自宿主超级传播导致的个体异质性离散。由于两项均反比于样本规模 n ，当期望报告病例数 $m = \rho n \rightarrow \infty$ 时，对瞬态参数 R_t 的推断完全服从经典大数定律，测量方差单调收敛于零（完整 PGF 复合与 Fisher 信息推导见附录 A.1）。

当个体超传播参数 $k \rightarrow \infty$ (个体繁殖退化为经典泊松分布) 时，模型退化为泊松情形，Fisher 信息量为 $\mathcal{I}(R_t | n) = \frac{\rho n}{R_t}$ ，与泊松更新过程中的标度律 [17] 一致；而在现实存在超传播（有限 k ）时，分母出现的 R_t^2/k 项反映超传播带来的信息损失。下节进一步展示，当推断目标由当期瞬态参数 R_t 切换为跨期基准 $\bar{R}$ 时，方差结构出现明显分化。

3.2 跨期基础水平的单期边际方差

命题 2 (跨期基础水平的单期边际方差). 在条件矩假设 (3) 下, 若使用单期估计量 $\frac{C_t}{\rho n}$ 估计跨期基础水平 $\bar{R}$, 其给定风险集 n 的条件边际方差为:

$$\text{Var}\left(\frac{C_t}{\rho n} \mid n\right) = v_R + \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn}. \quad (7)$$

解释: 全方差分解显示, 两个估计目标对应不同的方差结构。单期估计量 $\frac{C_t}{\rho n}$ 包含不可消除的跨期环境随机性 v_R 。当样本规模 $m \ll m_\times$ 时, 误差由微观抽样与个体超传播主导, 扩大病例数收益显著; 而当 $m \gg m_\times$ 时, 方差受制于环境底板 v_R , 单期规模扩张的边际收益趋近于零 (代数推导见附录 A.2)。

式 (7) 给出的 $v_R + A/m$ 方差结构, 与生态动力学中人口统计随机性和环境随机性的区分一致 [20, 21]: 前项 v_R 对应无法随横截面聚合消除的环境随机性底板, 与传染病时序动力学中由外部震荡诱发的宏观扰动相符 [22]; 后项 A/m 则对应随监测规模 $m = \rho n$ 按 $1/m$ 代数衰减的微观抽样与个体异质方差。

3.3 方差占比交叉点 $m_\times$

令 $m = \rho n$ 为上一代真实风险集对应的期望被报告人数 (当期新发报告数的条件期望为 $\rho n R_t$, 两者在 R_t 波动下不等; 图注与政策讨论中的期望报告病例数均取本定义)。式 (7) 可重写为 $v_R + A/m$, 其中

$$A = \bar{R} + \frac{\rho(\bar{R}^2 + v_R)}{k}. \quad (8)$$

本文称 A/m 为病例规模相关方差项。

定义 1 (方差占比交叉点). 当 $v_R > 0$ 时, 在基础水平单期估计方差式 (7) 内部, 病例规模相关方差项 A/m 与共同环境方差项 v_R 相等的期望报告病例规模定义为方差占比交叉点:

$$m_\times \triangleq \frac{A}{v_R} = \frac{\bar{R} + \rho(\bar{R}^2 + v_R)/k}{v_R}. \quad (9)$$

经济学与监测含义: $m_\times$ 的解释是在给定 $(\rho, k, \bar{R}, v_R)$ 下, 沿扩大 n 方向时两类方差相等的规模。在 $m = m_\times$ 处, 总方差中两项各占 50%。导数 $\frac{dV}{dm} = -\frac{A}{m^2}$ 在 $m_\times$ 处平滑连续, 不存在突变。当 $m > m_\times$ 时, 环境方差占主导, 增加病例数仍能降低方差, 但仅能作用于占比逐渐减小的 A/m 项。

3.4 监测杠杆的非对称性: 样本基数 n 与报告率 ρ 的精确拆解

在公共卫生监测实践中, 增加报告病例数 $m = \rho n$ 存在两条截然不同的政策路径: 其一是扩大监测捕获基数 n (如扩大哨点覆盖范围、汇总跨区域感染者); 其二是提高报告率 ρ (如加强密切接触者筛查、降低就医检测门槛)。本文将式 (7) 明确拆解为关于 (n, ρ) 的二元函数:

$$V(n, \rho) = v_R + \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn}. \quad (10)$$




图 1: 理论渐近方差、环境随机性地板与边际收益衰减的蒙特卡洛验证。(a) 瞬时再生数 R_t 条件测量方差式 (6) (蓝) 与跨期水平 $\bar{R}$ 方差式 (7) (红) 随期望报告规模 $m = \rho n$ 的双对数衰减曲线。瞬时方差严格趋零, 而跨期方差平稳收敛至环境随机性地板 $v_R = 0.04$ 。(b) 经验仿真方差与理论闭式解析解之比在全部参数网格下处于 0.988–1.017 之间, 验证了有限样本下 Cramér–Rao 下界的代数紧致性。(c) 误差预算动态演变: 在收益拐点 $m_x = 53.1$ 处, 规模相关项与环境随机性恰好各占 50%, 展现了误差主导机制的平滑交接。模拟基于 50,000 次独立重复试验, 参数基准设定为 $\bar{R} = 1.15, v_R = 0.04, k = 0.35, \rho = 0.25$ 。

为彻底理清报告率 ρ 的作用机制, 将第二项恒等拆解为:

$$\frac{\bar{R}}{\rho n} = \frac{\bar{R}}{n} + \frac{(1-\rho)\bar{R}}{\rho n}. \quad (11)$$

其中第一项 $\frac{\bar{R}}{n}$ 代表完全报告时固有的微观计数随机性, 第二项 $\frac{(1-\rho)\bar{R}}{\rho n}$ 代表由于不完全检测引起的二项抽稀方差。

命题 3 (监测杠杆的非对称性与超传播方差下界). 在单期观测设计下, 扩大基数 n 与提高报告率 ρ 对估计方差的削减效应存在本质非对称性:

- (i) **报告率杠杆的饱和下界:** 给定任意有限风险集规模 $n < \infty$, 当报告率趋于理想极限 ($\rho \rightarrow 1$, 即完全无漏报监测) 时, 漏报额外抽稀方差项 $\frac{(1-\rho)\bar{R}}{\rho n} \rightarrow 0$, 但估计方差存在严格大于环境地板的固有以下界:

$$\lim_{\rho \rightarrow 1} V(n, \rho) = v_R + \frac{\bar{R}}{n} + \frac{\bar{R}^2 + v_R}{kn} > v_R. \quad (12)$$

提高报告率消除的是漏报额外引入的抽稀方差, 无法消除完全报告时依然存在的计数波动 $\frac{\bar{R}}{n}$, 更无法消除由个体超传播 (k) 引起的内在子代抽样随机性 $\frac{\bar{R}^2 + v_R}{kn}$;

- (ii) **样本基数杠杆的全域收敛性:** 无论报告率 $\rho \in (0, 1]$ 处于何种水平, 只要扩大真实风险集规模至极限 ($n \rightarrow \infty$), 两项病例规模相关方差均严格收敛于零:

$$\lim_{n \rightarrow \infty} V(n, \rho) = v_R. \quad (13)$$

机制直觉: 提高报告率 ρ 仅消除由于漏报产生的纯二项抽稀方差, 但无法触及完全报告时固有的微观计数随机性与个体超传播离散; 唯有通过扩大哨点或跨区域聚合来扩大真实感染基数 n , 才能使各项条件方差同时衰减 (极限定理详见附录 A.3)。

命题 3 从动力学层面揭示了监测杠杆的非对称效应：在小风险集且个体传播高度离散时，单纯提高报告率无法替代扩大感染基数以压减方差。在公共卫生实践中，扩大捕获基数 n 与提升报告率 ρ 的边际实施成本和时间延迟各不相同，该命题为权衡两类监测路径的边际投入提供了明确的数理判据。

3.5 理想设计下的监测维度权衡：单期规模 vs 跨期跨度

进一步探讨监测资源分配的理论边界。考虑如下理想化重复采样设计：设设计者在 T 个观测期内设定相同的每期真实风险集规模 $n_T = B/(\rho T)$ ，记为设计方案 $D_T = (T, n_T)$ ；跨期基础水平 $\bar{R}$ 、报告率 ρ 、个体离散参数 k 与环境方差 v_R 保持不变。给定完整环境扰动序列后，各期继发分支与报告抽样过程条件独立，且条件均值为零。

基于设计 D_T 的 T 期观测数据，估计跨期基础水平 $\bar{R}$ 的样本均值估计量定义为：

$$\bar{\hat{R}}_T \triangleq \frac{1}{T} \sum_{t=1}^T \hat{R}_t = \frac{1}{T} \sum_{t=1}^T \frac{C_t}{\rho n_T}. \quad (14)$$

命题 4 (预算约束下的监测设计权衡与可行性集合). 在上述理想化重复采样设计下，若总监测输入规模（各期期望被报告风险集人数之和）受限为 $B = T \cdot m$ （其中 $m = \rho n_T$ 为每期上一代风险集对应的期望被报告人数，见第 3.3 节）：

(i) 若各期环境扰动跨期条件独立，在设计 D_T 下平均估计量的方差为：

$$\text{Var}(\bar{\hat{R}}_T | n_T) = \frac{v_R}{T} + \frac{A}{B}, \quad (15)$$

其中 $A = \bar{R} + \rho(\bar{R}^2 + v_R)/k$ 。当总预算 B 固定时，比较不同设计 D_T ，增加观测期数 T （相应减少每期样本 $m = B/T$ ）严格单调降低估计方差；

(ii) 若各期环境扰动存在一阶自回归自相关 $\text{Cov}(R_t, R_{t+s} | n_T) = v_R r^{|s|}$ ($0 \leq r < 1$)，则有限期数 T 下的精确方差为：

$$\text{Var}(\bar{\hat{R}}_T | n_T) = \frac{v_R}{T} \left[\frac{1+r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2} \right] + \frac{A}{B}, \quad (16)$$

在大期数极限 $T \gg 1$ 下，其渐近形式可表示为有效独立期数近似：

$$\text{Var}(\bar{\hat{R}}_T | n_T) \approx \frac{v_R}{T_{\text{eff}}(T, r)} + \frac{A}{B}, \quad T_{\text{eff}}(T, r) \triangleq T \frac{1-r}{1+r}; \quad (17)$$

(iii) 离散可行设计集合：当要求各期风险集相同且为正整数 ($n_T \in \mathbb{N}_+$)，并精确用尽总预算 B 时，设计者仅能在如下离散可行集合中比较期数：

$$\mathcal{T}(B, \rho) \triangleq \left\{ T \in \mathbb{N}_+ : \frac{B}{\rho T} \in \mathbb{N}_+ \right\}. \quad (18)$$

若 $B/\rho \in \mathbb{N}_+$ ，可行期数为其正整数因子集合；不等式 $T \leq \lfloor B/\rho \rfloor$ 仅是属于该集合的必要条件而非充分条件。

机制直觉：在总监测输入规模预算 $B = T \cdot m$ 约束下，样本方差项 A/B 恒定不变，唯有拉长独立观测期数 T 才能以 $O(1/T)$ 的速率压减跨期环境方差；当存在跨期正自相关时，有效独立期数被压缩为 T_{eff} ，进一步强化了多期监测的时间分配价值（完整 AR(1) 双重求和展开见附录 A.4）。

式 (15) 表明，在固定总输入规模预算 B 下，抽样方差项 A/B 恒定不变，唯有在可行集合 $\mathcal{T}(B, \rho)$ 中增加独立观测期数 T ，方能以 $O(1/T)$ 的速率削减共同环境方差 v_R 。而在真实疫情时序中普遍存在的自相关传播依赖，则通过式 (16) 的有效观测期 T_{eff} 展现出对监测时间分配的紧致修正。

推论 1 (成本与预算约束下的最优监测规模). 设监测系统在每个观测期存在固定的系统运转与维持成本 $c_0 > 0$ ，每捕获上报一个病例的边际成本为 $c_1 > 0$ （若按所覆盖的目标人群计算人均监测成本 c'_1 ，则对应 $c_1 = c'_1/\rho$ ）。在总成本预算 $B = T(c_0 + c_1 m)$ 约束下，假设设计者沿扩大基数 n 的方向（即固定报告率 ρ ，变动风险集 n ）寻求连续近似期数 $T \geq 1$ 与单期期望报告规模 m 的最优组合以最小化跨期估计方差 $\text{Var}(\widehat{R}_T) = \frac{v_R}{T} + \frac{A}{Tm}$ 。为保证期数 $T \geq 1$ 的可行性，要求单期规模满足可行上界 $m \leq (B - c_0)/c_1$ 。代入 $T = \frac{B}{c_0 + c_1 m}$ ，方差目标函数正比于 $v_R(c_0 + c_1 m) \left(1 + \frac{m_\times}{m}\right)$ 。对其关于 m 求一阶导并令其为零，由于二阶导数 $\frac{2c_0 A}{m^3} > 0$ 恒正，在满足可行边界条件下，唯一内部最优单期规模由下式给出：

$$m^* = \sqrt{\frac{c_0}{c_1} \cdot \frac{A}{v_R}} = \sqrt{\frac{c_0}{c_1} m_\times}. \quad (19)$$

注意：若由内部一阶条件求出的规模超出可行上界（即 $\sqrt{\frac{c_0}{c_1} m_\times} > \frac{B - c_0}{c_1}$ ），则由凸函数的单调性，最优配置取可行域边界角点解 $m^* = \frac{B - c_0}{c_1}$ （对应最低期数 $T = 1$ ）。命题 4 中无固定成本的纯总人数预算 $B = Tm$ 恰对应 $c_0 = 0$ 的特例，此时 $m^* \rightarrow 0$ ，即若无单期固定维持开销，资源配置应极端倾向于拉长期数 T ；推论 1 则刻画了存在固定周期开销时的现实权衡。若环境扰动在固定观测周期长度下存在一阶自回归自相关 $\text{Cov}(R_t, R_{t+s}) = v_R r^{|s|}$ ($r > 0$)，大期数极限下有效环境方差由 v_R 增大为 $v_{\text{eff}} \approx v_R \frac{1+r}{1-r}$ ，使得环境随机性相较抽样误差更为棘手，最优单期规模将相应调整为 $m_{\text{AR}}^* \approx \sqrt{\frac{c_0}{c_1} m_\times \frac{1-r}{1+r}} < m^*$ ，表明强自相关环境下应将更多预算向拉长观测期数 T 倾斜。

在数理统计层面，推论 1 中的方差与总成本结构，在数学形式上与经典两阶段抽样（Two-stage Sampling）的费用分配模型 [36] 形成了深刻对偶：时间观测期数 T 对应初级抽样单元数，单期期望捕获规模 m 对应次级样本量。当把一阶自回归环境波动展开后，最优单期规模 m^* 与参数 (v_R, A) 的依赖关系完全通过收益拐点 $m_\times$ 降维表征——在数值上， m^* 恰为成本比与收益拐点的几何平均值。以参数空间唯象情景为例：若固定边际成本比取 $c_0/c_1 = 10$ ，对应最优配置规模约为 $m^* \approx 14.6 \sim 22.2$ ；若 $c_0/c_1 = 100$ ，则对应 $m^* \approx 46.1 \sim 70.2$ 。

3.6 当期超临界增长判定检验与离散检出功效

利用式 (4) 的精确负二项条件分布，可直接建立基准模型下判定当期超临界增长 ($R_t > 1$) 的统计检验。考虑单侧假设检验问题：

$$H_0 : R_t \leq 1 \quad \text{对} \quad H_1 : R_t > 1. \quad (20)$$

命题 5 (当期超临界增长判定检验与精确离散功效). 在已知 (n, ρ, k) 的基准模型下:

- (i) 负二项分布族关于充分统计量 C_t 具有单调似然比 (Monotone Likelihood Ratio, MLR) 性质; 采用拒绝域 $\{C_t \geq c_\alpha\}$ 的非随机化上尾检验, 在复合原假设 $H_0: R_t \leq 1$ 下将第一类错误率严格控制在 α 以内: 由 MLR, 尾部概率 $\Pr_{R_t}(C_t \geq c)$ 关于 R_t 单调不减, 故 $\sup_{R_t \leq 1} \Pr_{R_t}(C_t \geq c_\alpha) = \Pr_{R_t=1}(C_t \geq c_\alpha)$, 即水平控制在边界点 $R_t = 1$ 处取上确界, 只需在该点校准即可。离散临界值 $c_\alpha \in \mathbb{N}$ 取使边界处超额拒绝概率受控的最小整数:

$$c_\alpha = \min \left\{ c \in \mathbb{N} : \Pr_{R_t=1}(C_t \geq c) \leq \alpha \right\}; \quad (21)$$

- (ii) 对于任意给定的备择增长强度 $R_t = 1 + \delta$ ($\delta > 0$), 该非随机化检验的理论检出功效由下式精确给出:

$$\pi(n, \delta) \triangleq \Pr_{R_t=1+\delta}(C_t \geq c_\alpha) = 1 - F_{\text{NB}}\left(c_\alpha - 1; nk, \frac{k}{k + \rho(1 + \delta)}\right), \quad (22)$$

其中 $F_{\text{NB}}(x; r, p) = \sum_{j=0}^{\lfloor x \rfloor} \frac{\Gamma(r)}{j! \Gamma(r-j)} p^j (1-p)^{r-j}$ 为负二项累积分布函数。

机制直觉: 负二项族关于报告计数 C_t 的单调似然比性质, 保证了单边拒绝域在复合原假设下的严格水平控制。由于离散临界值的阶梯状跳跃, 有限样本下的统计功效呈现出特有的锯齿状波动, 表明在极小计数阶段判断疫情超临界增长必须依据离散非随机化临界值, 常规正态逼近会造成显著的检验扭曲 (单调似然比证明见附录 A.5)。

由于报告计数的离散性, 非随机化检验在有限样本下实际水平严格小于名义水平 α (呈现保守性)。命题 5 判定的是当期传播参数是否超临界 ($R_t > 1$); 而在多期时间序列中, 推断系统状态由亚临界向超临界的转变过程则需进一步结合时变再生数轨迹的反弹识别方法 [18]。

3.7 预测误差的条件分解: 仅报告数据可见时的严格形式

在现实流行病学监测中, 真实感染历史不可见, 决策者仅能依据报告历史 $\mathcal{F}_t^C$ 进行前瞻推断。引入更新过程描述跨周感染压力:

$$\Lambda_{t+1} = \sum_{s=1}^S w_s I_{t+1-s}, \quad \sum_{s=1}^S w_s = 1. \quad (23)$$

假设在给定潜变量与报告历史下满足:

$$\mathbb{E}[I_{t+1} \mid \Lambda_{t+1}, R_{t+1}, \mathcal{F}_t^C] = \Lambda_{t+1} R_{t+1}. \quad (24)$$

并且, 在给定当期真实感染数 I_{t+1} 条件下, 报告抽样过程 $C_{t+1} \mid I_{t+1} \sim \text{Binomial}(I_{t+1}, \rho)$ 条件独立于既往报告历史 $\mathcal{F}_t^C$ 。

命题 6 (真实感染与报告病例的单步预测方差分解). 基于截至第 t 期的报告信息集 $\mathcal{F}_t^C$, 未来真实感染数 I_{t+1} 的预测方差严格满足全方差恒等式:

$$\text{Var}(I_{t+1} \mid \mathcal{F}_t^C) = \text{Var}(\Lambda_{t+1} R_{t+1} \mid \mathcal{F}_t^C) + \mathbb{E} \left[\text{Var}(I_{t+1} \mid \Lambda_{t+1}, R_{t+1}, \mathcal{F}_t^C) \mid \mathcal{F}_t^C \right]. \quad (25)$$

在上述二项观测假定下, 未来报告病例数 C_{t+1} 的预测方差严格由下式给出:

$$\text{Var}(C_{t+1} \mid \mathcal{F}_t^C) = \rho(1 - \rho) \mathbb{E}[I_{t+1} \mid \mathcal{F}_t^C] + \rho^2 \text{Var}(I_{t+1} \mid \mathcal{F}_t^C). \quad (26)$$

机制直觉：当真实感染不可观测时，二项抽稀观测噪声与底层感染状态空间的不确定性在预测方差中代数正交叠加，表明单代静态公式不能直接外推至时间序列更新过程（详细条件方差展开见附录 A.6）。

4 数值模拟评估

为检验上述解析推导的有限样本表现及其对时间序列预测的参照价值，本节设计两组模拟实验：其一评估命题 5 导出的增长判定检验有限样本功效与正态近似失效；其二在时间序列更新过程中清晰剥离事后代理增长统计量与事前单步病例预测的误差演变机制，评估其如何向参照曲线收敛。

4.1 当期超临界增长判定的有限样本检出功效与正态近似失效

在传染病预警实践中，分析人员常使用基于渐近正态近似的 Wald 检验 $Z = (\hat{R}_t - 1)/\sqrt{V_0}$ 来判定当期传播是否超临界 ($R_t > 1$)，其中零假设下的理论方差为 $V_0 = \frac{1}{\rho n} + \frac{1}{kn}$ ，拒绝域为 $\{Z \geq z_{1-\alpha}\}$ 。命题 5 指出，报告病例遵循离散负二项分布，因此正态连续近似在低病例规模或高超传播环境下可能出现严重扭曲。

本文在名义水平 $\alpha = 0.05$ 、固定报告率 $\rho = 0.25$ 下，针对不同超传播参数 $k \in \{0.1, 0.35, 1.0\}$ 与期望报告规模 $m \in [5, 600]$ 进行 30,000 次蒙特卡洛抽样检验，结果如图 2 所示。




图 2: 早期暴发检验尺度效应、功效边界与超传播惩罚。(a) 一类错误率控制：渐近正态 Wald 检验（虚线）在低病例规模 ($m < 40$) 且严重超传播 ($k = 0.1$) 时经验一类错误率最高达 8.1% ($m = 5$, 30,000 次模拟)，系统性高于名义水平；离散精确负二项检验（实线）在全样本网格上严格控制错误率低于 0.05。(b) 检出功效曲线随备择强度 $\delta = R_t - 1$ 的响应：在 $k = 0.35$ 时，达到 80% 功效所需的期望报告规模由微弱暴发 $\delta = 0.15$ 的 $m = 517.8$ ($n = 2071$) 急剧下降至 $\delta = 0.30$ 的 $m = 142.0$ ($n = 568$) 与 $\delta = 0.50$ 的 $m = 57.2$ ($n = 229$)。(c) 个体超传播离散度 k 的杠杆惩罚：在 $\delta = 0.25$ 增长强度下，达到 80% 检出功效所需的期望病例数从低异质性 $k = 1.0$ 的 $m = 142.0$ ($n = 568$) 急剧上升至严重超传播 $k = 0.1$ 的 $m = 415.0$ ($n = 1660$)，规模需求放大了近 3 倍。标称显著性水平 $\alpha = 0.05$ ，基准报告率 $\rho = 0.25$ 。

模拟结果展现了三项重要发现：

1. 第一类错误率失真：如图 2(a) 所示，渐近 Wald 检验在低病例规模且超传播 ($k \leq 0.35$) 时失效 ($k = 1.0$ 的最小规模点经验水平 0.0495，未过检)。在网格内最小规模 $m = 5$ 、

$k = 0.1$ 处, Wald 检验的经验一类错误率达到最高的 8.1% (30,000 次模拟), 约为名义水平 0.05 的 1.6 倍, 且全低规模段 ($m < 40$) 系统性过检, 极易引发虚假超临界报警; 相比之下, 命题 5 导出的离散精确临界值 c_α 在所有规模下均保守且严格受控于 0.05 以下。

2. 检出功效对备择强度的非线性响应: 如图 2(b) 所示, 在固定 $k = 0.35$ 时, 达到 80% 可靠功效所需的期望报告病例数随信号强度急剧下降: 微弱增长 ($\delta = 0.15$) 需要 $m = 517.8$ 例; 中度增长 ($\delta = 0.30$) 降至 $m = 142.0$ 例; 显著增长 ($\delta = 0.50$) 仅需 $m = 57.2$ 例即可可靠检出。
3. **超传播对样本需求的放大机制:** 如图 2(c) 所示, 在相同增长信号 ($\delta = 0.25$) 下, 个体异质性越强 (k 越小), 曲线右移越显著。从低异质性 $k = 1.0$ 到强超传播 $k = 0.1$, m 需求放大了近 3 倍。

4.2 时间序列更新过程: 事后增长统计量与事前单步病例预测

在时间序列动态更新过程中, 记预测时已知的历史报告加权和为:

$$D_t \triangleq \sum_{s=1}^S w_s C_{t+1-s}. \quad (27)$$

当历史连续多周报告为零时, 分母 $D_t = 0$ 导致比值无定义。在统计评估中, 本文明确规定评估仅在具备活跃历史信息的周 ($D_t > 0$) 上进行, **不做任何其他数据依赖的剔除**。实测表明, 在每组 150 条轨迹、每条 26 个预测起点 (共 3,900 个评价点) 中: 在 $m = 6$ 组中仅剔除 3 周 (发生率 0.077%, 有效周数 3,897); 在 $m = 12$ 组中仅剔除 1 周 (发生率 0.026%, 有效周数 3,899); 在 $m \geq 25$ 的所有规模组中剔除数为 0 (有效周数均为 3,900)。另需说明: 仿真中当期真实感染数被强制下界 $I_t \geq 1$ (代码中的 $\max(1, I)$ 截断), 该下界仅在极小规模的低概率周生效, 防止更新过程因零感染而永久熄灭; 它对小规模端的误差有轻微向下偏置。需要特别指明: 图 3 横轴的 m 表示每条轨迹的初始期望报告规模; 由于在 $\bar{R} = 1.15$ 下后续规模随传播过程动态变化, 理论曲线仅作按初始规模排列的对比参照。

在此活跃周子集上, 严格区分两个评价对象:

- (1) **事后代理增长统计量误差:** 在 $t + 1$ 期报告 C_{t+1} 实际观测后, 事后计算比值 $G_{t+1} \triangleq C_{t+1}/D_t$ 。其相对基础水平的均方误差定义为 $\mathbb{E}[(G_{t+1} - \bar{R})^2 | D_t > 0]$ 。
- (2) **事前单步病例预测相对均方误差 (Ex-ante Forecasting RelMSE):** 在 t 时刻, 决策者仅依据截至 t 期的报告历史, 对下一期报告病例数作出预测: $\hat{C}_{t+1|t} \triangleq \bar{R}D_t$ 。当 C_{t+1} 实际出现后, 计算相对均方预测误差:

$$\text{RelMSE}(m) \triangleq \mathbb{E} \left[\left(\frac{C_{t+1} - \hat{C}_{t+1|t}}{\hat{C}_{t+1|t}} \right)^2 \middle| D_t > 0 \right] = \frac{1}{\bar{R}^2} \mathbb{E} [(G_{t+1} - \bar{R})^2 | D_t > 0]. \quad (28)$$

式 (28) 表明: 在相同的活跃周样本上, 事前病例预测相对误差与事后增长统计量误差严格相差常数因子 $1/\bar{R}^2$ 。因此, 二者在每一规模组的相对翻倍削减率中常数因子完全相消, 经验降幅严格同一。

然而，这一代数等价性并不证明它们在理论上精确等于单代理想基准。设 $\mu_{t+1|t} \triangleq \mathbb{E}[C_{t+1} | \mathcal{F}_t^C]$ 与 $\sigma_{t+1|t}^2 \triangleq \text{Var}(C_{t+1} | \mathcal{F}_t^C)$ ，在活跃周上有严格条件分解：

$$\mathbb{E}[(G_{t+1} - \bar{R})^2 | D_t > 0] = \mathbb{E}\left[\frac{\sigma_{t+1|t}^2}{D_t^2} + \left(\frac{\mu_{t+1|t}}{D_t} - \bar{R}\right)^2 \middle| D_t > 0\right]. \quad (29)$$

式 (29) 清楚揭示了更新过程较之单代基准所增加的两个关键机制：其一是用报告历史代理真实感染压力导致的预测偏差项 $(\mu_{t+1|t}/D_t - \bar{R})^2$ ；其二是随机分母 D_t 对条件方差的倒数二次方重新加权。

因此，由已知真实风险集单代模型导出的 $V(m) = v_R + A/m$ 以及经缩放的参照曲线 $(v_R + A/m)/\bar{R}^2$ ，仅作为参照基准而非更新过程预测误差的精确定理。二者的渐近环境地板分别为 $v_R = 0.040$ 与 $v_R/\bar{R}^2 = 0.0302$ 。




图 3: 更新过程时序卷积下事后增长统计量与事前单步病例预测误差。(a) 事后代理增长统计量均方误差（黑色散点带 95% 置信区间）与单代已知基准参照曲线 $V(m) = v_R + A/m$ （红实线，其中 $A = 2.1232$, $v_R = 0.04$ ）的对照；(b) 事前单步病例预测相对均方误差（蓝色方块带 95% 置信区间）与缩放参照曲线 $\frac{v_R + A/m}{\bar{R}^2}$ （紫实线）： $m \geq 25$ 段贴合（参照的 0.75–0.98 倍）， $m = 6$ 处为参照的 1.82 倍；(c) 病例规模每翻一倍所带来的相对误差削减百分比：红圈为更新过程经验翻倍降幅（事后统计量与事前预测经验降幅严格同一； $m < 12$ 段经验降幅系统性高于解析式，首点 $m = 6 \rightarrow 12$ 的 73.5% 超出纵轴范围），深蓝实线为单代参照曲线的解析公式 $\frac{1}{2(1+m/m_\times)}$ 。在 $m = 10$ 时，参照翻倍削减为 42.1%；在交叉点 $m_\times = 53.1$ 处为 25.0%；越过交叉点后，在 $m = 200$ 时边际削减迅速衰减至 10.5%。（样本说明：每规模组共 150 条轨迹 $\times$ 26 个预测起点 = 3,900 点； $m = 6$ 组剔除 $D_t = 0$ 者 3 点，有效 3,897 点； $m = 12$ 组剔除 1 点，有效 3,899 点； $m \geq 25$ 各组有效点均为 3,900 点）。

数值实验结果展现了三项关键发现：

1. 事后统计量与参照曲线的对照：如图 3(a) 所示，事后代理增长统计量叠合了式 (29) 中的预测偏差与随机分母波动，其随规模衰减的方向与单代参照曲线 $v_R + A/m$ 一致，但幅度分两段：在中大规模段 ($m \geq 25$) 经验误差平滑趋向环境方差地板 $v_R = 0.040$ ，与参照曲线贴合；在极小规模段 ($m = 6$)，完整活跃周样本（不做任何数据依赖剔除）的经验均方误差为 0.718，明显高于单代参照值 0.394（相对损失口径为 0.543 对 0.298）——更新过程的重尾偏差在小规模端被随机分母二次放大，经验误差并未贴合参照曲线，这是单代基准在极小规模不适用的直接证据，而非噪声。 $m = 12$ 时两者已接近 (0.190 对 0.217)。

2. **事前预测相对误差的严格对应：**如图 3(b) 所示，在 t 时刻给出的病例预测相对均方误差（由代数恒等式与第 1 项只差常数 $1/\bar{R}^2$ ）在 $m \geq 25$ 段为缩放参照曲线 $\frac{v_R + A/m}{\bar{R}^2}$ 的 0.75–0.98 倍并渐近收敛于 $v_R/\bar{R}^2 = 0.0302$ ； $m = 6$ 处为参照的 1.82 倍（0.543 对 0.298），与第 1 项的小规模端偏离同源。
3. **边际削减收益的定量衰减规律：**针对解析参照曲线 $V(m) = v_R + A/m$ ，病例规模翻倍时的相对方差下降比例严格由下式给出：

$$\frac{V(m) - V(2m)}{V(m)} = \frac{1}{2(1 + m/m_\times)}. \quad (30)$$

如图 3(c) 所示，在 $m_\times \approx 53.1$ 下，当 $m = 10$ 时，规模翻倍可降低约 42.1% 的解析方差；越过交叉点 $m_\times = 53.1$ （此处理论边际收益为 25.0%）后，当 $m = 200$ 时，病例规模再翻倍仅能带来约 10.5% 的方差削减。这印证了本文的核心直觉：**越过交叉点后，扩大病例捕获依然能边际改善预测，但由于环境扰动占主导，其改善速率急剧放缓。**

4.3 数值实验复现规格与参数说明

为确保所有模拟数值与图表的高度可复现性，本节列明复现规格：

- (a) **软件包与离散分布参数化：**全部算法基于 Python 3.10 与 `scipy.stats` 实现。负二项分布采用标准形式 $NB(r, p)$ ，其中在条件均值 $\mu = \rho n R$ 与离散参数 k 下，参数映射为 $r = nk, p = \frac{k}{k + \rho R}$ 。累积尾概率由生存函数 `stats.nbinom.sf(c - 1, r, p)` 计算。
- (b) **图 2 离散功效与样本量枚举规则：**随机数种子设定为 20260924。对给定 $(k, \rho, \alpha = 0.05)$ ，临界值 c_α 通过整数搜索使零假设生存概率首次不超过 α 。在备择假设 $R_t = 1 + \delta$ 下，自 $n = 1$ 起以步长 1 递增枚举整数 n ，取首次满足功效 $\pi(n, \delta) \geq 0.80$ 的最小整数 n ，并换算为期望报告规模 $m = \rho n$ 。
- (c) **图 3 更新过程仿真参数与分母：**随机数种子设定为 20260925。感染间隔采用 4 周离散核 $w = (0.45, 0.35, 0.15, 0.05)$ ，环境扰动采用 Gamma 分布采样，均值为 $\bar{R} = 1.15$ ，方差为 $v_R = 0.04$ 。每规模组评估 150 条轨迹，时间跨度 $T = 30$ （前 4 周作为启动核，预测评估周为 $t = 4$ 至 29 共 26 周），总评价周数分母为 3,900。

5 实证检验：全美流感住院监测数据（2020–2026）

为对本文提出的理论方差结构、饱和交叉点 $m_\times$ 、报告杠杆冲击以及反证边界提供真实流行病学监测环境下的检验，本节利用全美疾控中心国家医疗保健安全网（CDC NHSN）周度流感住院报告数据开展系统实证。

5.1 数据源、制度分段与数据预处理

数据来自全美各州及华盛顿特区医院向 CDC NHSN 上报的周度实验室确诊新发流感住院人数 [37]（Total Influenza Admissions）及各州周度医院报告覆盖率（字段名 Percent

Hospitals Reporting Influenza Admissions)。该住院指标系全美 CDC FluSight 自 2021–22 赛季起确立的核心基准预测目标（参见 Mathis et al. [31] 针对全美 26 个前瞻预测团队的评估），具备坚实的公共卫生实战代表性。样本时间跨越 2020 年 8 月至 2026 年 9 月，涵盖 50 个州及华盛顿特区共 16,218 个州–周观测（其中 504 个州–周的住院数缺失按 0 例处理：P1 期 468 个、P2 期 36 个；在制度切换期未填报与零住院不能等同，该处理主要影响 P2 期，见第 5.5 节的解读边界）。样本筛选采用单一口径： $D_t \geq 5$ 的活跃周阈值，得 10,303 个州–周有效样本；本文第 5.2–5.6 节的全部主分析、稳健性与滚动核验均基于该口径，不另设覆盖率门槛（避免系统性地剔除低覆盖观测）。在此口径下三个报告制度阶段的医院平均填报覆盖率分别为 91.1%、54.6% 与 91.8%，自愿过渡期的覆盖率断崖式跌落构成本文考察报告率冲击的主要制度变异来源。

报告制度三阶段划分： 该监测系统在样本期内经历了三次具有政策调整特征的制度切换：

- (1) **前过渡高覆盖期（数据起点 2020 年 10 月至 2024 年 4 月 30 日，共 184 个有效周、 $N = 6,009$ ）：**该时段合并了两个制度子段——2020 年 10 月至 2022 年 9 月的大流行早期高强度上报（ $N = 2,627$ ，平均覆盖率 87.8%）与 2022 年 10 月 NHSN 法定强制上报起的法定强制段（ $N = 3,382$ ，平均覆盖率 93.7%），两子段合计平均覆盖率 91.1%（中位数 92.3%）；第 5.5 节的离散度对照将以法定强制段单列报告；
- (2) **第二阶段（自愿过渡期，2024 年 5 月 1 日至 2024 年 10 月 31 日，26 个有效周、 $N = 420$ ）：**强制令随紧急状态解除到期，医院转为自愿填报，各州平均报告覆盖率断崖式跌落至 54.6%（中位数 45.7%）；
- (3) **第三阶段（CMS 新规重制期，2024 年 11 月 1 日起至样本终点 2026 年 9 月初，96 个有效周、 $N = 3,874$ ）：**美国医疗保险与医疗补助服务中心（CMS）将呼吸道传染病数据上报重新作为医保定点医院资质条件，各州报告覆盖率迅速恢复至 91.8%（中位数 93.2%）。

状态空间设定与观测对象界定： 在离散周度时间序列中，取滞后权重向量 $w = (0.65, 0.25, 0.10)$ （滞后 1、2、3 周，平均回溯延迟为 $\sum_{s=1}^3 sw_s = 1.45$ 周，约 10.2 天）构建各州第 t 周的历史有效输入压力：

$$D_{j,t} = \sum_{s=1}^3 w_s C_{j,t+1-s}. \quad (31)$$

这里的 w 为经验滞后暴露权重（平均回溯 10.2 天符合流感临床与填报特征时滞），使 $G_{j,t+1} = C_{j,t+1}/D_{j,t}$ 成为住院增长态势的平滑经验代理变量。对不同滞后规格的完整敏感性分析汇报于表 1：原权重下有效样本 $N = 1,267$ ， $b = 2.2434$ （95% CI [1.5019, 3.0161]）， $m_\times = 22.65$ ；三周等权下 $N = 1,240$ ， $b = 1.9262$ （95% CI [1.0706, 2.8074]）， $m_\times = 12.64$ ；单周滞后下 $N = 1,290$ ， $b = 3.1337$ （95% CI [2.2031, 4.0668]）， $m_\times = 45.96$ 。结果表明，斜率项 b 在所有滞后规格下均稳健显著为正（Bootstrap 95% CI 严格远离零点）；但经验拐点收益拐点对回溯窗口长度存在敏感性（在 12.64 至 45.96 例/周间浮动），提示经验拐点应作为系统相关的量级参照。当 $D_{j,t} \geq 5$ 时进入有效推断样本集（理由见第 5.1 节）。

表 1: 不同滞后暴露权重设定下流行初期仿射模型的敏感性检验

加权设定方案	有效样本 N	阶段均值 $\bar{R}_{\text{early}}$	斜率 b	州聚类 95% CI	截距 a	经验收益拐点 $m_{\times}$
原复合权重 (0.65, 0.25, 0.10)	1267	1.6706	2.2434	[1.5019, 3.0161]	0.0991	22.65
三周等权平移 (1/3, 1/3, 1/3)	1240	1.9929	1.9262	[1.0706, 2.8074]	0.1524	12.64
单周直接滞后 (1.0, 0.0, 0.0)	1290	1.4802	3.1337	[2.2031, 4.0668]	0.0682	45.96

注: 各规格均在对应滞后权重构造的 $D_{j,t} \geq 5$ 下重新筛选有效样本并执行 FGLS 拟合, CI 由 1,500 次州聚类 Bootstrap 给出。

阶段条件化预测基准与识别限定: 本节在评估预测误差时,采用阶段条件化基准设定 $\hat{C}_{j,t+1|t} \triangleq \bar{R}_{\text{phase}} D_{j,t}$, 评分口径取相对尺度均方误差——相对误差评分在传染病预测评估中具有避免大流行周主导加权的光照尺度优势 [34]——在控制跨期趋势参数变化的同等基准下, 估计病例捕获规模 D_t 与相对预测误差的条件关联。医院维度的填报覆盖率 (比例) 可视为理论中报告率杠杆 ρ 在制度层面的宏观经验代理指标, 2024 年的制度切换由此构成命题 3 的天然对照场景, 其解释边界在第 5.5 节结合季节性子样本进一步校准。

5.2 检验一: 流行初期波段的方差衰减与经验收益放缓平台

按照第 2 节关于基准模型适用边界的定义, 本文在三个流感季节中提取流行初期上升波段 (Early Growth Phase): 2022–2023 季的 10 月 8 日至 11 月 26 日; 2023–2024 季的 10 月 14 日至 12 月 16 日; 2024–2025 季的 11 月 9 日至 1 月 18 日。在这些波段内, 人群对当年毒株的自发防护行为尚未全面激活, 公共卫生干预尚未强力介入, 传播环境相对平稳。此阶段有效样本 ($N = 1267$) 平均增长率为 $\bar{R}_{\text{early}} = 1.6706$ (标准差 0.7116)。本节主分析首先在同等阶段基准 $\bar{R}_{\text{early}}$ 下检验误差随规模的条件衰减形态; 并在第 5.3 节进一步提供逐周滚动的严格事前检验。

表 2 报告了各规模分组下单步相对平方误差的经验统计量。为考虑同州跨周的时间相关性与组内聚类不确定性, 表中同时给出常规 SEM 与按州 (State) 聚类的稳健标准误 (Cluster-robust SE); 本文的区间推断一律以州聚类 95% 置信区间为准。

表 2: 全美流感住院流行初期波段单步预测误差随周捕获规模的分组统计

每周有效规模 D_t	样本数 N	相对均方误差	中位数	普通 SEM	州聚类 SE	州聚类 95% 置信区间
[5, 20)	319	0.3292	0.0969	0.0425	0.0437	[0.2435, 0.4149]
[20, 50)	297	0.1605	0.0596	0.0169	0.0189	[0.1235, 0.1974]
[50, 100)	187	0.1446	0.0483	0.0194	0.0198	[0.1057, 0.1835]
[100, 250)	220	0.1118	0.0545	0.0110	0.0114	[0.0895, 0.1341]
[250, 600)	152	0.1032	0.0460	0.0097	0.0133	[0.0771, 0.1293]
[600, 5000)	92	0.1054	0.0735	0.0109	0.0146	[0.0769, 0.1340]

实证数据呈现出与理论命题 2 高度吻合的边际衰减特征。为使检验贴合理论的函数形式, 本文不做分箱均值的粗略目视比较, 而是按式 (7) 重写为 $v_R + A/m$ 后的形状, 直接对原始观测估计仿射模型:

$$\mathbb{E} \left[\left(\frac{G_{t+1} - \bar{R}_{\text{early}}}{\bar{R}_{\text{early}}} \right)^2 \middle| D_t \right] = a + \frac{b}{D_t}, \quad (32)$$

其中截距 a 代表与规模无关的经验损失底板 (整合了宏观环境随机性 $v_R/\bar{R}^2$ 与未观测感染压力




图 4: 全美流感住院真实数据经验拟合、平稳性失效与监测体制冲击。(a) 全美周度流感住院总人数 (蓝实线, 左轴) 与各州医院平均填报覆盖率 (红虚线, 右轴) 演变, 阴影区域标示 2024 年 5–11 月报告覆盖率骤降的自愿过渡期; (b) 流行初期上升波段中, 单步预测相对均方误差随每周病例捕获规模 D_t 的仿射衰减关系 (蓝圆点为经验均值与 95% CI, 橙方块为中位数), 误差在 $D_t \in [50, 250]$ 区间快速下降后平稳收敛至尺度不变量底板平台 (对应经验损失截距 $a = 0.0991$ 与均值 0.103), 灰色虚线标示经验收益拐点 22.6; (c) 达峰与回落期: 以流行初期估计的平稳基准 $\bar{R}_{\text{early}} = 1.6706$ 预测全部阶段时, 达峰与回落期 (红柱) 的总误差在所有规模组恒定处于 0.292–0.312 区间, 看似不再随 D_t 增大而下降; 但达峰期总体样本的均值偏移项占总损失 88.9% (0.267; 各规模箱占比 59.5%–94.8% 不等), 控制基准偏移后规模相关方差项仍显著为正, 证实失效的是跨期平稳基准假定而非病例规模本身; (d) 报告制度切换下观测增长率的尾部离散度 (对数轴箱线图, 含离群点): 自愿填报期标准差由 0.620 (法定强制子段) 升至 1.823 (扩张 194%), 偏度升至 14.98, 恢复强制后回落至 0.649 与 2.68; 主体分位距基本不变 (图中箱体宽度相近), 扩张集中于右尾离群点。实证基于全美 51 个辖区 CDC NHSN 2020–2026 年 16,218 个州-周有效住院监测观测。

的代理不确定性, 经验值 0.0991 与参数空间隐含值 0.014–0.029 相容); b 为规模相关项; 比值 b/a 对应理论交叉点的经验对应物, 标定了监测规模的经验收益拐点。估计采用一阶可行广义最小二乘 (FGLS, 权重取拟合值平方倒数), 置信区间由 1,500 次按州聚类的 Bootstrap 给出。

主拟合结果与经验收益拐点: 仿射模型估计给出规模相关方差项 $b = 2.2434$, 按州聚类的 bootstrap 95% 置信区间为 $[1.5019, 3.0161]$, 1,500 次重抽样中无一次出现 $b \leq 0$ 。这与式 (7) 中病例规模相关方差项 A/m 的递减形态相容。从极小规模 $[5, 20]$ (平均 $\text{ReLMSE} = 0.3292$) 扩大至 $[20, 50]$ (0.1605), 经验相对均方误差下降了 51.3%; 即使采用州聚类 95% 置信区间, $[5, 20]$ 的下界 (0.2435) 与 $[20, 50]$ 的上界 (0.1974) 仍严格分离。拟合截距给出 $a = 0.0991$ (95% CI $[0.0841, 0.1173]$), 为与规模无关的经验损失截距拟合值, 对应样本内已实现的大规模观测相对误差水平 (依第 6.2 节局限性分析, 其数值同时包含了未观测感染压力的代理不确定性, 不能单独识别为孤立的环境方差); 由 $m_x^{\text{emp}} = b/a$ 得经验收益拐点 22.6 (95% CI $[13.7, 33.7]$) 例/周。十分位组均值拟合给出与基准一致的 22.6; 但剔除损失最大的 1% 观测后交叉点左移至 10.6, 而在各事前滚动规格下位于 $22.5 \sim 42.7$ 区间, 表明该值对尾部处理和窗口设定有敏感性, 应视为量级估计而非点位识别。分箱计算 loss 的方差-均值比可见, $\text{Var}(L)/\mathbb{E}[L]^2$ 从 $[5, 20]$ 箱的 5.32 整体下降至 $[600, 5000]$ 箱的 0.99, 超额离散随规模扩大而收缩, 为 FGLS 采用 $1/\hat{\mu}^2$ 权重提供了依据。为检验基准估计不确定性与跨州同周时间相关性的潜在影响, 本文分别执行了两种单向聚类敏感性重抽: 其一为在 cluster bootstrap 每次重抽中对样本均值执行内生重估计 (Endogenous re-estimation), 所得 b 的 95% CI 为 $[1.5170, 2.9807]$; 其二为按观测周进行时间维度聚类重抽以检验同周外生冲击, 所得 b 的 95% CI 为 $[1.4728, 3.1191]$ 。在两种单向聚类敏感性分析下, 置信区间下界均稳健大于 1.47 且 1,500 次重抽无一为负, 有力支持了规模效应为正的基本结论。

滞后工具变量规格敏感性检验: 针对同期测度潜在的内生扰动, 本文进一步引入滞后 3–5 周规模 D_t^{iv} 进行两阶段最小二乘 (2SLS) 规格对照。在全初期波段汇集样本 ($N = 1,051$) 中, 以全阶段均值 $\bar{R}_{\text{early}} = 1.6706$ 归一化时, 第二阶段 b 为 2.5305 ($a = 0.0812$), 对应 OLS 为 1.3525; 若以子样本自身均值 (1.6266) 归一化则给出 $b = 2.8501$ ($a = 0.0807$, 对应 OLS 为 1.4581)。第一阶段未聚类 F 统计量为 1147.1 (按州聚类稳健 $F = 312.9$)。在各流感季初期波段内部独立运行中: 2022–23 季 ($N = 273$) 稳健 $F = 94.5$, $b_{\text{iv}} = 3.2787$ (OLS: 1.8865); 2023–24 季 ($N = 358$) 稳健 $F = 119.4$, $b_{\text{iv}} = 2.1867$ (OLS: 1.6760); 2024–25 季 ($N = 420$) 稳健 $F = 76.8$, $b_{\text{iv}} = 3.6131$ (OLS: 1.8295)。在汇集样本中, 差值 ($b_{\text{iv}} - b_{\text{ols}}$) 稳健排除零点 (子样本均值归一化下差值为 1.3921, 95% CI $[0.43, 2.41]$, 单侧 bootstrap 比例 0.0014), 表明在替代性滞后测度下, 规模项为正的形态与显著性依然保持稳健。作为参数空间的唯象对照, 设定代表性参数情景: 初期平均 $\bar{R}_{\text{early}} \approx 1.67$ 、超传播取值 $k \in [0.2, 0.5]$ [1]、住院比例数量级 $\rho \in [0.0056, 0.021]$ (基于 Zhou et al. [35] 住院负担与 Tokars et al. [38] 侵袭率折算) 及 $v_R \in [0.04, 0.08]$, 理论导出拐点约 21–49 例 ($m_x \approx 21.3 \sim 49.3$), 经验拐点 $m_x^{\text{emp}} = 22.6$ 在数量级上与之相容。

5.3 竞争基准对照与事前滚动核验

为回应仅评估单一阶段常数基准的局限性, 本文进一步构建了两类具备竞争性的事前预测基线: 其一是基于 Cori et al. [10] 滑动窗口更新过程的时变再生数预测 $\hat{C}_{t+1|t}^{\text{Cori}} = \hat{R}_t^{\text{Cori}} D_t$ (分别

取 1 周、2 周与 3 周滑动窗 τ)；其二是经典时间序列朴素平移基准 $\hat{C}_{t+1|t} = C_t$ 。在流行初期波段上，各基准的事前单步相对预测均方误差见表 3。结果有三点：(1) 全体均值上，2 周窗与 3 周窗 Cori 基线的 RelMSE 分别为 0.2876 与 0.2490，中位数为 0.0658 与 0.0626，性能优于朴素平移基准（均值 0.6367，中位数 0.1732）；(2) 关键在于分规模表现：在所有更新过程基准中，预测误差在 $D_t \leq 100$ 内随每周病例规模快速下降，越过百例量级后趋于平缓（约 0.087–0.098），进入收益放缓的经验底板平台；(3) 特别在大规模段（ $D_t \geq 100$ ），2 周与 3 周 Cori 基线的平均相对均方误差（约 0.087–0.098）甚至略低于常数阶段均值（0.103–0.112），原因在于时变参数能更好适应局部流行波动的拐点；但在小规模段（ $[5, 20)$ ），滑动窗口估计 R_t 自身引入了显著的有限样本小计数估计方差，导致误差高于平稳基准。对 2 周与 3 周 Cori 基线误差进行仿射拟合，分别给出 $b = 6.0637$ ($m_x = 74.7$) 与 $b = 4.9836$ ($m_x = 65.3$)。须指出评分尺度的敏感性：表 3 中基线相对均方误差采用各自预测值 $\hat{C}$ 归一化，该指标直观反映各模型自身的相对波动，但对预测值具有非对称敏感性（倾向于对预测值偏大的模型赋予较低相对惩罚）；若在相同的 1,244 个有效样本上换用以回顾性阶段均值为共同分母的归一化尺度（以消除分母差异并统一可比基准），Cori 2 周窗与朴素平移基线的整体相对均方误差分别收敛为 0.2230 与 0.2738（原自身尺度分别为 0.2876 与 0.6367）。分规模观察显示：在共同样本的小规模段（ $[5, 20)$ ），阶段均值基准（0.3275）显著优于时变更新基准（0.4149）与朴素预测（0.4951），这与有限样本下时变参数估计更不稳定的解释一致；在大规模段（ $[250, 600)$ 与 $[600, 5000)$ ），阶段均值（0.1032、0.1054）与朴素平移（0.1171、0.0642）表现出高度竞争力，反映出大规模下流感住院序列具有极强的短期自相关惯性；在大规模段误差不再呈现单调下降，而是进入基准依赖的平缓区间（约 0.064–0.131），证实规模收益放缓这一基本形态对归一化尺度的稳健性。这表明：无论采用回顾性阶段基准还是事前时变更新过程基准，预测误差均随每周病例规模呈现递减形态并在大规模段趋于平缓，而各基准的误差绝对水平与收益放缓的具体点位随基准构造方式与评价尺度而异。

表 3: 不同预测基准在流行初期波段单步相对均方误差 (RelMSE) 的规模分箱对照

每周有效规模 D_t	样本数 N	阶段均值基准	Cori 2 周窗基线	Cori 3 周窗基线	朴素平移基线
[5, 20)	319	0.3292	0.6576	0.5606	1.2563
[20, 50)	297	0.1605	0.2576	0.2288	0.5528
[50, 100)	187	0.1446	0.2271	0.1680	0.5639
[100, 250)	220	0.1118	0.0903	0.0870	0.3999
[250, 600)	152	0.1032	0.0975	0.0903	0.2356
[600, 5000)	92	0.1054	0.0983	0.0982	0.1360
全体样本均值	1267	0.1813	0.2876	0.2490	0.6367
全体样本中位数	1267	0.0653	0.0658	0.0626	0.1732

注：Cori 2 周窗与 3 周窗基线因局部比值非正分别剔除 23 与 16 个无效点，全体有效样本量分别为 1,244 与 1,251。

事后选定初期波段内的滚动起点核验： 上述主分析属回顾性口径。为核验规模效应结论在事前信息集下是否保持，本文对初期波段（波段本身为事后指定）每个观测 t 改用仅其前数据估计的基准重算损失：全部历史扩张窗（ $N = 1267$ ）得 $b = 9.1579$ （聚类 bootstrap 95% CI

[5.8168, 12.8750]), $b/a = 22.5$; 26 周滚动池 ($N = 1267$) 得 $b = 9.4562$ (CI [6.7612, 12.8078]), $b/a = 42.7$; 逐州扩张窗 ($N = 1260$) 得 $b = 13.2666$ (CI [9.1385, 18.2948]), $b/a = 38.9$; 三者的 a 分别为 0.4063、0.2217、0.3409。三种滚动规格下误差水平整体抬升 (a 从 0.099 升至 0.22–0.41)——回顾性基准确实偏乐观, 其份额分解体现了同等基准下的机制拆解, 且份额结构本身随基准口径在 39%–55% 间移动: 回顾口径 54.8%/45.2%、全部历史扩张窗 54.9%/45.1%、26 周滚动池 39.1%/60.9%、逐州扩张窗 41.3%/58.7% (与规模无关/规模份额); 但规模相关项在所有事前口径下均显著为正、分箱误差保持快速衰减并趋平缓, 大规模端 ($D_t \geq 250$) 实际观测的误差水平也稳定低于全体平均的四至六成。在三种事前基准下, 规模项均为正; 变化的只是误差的绝对水平与份额结构。

误差预算分解: 仿射拟合不仅给出参数, 还允许把初期波段的平均相对均方误差 (0.181) 直接分解为拟合值的代数分解份额: 与规模无关项 a 贡献 54.6%, 规模相关项 b/D_t 贡献 45.1%, 模型外残差不足 0.3%。作为对照, 样本中实际处于大规模端 ($D_t \geq 250$, 越过经验交叉点 22.6 一个量级, 共 244 个观测) 的组内平均相对均方误差为 0.104——与拟合截距 $a = 0.0991$ 数值一致 (该一致性仅表明截距对应样本内大规模观测的已实现水平, 不构成对其机制来源的识别), 即经验数据中已实现的大规模观测误差水平约为全体平均 (0.181) 的六成; 其余约五成半的误差份额落在与规模无关的拟合项上, 提示环境协变量采集与多期平滑是值得进一步评估的互补路径 (命题 4)。达峰期条件方差口径下的分解结构类似 (46.7% 对 55.6%)。这些份额可用于比较不同监测投入的收益: 规模收益真实存在, 但在各规格下约四至五成半 (39%–55%) 的误差份额与规模无关。监测投入应根据误差来源决定, 增加病例数并不总是最有效的选择。

5.4 检验二：达峰与回落期——失效的是平稳基准而非病例规模

科学命题的成立必须伴随明确的证伪边界, 但证伪检验本身必须可解释。本文的反证检验采取如下口径: **用流行初期估计的平稳基准 $\bar{R}_{\text{early}}$ 去预测全部阶段的病例**。此时总误差可分解为两部分: 其一是基准偏移造成的常数偏差 $(\bar{R}_{\text{early}} - \bar{R}_{\text{phase}})^2 / \bar{R}_{\text{early}}^2$, 它与病例规模无关; 二是该阶段内部的条件方差, 只有后者才回答规模是否还有用。若只报告总误差, 则误差不随规模下降可能是常数偏差主导的平凡结果, 不构成对规模有效性的检验。因此下文两者分别报告。达峰与回落阶段定义为各流感季全国达峰周 (2022-12-03、2023-12-30、2025-02-08) 及其随后 7 周, 共 1220 个州-周。在此期间, 全美各州平均增长率骤降至 $\bar{R}_{\text{peak}} = 0.8075$ (标准差 0.3048), 远低于流行初期的 1.6706。

表 4 与图 4(c) 给出了该口径下的分组误差。

对比两个阶段可以发现强烈的非对称性:

- **总误差层面:** 以平稳基准预测时, 达峰与回落期的误差在所有规模组恒定处于 0.292–0.312, 从 [5, 20) 组的 0.2998 到 [600, 5000) 组的 0.2916 几乎没有下降;
- **但这一平稳性主要是常数偏差所致:** 在达峰期总体样本的均值-方差分解中, 基准偏移项 $(\bar{R}_{\text{peak}} - \bar{R}_{\text{early}})^2 / \bar{R}_{\text{early}}^2 = 0.2669$, 占总体损失的 88.9%。须注意这是总体口径的份额: 按各箱自身均值计算的偏差占比随规模上升 ([5, 20) 箱 59.5% 至 [600, 5000) 箱 94.8%), 小规模箱的偏差占比明显更低、条件方差占比更高, 故总体份额不代表各规模箱具有相同的偏差结构;

表 4: 达峰与回落期: 以平稳基准 $\bar{R}_{\text{early}}$ 预测时的分组误差

每周有效规模 D_t	样本数 N	相对均方误差	中位数
[5, 20)	33	0.2998	0.2361
[20, 50)	140	0.2927	0.2591
[50, 100)	162	0.3120	0.3085
[100, 250)	312	0.3049	0.3005
[250, 600)	311	0.2998	0.2976
[600, 5000)	262	0.2916	0.2987

- **条件方差层面:** 改用达峰期自身均值 $\bar{R}_{\text{peak}}$ 作基准后, 仿射拟合给出 $a = 0.0665$ (95% CI [0.0467, 0.0897])、 $b = 7.9272$ (95% CI [5.4239, 11.2248]), 达峰期内部规模相关项显著为正。但阶段间的 b 比较必须统一损失尺度: 上述达峰期损失以 $\bar{R}_{\text{peak}} = 0.8075$ 归一化, 而初期损失以 $\bar{R}_{\text{early}} = 1.6706$ 归一化, 两个 b 分母不同。表 5 报告了三种口径的比较。在共同分母 ($\bar{R}_{\text{early}}$) 和未归一化口径下, 达峰期的 b (1.8521 与 5.1690) 均低于初期 (2.2434 与 6.2611)。为完善推断, 本文在同一样本和共同分母下估计了四种规格的两阶段斜率差: 分别 OLS (2.3049 对 1.3866, 差 -0.9183)、联合 OLS 交互项 (-0.9183 ; 按州聚类 bootstrap 95% CI $[-2.33, 0.59]$)、分别 FGLS (2.2434 对 1.8521, 差 -0.3913)、联合 FGLS 交互项 (-0.3913)。在两种估计程序中, 联合交互项均精确等于分别拟合的斜率差 (代数恒等)。四种规格的判断一致: 阶段斜率差点估计为负但区间包含零, 未发现达峰期斜率增强, 也不能断言其更低。共同支撑集 [50, 600) 上结论相同 (共同分母口径 1.6326 对 2.9264)。若以各自归一化口径直接比较 (7.9272 对 2.2434), 会得出达峰期规模项更高的误导性印象, 那只是分母差异所致;

表 5: 两阶段规模相关项 b 的三口径比较

损失口径	初期 b	达峰期 b	回答的问题
未归一化 $(G - \bar{R}_{\text{phase}})^2$	6.2611	5.1690	增长代理的绝对误差规模
共同分母 $\bar{R}_{\text{early}}^2$ 归一化	2.2434	1.8521	同一相对尺度下的阶段差异
各阶段均值归一化	2.2434	7.9272	各阶段相对自身基准的误差

- 因此正确的反证结论是关于基准而非样本量: 在疫情高峰与回落期, 人群行为改变、节假日填报积压及医疗系统挤兑使跨期平稳基准 $\bar{R}$ 不再适用, 单期预测的首要误差来源转为基准偏移, 这解释了平稳模型在达峰期近 88.9% 的总体误差贡献。但本文的检验不支持达峰期病例规模不再有用这一更强主张: 控制基准偏移后, 达峰期内部的规模相关项仍显著为正 ($b = 7.9272$, 95% CI [5.4239, 11.2248])。同时, 统一尺度后的比较表明达峰期的规模项并不比初期更强 (表 5) —— 规模在两阶段同样有用, 但未显示阶段间增强。实际含义是: 达峰期需要换用非平稳状态模型或显式行为协变量, 而不是停止扩大病例捕获。

时变经验交叉点的探索性证据: 上述两阶段对比 (初期 $b/a = 22.6$ 对达峰期 119.2) 提示经验交叉点可能随疫情阶段移动。为考察这一点, 本文对全部有效观测做 26 周滚动窗口的窗口条

件化仿射拟合（窗口内以自身均值 $\bar{R}_w$ 为基准）。251 个窗口的经验交叉点中位数为 36.5 (IQR [14.2, 61.6])，量级与分段估计一致，但离季窗口的估计极不稳定（个别窗口逾千例）；须注意逐周滚动产生的高度重叠窗口使该 IQR 的有效样本量小于表观窗口数，区间解读应视为保守。为考察窗口内基准与窗口误差同源的影响，进一步改用前一窗口的均值作滞后基准重估（滞后只保证时间先后，不自动保证外生性）：流感季窗口中位数 19.7 对非流感季 47.9，与窗口内基准下的分离（20.4 对 46.9）基本一致，说明该阶段性分离并非窗口内基准机械压缩的产物。稳健的定性事实是：经验交叉点不是常数——在传播活跃期规模收益的边界更近、扩大捕获更早进入回报放缓区，而低发期则需要更大的规模才能逼近环境底板，这说明不同流行阶段可能需要不同的监测规模。

5.5 检验三：报告制度切换对观测噪声的冲击（命题 3 的实证启示）

2024 年 5 月至 10 月全美报告覆盖率的骤降为观察报告链扰动提供了宏观现实切片。如图 4(d) 所示：在第一阶段强制报告期 ($N = 6,009$ ，平均覆盖率 91.1%)，观测增长率的标准差为 0.624、偏度为 3.29（法定强制子段 $N = 3,382$ 下为 0.620 与 3.45）；在第二阶段自愿填报期 ($N = 420$ ，覆盖率跌至 54.6%)，观测增长率的标准差攀升至 1.823（扩张 192.1%），偏度跃升至 14.98；而第三阶段恢复强制后 ($N = 3,874$ ，覆盖率回升至 91.8%)，标准差与偏度迅速回落至 0.649 与 2.68。稳健离散度指标显示，自愿期四分位距 ($0.638 \rightarrow 0.594$) 与中位绝对离差 ($0.298 \rightarrow 0.299$) 基本平稳，表明覆盖率下滑主要诱发了分布右尾的极端发散，这与命题 3 中报告率下降放大二项抽稀噪声的动力学预测相容。

5.6 检验四：空间跨区域汇聚的方差收益与异质性限制

针对通过地理汇聚扩大基数 n 的效果，本文将 50 个州及华盛顿特区的数据按周加总，构建全美整体流感住院时间序列。在全美汇总序列的流行初期波段中，平均周捕获规模为 $D_t \approx 6662$ 例，单步预测相对均方误差下降至 0.0348（中位数 0.0115， $N = 28$ ），降至单个大州经验平台（约 0.10）的三分之一左右。全国汇总后的相对误差更低，说明跨区域汇总可以削弱部分局部波动，与命题 3 中扩大真实基数 n 压减方差的理论方向一致；而属地化预警所需的州级参数异质性与达峰时间差，则界定了简单汇总的适用边界。

5.7 检验五：跨预测模型与跨病种大流行场景的扩展验证

为核验规模效应边际衰减形态在自设基准之外的适用边界，本文进一步引入两组外部真实场景数据开展扩展验证（结果汇总于表 6）：其一是 Mathis et al. [31] 披露的美国 CDC FluSight 2022–2023 季官方多模型前瞻集成预测（Flusight-ensemble）；其二是 Flaxman et al. [39] 公开的欧洲 11 国 COVID-19 早期大流行发病监测序列。

前瞻集成预警模型验证 (FluSight 2022–2023)： 在 FluSight 真实前瞻预测中，自变量为集合模型发布的周度预期住院规模 $\hat{Y}_{j,t}$ 。在纯事前信息筛选口径下 ($\hat{Y}_{j,t} \geq 5$ ，排除全国与海外属地，50 州与华盛顿特区有效样本 $N = 1,177$)，FGLS 拟合给出 $a = 0.1295$ (95% CI [0.1020, 0.1633])， $b = 7.8045$ (州聚类 95% CI [5.3582, 10.5260])，经验收益拐点为 $m_\times = 60.28$ 例/周（全辖区口

径下为 66.11，回顾性全样本下为 75.70)。尤为关键的是阶段均值-方差分解：在真实前瞻集成模型下，达峰转折期的相对偏差平方仅占总损失的 15.5

跨病种大流行场景验证（欧洲 11 国 COVID-19）： 基于 Flaxman et al. [39] 官方公开的欧洲 11 国早期暴发序列（2020 年 2 月至 4 月 7 天平滑日度确诊规模），在事前规模筛选下的有效增长样本（ $D_t \geq 5$ 且 $g > 0$ ， $N = 404$ ）下，拟合给出 $b = 33.9223$ （国家聚类 95% CI [14.6021, 74.9873]），经验收益拐点为 $m_\times = 124.7$ 例/天；在增长期样本（ $N = 318$ ）与截尾子样本（ $N = 307$ ）下， b 分别为 18.5337 与 12.7632（CI 均严格远离零点），对应拐点分别为 88.1 与 67.7 例/天。两组数据中的规模相关误差项均为正，且在不同病种和数据尺度下保持一致。但经验拐点随监测体系的指标定义、统计口径与时间分辨率而变，因此不能把这些拐点视为跨病种通用阈值。

表 6: 跨预测模型与跨病种大流行场景扩展验证与敏感性结果

验证场景与数据集	筛选规则与样本口径	样本数 N	斜率 b	聚类 95% CI	截距 a	经验收益拐点 $m_\times$
CDC FluSight 集成模型	州级纯事前筛选 ($\hat{Y} \geq 5$)	1177	7.8045	[5.3582, 10.5260]	0.1295	60.28
Mathis et al. [31]	全辖区事前筛选 (含全美汇总)	1203	8.0721	[5.5204, 10.7831]	0.1221	66.11
流感前瞻集成预测	州级回顾性对照 (含实际值 ≥ 5)	1137	8.5208	[5.7935, 11.4120]	0.1212	70.29
欧洲 11 国 COVID-19	事前历史规模 ($D_t \geq 5, g > 0$)	404	33.9223	[14.6021, 74.9873]	0.2721	124.7
Flaxman et al. [39]	增长期全样本 (增长比 $g > 1.0$)	318	18.5337	[7.1333, 44.0963]	0.2104	88.1
早期大流行确诊序列	原截尾子样本 ($1.0 < g < 10.0$)	307	12.7632	[7.2466, 20.0068]	0.1886	67.7

注：置信区间分别由 1,500 次按州 (FluSight) 和按国家 (COVID-19) 聚类的 Bootstrap 给出。

6 讨论与结论

6.1 机制讨论与理论对话

本文分析了病例规模对传染病监测推断的影响。既有前沿文献基于有效再生数推导出了 Fisher 信息下界随病例规模近似线性增长的标度律 [17, 18]，但这一极限主要是针对测量当期环境瞬时参数 R_t 成立的。本文的分析表明：一旦推断目标切换为消除单周共同波动的跨期基础水平 $\bar{R}$ ，共同环境随机性 v_R 便构成了单期横截面内仅凭病例聚合无法消除的方差成分；由此导出的方差交叉点 $m_\times$ ，在数理结构上恰对应单期信度比（方差成分分析中信号方差占总方差比例）等于 0.5 的对称位置 [24, 25]。

在此基础上，监测杠杆的非对称性（命题 3）阐明了公共卫生监测的资源分配逻辑：在存在个体超传播的疾病中，单纯提升报告率 ρ 存在单期饱和和下界，唯有扩大地理或人群覆盖基数 n 才能压制子代抽样波动。而在时间序列动态演化中，达峰期实证表明所谓样本量失效在本质上是跨期平稳假定的失效（总体常数偏差贡献达 88.9%）；当剥离均值漂移后，规模相关项依然稳定发挥方差削减效应。这提示决策者在不同流行相位应采取差异化的应对策略：在传播初期关注病例捕获规模以越过交叉点，而在达峰拐点则应迅速引入非平稳状态空间滤波或显式行为协变量。

6.2 方法学边界与研究展望

本文的理论经验发现为传染病监测设计提供了明确判据，同时也界定了若干值得深入拓展的方法学方向：

- (1) 理论命题 1–6 建立了已知风险集与报告率下的规范基准；在时间序列更新过程中，历史压力的随机分母波动在极小规模端会产生时序放大效应，未来研究可进一步在连续时间跳跃扩散框架下解析其确切稳态分布。
- (2) 经验截距 $a = 0.0991$ 刻画了与规模无关的系统性误差底板。更新方程代数表明该底板整合了宏观环境扰动与未观测潜变量代理噪声，未来结合前瞻队列流调数据有望实现两类方差成分的细分测度。
- (3) 工具变量回归证实了规模效应在替代性测度下的稳健存在性；未来研究若能结合医院层面的准实验性干预设计，将有助于进一步识别微观报告行为的时空异质性。

6.3 结论

本文构建了负二项分支过程与二项报告模型，分析了疫情监测中病例规模的推断收益边界。理论推导表明，推断跨期基准时存在由环境方差决定的交叉点，同时揭示了报告率与样本基数的非对称作用及成本约束下的权衡。全美 CDC NHSN 周度流感住院数据检验与该理论形态一致。结果显示规模收益真实存在但在达到数十例后明显放缓，各基准下约四至五成半 (39%–55%) 的误差份额落在与规模无关的拟合项上。未来可进一步结合气象行为协变量与状态空间滤波，拓展多毒株共存场景下的监测设计。

References

- [1] James O Lloyd-Smith, Sebastian J Schreiber, P Ekkehard Kopp, and Wayne M Getz. Superspreading and the effect of individual variation on disease emergence. *Nature*, 438(7066):355–359, 2005. doi: 10.1038/nature04153.
- [2] Akira Endo, Sam Abbott, Adam J Kucharski, and Sebastian Funk. Estimating the overdispersion in COVID-19 transmission using outbreak sizes outside China. *Wellcome Open Research*, 5:67, 2020. doi: 10.12688/wellcomeopenres.15842.3.
- [3] A Azmon, C Faes, and N Hens. On the estimation of the reproduction number based on misreported epidemic data. *Statistics in Medicine*, 33(7):1176–1192, 2014. doi: 10.1002/sim.6015.
- [4] Oliver Stoner, Theo Economou, and Gabriela Drummond Marques da Silva. A hierarchical framework for correcting under-reporting in count data. *Journal of the American Statistical Association*, 114(528):1481–1492, 2019. doi: 10.1080/01621459.2019.1573732.
- [5] David A Rasmussen, Oliver Ratmann, and Katia Koelle. Inference for nonlinear epidemiological models using genealogies and time series. *PLOS Computational Biology*, 7(8):e1002136, 2011. doi: 10.1371/journal.pcbi.1002136.
- [6] Benjamin D Dalziel, Stephen Kissler, Julia R Gog, Cécile Viboud, Ottar N Bjørnstad, C Jessica E Metcalf, and Bryan T Grenfell. Urbanization and humidity shape the intensity of influenza epidemics in U.S. cities. *Science*, 362(6410):75–79, 2018. doi: 10.1126/science.aat6030.

- [7] Adam J Kucharski, Timothy W Russell, Charlie Diamond, Yang Liu, John Edmunds, Sebastian Funk, and Rosalind M Eggo. Early dynamics of transmission and control of COVID-19: a mathematical modelling study. *The Lancet Infectious Diseases*, 20(5):553–558, 2020. doi: 10.1016/S1473-3099(20)30144-4.
- [8] Jacco Wallinga and Peter Teunis. Different epidemic curves for severe acute respiratory syndrome reveal similar impacts of control measures. *American Journal of Epidemiology*, 160(6):509–516, 2004. doi: 10.1093/aje/kwh255.
- [9] Christophe Fraser. Estimating individual and household reproduction numbers in an emerging epidemic. *PLOS ONE*, 2(8):e758, 2007. doi: 10.1371/journal.pone.0000758.
- [10] Anne Cori, Neil M Ferguson, Christophe Fraser, and Simon Cauchemez. A new framework and software to estimate time-varying reproduction numbers during epidemics. *American Journal of Epidemiology*, 178(9):1505–1512, 2013. doi: 10.1093/aje/kwt133.
- [11] Robin N Thompson, J E Stockwin, R D van Gaalen, J A Polonsky, Z N Kamvar, P A Demarsh, E Dahlgvist, S Li, E Miguel, T Jombart, et al. Improved inference of time-varying reproduction numbers during infectious disease outbreaks. *Epidemics*, 29:100356, 2019. doi: 10.1016/j.epidem.2019.100356.
- [12] Katelyn M Gostic, Lauren McGough, Edward B Baskerville, Sam Abbott, Keya Joshi, Christine Tedijanto, Rebecca Kahn, Rene Niehus, James A Hay, Pablo M De Salazar, et al. Practical considerations for measuring the effective reproductive number, R_t . *PLOS Computational Biology*, 16(12):e1008409, 2020. doi: 10.1371/journal.pcbi.1008409.
- [13] Nicholas Steyn, Kris V Parag, Robin N Thompson, and Christl A Donnelly. A primer on inference and prediction with epidemic renewal models and sequential Monte Carlo. *Statistics in Medicine*, 44(18-19):e70204, 2025. doi: 10.1002/sim.70204.
- [14] Pierre Nouvellet, Anne Cori, Tini Garske, Isobel M Blake, Ilaria Dorigatti, Wes Hinsley, Thibaut Jombart, Harriet L Mills, Gemma Nedjati-Gilani, Maria D Van Kerkhove, Christophe Fraser, Christl A Donnelly, Neil M Ferguson, and Steven Riley. A simple approach to measure transmissibility and forecast incidence. *Epidemics*, 22:29–35, 2018. doi: 10.1016/j.epidem.2017.02.012.
- [15] Samir Bhatt, Neil Ferguson, Seth Flaxman, Axel Gandy, Swapnil Mishra, James A Scott, et al. Semi-mechanistic Bayesian modeling of COVID-19 with renewal processes. *Journal of the Royal Statistical Society Series A: Statistics in Society*, 186(4):601–615, 2023. doi: 10.1093/jrssa/qnad030.
- [16] Johannes Bracher and Leonhard Held. A marginal moment matching approach for fitting endemic-epidemic models to underreported disease surveillance counts. *Biometrics*, 77(4):1202–1214, 2021. doi: 10.1111/biom.13371.
- [17] Kris V Parag, Christl A Donnelly, and Alexander E Zarebski. Quantifying the information in noisy epidemic curves. *Nature Computational Science*, 2(9):584–594, 2022. doi: 10.1038/s43588-022-00313-1.
- [18] Kris V Parag and Christl A Donnelly. Fundamental limits on inferring epidemic resurgence in real time using effective reproduction numbers. *PLOS Computational Biology*, 18(4):e1010004, 2022. doi: 10.1371/journal.pcbi.1010004.
- [19] Kris V Parag, Ben Lambert, Christl A Donnelly, and Sandor Beregi. Asymmetric limits on timely interventions from noisy epidemic data. *Communications Physics*, 8:450, 2025. doi: 10.1038/s42005-025-02358-w.
- [20] Steinar Engen, Øyvind Bakke, and Aminul Islam. Demographic and environmental stochasticity—concepts and definitions. *Biometrics*, 54(3):840–846, 1998. doi: 10.2307/2533838.

- [21] Pejman Rohani, Matthew J Keeling, and Bryan T Grenfell. The interplay between determinism and stochasticity in childhood diseases. *The American Naturalist*, 159(5):469–481, 2002. doi: 10.1086/339467.
- [22] Carles Bretó, Daihai He, Edward L Ionides, and Aaron A King. Time series analysis via mechanistic models. *The Annals of Applied Statistics*, 3(1):319–348, 2009. doi: 10.1214/08-AOAS201.
- [23] Rachael Aber, Yanming Di, and Benjamin D Dalziel. Time-series modeling of epidemics in complex populations: Detecting changes in incidence volatility over time. *PLOS Computational Biology*, 21(7):e1012882, 2025. doi: 10.1371/journal.pcbi.1012882.
- [24] Wayne A Fuller. *Measurement Error Models*. John Wiley & Sons, New York, 1987. doi: 10.1002/9780470316665.
- [25] Raymond J Carroll, David Ruppert, Leonard A Stefanski, and Ciprian M Crainiceanu. *Measurement Error in Nonlinear Models: A Modern Perspective*. Chapman & Hall/CRC, Boca Raton, 2nd edition, 2006. doi: 10.1201/9781420010138.
- [26] Geert Verbeke and Geert Molenberghs. *Linear Mixed Models for Longitudinal Data*. Springer, New York, 2000. doi: 10.1007/978-1-4419-0300-6.
- [27] Ben G Armstrong. Effect of measurement error on epidemiological studies of environmental and occupational exposures. *Occupational and Environmental Medicine*, 55(10):651–656, 1998. doi: 10.1136/oem.55.10.651.
- [28] Benjamin M Althouse, Samuel V Scarpino, Lauren Ancel Meyers, John W Ayers, M Bargsten, J Baumbach, et al. Enhancing disease surveillance with novel data streams: challenges and opportunities. *EPJ Data Science*, 4:17, 2015. doi: 10.1140/epjds/s13688-015-0054-0.
- [29] Nicholas G Reich, Craig J McGowan, Teresa K Yamana, Abhinav Tushar, Evan L Ray, Dave Osthus, Sasikiran Kandula, Logan C Brooks, Willow Crawford-Crudell, Graham Casey Gibson, Evan Moore, Rebecca Silva, Matthew Biggerstaff, Michael A Johansson, Roni Rosenfeld, and Jeffrey Shaman. Accuracy of real-time multi-model ensemble forecasts for seasonal influenza in the U.S. *PLOS Computational Biology*, 15(11):e1007486, 2019. doi: 10.1371/journal.pcbi.1007486.
- [30] Matthew Biggerstaff, Michael A Johansson, David Alper, Logan C Brooks, Prithwish Chakraborty, David C Farrow, et al. Results from the second year of a collaborative effort to forecast influenza seasons in the United States. *Epidemics*, 24:26–33, 2018. doi: 10.1016/j.epidem.2018.02.003.
- [31] Shannon M Mathis, Alexander E Webber, Teresa M León, Eleanor L Murray, Monica Sun, Lauren A White, et al. Evaluation of FluSight influenza forecasting in the 2021–22 and 2022–23 seasons with a new target laboratory-confirmed influenza hospitalizations. *Nature Communications*, 15:6289, 2024. doi: 10.1038/s41467-024-50601-9.
- [32] Estee Y Cramer, Evan L Ray, Velma K Lopez, Johannes Bracher, Andrea Brennen, Alvaro J Castro Rivadeneira, Aaron Gerding, Tilmann Gneiting, Nicholas G Reich, et al. Evaluation of individual and ensemble probabilistic forecasts of COVID-19 mortality in the United States. *Proceedings of the National Academy of Sciences*, 119(15):e2113561119, 2022. doi: 10.1073/pnas.2113561119.
- [33] Evan L Ray, Logan C Brooks, Jacob Bien, Matthew Biggerstaff, Nikos I Bosse, Johannes Bracher, Estee Y Cramer, Sebastian Funk, Aaron Gerding, Michael A Johansson, et al. Comparing trained and untrained probabilistic ensemble forecasts of COVID-19 cases and deaths in the United States. *International Journal of Forecasting*, 39(3):1366–1383, 2023. doi: 10.1016/j.ijforecast.2022.06.005.
- [34] Nikos I Bosse, Sam Abbott, Anne Cori, Edwin van Leeuwen, Johannes Bracher, and Sebastian Funk. Scoring epidemiological forecasts on transformed scales. *PLOS Computational Biology*, 19(8):e1011393, 2023. doi: 10.1371/journal.pcbi.1011393.

- [35] Hong Zhou, William W Thompson, Cécile G Viboud, Corinne M Ringholz, Po-Yung Cheng, Claudia Steiner, et al. Hospitalizations associated with influenza and respiratory syncytial virus in the United States, 1993–2008. *Clinical Infectious Diseases*, 54(10):1427–1436, 2012. doi: 10.1093/cid/cis211.
- [36] William G Cochran. *Sampling Techniques*. John Wiley & Sons, New York, 3rd edition, 1977.
- [37] Centers for Disease Control and Prevention. Weekly Hospital Respiratory Data (HRD) Metrics by Jurisdiction, National Healthcare Safety Network (NHSN). <https://data.cdc.gov/d/ua7e-t2fy>, 2026. CDC open-data catalogue record ua7e-t2fy. Accessed 2026-09-05.
- [38] Jerome I Tokars, Sonja J Olsen, and Carrie Reed. Seasonal incidence of symptomatic influenza in the United States. *Clinical Infectious Diseases*, 66(10):1511–1518, 2018. doi: 10.1093/cid/cix1060.
- [39] Seth Flaxman, Swapnil Mishra, Axel Gandy, H Juliette T Unwin, Thomas A Mellan, Helen Coupland, Charles Whittaker, Harrison Zhu, Tresnia Berah, Jeffrey W Eaton, et al. Estimating the effects of non-pharmaceutical interventions on COVID-19 in Europe. *Nature*, 584(7820):257–261, 2020. doi: 10.1038/s41586-020-2405-7.

A 数学命题完整证明 (Supplementary Proofs)

A.1 命题 1 的数学证明

证明. 由负二项分布的概率生成函数(PGF), 若个体继发感染数 $X_{i,t} \sim \text{NB}(k, p)$, 其中 $p = \frac{k}{k+R_t}$, 则 $I_t = \sum_{i=1}^n X_{i,t} \sim \text{NB}(nk, p)$, 其 PGF 为 $G_{I_t}(s) = \left(\frac{p}{1-(1-p)s} \right)^{nk}$. 在二项抽样 $C_t | I_t \sim \text{Binomial}(I_t, \rho)$ 下, 复合分布的 PGF 为:

$$G_{C_t}(s) = G_{I_t}(1 - \rho + \rho s) = \left(\frac{p}{1 - (1-p)(1 - \rho + \rho s)} \right)^{nk} = \left(\frac{p^*}{1 - (1-p^*)s} \right)^{nk},$$

其中 $p^* = \frac{p}{1-\rho(1-p)} = \frac{k}{k+\rho R_t}$. 这证明了 $C_t | n, R_t$ 服从形状参数为 nk 、成功概率为 p^* 的负二项分布, 条件均值为 $\rho n R_t$.

其对数似然函数为:

$$\ln L(R_t) = \text{const} - (nk + C_t) \ln(k + \rho R_t) + C_t \ln R_t.$$

对 R_t 求导并令得分为零:

$$\frac{\partial \ln L}{\partial R_t} = -\frac{\rho(nk + C_t)}{k + \rho R_t} + \frac{C_t}{R_t} = \frac{k(C_t - \rho n R_t)}{R_t(k + \rho R_t)} = 0 \implies \hat{R}_t^{\text{MLE}} = \frac{C_t}{\rho n}.$$

计算得分函数的方差以求 Fisher 信息量:

$$\mathcal{I}(R_t | n) = \text{Var} \left(\frac{\partial \ln L}{\partial R_t} \right) = \frac{k^2 \text{Var}(C_t | n, R_t)}{R_t^2 (k + \rho R_t)^2}.$$

代入负二项方差 $\text{Var}(C_t | n, R_t) = \rho n R_t + \frac{\rho^2 n R_t^2}{k} = \frac{\rho n R_t (k + \rho R_t)}{k}$:

$$\mathcal{I}(R_t | n) = \frac{k^2 \cdot \frac{\rho n R_t (k + \rho R_t)}{k}}{R_t^2 (k + \rho R_t)^2} = \frac{k \rho n R_t}{R_t^2 (k + \rho R_t)} = \frac{n}{\frac{R_t}{\rho} + \frac{R_t^2}{k}}.$$

因此其倒数恰为 $\text{Var}(\hat{R}_t | n, R_t) = \frac{R_t}{\rho n} + \frac{R_t^2}{kn}$. □

A.2 命题 2 的数学证明

证明. 应用全方差公式以 $\bar{R}$ 为目标分解:

$$\text{Var} \left(\frac{C_t}{\rho n} \middle| n \right) = \text{Var} \left(\mathbb{E} \left[\frac{C_t}{\rho n} \middle| n, R_t \right] \middle| n \right) + \mathbb{E} \left[\text{Var} \left(\frac{C_t}{\rho n} \middle| n, R_t \right) \middle| n \right].$$

由命题 1, 第一项为 $\text{Var}(R_t | n) = v_R$. 第二项为:

$$\mathbb{E} \left[\frac{R_t}{\rho n} + \frac{R_t^2}{kn} \middle| n \right] = \frac{\mathbb{E}[R_t | n]}{\rho n} + \frac{\mathbb{E}[R_t^2 | n]}{kn}.$$

利用条件二阶矩关系 $\mathbb{E}[R_t^2 | n] = \text{Var}(R_t | n) + (\mathbb{E}[R_t | n])^2 = v_R + \bar{R}^2$, 相加即得式 (7). □

A.3 命题 3 的数学证明

证明. 将式 (11) 代入式 (10) 分别令 $\rho \rightarrow 1$ 与 $n \rightarrow \infty$, 代入极限直接即得. □

A.4 命题 4 的数学证明

证明. 由全方差公式, 由于给定环境序列后分支与抽样过程条件独立, 平均估计量的方差严格分解为环境项与抽样项:

$$\begin{aligned}\text{Var}(\widehat{R}_T | n_T) &= \frac{1}{T^2} \text{Var}\left(\sum_{t=1}^T R_t \middle| n_T\right) + \frac{1}{T^2} \sum_{t=1}^T \mathbb{E}[\text{Var}(\widehat{R}_t | n_T, R_t) | n_T] \\ &= \frac{1}{T^2} \text{Var}\left(\sum_{t=1}^T R_t \middle| n_T\right) + \frac{A}{T(\rho n_T)}.\end{aligned}$$

将 $n_T = B/(\rho T)$ 代入抽样项, 即得 $\rho n_T = B/T$, 从而第二项恒为 A/B . 在环境跨期独立假定下, 第一项化为 v_R/T , 相加直接得式 (15). 若各期环境扰动存在一阶自回归自相关, 利用平稳协方差双重求和展开:

$$\text{Var}\left(\sum_{t=1}^T R_t \middle| n_T\right) = T v_R + 2 v_R \sum_{s=1}^{T-1} (T-s) r^s = v_R T \left[\frac{1+r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2} \right].$$

除以 T^2 即得式 (16). 当 $T \gg 1$ 时忽略 $O(1/T^2)$ 项, 直接得到有效期数近似. 最后由 $n_T = B/(\rho T) \in \mathbb{N}_+$ 即得式 (18). $\square$

A.5 命题 5 的数学证明

证明. (i) 给定 (n, ρ, k) , C_t 的分布族为以 R_t 为参数的负二项族, 其概率质量函数 $\Pr(C_t = j) \propto (k/(k + \rho R_t))^{nk} (1 - p^*)^j$. 对任意 $R'_t > R_t$, 似然比 $\Pr_{R'_t}(j)/\Pr_{R_t}(j)$ 关于 j 严格单调递增 (分子分母中 $(1 - p^*)^j$ 的指数律比较, p^* 随 R_t 递减), 故该族关于充分统计量 C_t 具有单调似然比. 由 MLR 性质, 尾部概率 $\Pr_{R_t}(C_t \geq c)$ 关于 R_t 单调不减, 因此 $\sup_{R_t \leq 1} \Pr_{R_t}(C_t \geq c_\alpha) = \Pr_{R_t=1}(C_t \geq c_\alpha) \leq \alpha$, 即拒绝域 $\{C_t \geq c_\alpha\}$ 在复合原假设下严格控制水平. (ii) 在备择 $R_t = 1 + \delta$ 处直接计算同一拒绝域的概率即得式 (22). 另注: 固定 (ρ, k) 时, 整数临界值 $c_\alpha(n)$ 作为 n 的函数单调不减 (随 nk 呈现离散阶梯状跳变), 但由于离散阶梯跳跃, 实际检验水平与统计功效 $\pi(n, \delta)$ 关于 n 呈现局部的非单调锯齿形波动, 故满足特定功效要求的最小样本量确定必须逐点枚举而非单纯二分搜索. $\square$

A.6 命题 6 的数学证明

证明. 对 I_{t+1} 以 (Λ_{t+1}, R_{t+1}) 为条件应用全方差公式, 即得式 (25). 对于报告病例 C_{t+1} , 以 I_{t+1} 为条件应用全方差公式:

$$\text{Var}(C_{t+1} | \mathcal{F}_t^C) = \mathbb{E}[\text{Var}(C_{t+1} | I_{t+1}, \mathcal{F}_t^C) | \mathcal{F}_t^C] + \text{Var}(\mathbb{E}[C_{t+1} | I_{t+1}, \mathcal{F}_t^C] | \mathcal{F}_t^C).$$

由条件独立假定 $C_{t+1} | (I_{t+1}, \mathcal{F}_t^C) \sim \text{Binomial}(I_{t+1}, \rho)$, 有 $\text{Var}(C_{t+1} | I_{t+1}, \mathcal{F}_t^C) = I_{t+1} \rho (1 - \rho)$ 与 $\mathbb{E}[C_{t+1} | I_{t+1}, \mathcal{F}_t^C] = \rho I_{t+1}$, 代入即得式 (26). $\square$