病例规模与再生数估计精度：环境波动下的收益边界及美国流感住院数据检验

王驰

西安科技大学　应用统计硕士专业学位研究生　学号 24201221020

摘要

多收集病例能让再生数估计精确多少，取决于要估计什么。本文在负二项传播与二项报告的框架下区分两个估计目标。估计当期再生数时，报告数除以预计报告规模得到的估计量在每个有限规模上都达到 Cramér–Rao 下界，方差随规模趋于零。估计跨期平均传播水平时，方差为 $v_R + A/m$，其中 v_R 是环境波动造成的方差，m 是预计报告病例数；环境项构成规模无法突破的底板。两项相等处的交叉点 $m_\times = A/v_R$ 为规模提供了一把尺子。规模达到 $m_\times$ 后，再翻一倍只能把方差降低 25%。这一结构有三点设计含义。扩大覆盖面比提高报告率更能压低方差。多期预算下，最优单期规模取成本比与交叉点的几何平均。小规模时应使用精确增长检验，常用的正态近似检验会超过名义水平。更新过程仿真表明，在时间序列中单代公式只能作参照曲线，不构成误差下界。本文用美国国家医疗安全网络 16,218 个州周的流感住院数据做检验。流行初期的预测误差呈“常数加规模反比”的形状，经验交叉点为 22.6 例/周，与理论情景区间 21.3–49.2 同一量级。规模项在多种替代规格和两组外部数据中都为正。拟合的截距与斜率则都在情景隐含值的三倍以上。滞后权重的比较表明，报告噪声使分母随机，抬高了斜率；截距随分母的回溯滞后上升，与环境的时间相关一致。因此经验交叉点只能作量级参考。达峰期 88.9% 的误差来自基准偏移，换用阶段自身基准后规模效应依然存在。结果提示，预警和趋势估计宜分开设计。

关键词：再生数；环境随机性；超传播；监测规模；方差分解；流感住院

1　引言

监测机构常面对一个朴素的问题，即多收集病例能让再生数估计精确多少。直觉的回答是病例越多越准。在泊松近似下，再生数估计的方差与病例数成反比，Fisher 信息随病例数线性增长 [1]。按这个思路，扩大监测规模总能换来同比例的精度提升。

在传染病监测中，这一直觉有两处不成立。第一处在估计目标。若关心的是当期再生数 R_t，规模确实带来持续收益；若关心的是一段时期内的平均传播水平，情况就不同了。同一辖区、同一时段的感染者共享天气、接触模式和人群流动，这些环境扰动让每期的 R_t 围绕均值波动 [2, 3]。病例再多，也只是把这一期的 R_t 测得更准，测不掉 R_t 本身的波动。生态学把这类波动称为环境随机性，与个体层面的人口随机性相区分 [4, 5]。第二处在数据结构。真实序列中，下一周的感染压力取决于此前各周的感染人数，而漏报使这些人数无法完全观测，所以分母本身也是随机的。单代模型的方差公式在这里只能作参照，不能当作误差下界。

再生数估计已有成熟的方法体系。基于世代间隔和更新方程的估计方法是实时追踪的主要工具 [6–8]，这些方法在实际使用中的窗口选择、延迟和偏差也有系统讨论 [9–12]。超传播使继发感染数严重过离散，通常用负二项分布刻画 [13–15]。漏报和报告偏差的修正见文献 [16–18]，状态空间与半机制模型见文献 [19, 20]。信息论方向上，Parag 等量化了带噪发病曲线所含的信息，并给出识别疫情反弹所需时间的下限 [1, 21, 22]。这些工作回答的是“给定数据能知道多少”。它们很少把环境波动单列为一个方差成分，也就没有回答“规模扩大到多少以后，再扩大就不划算了”。

本文在负二项传播与二项报告的框架下处理规模收益的边界，得到三项结果。

1. 区分两个估计目标。目标 I 是当期 R_t，其估计方差随规模趋于零；目标 II 是跨期平均水平 $\overline{R}$，方差为 $v_R + A/m$，其中 v_R 是环境方差，m 是预计报告的病例数。两项相等处定义为交叉点 $m_\times = A/v_R$。规模达到 $m_\times$ 时，再翻一倍只能把方差降低 25%。

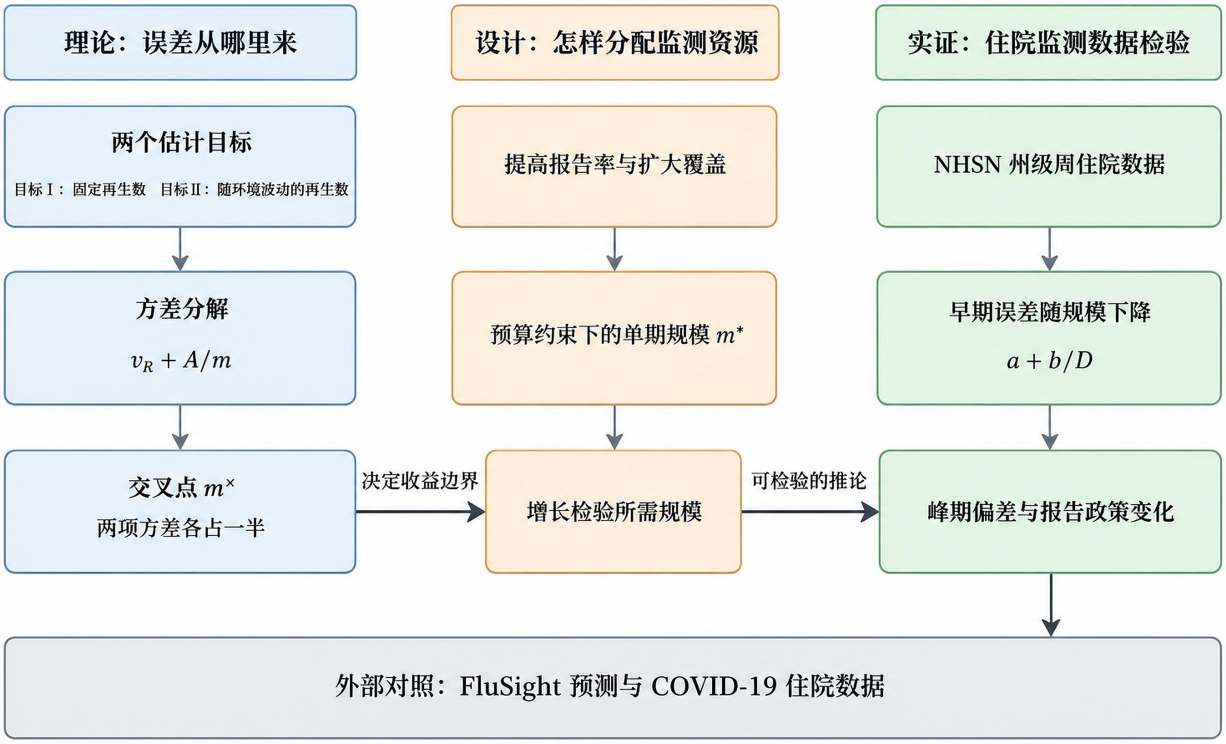


图 1 本文结构。左列为方差理论，中列为由此得到的监测设计，右列为美国流感住院数据的检验，底部为外部对照。

2. 由方差结构推出三点设计含义，涉及报告率与覆盖面的取舍、多期预算下的最优单期规模，以及小规模时如何检验疫情是否在增长。最优规模问题与经典两阶段抽样的费用分配同构 [23]。
3. 用 16,218 个州周的住院数据检验上述结论。数据来自美国国家医疗安全网络（NHSN）的流感住院周报 [24]。流行初期的预测误差呈“常数加规模反比”的形状，经验交叉点为 22.6 例，与理论情景区间 21.3–49.2 处于同一量级。截距与斜率的绝对值都高于理论值，第 6 节说明其来源。

图 1 给出全文结构。第 2 节建立模型并定义两个估计目标，第 3 节推导方差结构，第 4 节讨论监测设计。第 5 节用更新过程仿真考察时间序列中的规模效应，第 6 节是实证检验。第 7 节讨论含义与局限，第 8 节总结。全部证明见附录 A，复现参数见附录 B。

2　模型与估计目标

2.1　传播与报告

考虑第 t 期的传播。上一代有 n 名感染者，第 i 人产生 $X_{i,t}$ 个继发感染。为刻画超传播，设给定当期再生数 R_t 时 $X_{i,t}$ 相互独立，且服从负二项分布

$$X_{i,t} \mid R_t \sim \mathrm{NB}(k,\ k/(k+R_t)), \qquad \mathrm{E}(X_{i,t} \mid R_t) = R_t, \quad \mathrm{Var}(X_{i,t} \mid R_t) = R_t + \frac{R_t^2}{k}. \tag{1}$$

这里 k 是离散参数，k 越小，少数人造成大部分传播的现象越明显。式 (1) 等价于个体再生数服从均值为 R_t、形状参数为 k 的 Gamma 分布，继发感染数在其上服从泊松分布 [13]。

同期新感染总数 $I_t = \sum_{i=1}^{n} X_{i,t}$ 服从 $\mathrm{NB}(nk,\ k/(k+R_t))$。监测系统只看到其中一部分，每名新感染者独立地以概率 ρ 被报告，报告数 $C_t \mid I_t \sim \mathrm{Bin}(I_t, \rho)$。负二项分布经二项稀疏后仍是负二项分布（附录 A.1），由此得到报告数的条件分布

$$C_t \mid n, R_t \sim \mathrm{NB}(nk,\ k/(k+\rho R_t)), \qquad \mathrm{E}(C_t \mid n, R_t) = \rho n R_t, \quad \mathrm{Var}(C_t \mid n, R_t) = \rho n R_t + \frac{\rho^2 n R_t^2}{k}. \tag{2}$$

记 $m=\rho n$，即上一代感染者中预计被报告的人数。下文用 m 度量监测规模。

报告数的相对方差由两部分组成，可写为

$$\frac{\mathrm{Var}(C_t \mid n, R_t)}{\mathrm{E}(C_t \mid n, R_t)^2} = \frac{1}{\rho n R_t} + \frac{1}{nk}. \tag{3}$$

第一项来自报告抽样，提高报告率 ρ 可以压低它；第二项来自超传播，只能靠增加感染者人数 n 来压低。这一不对称在第 3.3 节会再次出现。

2.2 两个估计目标

R_t 随时间波动。天气、学校假期和人群流动会让各期的传播强度围绕某个平均水平上下变化。设 $\mathrm{E}(R_t)=\overline{R}$，$\mathrm{Var}(R_t)=v_R$，称 v_R 为环境方差。

监测要回答的问题可以分为两类。

目标 I 是当期再生数 R_t。例如，卫生部门想知道本周的传播是否比上周更快，关心的是这一期实际发生的 R_t。

目标 II 是平均水平 $\overline{R}$。例如，制定一个流行季的床位计划时，需要的是该时段典型的传播强度，而单期的 R_t 只是围绕 $\overline{R}$ 的一次随机实现。

两个目标用同一个估计量 $\widehat{R}_t = C_t/(\rho n)$，但误差的参照对象不同。目标 I 的误差是 $\widehat{R}_t - R_t$，目标 II 的误差是 $\widehat{R}_t - \overline{R}$。后者多出了 $R_t - \overline{R}$ 这一项，它不随规模变化。

2.3 基本假设

第 3–4 节的推导依赖以下四条假设。

H1 给定 R_t，各感染者的继发感染数相互独立且服从式 (1)，报告过程为独立二项抽样。

H2 同一期的感染者共享同一个 R_t，即环境扰动作用在“期”这一层面。

H3 离散参数 k 与报告率 ρ 已知。

H4 规模 n 与当期环境无关：$\mathrm{E}(R_t \mid n)=\overline{R}$，$\mathrm{Var}(R_t \mid n)=v_R$。

H4 需要单独说明。若 n 由设计固定，例如每期追踪固定数目的指示病例，H4 自然成立。若 n_t 是此前传播的结果，而 R_t 又有时间相关，那么大的 n_t 往往出现在 R 偏高的时期，H4 不再自动成立。真实监测序列属于后一种情况，第 5 节专门讨论。H3 在实践中也只是近似，k 需要估计，其影响见第 4.2 节和第 7 节。

3 方差结构

本节在 H1–H4 下比较两个估计目标的方差。目标 I 的方差随规模趋于零，目标 II 的方差有一个由环境决定的底板；两者之间的过渡由交叉点 $m_\times$ 刻画。

3.1 当期再生数

先看目标 I。此时 R_t 视为固定参数，估计量的性质由式 (2) 直接决定。

命题 1 (当期再生数的有效估计) 在 H1–H3 下，给定 n 与 $R_t>0$，估计量 $\widehat{R}_t = C_t/(\rho n)$ 满足：

(i) $\widehat{R}_t$ 是 R_t 的极大似然估计；当 $C_t=0$ 时，似然在边界 $R_t=0$ 处取最大值；

(ii) $\widehat{R}_t$ 无偏，方差为 $\mathrm{Var}(\widehat{R}_t \mid n, R_t) = R_t/(\rho n) + R_t^2/(kn)$；

(iii) 对任意 n，该方差都等于 Cramér–Rao 下界 $1/\mathcal{I}(R_t)$，其中 $\mathcal{I}(R_t) = n/(R_t/\rho + {R_t}^2/k)$；

(iv) $\widehat{R}_t$ 是 R_t 的一致最小方差无偏估计。

结论 (iii) 不是渐近结果。得分函数恰好可以写成 $\mathcal{I}(R_t)(\widehat{R}_t - R_t)$ 的形式，所以下界在每个有限 n 处都能取到。结论 (iv) 来自单参数指数族中 C_t 的完备充分性，需要 k 已知 [25, 26]。方差由两部分组成，与式 (3) 的两项一一对应，$R_t/(\rho n)$ 来自报告抽样，$R_t^2/(kn)$ 来自超传播。两部分都按 $1/n$ 衰减，规模越大，当期再生数估得越准，没有底板。

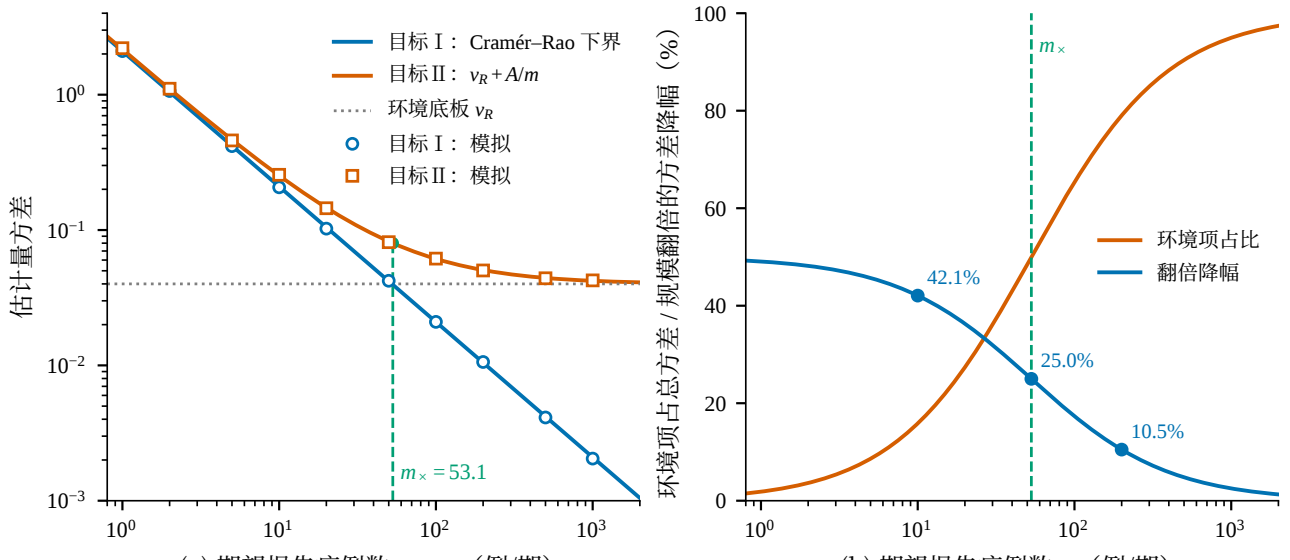


图 2 两个估计目标的方差结构。参数为 $\overline{R} = 1.15$，$v_R = 0.04$，$k = 0.35$，$\rho = 0.25$，对应 $A = 2.1232$，$m_\times = 53.1$。(a) 目标 I 的方差（即 Cramér–Rao 下界，取 $R_t = \overline{R}$）与目标 II 的方差 $v_R + A/m$ 随规模的变化，空心点为每个规模 20,000 次模拟的方差，虚线标出交叉点。(b) 环境项在目标 II 总方差中的占比，以及规模翻倍带来的方差降幅；三个标注点对应 $m = 10$、$m_\times$ 与 200。

我们用蒙特卡洛模拟核对了命题 1(iii)。在 m 从 1 到 1000 的 10 个规模上各做 20,000 次模拟，方差与 CRLB 之比在 0.98–1.02，差异来自蒙特卡洛误差（图 2a 中的圆点）。

3.2 跨期平均与交叉点

目标 II 要估计的是 $\overline{R}$。R_t 现在是随机的，估计误差多出了环境波动这一项。

命题 2 (跨期平均水平的方差) 在 H1–H4 下，$\widehat{R}_t = C_t/(\rho n)$ 是 $\overline{R}$ 的无偏估计，其方差为

$$V(m) = \mathrm{Var}(\widehat{R}_t \mid n) = v_R + \frac{\overline{R}}{\rho n} + \frac{\overline{R}^2 + v_R}{kn} = v_R + \frac{A}{m}, \qquad A = \overline{R} + \frac{\rho(\overline{R}^2 + v_R)}{k}. \tag{4}$$

定义交叉点 $m_\times = A/v_R$，则：

(i) $m \to \infty$ 时 $V(m) \to v_R$；

(ii) 规模项在总方差中的份额为 $1/(1 + m/m_\times)$，在 $m = m_\times$ 处两项各占一半；

(iii) 规模从 m 翻倍到 $2m$，方差下降的比例为 $1/[2(1 + m/m_\times)]$；

(iv) $V(m)$ 严格递减且严格凸，对 m 的弹性为 $-m_\times/(m + m_\times)$，在 $m = m_\times$ 处等于 $-1/2$。

式 (4) 由全方差公式得到。条件方差的期望给出 A/m，条件均值 R_t 的方差给出 v_R。A 中的二次项为 $\overline{R}^2 + v_R$，因为超传播项 $R_t^2/(kn)$ 要对 R_t 取期望，而 $\mathrm{E}(R_t^2) = \overline{R}^2 + v_R$。

交叉点的含义要说清楚。$V(m)$ 处处凸，二阶导数为 $2A/m^3 > 0$，曲线上没有“转折”，所以 $m_\times$ 不是收益突然消失的位置。它的作用是给规模提供一把尺子。规模低于 $m_\times$ 时，误差主要来自病例太少，扩大规模收效明显；规模高于 $m_\times$ 时，误差主要来自环境波动，翻倍的收益迅速变小。

图 2 用一组示意参数画出这一结构，取 $\overline{R} = 1.15$，$v_R = 0.04$，$k = 0.35$，$\rho = 0.25$。此时 $A = 2.1232$，$m_\times = 53.1$。规模为 10、53.1 和 200 时，翻倍降幅依次为 42.1%、25.0% 和 10.5%。目标 II 的模拟方差与式 (4) 之比同样落在 0.98–1.02。

底板 v_R 在单一环境内无法通过扩大规模消除，但可以通过汇总多个环境来压低。设 J 个辖区的环境方差同为 v_R，两两相关系数的平均值为 $\bar{c}$。等权汇总后，环境项变为

$$v_R\,\bar{c} + \frac{v_R(1 - \bar{c})}{J}. \tag{5}$$

各辖区的扰动不完全同步时（$\bar{c} < 1$），汇总能降低底板；完全同步时汇总无效。第 6.5 节会用全国加总序列估计 $\bar{c}$。

3.3 报告率与覆盖面

$m = \rho n$ 可以通过两条途径扩大，即提高报告率 ρ，或扩大覆盖的人群使 n 增大。式 (4) 表明两者的作用并不相同。

命题 3 (报告率与覆盖面的不对称) 在 H1–H4 下：

(i) 固定 n 令 $\rho \to 1$，$V \to v_R + \overline{R}/n + (\overline{R}^2 + v_R)/(kn)$，极限严格大于 v_R；

(ii) 固定 ρ 令 $n \to \infty$，$V \to v_R$；

(iii) 报告项可以拆为 $\overline{R}/(\rho n) = \overline{R}/n + (1-\rho)\overline{R}/(\rho n)$，第二部分是漏报带来的额外方差；

(iv) 把 n 与 ρ 各提高相同的小比例，前者带来的方差下降是后者的 $A/\overline{R} = 1 + \rho(\overline{R}^2 + v_R)/(k\overline{R})$ 倍。

命题 3 说明，提高报告率与扩大覆盖的作用不对称。即使报告完全，超传播项仍然存在，只有扩大覆盖才能把方差压到 v_R。不过，两者的差距取决于 ρ 的大小。在图 2 的参数下，$A/\overline{R} = 1.85$，扩大覆盖的效果接近提高报告率的两倍。在流感住院监测中，住院占感染的比例约为 0.0056–0.021[27, 28]。取第 6.2 节的情景参数，这一倍数只有 1.02–1.18。也就是说，对住院数据而言，两条途径的效果几乎相同，选择哪一条主要看成本。

4 监测设计

方差结构可以回答两个设计问题，即总预算固定时期数与单期规模如何取舍，以及规模较小时如何可靠地判断疫情是否在增长。

4.1 多期预算分配

设共观测 T 期，每期预计报告 m 例，总量 $B = Tm$ 固定。用各期估计的平均值 $T^{-1}\sum_t \widehat{R}_t$ 估计 $\overline{R}$。

命题 4 (多期分配) 在 H1–H4 下，若各期 R_t 相互独立，则

$$\frac{1}{T^2}\,\mathrm{Var}\Big(\sum_{t=1}^{T}\widehat{R}_t\Big) = \frac{v_R}{T} + \frac{A}{B}. \tag{6}$$

若 R_t 服从系数为 $r \in (0,1)$ 的平稳一阶自回归过程，规模项仍为 A/B，环境项变为

$$\frac{v_R}{T}\cdot\frac{1+r}{1-r} - \frac{2r(1-r^T)\,v_R}{T^2(1-r)^2}. \tag{7}$$

两种情形下，方差都随 T 严格递减。

总量固定时，规模项 A/B 与如何切分无关，环境项则随期数增多而下降。所以只看方差，期数越多越好。式 (7) 是一阶自回归过程部分和方差的精确表达式 [29]。常用的有效期数近似 $T_{\text{eff}} = T(1-r)/(1+r)$ 只保留了方括号内第一项，总会高估环境项。$r = 0.8$ 时，$T = 26$ 高估 20.5%，$T = 10$ 高估 65.8%。近似只在 $T \gg 2r/(1-r^2)$ 时可用。

实际切分还受整数约束。每期需要 $n = B/(\rho T)$ 名感染者，因此 T 必须整除 B/ρ。例如 $B = 30$、$\rho = 0.25$ 时，$B/\rho = 120$，可行的 T 为 120 的 16 个因数；$\rho = 0.7$ 时 B/ρ 非整数，可行集为空，只能放宽总量。

期数不能无限增加，因为每多观测一期都有固定成本，例如启动一轮调查或维持一个报告周期。设每期固定成本为 c_0，每例预计报告病例的边际成本为 c_1，总经费为 $\mathcal{B}$，于是 $T = \mathcal{B}/(c_0 + c_1 m)$。

推论 1 (最优单期规模) 在命题 4 的独立情形下，估计方差为 $f(m) = (c_0 + c_1 m)(v_R + A/m)/\mathcal{B}$。当 $c_0 > 0$ 时，它在下式处取最小值

$$m^* = \sqrt{\frac{c_0}{c_1}}\,m_{\times}, \qquad f(m^*) = \frac{(\sqrt{c_0 v_R} + \sqrt{c_1 A})^2}{\mathcal{B}}. \tag{8}$$

若 $\mathcal{B} < c_0 + c_1 m^*$，约束 $T \geq 1$ 起作用，最优解取 $T = 1$；若 $c_0 = 0$，最优解为 $m \to 0$。

最优单期规模是成本比 c_0/c_1 与交叉点 $m_\times$ 的几何平均。这与两阶段抽样的费用分配是同一个问题 [23]。期数 T 对应初级单元数，v_R 对应初级单元间方差，A 对应单元内方差，c_0 与 c_1 分别对应初级单元和次级单元的单位成本。

按第 6.2 节的情景参数，$m_\times$ 在 21.3–49.2。$c_0/c_1 = 10$ 时 m^* 为 14.6–22.2，$c_0/c_1 = 100$ 时为 46.1–70.1。在图 2 的参数下（$m_\times = 53.1$），两种成本比对应的 m^* 为 23.0 和 72.9。

连续解需要取整后才能执行。取图示参数，$c_0 = 100$，$c_1 = 1$，$\mathcal{B} = 600$，连续解为 $m^* = 72.86$，对应的 T 不是整数。逐个比较整数 T 后，最优方案是 $T = 3$、$m = 100$，方差为 0.02041。若环境服从一阶自回归，m^* 应乘以约 $\sqrt{(1-r)/(1+r)}$，即正相关使最优方案偏向更多、更小的期。仍取图示参数与 $c_0/c_1 = 100$，$r = 0.5$ 时精确最优与近似值分别为 42.9 和 42.1，$r = 0.8$ 时为 25.0 和 24.3。

4.2 增长检验

监测中最常见的判断是疫情是否在增长，即检验 $H_0 : R_t \le 1$ 对 $H_1 : R_t > 1$。这是目标 I 层面的问题。

命题 5 (精确增长检验) 在 H1–H3 下，C_t 的分布族关于 R_t 具有单调似然比。令 c_α 为满足 $P_{R_t=1}(C_t \ge c) \le \alpha$ 的最小整数，检验在 $C_t \ge c_\alpha$ 时拒绝 H_0。该检验有以下三条性质。

(i) 第一类错误概率在 $R_t \le 1$ 上的上确界在 $R_t = 1$ 处取得，实际水平 $\alpha^* \le \alpha$。

(ii) 该检验在水平 α^* 下一致最优；加入随机化的 Karlin–Rubin 检验恰好达到水平 α，并在该水平下一致最优。

(iii) 在 $R_t = 1 + \delta$ 处的功效为：

$$\pi(n, \delta) = 1 - F_{\mathrm{NB}}(c_\alpha - 1;\ nk,\ k/[k + \rho(1+\delta)]). \tag{9}$$

命题 5 是单调似然比族上的标准结论 [30, 31]。它依赖 k 已知；若 k 用数据估计，水平不再有精确保证。

实际工作中常用正态近似的 Wald 检验，即把 $(\widehat{R}_t - 1)/\sqrt{V_0}$ 与正态分位数比较，其中 $V_0 = 1/(\rho n) + 1/(kn)$ 是 $R_t = 1$ 时的方差。该检验的实际水平同样可以用负二项分布函数精确算出。图 3a 显示，小规模时 Wald 检验系统性地超过名义水平。$k = 0.1$、$m = 5$ 时实际水平为 7.81%；在 $m < 40$ 的范围内，$k = 0.1$、0.35 和 1 的最大实际水平分别为 8.03%、8.75% 和 10.40%。精确检验在整个网格上的最大水平为 0.05000，没有超出名义水平。

功效随 n 的变化呈锯齿状。c_α 只能取整数，每当它跳升一格，功效会短暂下降。以 $k = 0.35$、$\delta = 0.3$ 为例，n 从 400 增加到 699 的过程中，功效下降了 82 次。因此只报告“首次达到 80% 功效的规模”并不够，还要给出“此后始终保持 80% 以上的规模”。在 $\rho = 0.25$ 下，$k = 0.35$ 时 $\delta = 0.15$、0.3、0.5 依次为 2071/2107、568/581、229/235；$\delta = 0.25$ 时，$k = 1$ 为 568/585，$k = 0.1$ 为 1660/1684。

这些数字与第 3.2 节的结论形成对照。$k = 0.35$ 时，要稳定检出 15% 的增长，每期需要约 2107 名感染者，即 $m \approx 527$ 例预计报告，是图示交叉点的十倍左右。对目标 II 而言，规模过了 $m_\times$ 收益就明显变小；对判断当期增长这类目标 I 问题，规模的价值要大得多。

5 时间序列中的规模效应

前两节假定上一代感染者人数 n 已知。真实监测序列不满足这一点。下一周的新感染由此前几周的感染共同产生，感染压力可写为 $\Lambda_{t+1} = \sum_{s \ge 1} w_s I_{t+1-s}$，其中 w_s 是世代间隔分布。漏报使 $I_1, \dots, I_t$ 无法完全观测，所以下一周的感染压力 Λ_{t+1} 也是随机的。实际能用的只是报告数的加权和 $D_t = \sum_{s \ge 1} w_s C_{t+1-s}$，并以 $G_t = C_{t+1}/D_t$ 作为增长统计量。

5.1 信息集与误差分解

预测误差取决于可用的信息集。记 $\mathcal{F}_t$ 为截至第 t 周的全部报告，$m = \rho\ \mathrm{E}(\Lambda_{t+1} \mid \mathcal{F}_t)$。

注 1 设给定 Λ_{t+1} 与 R_{t+1} 时，C_{t+1} 服从式 (2) 中以 Λ_{t+1} 代替 n 的负二项分布，且在 $\mathcal{F}_t$ 条件下 Λ_{t+1} 与 R_{t+1} 独立。两次使用全方差公式，可得

$$\frac{\mathrm{Var}(C_{t+1} \mid \mathcal{F}_t)}{[\rho\ \mathrm{E}(\Lambda_{t+1} \mid \mathcal{F}_t)]^2} = v_R + \frac{A}{m} + \mathrm{CV}^2(\Lambda_{t+1} \mid \mathcal{F}_t)\,(\overline{R}^2 + v_R). \tag{10}$$

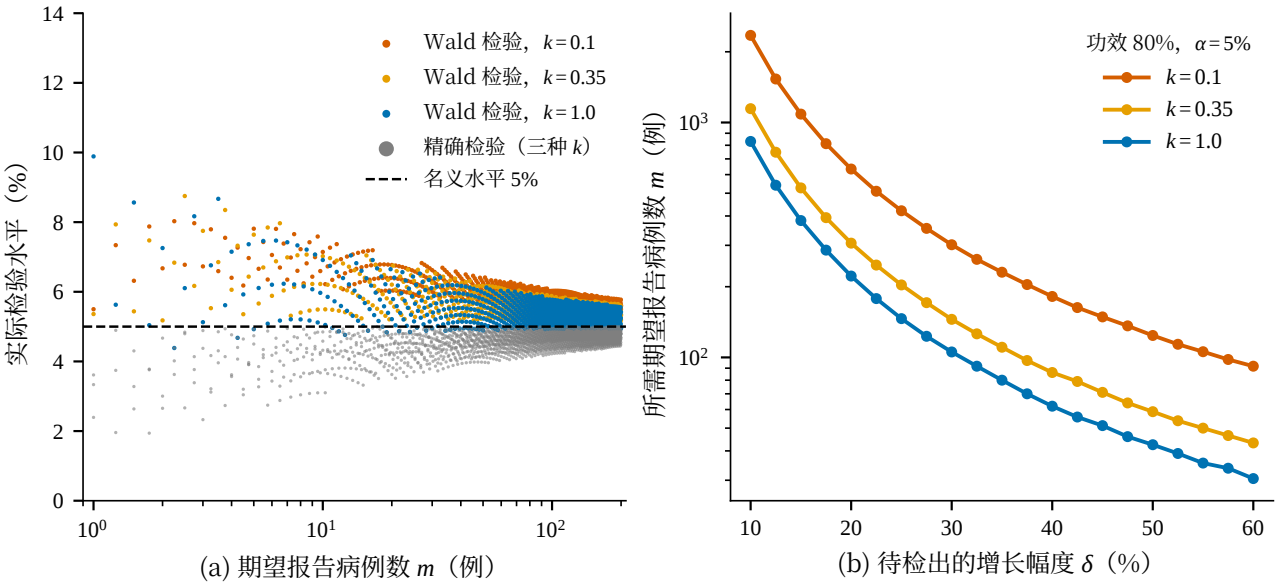


图 3 增长检验的实际水平与所需规模，$\rho = 0.25$，名义水平 5%，全部由负二项分布函数精确计算。(a) Wald 检验（按 k 着色）与精确检验（灰色）的实际水平随期望报告规模的变化。(b) 达到并保持 80% 功效所需的期望报告规模与待检出增长幅度 δ 的关系。

当 Λ_{t+1} 完全已知时，变异系数项为零，式 (10) 退化为命题 2。

式 (10) 中多出的一项来自感染压力的不确定性。它与规模无关，并会随漏报程度和世代间隔的展宽而变大。

实证中使用的误差指标有两种读法。用 $\overline{R}D_t$ 预测 C_{t+1} 的相对误差，与用 G_t 估计 $\overline{R}$ 的相对误差恒等

$$\frac{(C_{t+1}-\overline{R}D_t)^2}{(\overline{R}D_t)^2}=\frac{(G_t-\overline{R})^2}{\overline{R}^2}. \tag{11}$$

记 $\mu_t=\mathrm{E}(C_{t+1}\mid\mathcal{F}_t)$，$\sigma_t^2=\mathrm{Var}(C_{t+1}\mid\mathcal{F}_t)$。由于 D_t 由 $\mathcal{F}_t$ 决定，增长统计量的均方误差可以分解为

$$\mathrm{E}[(G_t-\overline{R})^2]=\mathrm{E}((\sigma_t/D_t)^2)+\mathrm{E}[(\mu_t/D_t-\overline{R})^2]. \tag{12}$$

第二项是条件偏差，非负。第一项则不必等于 v_R+A/D_t，因为 D_t 只是 $\rho\Lambda_{t+1}$ 的带噪代理，$(\sigma_t/D_t)^2$ 可能高于也可能低于单代公式。因此，单代公式 $(v_R+A/m)/\overline{R}^2$ 在时间序列中只能作参照曲线，一般情况下不构成下界。

5.2 更新过程仿真

为了解参照曲线的偏离程度，我们模拟了带环境波动的更新过程。世代间隔取 4 周离散核，权重依次为 0.45、0.35、0.15、0.05；每周 R_t 独立抽自均值 1.15、方差 0.04 的 Gamma 分布；$I_t\sim\mathrm{NB}(k\Lambda_t,\,k/(k+R_t))$，$k=0.35$；报告数 $C_t\sim\mathrm{Bin}(I_t,0.25)$。为避免轨迹灭绝，$I_t$ 截断为不小于 1。前 4 周的感染数设为 m_0/ρ，使初始每周期望报告 m_0 例，m_0 取 6 到 800 共 8 档。每档模拟 400 条 30 周的轨迹，每条有 26 个评价点，随机种子为 20261014。截断只在小规模时发生，$m_0=6$ 与 12 时的比例分别为 1.42% 与 0.16%，$m_0\geq 25$ 时为零。

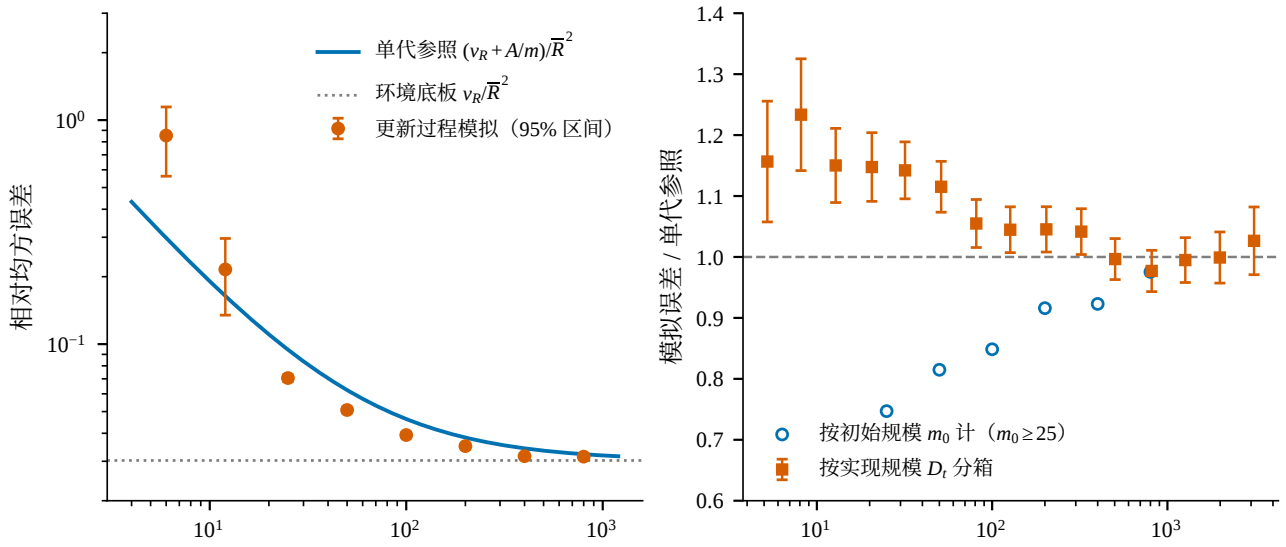
图 4 给出结果。

按初始规模 m_0 计，$m_0\geq 25$ 时模拟误差是参照曲线的 0.75–0.98 倍，低于参照。原因是 $\overline{R}>1$，疫情在评价期内增长，实际规模高于初始规模；D_t/m_0 的中位数为 1.86–2.35。

按实际规模 D_t 分组，结论反过来。$D_t<400$ 时模拟误差是参照的 1.04–1.23 倍，高于参照，多出的部分来自随机分母；$D_t\geq 400$ 时比值为 0.98–1.03，两者基本重合。

m_0 很小时误差分布有重尾。$m_0=12$ 时比值为 1.31；$m_0=6$ 时为 2.87，且标准误很大，这一数值不稳定。

所以，参照曲线是高估还是低估误差，取决于横轴用哪种规模。按实际规模计，“常数加规模反比”的形状大体成立，小规模处误差略高。这为第 6 节用 $a+b/D_t$ 拟合实证误差提供了依据。仿真中各周 R_t 相互独立，D_t 与当期环境无关；真实数据中 R_t 有时间相关，H4 不再成立，这会进一步抬高实证截距与斜率。



(a) 初始期望报告规模 m_0（例/周）　　(b) 实现规模 D_t 或初始规模 m_0（例/周）

图 4 更新过程仿真中的规模效应。每个初始规模 400 条轨迹，每条 26 个评价点，误差棒为 95% 区间。(a) 增长统计量的相对均方误差随初始规模 m_0 的变化，实线为单代参照曲线 $(v_R + A/m)/\overline{R}^2$，点线为环境底板。参照曲线不是误差下界。(b) 模拟误差与参照曲线之比：方块按实际规模 D_t 分组，空心圆按初始规模 m_0（$m_0 \geq 25$）计算。

6　美国流感住院数据的检验

本节用美国流感住院周报检验误差是否呈“常数加规模反比”的形状，分析拟合的截距与斜率为何高于理论值，并考察疫情阶段和报告制度变化时这一形状的变化。

6.1　数据与口径

数据来自美国国家医疗安全网络（NHSN）公布的各辖区每周实验室确诊流感住院数，以及各辖区填报医院所占比例 [24]。样本覆盖 50 个州与华盛顿特区，共 16,218 个州周。其中 504 个州周的住院数缺失，按 0 处理，其中 468 个在第一期，36 个在第二期。

规模用此前三周报告数的加权和度量

$$D_t = 0.65\,C_t + 0.25\,C_{t-1} + 0.10\,C_{t-2}. \tag{13}$$

相对待预测的 C_{t+1}，D_t 的平均回溯滞后为 1.45 周，约 10.2 天。增长统计量取 $G_t = C_{t+1}/D_t$。只保留 $D_t \geq 5$ 的州周，得到 10,303 个有效观测。

G_t 与第 2 节的 R_t 不是同一个量。流感的世代间隔约 3 天，一周约跨两代，G_t 是两代左右增长的合成，其均值和方差都不等于单代再生数的均值和方差。所以下文只用模型的结构，即误差随规模的形状，不把拟合得到的系数解读为单代参数的估计。

误差指标采用相对均方误差。以某一阶段的平均增长比 $\overline{R}$ 为基准，第 t 周的损失为 $L_t = [(G_t - \overline{R})/\overline{R}]^2$。由式 (11)，它也是用 $\overline{R}D_t$ 预测 C_{t+1} 的相对误差平方，属于常用的相对误差评分 [32]。在单代模型下，以预计报告规模 m 代替 D_t，有

$$\mathrm{E}(L_t \mid D_t) \approx a + \frac{b}{D_t}, \qquad a = \frac{v_R}{\overline{R}^2}, \quad b = \frac{A}{\overline{R}^2}, \quad \frac{b}{a} = m_{\times}. \tag{14}$$

式 (14) 是下文的拟合形式。b/a 称为经验交叉点。

样本期内 NHSN 的填报制度变过两次（图 5）。2020 年 10 月至 2024 年 4 月 30 日为强制填报，下称第一期，有效观测 6,009 个，平均填报率 91.1%。2024 年 5 月 1 日至 10 月 31 日改为自愿填报，下称第二期，有效观测 420 个，平均填报率 54.6%，中位数 45.7%。2024 年 11 月 1 日起，美国联邦医疗保险与医疗补助服务中心恢复强制要求，下称第三期，有效观测 3,874 个，平均填报率 91.8%。

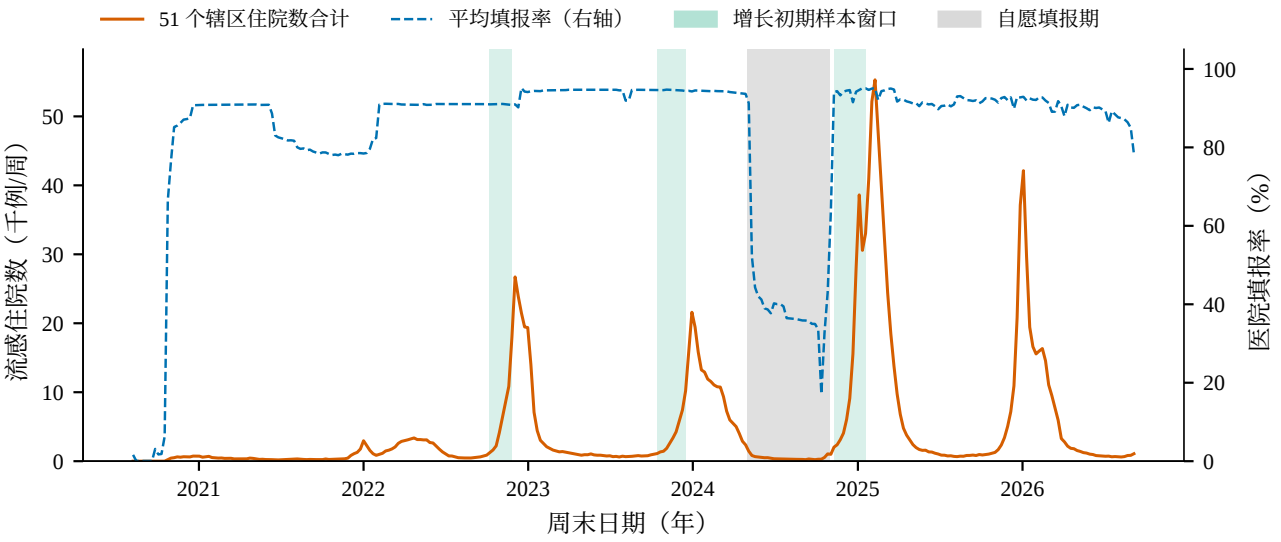


图 5 美国 51 个辖区每周流感住院数合计（实线，左轴）与医院平均填报率（虚线，右轴）。缺失按 0 计入合计。绿色区间为三个流行季的增长初期样本窗口，灰色区间为 2024 年 5–10 月的自愿填报期。

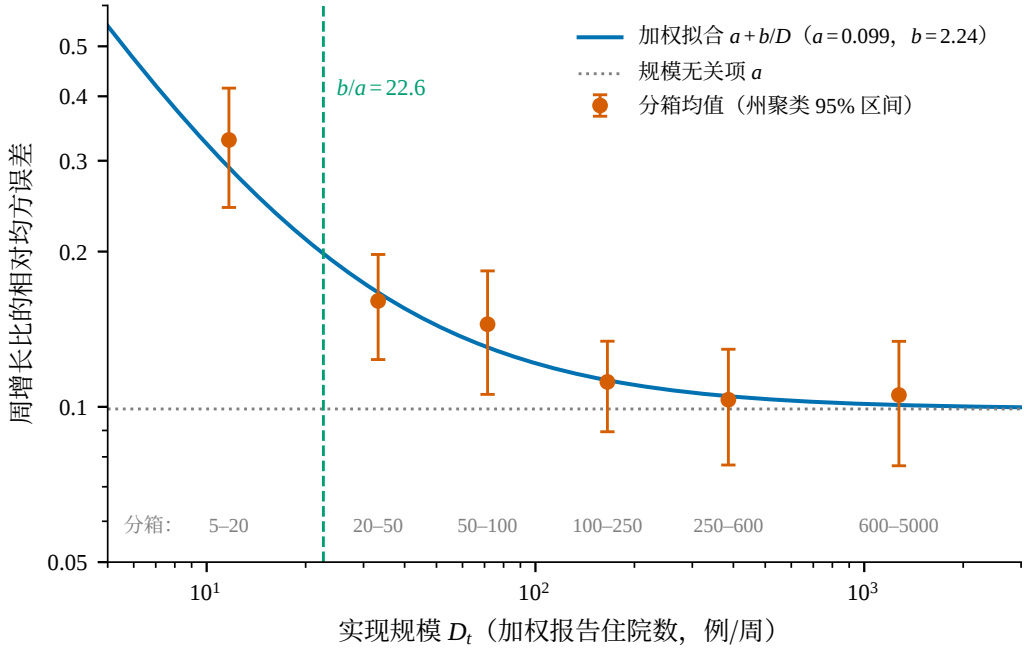


图 6 流行初期单步预测误差随实现规模 D_t 的变化，共 1,267 个州周。圆点为各分箱均值，画在箱内平均 D_t 处，误差棒为按州聚类重抽的 95% 区间；曲线为 $a + b/D$ 的拟合，水平虚线为截距 a，竖线为经验交叉点 b/a。

6.2 流行初期的规模效应

模型假定各期环境围绕同一均值波动。流行初期最接近这一情形，所以主分析取三个流行季的增长初期，即 2022 年 10 月 8 日至 11 月 26 日，2023 年 10 月 14 日至 12 月 16 日，2024 年 11 月 9 日至 2025 年 1 月 18 日。窗口内共 1,267 个有效州周，平均增长比 $\overline{R}_{\text{early}} = 1.6706$，标准差 0.7116。

误差随规模下降，并逐渐趋平（图 6）。按 D_t 分为六箱，$[5, 20)$ 箱的平均损失为 0.329（$N = 319$，95% 区间 0.244–0.415），$[20, 50)$ 箱降到 0.161，$[100, 250)$ 箱为 0.112，此后两箱停在 0.103 和 0.105 附近。

我们用可行广义最小二乘拟合式 (14)，权重取 $1/\hat{\mu}^2$，$\hat{\mu}$ 为一步拟合值 [33]；区间由按州聚类的 1,500 次重抽给出 [34, 35]。结果为 $a = 0.0991$（95% 区间 0.0841–0.1173），$b = 2.2434$（1.5019–3.0161），1,500 次重抽中没有一次 $b \le 0$。经验交叉点 $b/a = 22.6$ 例/周（13.7–33.7）。用十分位分组均值拟合，交叉点同样为 22.6。

权重的选择只影响效率，不影响一致性。损失的离散程度随规模收缩，$\mathrm{Var}(L)/\,\mathrm{E}(L)^2$ 从最小箱的 5.32 降到最大箱的 0.99，所以 $1/\hat{\mu}^2$ 并非最优权重。不过权重只依赖 D_t，拟合仍然一致；普通最小二乘给出 $b = 2.305$，

与 2.243 接近。

交叉点对极端值敏感。去掉损失最大的 1% 观测后，$a = 0.1077$，$b = 1.137$（0.697–1.661），交叉点降到 10.6（5.9–17.3）。两项单向聚类的敏感性分析结论不变。每次重抽都重新估计基准 $\overline{R}_{\text{early}}$，$b$ 的 95% 区间为 1.517–2.981；改为按周聚类，区间为 1.473–3.119。州与周两个维度的双向聚类没有做，原因见第 7 节。

把平均损失拆开，可以看出扩大规模还剩多少空间。样本平均损失为 0.181，截距 a 占 54.6%，规模项 b/D_t 占 45.1%，拟合残差占 0.2%；规模项按 D_t 的调和平均数 27.4 计算。若所有州周的规模都提高到 250，模型给出的平均损失为 0.107，下降 40.9%。实际 $D_t \geq 250$ 的 244 个州周平均损失为 0.104，约为全样本均值的六成。后一个数与模型上限 0.108 接近，但它由拟合机械地决定，不构成独立证据。

经验交叉点 22.6 与理论情景区间同一量级。情景参数取 $\overline{R} = 1.67$，$k \in [0.2, 0.5]$[13]，$\rho \in [0.0056, 0.021]$[27, 28]，$v_R \in [0.04, 0.08]$，此时 A 在 1.702–1.967，$m_\times$ 在 21.3–49.2。但比值吻合不能当作对结构参数的检验。情景隐含的截距为 0.0143–0.0287，斜率为 0.610–0.705；实证 a 是前者的 3.5–6.9 倍，b 是后者的 3.2–3.7 倍。两者被放大的倍数相近，比值才碰巧落在区间内。

6.3 截距与斜率为什么偏大

偏大有两个来源，分别作用于斜率和截距。

分母噪声主要抬高斜率。D_t 本身是带二项报告噪声的计数，比真实感染压力 $\rho\Lambda_{t+1}$ 多一层随机性。用 delta 方法展开，斜率近似为

$$b \approx \frac{A + (1-\rho)(\overline{R}^2 + v_R)\sum_s {w_s}^2}{\overline{R}^2}, \tag{15}$$

其中 $\sum_s {w_s}^2$ 是式 (13) 中滞后权重的平方和。权重越集中，D_t 越接近单周计数，噪声越大，b 也越大。这与测量误差文献中分母或自变量含噪时的系数偏移是同一类问题 [36, 37]。

式 (15) 预测的是不同滞后权重之间 b 的相对变化，这一点与数据吻合（图 7a）。我们比较三种权重，即主规格（0.65/0.25/0.10，$\sum w^2 = 0.495$）、只用当周（$\sum w^2 = 1$）和三周等权（$\sum w^2 = 0.333$）。实证斜率依次为 2.243、3.134（2.203–4.067）和 1.926（1.071–2.807）。相对主规格，后两者的比值为 1.40 和 0.86；式 (15) 在情景参数下的预测为 1.44 和 0.86。情景参数取 $\overline{R} = 1.67$，$v_R = 0.06$，$k = 0.35$，$\rho = 0.021$，$A = 1.8409$。预测斜率为 1.155、1.660、0.993，模拟值为 1.195、1.566、0.999。

水平上，分母噪声只解释了一部分。没有分母噪声时，情景斜率为 0.660，约为实证值的 29%；加入二项噪声后升到 1.155，约为 51%。剩余部分的一个可能来源是报告过程的超额离散，把报告离散度设为 $\varphi = 1.96$ 时，模拟斜率为 2.019。这只是可能的解释之一，数据本身无法区分。

分母噪声只抬高斜率，不抬高截距。情景模拟中三种权重的截距为 0.0225、0.0202、0.0214，几乎不变，于是 b/a 被推高到 59.2，而真实的 A/v_R 只有 30.7。因此，用 b/a 估计 $m_\times$ 会系统性偏大。

截距的放大另有来源。实证截距随回溯滞后单调上升，平均滞后为 1.0、1.45、2.0 周时，a 分别为 0.0682、0.0991、0.1524（图 7b），都远高于情景隐含的 0.014–0.029；模拟中截距不随滞后变化。这与式 (12) 的条件偏差项一致。真实的 R_t 有时间相关，分母越陈旧，μ_t/D_t 偏离 $\overline{R}$ 越远，偏差项越大。前面提到的 G_t 跨两代左右，也会放大与规模无关的波动。

在三种滞后权重下，规模项都为正，误差形状稳定。经验交叉点则随权重在 12.6–46.0 之间变化，它描述 G_t 这一统计量的误差结构，不能当作 A/v_R 的估计。

6.4 达峰期与报告制度变化

流行达峰后，基准本身失效。取三个流行季的全国峰值周（2022 年 12 月 3 日、2023 年 12 月 30 日、2025 年 2 月 8 日）及其后 7 周，共 1,220 个州周，平均增长比降到 $\overline{R}_{\text{peak}} = 0.8075$，标准差 0.3048。若继续用初期均值 1.6706 作基准，各箱的平均损失都在 0.29–0.31，看不出随规模下降。

图 8 把这部分损失拆成两块，即基准偏移造成的常数偏差 $(\overline{R}_{\text{early}} - \overline{R}_{\text{peak}})^2/\overline{R}_{\text{early}}^2 = 0.2669$，以及箱内围绕峰期均值的波动。偏差项占总损失的 88.9%，从最小箱的 59.5% 升到最大箱的 94.8%。除最小箱外，峰期损失是同箱初期损失的 1.8–2.9 倍。

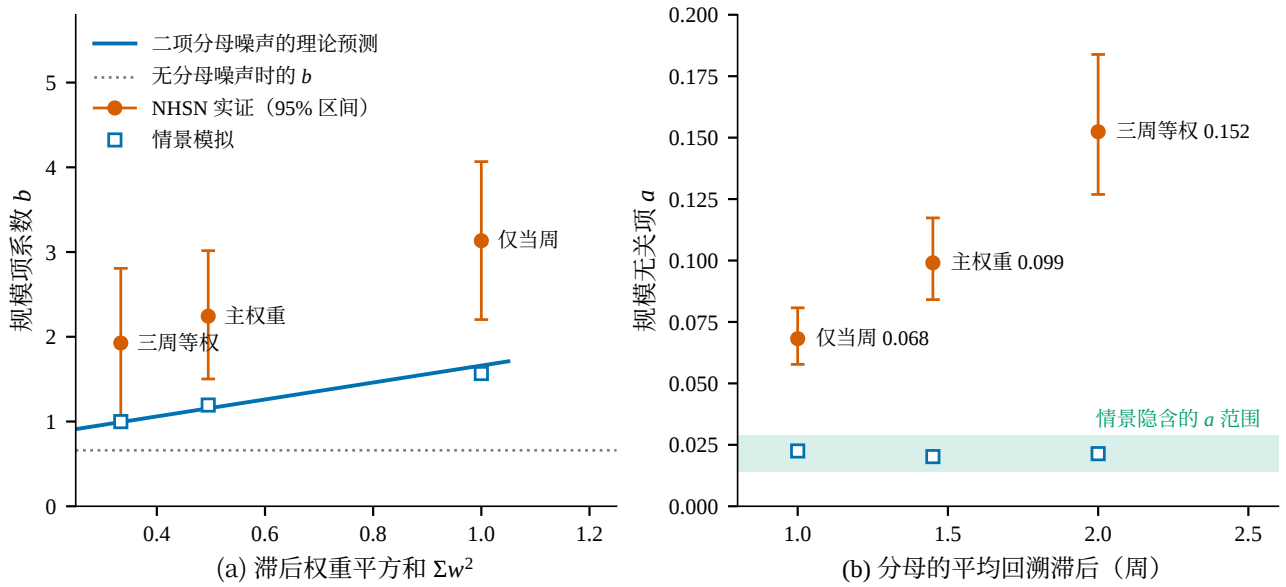


图 7 滞后权重对拟合系数的影响。(a) 规模项系数 b 与滞后权重平方和 $\sum w^2$ 的关系：圆点为三种权重的实证估计及 95% 区间，方块为情景模拟值，斜线为二项分母噪声的一阶近似，水平虚线为没有分母噪声时的 b。(b) 截距 a 与分母平均回溯滞后的关系，阴影为情景隐含的截距范围 0.014–0.029。

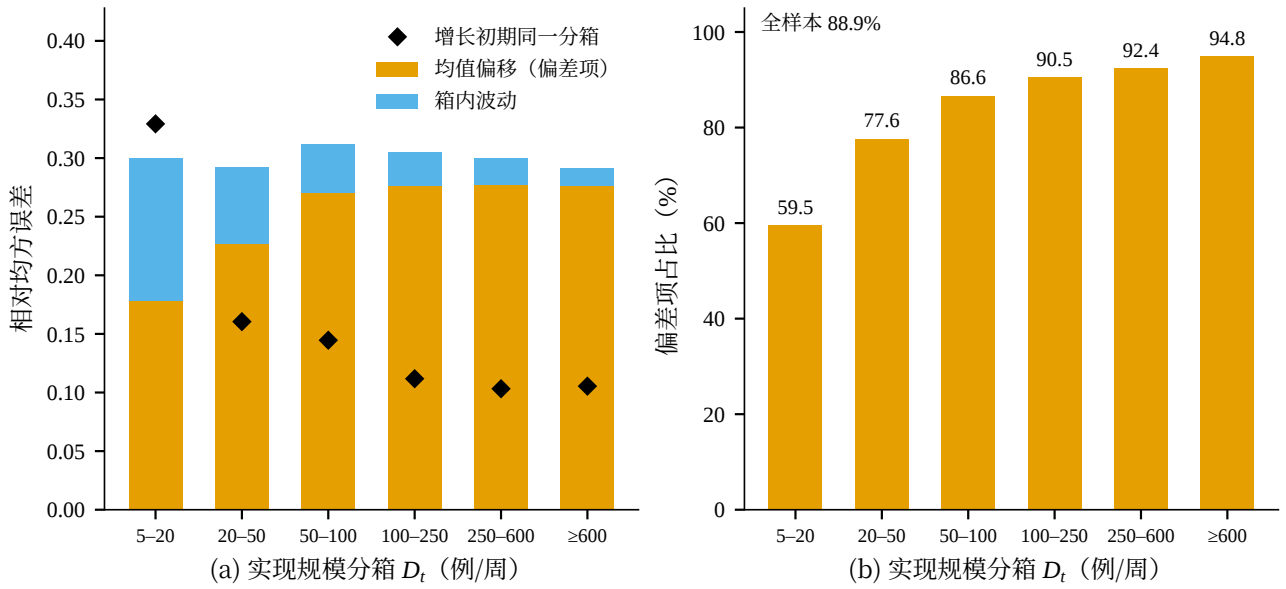


图 8 达峰期（峰值周及其后 7 周）以流行初期均值为基准时的误差分解。(a) 各规模箱的平均损失，分为基准偏移造成的偏差项与箱内波动，菱形为同一分箱在流行初期的平均损失。(b) 偏差项在各箱损失中的占比。

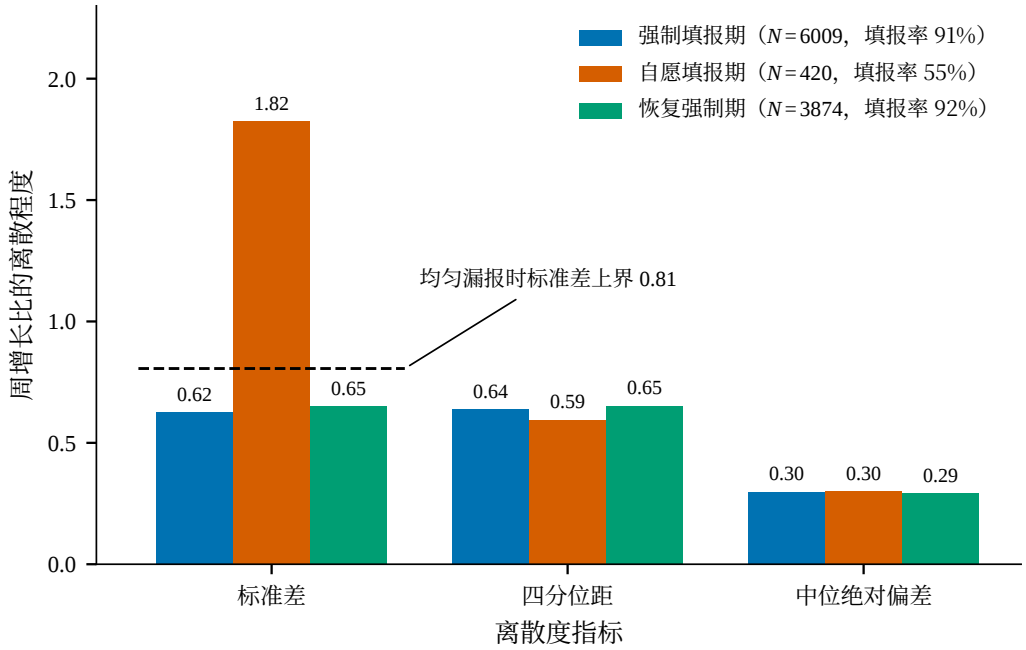


图 9 三个填报制度期内周增长比 G_t 的离散程度。柱上数字为指标值。虚线为填报率从 91.1% 降至 54.6% 时，若漏报在医院间均匀发生，第二期标准差可能达到的上限。

改用峰期自身均值作基准后，规模效应重新出现，$a = 0.0665$（0.0467–0.0897），$b = 7.927$（5.424–11.225），交叉点 119.2（64.0–225.9），平均损失 0.142。这里的 b 不能直接和初期的 2.243 比较，因为两者的归一化分母不同。统一用 $\overline{R}_{\text{early}}$ 归一化后，峰期斜率为 1.852，低于初期的 2.243；不归一化时为 5.169 对 6.261。同一样本上的联合回归中，阶段交互项为 -0.92，95% 区间 -2.33–0.59，包含零。所以达峰期规模仍然有用，但没有证据表明它比初期更有用或更没用。达峰期应当换用能跟踪基准变化的模型，同时继续维持病例规模。

报告制度变化提供了另一类证据（图 9）。从第一期到第二期，G_t 的标准差从 0.624 升到 1.823，增加 192%；第三期回到 0.649。稳健离散度几乎不动。四分位距为 0.638、0.594、0.652，第二期反而略低；中位绝对偏差为 0.298、0.299、0.292。偏度从 3.29 升到 14.98，再回到 2.68；G_t 的最大值从 12.7 升到 33.9。

若填报率下降只是均匀地稀疏了病例，标准差最多放大到 $0.624 \times \sqrt{91.11/54.59} = 0.806$，即 1.29 倍。实际放大了 2.92 倍，而且只有标准差放大、分位数指标不变。这说明扩张来自少数极端周，例如部分医院时报时不报造成的跳变；整体噪声并没有均匀增加。它与命题 3 只有定性联系。报告率下降会增加方差，但第二期的主要变化是结构性扰动，无法用 ρ 的变化定量解释。

6.5 稳健性与外部对照

图 10 汇总了各规格下的经验交叉点。规模项在所有规格下都为正；交叉点在 10.6–124.7 之间变化，这说明它只能作量级参考。

6.5.1 替代性滞后测度

D_t 与 C_{t+1} 同源，同期测度可能带来内生性。用滞后 3–5 周的规模作 $1/D_t$ 的工具变量，在流行季内合并样本（$N = 1{,}051$）上做两阶段最小二乘 [33]，得到 $b_{\text{iv}} = 2.53$（1.11–4.11），同一样本的普通最小二乘为 1.35，两者之差的 95% 区间为 0.30–2.11；对应交叉点 31.1。第一阶段 F 统计量为 1147.1，按州聚类为 312.9。排除限制无法检验，所以工具变量估计只说明在替代性滞后测度下，规模项保持为正。b_{iv} 高于普通最小二乘，与测量误差造成的衰减偏误方向一致 [36]。

6.5.2 事前基准

主分析的基准 $\overline{R}_{\text{early}}$ 用到了整个窗口的数据，属于回顾性口径。改用只含过去信息的基准后，误差整体上升。全部历史扩张窗的 $a = 0.406$，$b = 9.158$（5.82–12.88）；26 周滚动池的 $a = 0.222$，$b = 9.456$；逐州扩张

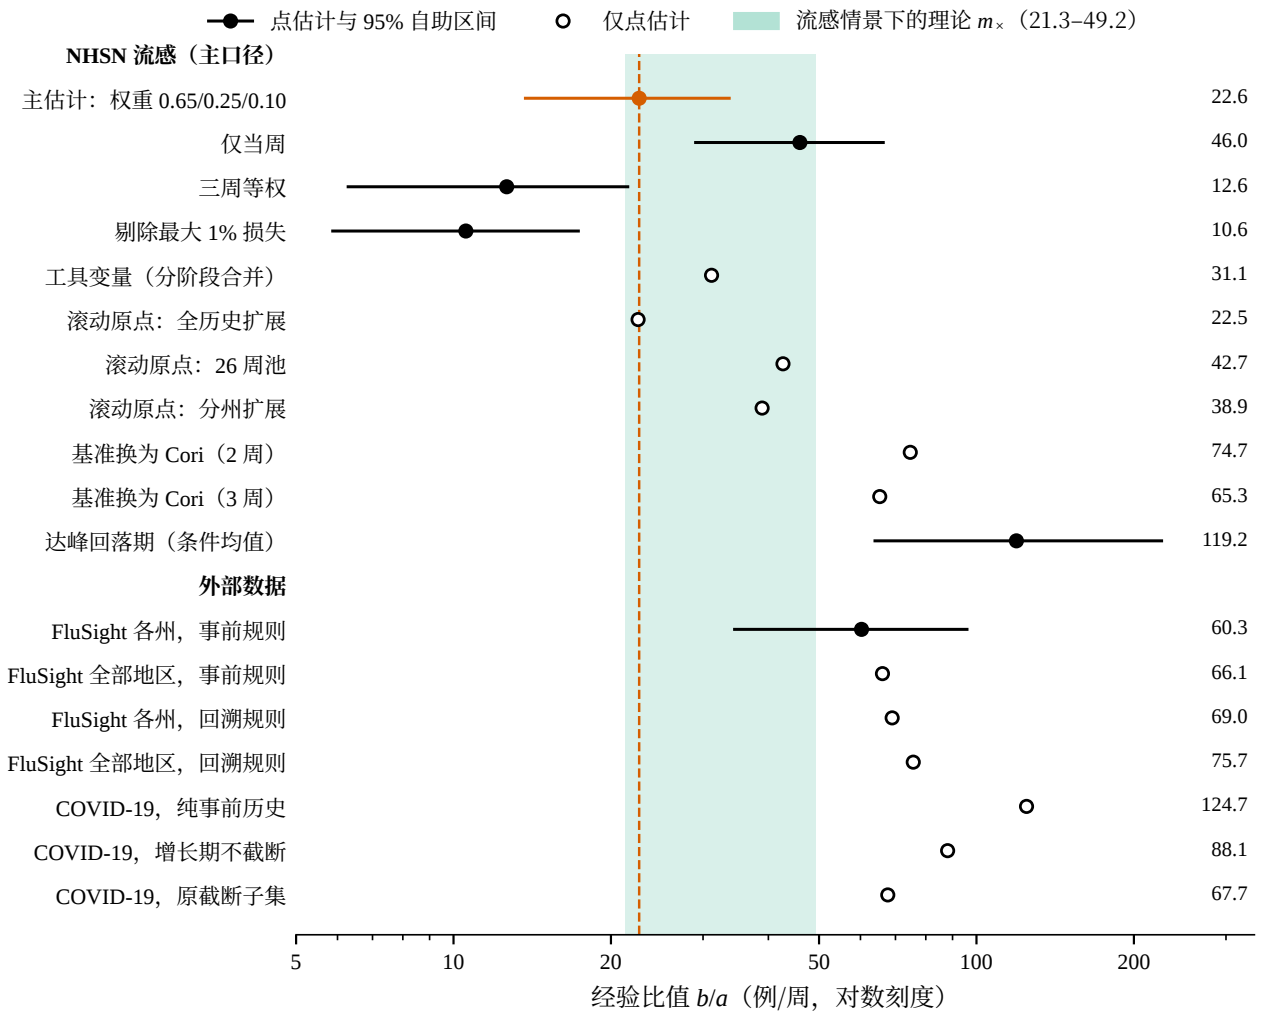


图 10 各规格下的经验交叉点 b/a。横线为 95% 区间（只有部分规格提供），阴影为理论情景区间 21.3–49.2，竖直虚线为主估计 22.6，右侧列出点估计。上部为 NHSN 数据的不同规格，下部为外部数据。

窗的 $a = 0.341$，$b = 13.27$。三种口径下所有重抽的 b 都为正，交叉点在 22.5–42.7。截距在总损失中的份额随口径在 39%–55% 移动。

6.5.3 时变基准

用 Cori et al. [8] 的滑动窗口估计 R_t 作预测，2 周窗与 3 周窗的平均损失为 0.288 和 0.249，阶段均值基准为 0.181，直接用本周病例数预测下周的朴素方法为 0.637。对 Cori 基准的损失拟合式 (14)，2 周窗 $a = 0.0812$、$b = 6.064$，交叉点 74.7；3 周窗交叉点 65.3。时变估计在小规模时自身噪声大，所以斜率更陡。

6.5.4 空间汇总

全国加总序列的流行初期平均规模约 6,662 例/周，平均损失降到 0.0348（中位数 0.0115，$N = 28$），约为单州截距的三分之一。按式 (5)，这对应一个小于 1 的州间环境相关 $\bar{c}$，粗略推算约为 0.34。这一推算忽略了分母噪声和 G_t 的口径问题，只能当作量级。

6.5.5 外部数据

FluSight 是美国疾病控制与预防中心组织的流感住院前瞻预测，我们使用其 2022–2023 季的集成预测 [38]，相关评价框架见文献 [39, 40]。以集成模型事前给出的预测规模 $\hat{Y} \geq 5$ 筛选州级样本（$N = 1{,}177$），$a = 0.1295$，$b = 7.805$（5.358–10.526），交叉点 60.3（34.5–95.9）；其余三种筛选口径为 66.1、69.0 和 75.7。把该集成预测在各流行阶段内的相对均方误差拆成均值偏差平方与阶段内方差两部分，均值偏差平方在峰期（$N = 206$）占 15.5%，

在上升期（$N = 216$）和回落期（$N = 755$）分别占 32.3% 和 1.5%。欧洲 11 国 2020 年 2–4 月的 COVID-19 序列 [41] 给出更大的交叉点。纯事前口径 $N = 404$，$b = 33.92$（14.60–74.99），交叉点 124.7；只取增长期为 88.1，截断子样本为 67.7。两组外部数据中规模项都为正，交叉点高于 NHSN 主估计。病种、预测方法和报告系统都不同，这些数字不宜直接比较大小。

7 讨论

7.1 对监测工作的含义

本文的核心区分是估计目标。同一份病例数据，用来判断本周是否在增长，与用来估计一段时期的平均传播水平，对规模的需求相差很大。前者属于目标 I，方差随规模趋于零，第 4.2 节的计算表明，要稳定检出 15% 的增长，所需规模约是交叉点的十倍。后者属于目标 II，规模超过 $m_\times$ 以后，误差主要来自环境波动，继续扩大病例捕获的回报迅速变小。

由此可以提出双轨监测的思路。对预警类问题，规模越大越好，资源应当投向报告及时、覆盖完整的单元。对趋势类问题，规模达到交叉点的量级后，更有效的做法是增加观测期数，或把多个辖区汇总。命题 4 和式 (5) 分别给出了时间和空间两个方向的收益；全国汇总序列的误差约为单州截距的三分之一，与后者的方向一致。

达峰期的结果提示了另一种失效方式。用初期均值预测峰期时，损失的 88.9% 来自基准偏移，规模再大也无济于事；但换用峰期自身的基准后，规模项又恢复为正。所以在流行阶段转换时，应优先更新基准模型；单靠扩大数据规模无法消除基准偏移。FluSight 集成预测在峰期的偏差占比为 15.5%（第 6.5 节），说明能跟踪阶段变化的预测模型可以大幅压低这一项，但这一对比来自不同的模型和样本，只能作方向性参考。

报告制度切换的证据需要谨慎解读。自愿填报期 G_t 的标准差大幅扩张，而四分位距和中位绝对偏差几乎不变，主要变化是少数极端周。对监测部门而言，这类结构性扰动比均匀的漏报更难处理，用稳健离散度监控数据质量会比标准差更可靠。

与已有研究相比，Parag 等的信息论结果针对的是当期再生数，信息随病例数线性增长 [1, 21]，这与本文目标 I 的结论一致。本文补充的是目标 II。环境方差 v_R 给出了一个规模无法突破的底板，交叉点 $m_\times$ 把这一底板换算成具体的病例数。生态学中环境随机性与人口随机性的区分 [4, 5] 在这里得到了一个监测设计上的对应。

7.2 局限

以下七点限定了上述结论的适用范围。

周增长比与单代再生数的口径不同。流感的世代间隔约 3 天，G_t 跨两代左右，其均值与方差都不同于模型中的 R_t。实证部分只检验了误差随规模的形状，拟合的 a、b 不能解读为 $v_R/\overline{R}^2$ 与 $A/\overline{R}^2$ 的估计。若要估计单代参数，需要日度数据或显式的世代间隔反卷积。

分母含有报告噪声。D_t 是带报告噪声的计数，第 6.3 节表明，它会抬高斜率而不抬高截距，使 b/a 系统性地高估 $m_\times$。二项噪声只解释了实证斜率的一半左右，剩余部分可能来自报告过程的超额离散，也可能另有来源，本文无法区分。经验交叉点随滞后权重在 12.6–46.0 之间变化，所以 22.6 只能当作量级。

单代公式在时间序列中不构成下界。式 (12) 的第一项可能高于也可能低于单代公式，更新过程仿真中两种情形都出现了。本文把单代公式作为参照曲线使用，没有用它判断实证误差是否“已到极限”。

环境存在时间相关。理论部分的 H4 要求规模与当期环境无关，更新过程仿真也让各周 R_t 独立。真实的 R_t 有时间相关，大规模往往出现在传播较快的时期。实证截距随回溯滞后上升，正是这种相关的表现。本文没有对 R_t 的相关结构建模，相关程度如何影响 a 的大小，有待进一步研究。

推断方法有两处不足。聚类重抽只在州或周一个维度上进行。州与周的双向聚类在聚类数较少时方差估计不稳定 [35, 42]，本文有 51 个州，而每个流行初期窗口只有 8–11 周，因此只报告了两个单向结果。工具变量回归的排除限制无法检验，结果只能作为替代测度下的稳健性证据。

部分参数依赖外部取值。情景区间依赖离散参数 k 和住院比例 ρ 的外部取值，二者在流感住院数据中都没有精确估计。精确增长检验也要求 k 已知，用估计值代入后，水平不再有精确保证。由全国序列推算的州间相关 $\bar{c} \approx 0.34$ 忽略了分母噪声和口径问题，只是粗略的量级。

样本窗口是事后划定的。第 6.5 节的事前基准只解决了基准的前视问题，没有解决窗口选择本身。第二期缺失的 36 个州周按 0 处理，在自愿填报期，未填报与零住院不能等同，这会影响第二期离散度的解读。

8　结论

扩大监测规模的收益取决于估计目标。估计当期再生数时，估计量 $C_t/(\rho n)$ 在每个有限规模上都达到 Cramér–Rao 下界，规模越大越准。估计跨期平均水平时，方差为 $v_R + A/m$，环境方差 v_R 构成一个规模无法突破的底板；交叉点 $m_\times = A/v_R$ 处两项方差相等，此后规模翻倍只能把方差降低不到四分之一。

这一结构给出了三条设计含义。扩大覆盖面比提高报告率更能压低方差，但对住院数据两者差别很小。多期预算下，最优单期规模为 $\sqrt{(c_0/c_1)m_\times}$。小规模时判断疫情是否增长，应使用精确检验，并报告“此后始终保持目标功效”的规模。

美国流感住院数据支持“常数加规模反比”的误差形状。流行初期的经验交叉点为 22.6 例/周，与情景区间同一量级，并在多种替代规格和两组外部数据中保持规模项为正。但截距与斜率都在情景隐含值的三倍以上，部分来自分母噪声，部分来自环境的时间相关。经验交叉点因此只能作为量级参考，不能当作结构参数的估计。

对监测实践而言，预警需要尽可能大的病例规模。趋势估计的规模到了交叉点量级以后，增加观测期数或汇总相邻辖区更有效。流行阶段转换时，应当先更新基准模型。

A　证明

本附录给出正文各命题的完整证明。负二项分布 NB(r,p) 取“失败次数”参数化，概率母函数为

$$G(s)=\frac{p^{r}}{[1-(1-p)s]^{r}},\qquad \mathrm{E}\,X=\frac{r(1-p)}{p},\quad \mathrm{Var}\,X=\frac{r(1-p)}{p^{2}}. \tag{16}$$

取 $r=k$、$p=k/(k+R)$，由式 (16) 即得式 (1) 中的均值与方差。

A.1　负二项分布的求和与稀疏

引理：若 $X_1,\dots,X_n$ 独立同分布于 NB(k,p)，则 $I=\sum_i X_i \sim$ NB(nk,p)；若再有 $C \mid I \sim \mathrm{Bin}(I,\rho)$，则 $C \sim$ NB(nk,p')，其中 $p'=p/[1-(1-p)(1-\rho)]$。

证明：独立和的概率母函数等于各项之积，故 $G_I(s)=G(s)^n$，即 NB(nk,p)。二项稀疏对应复合 $G_C(s)=G_I(1-\rho+\rho s)$。记 $q=1-(1-p)(1-\rho)$，则

$$G_C(s)=\frac{p^{nk}}{[q-(1-p)\rho s]^{nk}}=\frac{(p/q)^{nk}}{\{1-[(1-p)\rho/q]\,s\}^{nk}}.$$

由于 $1-p/q=(q-p)/q=(1-p)\rho/q$，$G_C$ 正是 NB$(nk,p/q)$ 的母函数。代入 $p=k/(k+R_t)$，得 $q=(k+\rho R_t)/(k+R_t)$，$p'=k/(k+\rho R_t)$，这就是式 (2)。式 (3) 由式 (2) 的均值与方差直接相除得到。　□

A.2　命题 1 的证明

记 c 为 C_t 的观测值，$\theta=\rho R_t$。由式 (2)，对数似然为

$$\ell(R_t)=\text{常数}+nk\log\frac{k}{k+\theta}+c\log\frac{\theta}{k+\theta}.$$

对 R_t 求导并整理，得分函数为

$$S(R_t)=\frac{c}{R_t}-\frac{(c+nk)\rho}{k+\rho R_t}=\frac{k\rho n}{R_t(k+\rho R_t)}(\widehat{R}_t-R_t). \tag{17}$$

(i) 当 $c>0$ 时，由式 (17)，S 在 $R_t<\widehat{R}_t$ 时为正，在 $R_t>\widehat{R}_t$ 时为负，似然在 $\widehat{R}_t$ 处取唯一最大值。当 $c=0$ 时，$S(R_t)=-nk\rho/(k+\rho R_t)<0$，似然在 $(0,\infty)$ 上严格递减，最大值在边界 $R_t=0$，与 $\widehat{R}_t=0$ 一致。

(ii) 由式 (2)，$\mathrm{E}\,\widehat{R}_t = \rho n R_t/(\rho n) = R_t$，且

$$\mathrm{Var}(\widehat{R}_t) = \frac{\rho n R_t + \rho^2 n R_t^2/k}{(\rho n)^2} = \frac{R_t}{\rho n} + \frac{R_t^2}{kn} = \frac{R_t(k+\rho R_t)}{k\rho n}.$$

(iii) Fisher 信息为得分函数的方差。由式 (17) 与 (ii) 得

$$\mathcal{I}(R_t) = \frac{(k\rho n)^2}{[R_t(k+\rho R_t)]^2}\,\mathrm{Var}(\widehat{R}_t) = \frac{k\rho n}{R_t(k+\rho R_t)} = \frac{n}{R_t/\rho + {R_t}^2/k}.$$

因此 $\mathrm{Var}(\widehat{R}_t) = 1/\mathcal{I}(R_t)$。式 (17) 表明得分函数是 $\widehat{R}_t - R_t$ 的倍数，这正是 Cramér–Rao 不等式取等号的充要条件，对每个有限 n 都成立。

(iv) 式 (2) 的概率函数可写为 $h(c)\exp[\eta c - \psi(\eta)]$，其中自然参数 $\eta = \log[\rho R_t/(k+\rho R_t)]$。$k$ 已知时这是单参数指数族；R_t 取遍 $(0,\infty)$ 时，η 取遍 $(-\infty, 0)$，含开区间，所以 C_t 是完备充分统计量。$\widehat{R}_t$ 是 C_t 的函数且无偏，由 Lehmann–Scheffé 定理，它是一致最小方差无偏估计 [25]。 □

A.3 命题 2 的证明

由 H4，给定 n 时 R_t 的均值与方差为 $\overline{R}$ 与 v_R。由命题 1(ii)，$\mathrm{E}(\widehat{R}_t \mid n, R_t) = R_t$，所以 $\mathrm{E}(\widehat{R}_t \mid n) = \overline{R}$。由全方差公式

$$\mathrm{Var}(\widehat{R}_t \mid n) = \mathrm{E}\{R_t/(\rho n) + R_t^2/(kn) \mid n\} + \mathrm{Var}(R_t \mid n) = \frac{\overline{R}}{\rho n} + \frac{\overline{R}^2 + v_R}{kn} + v_R.$$

以 $m = \rho n$ 代入，前两项之和为 A/m，得式 (4)。

(i) $A/m \to 0$。(ii) 规模项份额为 $(A/m)/(v_R + A/m) = 1/(1 + m v_R/A) = 1/(1 + m/m_\times)$。(iii) 翻倍降幅为 $[V(m) - V(2m)]/V(m) = [A/(2m)]/(v_R + A/m) = 1/[2(1 + m/m_\times)]$。(iv) $V'(m) = -A/m^2 < 0$，$V''(m) = 2A/m^3 > 0$；弹性为 $mV'(m)/V(m) = -(A/m)/(v_R + A/m) = -m_\times/(m + m_\times)$，在 $m = m_\times$ 处为 $-1/2$。 □

式 (5) 的推导如下。J 个环境项方差同为 v_R、两两相关系数平均为 $\bar{c}$ 时，其等权平均的方差为 $J^{-2}[J v_R + J(J-1)\bar{c} v_R] = v_R[\bar{c} + (1-\bar{c})/J]$。

A.4 命题 3 的证明

把式 (4) 写成 n 与 ρ 的函数

$$V(n,\rho) = v_R + \frac{\overline{R}}{\rho n} + \frac{\overline{R}^2 + v_R}{kn}.$$

(i) 令 $\rho \to 1$，第二项趋于 $\overline{R}/n > 0$，第三项与 ρ 无关且为正，故极限严格大于 v_R。(ii) 令 $n \to \infty$，后两项都趋于零。(iii) 由 $1/\rho = 1 + (1-\rho)/\rho$ 直接得到。(iv) 两个方向的边际效应为

$$-\frac{\partial V}{\partial \log n} = \frac{\overline{R}}{\rho n} + \frac{\overline{R}^2 + v_R}{kn} = \frac{A}{m}, \qquad -\frac{\partial V}{\partial \log \rho} = \frac{\overline{R}}{\rho n} = \frac{\overline{R}}{m}.$$

二者之比为 $A/\overline{R} = 1 + \rho(\overline{R}^2 + v_R)/(k\overline{R})$。 □

A.5 命题 4 的证明

设各期上一代人数均为 n，给定 $(R_1, \ldots, R_T)$ 时各期报告数相互独立。记 $\bar{R}_T = T^{-1}\sum_t R_t$。由全方差公式

$$\frac{1}{T^2}\,\mathrm{Var}\Big(\sum\nolimits_t \widehat{R}_t\Big) = \mathrm{Var}(\bar{R}_T) + \frac{1}{T^2}\sum_t \mathrm{E}\{R_t/(\rho n) + R_t^2/(kn)\} = \mathrm{Var}(\bar{R}_T) + \frac{A}{Tm}.$$

第二项等于 A/B，只依赖 R_t 的边际分布，与相关结构无关。R_t 独立时 $\mathrm{Var}(\bar{R}_T) = v_R/T$，得式 (6)。

一阶自回归情形下，$\mathrm{Cov}(R_s, R_t) = v_R r^{|s-t|}$，于是

$$T^2\,\mathrm{Var}(\bar{R}_T) = v_R\,T + 2v_R\sum_{h=1}^{T-1}(T-h)r^h, \qquad \sum_{h=1}^{T-1}(T-h)r^h = \frac{r[T(1-r) - (1-r^T)]}{(1-r)^2}.$$

后一个等式可对 T 归纳验证。代入整理即得式 (7)。

单调性。记 $S_T = T^2\,\mathrm{Var}(\bar R_T)$，$\Delta_j = v_R(1+2\sum_{h=1}^{j} r^h)$，则 $S_{T+1} = S_T + \Delta_T$，$S_T = \sum_{j=0}^{T-1}\Delta_j$。$\mathrm{Var}(\bar R_{T+1}) < \mathrm{Var}(\bar R_T)$ 等价于 $T^2\Delta_T < (2T+1)S_T$。数列 Δ_j 的增量 $2v_R r^{j+1}$ 递减，所以它是凹数列，满足 $\Delta_j \ge [(T-j)\Delta_0 + j\Delta_T]/T$。对 $j = 0, \dots, T-1$ 求和，得 $S_T \ge [(T+1)\Delta_0 + (T-1)\Delta_T]/2$。记 $d = \Delta_T - \Delta_0$，代入 $\Delta_0 = v_R$，有

$$(2T+1)S_T - T^2\Delta_T \ge (T+1)(Tv_R - d/2).$$

由于 $d = 2v_R\sum_{h=1}^{T} r^h < 2Tv_R$，右端为正。$r = 0$ 时即独立情形，单调性显然。 □

A.6 推论 1 的证明

由式 (6)，以 $T = \mathcal{B}/(c_0 + c_1 m)$、$B = Tm$ 代入，得

$$f(m) = \frac{(c_0 + c_1 m)(v_R + A/m)}{\mathcal{B}} = \frac{c_0 v_R + c_1 A + c_1 v_R m + c_0 A/m}{\mathcal{B}}.$$

$f'(m) = (c_1 v_R - c_0 A/m^2)/\mathcal{B}$，$f''(m) = 2c_0 A/(m^3\mathcal{B}) > 0$。$c_0 > 0$ 时 f 在 $(0,\infty)$ 上严格凸，唯一驻点为 $m^{*2} = c_0 A/(c_1 v_R) = (c_0/c_1)m_\times$。代回得 $f(m^*) = [c_0 v_R + c_1 A + 2\sqrt{c_0 c_1 v_R A}]/\mathcal{B}$，即式 (8)。

约束 $T \ge 1$ 等价于 $m \le (\mathcal{B} - c_0)/c_1$。若 m^* 超出这一范围，f 在可行区间上递减，最优解取右端点，即 $T = 1$。若 $c_0 = 0$，$f(m) = c_1(v_R m + A)/\mathcal{B}$ 严格递增，下确界在 $m \to 0$ 处取得。

整数解。$m = (\mathcal{B}/T - c_0)/c_1$ 关于 T 单调，而 f 关于 m 单峰，所以 f 作为 T 的函数也单峰，整数最优解是连续最优期数两侧的两个整数之一。正文的取整例子即按此比较。环境服从一阶自回归且 T 较大时，环境项约为 $v_R(1+r)/[(1-r)T]$，相当于把 v_R 换成 $v_R(1+r)/(1-r)$，于是 m^* 约乘以 $\sqrt{(1-r)/(1+r)}$。 □

A.7 命题 5 的证明

取 $R > R'$。由式 (2)，两者的似然比为

$$\frac{f(c;R)}{f(c;R')} = \frac{(k+\rho R')^{nk}\,[R(k+\rho R')]^{c}}{(k+\rho R)^{nk}\,[R'(k+\rho R)]^{c}}.$$

由于 $R/(k+\rho R)$ 关于 R 严格递增，方括号内大于 1，似然比关于 c 严格递增，分布族具有单调似然比。

(i) 对单调似然比族，形如 $\{C_t \ge c\}$ 的检验的功效函数关于 R_t 非降 [31]，所以在 $R_t \le 1$ 上的最大拒绝概率在 $R_t = 1$ 处取得，等于 $\alpha^* = P_{R_t=1}(C_t \ge c_\alpha) \le \alpha$。

(ii) 由 Karlin–Rubin 定理 [30]，对任意水平，形如“$C_t > c$ 时拒绝，$C_t = c$ 时以概率 γ 拒绝”的检验在该水平下一致最优。非随机检验 $\{C_t \ge c_\alpha\}$ 是 $c = c_\alpha - 1$、$\gamma = 1$ 的特例，所以在水平 α^* 下一致最优；适当选取 γ 可以使水平恰为 α。

(iii) $R_t = 1 + \delta$ 时，$C_t \sim \mathrm{NB}(nk, k/[k + \rho(1+\delta)])$，拒绝概率为 $1 - F_{\mathrm{NB}}(c_\alpha - 1)$，即式 (9)。 □

A.8 注 1、式 (12) 与式 (15) 的推导

以下所有期望都在 $\mathcal{F}_t$ 条件下取，$\overline{R}$、v_R 理解为 R_{t+1} 的条件均值与方差。记 $\bar\Lambda = \mathrm{E}(\Lambda_{t+1} \mid \mathcal{F}_t)$，$m = \rho\bar\Lambda$。第一次使用全方差公式，以 (Λ_{t+1}, R_{t+1}) 为条件

$$\mathrm{Var}(C_{t+1}) = \mathrm{E}(\rho\Lambda_{t+1}R_{t+1} + \rho^2\Lambda_{t+1}R_{t+1}^2/k) + \mathrm{Var}(\rho\Lambda_{t+1}R_{t+1}).$$

由条件独立，第一项为 $\rho\bar\Lambda\overline{R} + \rho^2\bar\Lambda(\overline{R}^2 + v_R)/k = m\,A$。第二步计算乘积的方差

$$\mathrm{Var}(\Lambda_{t+1}R_{t+1}) = \mathrm{E}(\Lambda_{t+1}^2)\,\mathrm{E}(R_{t+1}^2) - \bar\Lambda^2\overline{R}^2 = \bar\Lambda^2[v_R + \mathrm{CV}^2(\Lambda_{t+1})(\overline{R}^2 + v_R)].$$

两项相加后除以 m^2，即得式 (10)。

式 (12) 的推导如下。D_t 由 $\mathcal{F}_t$ 决定，所以 $\mathrm{E}(G_t \mid \mathcal{F}_t) = \mu_t/D_t$，$\mathrm{Var}(G_t \mid \mathcal{F}_t) = (\sigma_t/D_t)^2$。对 $\mathrm{E}[(G_t - \overline{R})^2 \mid \mathcal{F}_t] = \mathrm{Var}(G_t \mid \mathcal{F}_t) + [\mathrm{E}(G_t \mid \mathcal{F}_t) - \overline{R}]^2$ 再取期望即可。式 (11) 是两边同除以 $\overline{R}D_t$ 的代数恒等式。

式 (15) 的推导换用另一个条件。记 $\mathcal{H}_t$ 为截至第 t 周的真实感染史，并把式 (13) 的滞后权重当作感染压力的权重，即 $\Lambda_{t+1}=\sum_s w_s I_{t+1-s}$，$\sum_s w_s=1$。给定 $\mathcal{H}_t$，Λ_{t+1} 已经确定，取 $m=\rho\Lambda_{t+1}$。它与正文的 $m=\rho\,\mathrm{E}(\Lambda_{t+1}\mid\mathcal{F}_t)$ 相差一层报告噪声，式 (14) 的拟合又以 D_t 代替 m，式 (15) 描述的正是这层噪声。各周报告独立地服从 $C_{t+1-s}\mid I_{t+1-s}\sim\mathrm{Bin}(I_{t+1-s},\rho)$，所以分母的条件均值与条件方差为

$$\mathrm{E}(D_t\mid\mathcal{H}_t)=\rho\Lambda_{t+1},\qquad \mathrm{Var}(D_t\mid\mathcal{H}_t)=\rho(1-\rho)\sum_s {w_s}^2 I_{t+1-s}.$$

在平稳规模附近取 $I_{t+1-s}\approx\Lambda_{t+1}$，并令 $D_t=m(1+\delta)$，则 $\mathrm{E}\,\delta=0$，$\mathrm{E}\,\delta^2=c/m$，其中 $c=(1-\rho)\sum_s {w_s}^2$，而 $\mathrm{E}\,\delta^3$ 与 $\mathrm{E}\,\delta^4$ 都是 $O(m^{-2})$。记 $X=C_{t+1}/m$，于是 $G_t=X/(1+\delta)$。给定 $\mathcal{H}_t$，C_{t+1} 的报告抽样与此前各周的报告抽样相互独立，X 与 δ 独立，展开中没有交叉项。与第 3 节相同，$\mathrm{E}\,X=\overline{R}$，$\mathrm{Var}\,X=v_R+A/m$。把 $(1+\delta)^{-1}$ 展开到 δ^2 再取期望，得到

$$\mathrm{E}(G_t\mid\mathcal{H}_t)=\overline{R}\Big(1+\frac{c}{m}\Big)+O(m^{-2}),\qquad \mathrm{Var}(G_t\mid\mathcal{H}_t)=v_R+\frac{A+(\overline{R}^2+3v_R)\,c}{m}+O(m^{-2}).$$

只保留 δ 的一阶项时，方差的附加项是 $\mathrm{E}(R_{t+1}^2)\,c/m=(\overline{R}^2+v_R)\,c/m$。$\delta^2$ 的期望与 $1/m$ 同阶，它另外贡献 $2v_Rc/m$，并使条件均值上移 $\overline{R}c/m$。以条件均值的平方归一化，两处二阶效应相互抵消：

$$\frac{\mathrm{Var}(G_t\mid\mathcal{H}_t)}{[\mathrm{E}(G_t\mid\mathcal{H}_t)]^2}=\frac{v_R}{\overline{R}^2}+\frac{A+(1-\rho)(\overline{R}^2+v_R)\sum_s {w_s}^2}{\overline{R}^2\,m}+O(m^{-2}).$$

上式中 $1/m$ 的系数就是式 (15)。若按 L_t 的定义以固定的 $\overline{R}$ 归一化，系数变为 $[A+(1-\rho)(\overline{R}^2+3v_R)\sum_s {w_s}^2]/\overline{R}^2$。在第 6.3 节的情景参数下，主规格因此多出 0.021，约为式 (15) 的 1.8%，正文略去了这一项。

这一推导用到三个条件。第一，$\sum_s w_s=1$ 且 $I_{t+1-s}\approx\Lambda_{t+1}$。规模以周增长比 r 变化时，$\sum_s {w_s}^2$ 应换成 $\sum_s {w_s}^2 I_{t+1-s}/\Lambda_{t+1}$，主规格在 $r=1.67$ 时为 0.555，在 $r=0.8$ 时为 0.461。第二，各周报告抽样条件独立。若报告比例存在跨周的共同冲击，X 与 δ 相关，展开中会多出交叉项。第三，m 要足够大。对固定的 m 逐点枚举二项分布并截断 $D_t\geq 5$，主规格下 $m[\mathrm{CV}^2(G_t\mid\mathcal{H}_t)-v_R/\overline{R}^2]$ 在 $m=20$ 时为 1.223，在 $m=320$ 时为 1.159，按 $1/m$ 外推为 1.155，与式 (15) 一致；只用当周权重时，$m=20$ 处为 1.972，高阶余项已不可忽略。实证拟合以 D_t 代替 m，属于含噪回归元。第 6.3 节模拟值与预测值的差距来自这一步、$D_t\geq 5$ 的截断和小规模处的高阶余项，三者方向不同，部分相互抵消。

B 复现说明

第 3 节的蒙特卡洛核对在 $m\in[1,1000]$ 的 10 个规模上各做 20,000 次模拟，随机种子 20261013。第 5.2 节的更新过程仿真每个初始规模 400 条轨迹，随机种子 20261014。第 4.2 节的检验水平与功效全部由负二项分布函数精确计算，没有模拟误差。

实证数据为 NHSN 公开的州级每周流感住院数与医院填报比例 [24]，样本截至 2026 年 9 月。仿射拟合的区间由按州聚类的 1,500 次重抽得到，工具变量回归使用 10,000 次重抽。FluSight 与欧洲 COVID-19 数据分别取自文献 [38, 41] 公开的数据，聚类单位分别为州和国家。全部仿真、拟合与作图脚本随中间文件一并保存。

参考文献

[1] Kris V Parag, Christl A Donnelly, and Alexander E Zarebski. Quantifying the information in noisy epidemic curves. *Nature Computational Science*, 2(9):584–594, 2022.

[2] Benjamin D Dalziel, Stephen Kissler, Julia R Gog, Cécile Viboud, Ottar N Bjørnstad, C Jessica E Metcalf, and Bryan T Grenfell. Urbanization and humidity shape the intensity of influenza epidemics in U.S. cities. *Science*, 362(6410):75–79, 2018.

[3] David A Rasmussen, Oliver Ratmann, and Katia Koelle. Inference for nonlinear epidemiological models using genealogies and time series. *PLOS Computational Biology*, 7(8):e1002136, 2011.

[4] Steinar Engen, Øyvind Bakke, and Aminul Islam. Demographic and environmental stochasticity—concepts and definitions. *Biometrics*, 54(3):840–846, 1998.

[5] Pejman Rohani, Matthew J Keeling, and Bryan T Grenfell. The interplay between determinism and stochasticity in childhood diseases. *The American Naturalist*, 159(5):469–481, 2002.

[6] Jacco Wallinga and Peter Teunis. Different epidemic curves for severe acute respiratory syndrome reveal similar impacts of control measures. *American Journal of Epidemiology*, 160(6):509–516, 2004.

[7] Christophe Fraser. Estimating individual and household reproduction numbers in an emerging epidemic. *PLOS ONE*, 2(8):e758, 2007.

[8] Anne Cori, Neil M Ferguson, Christophe Fraser, and Simon Cauchemez. A new framework and software to estimate time-varying reproduction numbers during epidemics. *American Journal of Epidemiology*, 178(9):1505–1512, 2013.

[9] Robin N Thompson, J E Stockwin, R D van Gaalen, J A Polonsky, Z N Kamvar, P A Demarsh, E Dahlqwist, S Li, E Miguel, T Jombart, et al. Improved inference of time-varying reproduction numbers during infectious disease outbreaks. *Epidemics*, 29: 100356, 2019.

[10] Katelyn M Gostic, Lauren McGough, Edward B Baskerville, Sam Abbott, Keya Joshi, Christine Tedijanto, Rebecca Kahn, Rene Niehus, James A Hay, Pablo M De Salazar, et al. Practical considerations for measuring the effective reproductive number, R_t. *PLOS Computational Biology*, 16(12):e1008409, 2020.

[11] Pierre Nouvellet, Anne Cori, Tini Garske, Isobel M Blake, Ilaria Dorigatti, Wes Hinsley, Thibaut Jombart, Harriet L Mills, Gemma Nedjati-Gilani, Maria D Van Kerkhove, Christophe Fraser, Christl A Donnelly, Neil M Ferguson, and Steven Riley. A simple approach to measure transmissibility and forecast incidence. *Epidemics*, 22:29–35, 2018.

[12] Nicholas Steyn, Kris V Parag, Robin N Thompson, and Christl A Donnelly. A primer on inference and prediction with epidemic renewal models and sequential Monte Carlo. *Statistics in Medicine*, 44(18-19):e70204, 2025.

[13] James O Lloyd-Smith, Sebastian J Schreiber, P Ekkehard Kopp, and Wayne M Getz. Superspreading and the effect of individual variation on disease emergence. *Nature*, 438(7066):355–359, 2005.

[14] Akira Endo, Sam Abbott, Adam J Kucharski, and Sebastian Funk. Estimating the overdispersion in COVID-19 transmission using outbreak sizes outside China. *Wellcome Open Research*, 5:67, 2020.

[15] Adam J Kucharski, Timothy W Russell, Charlie Diamond, Yang Liu, John Edmunds, Sebastian Funk, and Rosalind M Eggo. Early dynamics of transmission and control of COVID-19: a mathematical modelling study. *The Lancet Infectious Diseases*, 20 (5):553–558, 2020.

[16] A Azmon, C Faes, and N Hens. On the estimation of the reproduction number based on misreported epidemic data. *Statistics in Medicine*, 33(7):1176–1192, 2014.

[17] Oliver Stoner, Theo Economou, and Gabriela Drummond Marques da Silva. A hierarchical framework for correcting under-reporting in count data. *Journal of the American Statistical Association*, 114(528):1481–1492, 2019.

[18] Johannes Bracher and Leonhard Held. A marginal moment matching approach for fitting endemic-epidemic models to underreported disease surveillance counts. *Biometrics*, 77(4):1202–1214, 2021.

[19] Carles Bretó, Daihai He, Edward L Ionides, and Aaron A King. Time series analysis via mechanistic models. *The Annals of Applied Statistics*, 3(1):319–348, 2009.

[20] Samir Bhatt, Neil Ferguson, Seth Flaxman, Axel Gandy, Swapnil Mishra, James A Scott, et al. Semi-mechanistic Bayesian modeling of COVID-19 with renewal processes. *Journal of the Royal Statistical Society Series A: Statistics in Society*, 186(4): 601–615, 2023.

[21] Kris V Parag and Christl A Donnelly. Fundamental limits on inferring epidemic resurgence in real time using effective reproduction numbers. *PLOS Computational Biology*, 18(4):e1010004, 2022.

[22] Kris V Parag, Ben Lambert, Christl A Donnelly, and Sandor Beregi. Asymmetric limits on timely interventions from noisy epidemic data. *Communications Physics*, 8:450, 2025.

[23] William G Cochran. *Sampling Techniques*. John Wiley & Sons, New York, 3rd edition, 1977.

[24] Centers for Disease Control and Prevention. *Weekly Hospital Respiratory Data (HRD) Metrics by Jurisdiction, National Healthcare Safety Network (NHSN)*, 2026.

[25] Erich L. Lehmann and George Casella. *Theory of Point Estimation*. Springer, New York, 2 edition, 1998.

[26] George Casella and Roger L. Berger. *Statistical Inference*. Duxbury, 2 edition, 2002.

[27] Hong Zhou, William W Thompson, Cécile G Viboud, Corinne M Ringholz, Po-Yung Cheng, Claudia Steiner, et al. Hospitalizations associated with influenza and respiratory syncytial virus in the United States, 1993–2008. *Clinical Infectious Diseases*, 54 (10):1427–1436, 2012.

[28] Jerome I Tokars, Sonja J Olsen, and Carrie Reed. Seasonal incidence of symptomatic influenza in the United States. *Clinical Infectious Diseases*, 66(10):1511–1518, 2018.

[29] James D. Hamilton. *Time Series Analysis*. Princeton University Press, Princeton, 1994.

[30] Samuel Karlin and Herman Rubin. The theory of decision procedures for distributions with monotone likelihood ratio. *The Annals of Mathematical Statistics*, 27(2):272–299, 1956.

[31] Erich L. Lehmann and Joseph P. Romano. *Testing Statistical Hypotheses*. Springer, New York, 3 edition, 2005.

[32] Nikos I Bosse, Sam Abbott, Anne Cori, Edwin van Leeuwen, Johannes Bracher, and Sebastian Funk. Scoring epidemiological forecasts on transformed scales. *PLOS Computational Biology*, 19(8):e1011393, 2023.

[33] Jeffrey M. Wooldridge. *Econometric Analysis of Cross Section and Panel Data*. MIT Press, Cambridge, MA, 2 edition, 2010.

[34] A. Colin Cameron, Jonah B. Gelbach, and Douglas L. Miller. Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics*, 90(3):414–427, 2008.

[35] A. Colin Cameron and Douglas L. Miller. A practitioner's guide to cluster-robust inference. *Journal of Human Resources*, 50(2): 317–372, 2015.

[36] Wayne A Fuller. *Measurement Error Models*. John Wiley & Sons, New York, 1987.

[37] Raymond J Carroll, David Ruppert, Leonard A Stefanski, and Ciprian M Crainiceanu. *Measurement Error in Nonlinear Models: A Modern Perspective*. Chapman & Hall/CRC, Boca Raton, 2nd edition, 2006.

[38] Shannon M Mathis, Alexander E Webber, Teresa M León, Eleanor L Murray, Monica Sun, Lauren A White, et al. Evaluation of FluSight influenza forecasting in the 2021–22 and 2022–23 seasons with a new target laboratory-confirmed influenza hospitalizations. *Nature Communications*, 15:6289, 2024.

[39] Nicholas G Reich, Craig J McGowan, Teresa K Yamana, Abhinav Tushar, Evan L Ray, Dave Osthus, Sasikiran Kandula, Logan C Brooks, Willow Crawford-Crudell, Graham Casey Gibson, Evan Moore, Rebecca Silva, Matthew Biggerstaff, Michael A Johansson, Roni Rosenfeld, and Jeffrey Shaman. Accuracy of real-time multi-model ensemble forecasts for seasonal influenza in the U.S. *PLOS Computational Biology*, 15(11):e1007486, 2019.

[40] Estee Y Cramer, Evan L Ray, Velma K Lopez, Johannes Bracher, Andrea Brennen, Alvaro J Castro Rivadeneira, Aaron Gerding, Tilmann Gneiting, Nicholas G Reich, et al. Evaluation of individual and ensemble probabilistic forecasts of COVID-19 mortality in the United States. *Proceedings of the National Academy of Sciences*, 119(15):e2113561119, 2022.

[41] Seth Flaxman, Swapnil Mishra, Axel Gandy, H Juliette T Unwin, Thomas A Mellan, Helen Coupland, Charles Whittaker, Harrison Zhu, Tresnia Berah, Jeffrey W Eaton, et al. Estimating the effects of non-pharmaceutical interventions on COVID-19 in Europe. *Nature*, 584(7820):257–261, 2020.

[42] A. Colin Cameron, Jonah B. Gelbach, and Douglas L. Miller. Robust inference with multiway clustering. *Journal of Business & Economic Statistics*, 29(2):238–249, 2011.