硕 士 学 位 论 文

疫情监测中的病例规模收益边界：估计目标、环境随机性与外部验证

Boundaries of Surveillance Scale Returns in Epidemic Monitoring: Estimation Targets, Environmental Stochasticity, and External Validation

学科专业：应用统计硕士 (MAS)

研究方向：流行病学建模与生物数学动力学

学位级别：硕士研究生

答辩日期：2026 年秋季

2026 年 10 月

摘　要

在传染病监测与公共卫生应急决策中，扩大病例捕获规模一直被视为提高推断精度的主要手段。大数定律暗示方差随样本量按 $O(1/m)$ 衰减，促使疾控机构在应对呼吸道传染病时不断扩大哨点网络和检测通量。然而，在真实大流行应对中，公共卫生系统频繁面临显著的“精度平台瓶颈”：在疫情高发期即便捕获上万病例，模型的短期预测误差依然居高不下；继续扩大监测网络所带来的推断增益极其微弱。

本文针对这一现实矛盾，从微观生物学生灭分支过程与宏观二项报告抽稀机制出发，构建了两阶段随机数据生成与推断分析框架，首次从数理上澄清了 ** 推断目标决定规模收益 ** 的根本规律：第一，若推断目标为当期瞬时再生数 R_t（目标 A），理论证明其无偏估计量的方差严格达到 Cramér–Rao 下界并随规模无界衰减，此时大数定律完全主导，样本越大越好；第二，若推断目标为跨期基础传播基准 $\bar{R}$（目标 B），由于单期横截面样本无法消除全员共享的宏观环境随机扰动，全方差分解严格导出了包含不可约环境方差底板 v_R 的仿射损失结构 $\mathrm{Var} = v_R + A/m$，并内生导出特征规模平衡点 $m_\times \equiv A/v_R$；第三，本文严格证明了监测杠杆的理论非对称性：提高报告率 $\rho \to 1$ 存在无法突破的方差下界，而扩大风险基数 $n \to \infty$ 方差收敛至 v_R；在运筹抽样设计中，证明了固定总人数预算下抽样误差恒为常数，并在显式经费约束下导出了最优单期规模闭式解，在数学形式上同构于经典 Cochran 两阶段抽样对偶模型。

在经验检验层面，本文采集全美 CDC NHSN 长达六年（2020–2026）、涵盖 50 州及华盛顿特区的 16,218 条周度真实住院记录（基于客观门槛筛选出 10,303 个活跃周分析样本）。采用可行广义最小二乘法（FGLS）与 1,500 次聚类 Bootstrap 检验，证实规模反比项高度显著为正（$\hat{b} = 2.2434$，95% CI $[1.50, 3.02]$），经验平衡点约为 22.6 例/周。均值–方差正交分解进一步揭示，达峰期看似恒定的高误差中整整 88.9% 源于基准漂移，剥离后规模项依然显著有用。最后，本文引入 CDC FluSight 官方多模型前瞻集成预测与欧洲 11 国早期 COVID-19 数据完成扩展验证，证实多模型集成可将达峰偏差剧烈压缩至 15.5%。上述结论为国家传染病监测体系在不同流行阶段由“单纯扩量”向“协同提质”的资源优化配置提供了坚实的量化基准。

关键词：病例规模；估计目标；不可约环境方差；负二项分支过程；特征平衡点；Cochran 抽样对偶；流行病学监测

Abstract

In infectious disease surveillance and public health decision-making, expanding case ascertainment has long been regarded as the primary lever for enhancing inferential precision. The law of large numbers suggests that estimation variance decays asymptotically at $O(1/m)$, encouraging public health agencies to continually expand sentinel networks and laboratory testing capacity. However, in real-world pandemic responses, surveillance systems consistently encounter a prominent "precision plateau": during transmission peaks, even when capturing tens of thousands of weekly hospitalizations, short-term forecasting errors remain elevated, and further scaling up case counts yields diminishing marginal improvements.

To address this empirical paradox, this thesis establishes a two-stage hierarchical stochastic framework integrating microscale Galton–Watson branching processes with macroscale binomial reporting thinning. We demonstrate that **the inferential target fundamentally governs surveillance scale returns**: First, when estimating the instantaneous reproduction number R_t (Target A), the variance of the uniform minimum-variance unbiased estimator (UMVUE) strictly achieves the Cramér–Rao lower bound and decays at $O(1/m)$ without an intrinsic floor, confirming that larger sample sizes are unconditionally advantageous. Second, when the objective shifts to estimating the intertemporal baseline transmission rate $\bar{R}$ (Target B), cross-sectional case counts cannot average out shared macro-environmental shocks. Law of total variance yields an affine loss structure $\mathrm{Var} = v_R + A/m$, characterized by an irreducible environmental floor v_R and an endogenous crossover scale $m_\times \equiv A/v_R$. Third, we establish the mathematical asymmetry of surveillance levers: eliminating underreporting ($\rho \to 1$) leaves a strictly positive variance lower bound, whereas expanding population base ($n \to \infty$) asymptotically drives total variance to v_R. Under operational cost constraints, we prove the strict convexity of the objective variance function and derive the closed-form optimal batch scale, demonstrating mathematical duality with classical Cochran two-stage sampling theory.

Empirically, we analyze 16,218 state-week records spanning six years (2020–2026)

from the US CDC NHSN hospital surveillance system, isolating 10,303 active observations under objective filtering. Feasible generalized least squares (FGLS) and 1,500 cluster bootstraps confirm a strictly positive scale coefficient ($\hat{b} = 2.2434$, 95% CI $[1.50, 3.02]$) and an empirical crossover of 22.6 cases/week. Orthogonal variance decomposition reveals that 88.9% of peak forecasting error arises from baseline shift rather than sample size failure. Finally, out-of-sample evaluations using CDC FluSight multi-model prospective forecasts and European COVID-19 daily surveillance confirm that multi-model ensembling suppresses peak bias down to 15.5%. These findings provide rigorous quantitative benchmarks for resource allocation in public health surveillance.

Keywords: Case Count Scale; Estimation Targets; Irreducible Environmental Stochasticity; Negative Binomial Branching Process; Characteristic Crossover; Cochran Sampling Duality; Epidemic Surveillance

目录

摘要 ii

Abstract iii

第一章 绪 论 1

1.1 研究背景与问题提出 1

1.1.1 传染病监测的世纪演进：从宏观仓室到微观统计推断 1

1.1.2 公共卫生应急决策中的“规模崇拜”困境与现实悖论 2

1.2 国内外研究现状与文献综述 2

1.2.1 时变再生数估计方法的演进历程 3

1.2.2 微观生物学超传播与过度离散建模 3

1.2.3 信息论极限与既有文献的关键缺口 4

1.3 本文研究动机与核心科学贡献 5

1.3.1 核心研究动机 5

1.3.2 主要学术贡献 6

1.4 论文结构安排与技术路线 7

第二章 动力学建模与观测机制 9

2.1 微观生灭分支过程与生物学超传播机制 9

2.1.1 经典 Galton–Watson 分支过程与代际传递 9

2.1.2 个体传染力的 Gamma 连续混合模型：从微观连续积分到负二项 PMF 9

2.1.3 成功概率 p 的反直觉统计物理顿悟 11

2.2 宏观观测系统的不完全性与二项报告抽稀过程 12

2.2.1 二项报告抽稀的形式化定义 12

2.2.2 报告率参数 ρ 的真实流行病学折算逻辑 13

2.3 概率母函数复合律与分布族保族封闭性定理 13

2.3.1 单代独立感染者和的概率母函数 13

2.3.2 PGF 复合运算与分布族封闭性证明 14

2.3.3 观测变量的二阶矩结构解析 15
2.4 微观分支过程与宏观确定性仓室 ODE 的流体极限动力学桥梁 16
2.4.1 经典 Kermack–McKendrick SIR 动力系统与相空间稳定性 . . . 16
2.4.2 纯跳跃马尔可夫生灭过程的生成元与鞅表示 17
2.4.3 Kurtz 密度相关大数定律（Fluid Limit Theorem） 17
2.4.4 动力学理论定位与本文研究切入点 18
2.5 呼吸道传染病过度离散参数 k 经验校准综述 18
2.5.1 主要病原体离散参数测量大表 18
2.5.2 对本文参数设定的启示 18

第三章 统计推断与运筹优化理论 20
3.1 推断目标分化：瞬态参数与跨期平稳基准 20
3.2 目标 A 的点估计与 Cramér–Rao 渐近有效性 20
3.3 目标 B 的全方差分解与仿射损失结构 24
3.3.1 不可约宏观环境方差的数理引入 24
3.3.2 全方差公式展开与仿射损失结构推导 24
3.3.3 特征规模平衡点 $m_\times$ 的内生导出与物理意义 25
3.4 监测杠杆的理论非对称性定理 26
3.5 多期时间抽样设计与样本预算恒常性 27
3.6 经费预算约束下的运筹优化与 Cochran 抽样对偶 29

第四章 蒙特卡洛数值模拟与机制检验 32
4.1 模拟实验规格与算法设计 32
4.1.1 算法环境与负二项离散生成机制 32
4.2 命题 5：超临界增长检测的精确检验与离散功效锯齿 32
4.2.1 单调似然比（MLR）一阶对数差分严格为正证明 32
4.2.2 数值实验发现：Wald 正态近似失真与超传播惩罚 34
4.3 命题 6：更新过程条件预测误差全方差分解 35
4.3.1 两步全方差公式展开与式 (29) 偏差项推导 35
4.3.2 更新过程双口径争议彻底澄清 37

第五章 全美流感住院大数据实证分析 39
5.1 数据来源与样本量筛选漏斗 39
5.1.1 CDC NHSN 监测系统背景与面板数据结构 39
5.1.2 核心客观筛选门槛与样本加和闭环 39

5.1.3 滞后暴露加权向量的临床时滞依据与敏感性检验 40
5.2 计量模型构建与可行广义最小二乘法（FGLS） 42
5.2.1 普通最小二乘法（OLS）在监测数据中的失效分析 42
5.2.2 FGLS 迭代加权回归算法与聚类 Bootstrap 42
5.3 流行初期主实证结果与仿射结构验证 43
5.3.1 核心参数估计结果 43
5.4 达峰期震撼反转：88.9% 常数偏差与正交分解 46
5.4.1 传统认知误区与表象困境 46
5.4.2 均值–方差正交分解定理与反转证实 46
5.5 制度冲击与空间汇聚检验 48
5.5.1 检验三：2024 年自愿填报政策切换的微观噪声冲击 48
5.5.2 检验四：全国 51 辖区空间汇聚收益的对偶性 48
5.6 全美空间分层异质性与稳健性全景检验 49
5.6.1 四大地理分区子样本仿射拟合 49
5.6.2 三大人口规模梯队的分层检验 49

第六章 跨模型与跨病种外部扩展验证 52
6.1 外部验证的设计原则与独立性界定 52
6.1.1 为什么必须开展外部独立场景验证? 52
6.2 CDC FluSight 官方多模型前瞻集成预测验证 53
6.2.1 数据源架构与纯事前样本筛选规范 53
6.2.2 集成预测实证估计结果 53
6.2.3 达峰期均值偏差剧烈消除：多模型集成的终极价值 53
6.3 欧洲 11 国 COVID-19 早期传播跨病种扩展验证 55
6.3.1 欧洲 11 国早期大流行日度监测数据背景 55
6.3.2 纯事前增长样本筛选与参数估计 55
6.4 外部验证的核心启示与经验边界界定 57

第七章 监测资源优化策略与研究展望 58
7.1 国家公共卫生监测体系的资源配置策略矩阵 58
7.1.1 流行初期与低发期 ($m < m_{\times}$) ——「全力扩量，迅速越峰」 . . 58
7.1.2 流行达峰与饱和期 ($m > m_{\times}$) ——「战略提质，协同平滑」 . . 58
7.2 研究局限性与方法学边界 59
7.2.1 不可约环境方差 v_R 始终为拟合量而非物理直接测量量 59

7.2.2 观测覆盖率变动与事件级二项抽稀的微观机制差异 59
7.2.3 时间序列卷积中的单向因果性与内生性 60
7.3 未来研究展望：双轨前瞻主动追踪队列的解耦设计 60
7.4 本章小结与全文总结 60
7.5 面向疾控机构的监测资源优化配置量化操作手册 61
7.5.1 第一步：监测系统基线参数测定与建档 61
7.5.2 第二步：暴露规模在线滑动卷积监控 61
7.5.3 第三步：两阶段资源调度自动切换规则 62

附录 A 数学命题保姆级代数推导补充 63
A.1 命题 1 中得分函数负二阶导期望的逐步代数推导 63
A.2 命题 4 中 AR(1) 错位相减求和级数推导补遗 63
A.3 推论 1 成本优化函数一阶导驻点与二阶导符号判定 64

附录 B 核心模拟与计量回归 Python 源码清单 66
B.1 负二项分支过程与二项报告抽稀离散仿真实现 66
B.2 命题 5 超临界增长精确检验与临界值枚举算法 67
B.3 两阶段可行广义最小二乘法 (FGLS) 迭代回归算法 68
B.4 按州聚类非参数 Bootstrap 统计推断算法 70

插图

1.1 **全文研究技术路线与端到端理论推断全景架构图**。展示从已知输入（真实观测数据流、生物学先验参数与运筹成本约束）到微观分支机制、渐近推断方差分解（目标 A 与目标 B 的分化）、监测运筹优化（Cochran 抽样对偶）、假设检验天花板，直至全美真实流感住院大数据计量检验与公共卫生决策矩阵的端到端逻辑闭环。 7

4.1 **早期暴发检验尺度效应、功效边界与超传播惩罚**。(a) 一类错误率控制：渐近正态 Wald 检验（虚线）在低病例规模（$m < 40$）且严重超传播（$k = 0.1$）时经验一类错误率最高达 8.1%（$m = 5$），系统性高于名义水平 0.05（严重虚警）；离散精确负二项检验（实线）在全样本网格上严格控制错误率低于 0.05。(b) 检出功效曲线随备择强度 $\delta = R_t - 1$ 的响应：在 $k = 0.35$ 时，达到 80% 功效所需的期望报告规模由微弱暴发 $\delta = 0.15$ 的 $m = 517.8$ 急剧下降至 $\delta = 0.30$ 的 $m = 142.0$ 与 $\delta = 0.50$ 的 $m = 57.2$。(c) 个体超传播离散度 k 的杠杆惩罚：在 $\delta = 0.25$ 增长强度下，达到 80% 检出功效所需的期望病例数从低异质性 $k = 1.0$ 的 $m = 142.0$ 急剧上升至严重超传播 $k = 0.1$ 的 $m = 415.0$，规模需求放大了近 3 倍。标称显著性水平 $\alpha = 0.05$，基准报告率 $\rho = 0.25$。 . . . 35

4.2 **更新过程时序卷积下事后增长统计量与事前单步病例预测误差**。(a) 事后代理增长统计量随规模衰减轨迹，在中大规模段贴合单代参照 $v_R + A/m$，在小规模段被随机分母二次放大。(b) 事前病例预测相对均方误差（RelMSE）与参照曲线对比。(c) 边际削减收益定量衰减规律：规模翻倍的方差下降比例严格由式 (4.19) 给出，越过平衡点后急剧放缓。 37

5.1 **全美流感住院实证拟合、分箱分布与机制分解**。(a) 真实全美 50 州流感住院数据 FGLS 仿射拟合线（实线）与分箱样本均值（散点及误差棒）高度契合；(b) 各规模区间内的离散度比值 $\mathrm{Var}/\mathrm{Mean}^2$ 随病例数从小规模段的 5.32 单调收敛至大规模段的 0.99；(c) 达峰期看似恒定的高误差中，88.9% 来自基准漂移，剥离后纯条件方差依然显著随规模递减；(d) 政策冲击与空间汇聚检验。 45

表格

1.1 本文与既有核心文献在模型机制与推断理论维度的系统对比 5

2.1 全球主要人类传染病生殖数过度离散参数 k 实证测量元分析汇总表 . . 19

5.1 全美流感住院实证数据筛选漏斗与样本量划分全景表 41
5.2 滞后暴露加权向量 w 的敏感性检验结果对比表 42
5.3 全美 CDC NHSN 流感住院实证主回归与稳健性检验估计结果 44
5.4 全美流感住院达峰期预测误差正交分解与各规模分箱对照表 47
5.5 全美四大地理分区流感住院初期仿射模型分层估计对比表 50
5.6 按辖区常住人口规模梯队划分的流感住院仿射分层估计表 51

6.1 CDC FluSight 官方多模型前瞻集成预测实证估计与敏感性对照表 . . . 54
6.2 欧洲 11 国早期 COVID-19 日度监测实证估计与口径敏感性对比 . . . 56

第一章　绪　论

1.1　研究背景与问题提出

1.1.1　传染病监测的世纪演进：从宏观仓室到微观统计推断

自二十世纪初近代数理流行病学创立以来，定量刻画传染病传播动态、评估防控干预成效一直是应用数学、统计学与公共卫生交叉领域的核心前沿。1927 年，Kermack 与 McKendrick 提出了划时代的确定性仓室易感–感染–移出（SIR）常微分方程模型 [Kermack and McKendrick, 1927]，首次奠定了通过微分方程动力系统定性理论研究传染病临界暴发阈值的理论根基。在过去的近一个世纪中，以 Anderson 与 May [Anderson and May, 1991]、Hethcote [Hethcote, 2000] 以及马知恩先生学派 [马知恩 et al., 2004, 马知恩 and 周义仓, 2001] 为代表的学者们，将常微分方程稳定性理论、下一代矩阵法 [Diekmann and Heesterbeek, 2000, Diekmann et al., 1990] 与分岔分析深入引入传染病动力学，确立了基本再生数 $\mathcal{R}_0$ 作为无病平衡点局部与全局渐近稳定性的核心判据。

然而，经典确定性微分方程仓室模型本质上依赖于“大数定律完全成立”的流体极限假定（Fluid Limit Theorem）[Kurtz, 1970, 1971]，即假设易感人群与感染人群规模无限大、个体接触完全均匀混合、系统演化完全遵循确定性均值轨道。进入二十一世纪，随着全球化人口流动加剧、新型呼吸道病原体（如 SARS、高致病性禽流感、H1N1 新型流感及 COVID-19）频繁爆发，真实疫情传播展现出高度复杂的随机性特征。一方面，真实世界中的传染病暴发始于少数感染个体的微观随机链式反应，必须借助随机生灭过程与 Galton–Watson 分支过程进行建模 [Britton, 2010, Harris, 1963, Jagers, 1975]；另一方面，流行病学决策者往往无法直接观测到全社会底层的全部感染状态，只能通过哨点医院网络记录到带有严重滞后与漏报的病例计数时序序列。

在此背景下，传染病监测的推断范式经历了从“基于大样本长时程拟合静态参数”向“基于实时观测病例流估计时变瞬时再生数 R_t”的深刻转变。时变再生数 R_t 定义为在 t 时刻特定的防控干预、气象环境与人群行为条件下，平均一个感染者引发的二次感染人数。由于 $R_t = 1$ 精确对应了动力系统在相空间中的稳定临界分界线，实时监测 R_t 是否越过 1 成为指导学校停课、医疗资源调度与口罩令实施的关键决策指针。

1.1.2 公共卫生应急决策中的“规模崇拜”困境与现实悖论

伴随现代生物检测技术通量的激增与数字化疫情直报网络的普及，公共卫生监测实践中普遍滋生了一种强烈的经验预设，即所谓的 **“监测规模崇拜”**（Surveillance Scale Worship）。这一直觉认为：

> “捕获的数据越多越好，样本量越大推断越准。只要疾控机构不断增加检测哨点、扩大医院上报覆盖面、增加报告确诊人数（即增大病例样本规模 m），统计推断与前瞻预测的不确定性就能被无界压缩。”

这一直觉在纯粹的数理统计抽样理论中似乎不言自明——大数定律与中心极限定理指出，独立同分布样本均值的估计方差随样本量按 $O(1/m)$ 速率严格递减，因此投入更多资源捕获更多病例，理应获得更高的预测精度。

然而，在多次全球性重大传染病暴发的应对实务中，世界卫生组织（WHO）及各国疾控中心频繁陷入极其尴尬的现实困境：

(1) ** 高峰期预测精度平台瓶颈 **：在疫情高发暴发期，医疗监测系统每周能捕获成千上万例确诊住院病例，但前瞻预测模型的相对误差往往依然居高不下；

(2) ** 边际扩网收益锐减 **：卫生部门投入巨额财政资金成倍扩建检测网络后，对未来趋势判断的改善却极其微弱，迅速陷入明显的平台钝化期；

(3) ** 资源错配困境 **：在疫情低发期或早期，由于病例稀疏，系统饱受抽样噪声干扰而频繁产生虚警或漏报；而在高发期，巨额采样资源堆积在已被证实处于饱和状态的大型医院，造成基层流调资源的严重浪费。

面对这一现实矛盾，流行病学界以往多笼统地归咎于“医院瞒报漏报”、“公众就医行为改变”或“具体预测模型结构设定不当”。但这些定性解释始终未能回答一个根本性的数学与统计学科学设问：

在资源受限情境下，无限扩大病例报告规模的边际方差收益何时递减？
微观抽样误差与宏观环境噪声究竟如何抗衡？
是否存在一个内生决定且可严格解析计算的特征规模临界平衡点？

1.2 国内外研究现状与文献综述

为了系统厘清上述科学设问的学术渊源，本节系统梳理时变再生数估计、超传播离散建模、信息论极限及运筹抽样设计的既有研究脉络，并剖析既有理论的关键缺口。

1.2.1 时变再生数估计方法的演进历程

在实时再生数估计领域，早期的经典方法依赖于回顾性代际追踪。Wallinga 与 Teunis [Wallinga and Teunis, 2004] 提出了基于病例对（Pairwise）相对发病时间间隔概率的拟似然估计法（WT 方法）。然而，WT 方法本质上估计的是“病例队列再生数”（Case Reproduction Number），即一个特定发病日期的感染者在其整个病程中引发的总后续感染数，这导致其在疫情当周无法实时结算，必须等待一个完整潜伏传播周期后才能完成回顾性后验修正，存在长达数周的结构性时滞 [Cauchemez et al., 2006, Fraser, 2007]。

为了消除这一回顾性时滞，Fraser [Fraser, 2007] 提出了基于更新方程（Renewal Equation）的瞬时再生数理论框架。在假定感染代际时间（Generation Time）分布已知的前提下，当期新发感染数可表示为历史感染压力的加权卷积：

$$I_t = R_t \sum_{s=1}^{t} I_{t-s} w_s, \tag{1.1}$$

其中 w_s 为代际间隔概率密度。随后，Cori 等人 [Cori et al., 2013] 在《American Journal of Epidemiology》上发表了标志性的 EpiEstim 框架。EpiEstim 假设在滑动的局部时间窗口 τ 内传播强度恒定，假定观测病例在给定历史卷积压力下服从泊松分布，并利用共轭 Gamma 先验导出了后验分布的解析闭式解。Thompson 等人 [Thompson et al., 2019] 进一步将该框架推广至考虑输入病例与本土病例分化的场景；Gostic 等人 [Gostic et al., 2020] 则系统评估了就医填报时滞反卷积平滑对 EpiEstim 稳定性的影响。

然而，EpiEstim 及其衍生方法的核心假设均建立在 ** “条件独立泊松分布” ** 之上。在数理统计上，泊松分布强制方差等于均值，这一假定严重忽略了真实人类传染病中普遍存在的微观超传播特征。

1.2.2 微观生物学超传播与过度离散建模

真实传染病的传播过程绝非均匀微观相遇。2005 年，Lloyd-Smith 等人 [Lloyd-Smith et al., 2005] 在《Nature》上发表了奠基性论文，通过对全球 8 种传染病的历史个体接触追踪数据进行元分析，证实人类传染病普遍遵循“20/80 法则”——即大约 20% 的高感染力个体引发了全社会 80% 的二次感染事件（所谓的“超级传播事件”，Superspreading Events, SSEs）。

Lloyd-Smith 等人提出用 ** 负二项分支过程（Negative Binomial Branching Process）** 替代经典泊松分支过程，其微观机制是个体感染力服从 Gamma 混合泊松分

布：

$$Y_{t,j} \mid \nu_{t,j} \sim \text{Poisson}(\nu_{t,j}), \quad \nu_{t,j} \sim \text{Gamma}\left(k, \frac{R_t}{k}\right), \tag{1.2}$$

从而积分边缘化导出个体子代二元分布 $Y_{t,j} \sim \text{NB}(k, \frac{k}{k+R_t})$，其方差结构为：

$$\text{Var}(Y_{t,j}) = R_t + \frac{R_t^2}{k}. \tag{1.3}$$

在此模型中，k 被定义为 ** 生物学生殖数过度离散参数 **（Dispersion Parameter）。当 $k \to \infty$ 时，模型退化为经典泊松分布；当 $k \to 0$ 时，模型表现出极端的重尾特征。随后的 COVID-19 大流行研究中，Endo 等 [Endo et al., 2020]、Althouse 等 [Althouse et al., 2020] 及 Sneppen 与 Simonsen [Sneppen and Simonsen, 2021] 广泛证实新型冠状病毒的离散参数极低（$k \approx 0.1 \sim 0.3$），表现出极强的超传播倾向。

过度离散特性的引入，意味着微观传染具有极高的重尾随机涨落。如果疾控系统收集到的样本量有限，少量超级传播者的出现或缺席将引发剧烈的抽样方差，常规渐近正态近似将在小计数区间彻底失真。

1.2.3 信息论极限与既有文献的关键缺口

近年来，物理学家与应用数学家开始尝试利用信息论工具探究带噪疫情曲线的推断极限。2022 年，牛津大学的 Parag 等人 [Parag et al., 2022] 在《Nature Physics》上发表封面论文《Fundamental limits on inferring epidemic dynamics from noisy case count data》，利用 Fisher 信息矩阵（Fisher Information Matrix）与 Cramér–Rao 下界，系统推导了在不完全报告与观测噪声下估计再生数的信息量上限。

Parag 等人的核心结论表明：观测曲线所包含的 Fisher 信息量 $\mathcal{I}(R_t)$ 随观测病例数近似呈线性增长。这一结论在物理学界引起了广泛关注，但其推导隐含了一个关键前提——** 其推断目标始终锚定在“当期特定微观环境下的瞬态参数 R_t”**。

这正是既有文献留下的 ** 最致命的理论断裂与盲区 **：

(a) ** 推断目标的严重混淆 **：实际公共卫生决策者需要的往往不是某一周受微观偶然扰动影响的单期瞬态抖动值 R_t，而是能够反映潜在流行趋势、消除单周气象或节假日偶发波动的 ** 跨期平稳传播基准 $\bar{R}$**。既有文献从未区分这两个目标在方差标度律上的本质分化。

(b) ** 忽视不可约宏观环境噪声 **：在宏观动力学系统中，除了个体抽样的人口统计随机性（Demographic Stochasticity）外，全社会所有感染者不可避免地共同暴露于宏观气象变迁、社会流动潮汐与政策突变等 ** 不可约环境随机性（Environmental Stochasticity）** 之下。当估计跨期基准时，单期样本无论扩大到多大，本质上都只能捕获该宏观环境在该期的一个实现值！

(c) ** 缺乏运筹维度的经济学对偶 **：既有流行病学研究多停留在“被动给定样本下评估误差”，鲜有将统计推断方差分解与实际监测网络的运作预算、时间抽样期数与单期规模进行联合运筹优化。

表 1.1 系统总结了本文与既有标志性文献在建模维度与推断性质上的本质对比。

表 1.1: 本文与既有核心文献在模型机制与推断理论维度的系统对比

比较维度	**经典仓室 ODE (Kermack)**	**EpiEstim 框架 (Cori 2013)**	**信息论界限 (Parag 2022)**	**本文理论框架**
微观生成机制	宏观确定性连续流体	条件独立泊松分布	状态空间观测模型	负二项超传播分支过程
宏观报告环节	假定完全无偏报告	静态先验平滑假定	独立乘性高斯/泊松噪声	条件二项报告抽稀保族过程
核心推断目标	静态渐近参数 $\mathcal{R}_0$	局部滑窗时变 R_t	单期瞬态连续参数 R_t	** 区分瞬态 R_t 与跨期基准 $\bar{R}$**
环境变异考量	无(确定性流形)	无（完全吸收入先验）	视为普通可加测量噪声	** 显式建模不可约环境方差 v_R**
规模收益结论	无样本规模维度	样本越大后验方差越小	信息量随病例数线性增长	** 存在内生特征平衡点 $m_\times$**
运筹成本对偶	无	无	无	** 同构于 Cochran 两阶段抽样 **
真实大数据检验	历史唯象拟合	局部小样本演示	数值仿真为主	** 全美 1.6 万记录与外部多病种 **

1.3 本文研究动机与核心科学贡献

1.3.1 核心研究动机

立足于上述理论断裂与现实困境，本文旨在打破“规模越大越好”的传统单一教条，建立一套贯通 **“微观超传播分支过程 → 宏观二项报告抽稀 → 渐近推断方差分解 → 运筹抽样设计 → 真实大数据计量检验”** 的完整理论与实证闭环体系，精

准回答流行病学监测资源何时应当由“单纯扩充数量”转向“结构性协同提质”。

1.3.2 主要学术贡献

本文的核心学术创新可概括为以下四项支柱性贡献：

1. ** 理论框架破局：确立“推断目标决定规模收益”的方差标度律分化 **
本文从微观概率母函数（PGF）复合律出发，严密证明了负二项分支过程在二项抽样下具有严格的分布族封闭性。在此基石上，本文证明：若目标为当期瞬态再生数 R_t（目标 A），估计量方差达到 Cramér–Rao 下界并随规模 m 按 $O(1/m)$ 无界衰减；若目标为跨期基础传播基准 $\bar{R}$（目标 B），全方差分解严格导出了包含不可约环境方差底板 v_R 的仿射损失结构：

$$\mathrm{Var} = v_R + \frac{A}{m}, \tag{1.4}$$

并内生导出了刻画人口统计随机性向环境随机性跃迁的特征规模平衡点 $m_\times \equiv A/v_R$。

2. ** 运筹机制创新：证明监测杠杆非对称性与 Cochran 两阶段抽样对偶 **
在监测杠杆比较上，本文严格证明了提高报告率 $\rho \to 1$ 无法突破微观泊松与超传播方差下界，而扩大风险基数 $n \to \infty$ 方可使方差收敛至 v_R。在运筹设计上，本文证明在固定总样本人数预算 $B = Tm$ 下微观抽样误差恒为常数 A/B；并在显式经费预算约束 $\mathcal{B} = T(c_0 + c_1 m)$ 下证明了目标方差函数的严格凸性，推导出最优单期规模闭式解 $m^* = \sqrt{\frac{c_0}{c_1} m_\times}$，在数学结构上完美同构于经典抽样调查 Cochran 两阶段最优分配模型。

3. ** 数理与仿真深化：解析离散功效锯齿波与更新过程预测双口径机制 **
针对爆发早期假设检验 $H_0 : R_t \le 1$，本文证明单调似然比（MLR）一阶对数差分严格为正，利用 Karlin–Rubin 定理构造了 UMP 检验，揭示了离散计数阶梯跳跃引发的功效锯齿波机制，证实检验目标存在天然饱和天花板 $m_{80\%}$。在更新过程时间序列预测中，推导了条件预测方差分解式，阐明了用历史卷积代理真实感染所必然引入的额外非负预测偏差项，彻底澄清了初始参数口径与实际实现规模口径下的参照收敛性。

4. ** 真实大数据实证：全美六年流感住院实证反转与外部多病种跨场景验证 **
基于全美 CDC NHSN 覆盖 50 州及 DC 长达六年的 16,218 条真实住院面板数据（客观筛选 10,303 个活跃周），采用可行广义最小二乘法（FGLS）与 1,500 次聚类 Bootstrap 检验，证实规模反比项高度显著为正（$\hat{b} = 2.2434$，CI $[1.50, 3.02]$），经验平衡点约为 22.6 例/周。均值–方差正交分解惊人地揭示，达峰期看似恒定

的高误差中 88.9% 源于基准失配，扣除后规模项依然显著有用，有力推翻了“达峰期样本量失效”的传统误读；进一步引入 CDC FluSight 官方集成预测（达峰偏差从 88.9% 骤降至 15.5%）与欧洲 11 国 COVID-19 数据，证实了多模型集成对系统漂移的校准价值及仿射规律跨病种的稳健性。

1.4 论文结构安排与技术路线

为系统展现本文的逻辑流向与整体研究脉络，图 1.1 给出了贯通全书的“多源输入 → 微观分支机制 → 渐近推断方差理论 → 运筹优化设计 → 真实大数据实证与政策矩阵”的端到端技术路线全景架构。



图 1.1: **全文研究技术路线与端到端理论推断全景架构图**。展示从已知输入（真实观测数据流、生物学先验参数与运筹成本约束）到微观分支机制、渐近推断方差分解（目标 A 与目标 B 的分化）、监测运筹优化（Cochran 抽样对偶）、假设检验天花板，直至全美真实流感住院大数据计量检验与公共卫生决策矩阵的端到端逻辑闭环。

本学位论文其余部分的组织架构安排如下：

第二章：动力学建模与观测机制。从微观生灭分支过程出发，展开个体传染力 Gamma 连续混合积分推导；深入阐释成功概率 $p = \frac{k}{k+R_t}$ 与抽稀后 p^* 的统计物理顿悟；通过概率母函数复合律严格证明二项抽稀保族封闭性；并在第 2.4 节建立微观随机分支过程与宏观确定性仓室常微分方程系统的 Kurtz 流体极限动力学理论桥梁。

第三章：渐近推断与运筹优化理论。严格形式化定义推断目标 A 与目标 B；给

出命题 1 条件似然、得分方程、双层全期望塔式法则无偏性证明与 Fisher 信息双套算法（UMVUE）；推导命题 2 跨期全方差仿射分解；证明命题 3 监测杠杆理论非对称性；给出命题 4 多期时间抽样预算恒常性与 AR(1) 错位相减求和闭式解；证明推论 1 成本优化严格凸性与 Cochran 抽样对偶。

第四章：蒙特卡洛仿真与机制检验。介绍 Python 蒙特卡洛随机模拟实验规格；检验命题 5 超临界增长精确检验、MLR 一阶差分、离散功效锯齿波与 Wald 正态失真；验证命题 6 更新过程单步预测两步全方差分解与式 (29) 预测偏差项；系统澄清图 1、图 2、图 3 的双口径参照关系。

第五章：全美流感住院大数据实证分析。详细梳理全美 CDC NHSN 监测系统背景、16,218 条原始记录筛选至 10,303 样本的客观漏斗与三大制度期算术闭环；针对重尾异方差构建 FGLS 计量拟合；汇报流行初期核心估计结果；展开达峰期 88.9% 偏差正交分解反转；评估 2024 年自愿填报政策冲击与全国 51 辖区空间汇聚对偶收益。

第六章：跨模型与跨病种外部扩展验证。阐述外部验证的设计原则；汇报 CDC FluSight 官方多模型前瞻集成预测实证结果，展示多模型集成将达峰偏差压缩至 15.5% 的去偏机制；汇报欧洲 11 国早期 COVID-19 纯事前日度发病实证结果，论证仿射递减项的跨病种普适性与经验平衡点的尺度敏感性。

第七章：监测资源优化策略与研究展望。构建国家公共卫生监测体系在不同流行阶段的“差异化两阶段资源配置策略矩阵”；深入剖析当前研究将平衡点作为拟合量而非测量量的方法学局限；提出基于前瞻性主动社区追踪队列的双轨解耦识别设计；对全文核心结论进行总结。

附录 A 提供论文所有命题与推论的保姆级中间推导展开细节。

第二章　动力学建模与观测机制

2.1　微观生灭分支过程与生物学超传播机制

2.1.1　经典 Galton–Watson 分支过程与代际传递

在传染病暴发初期，当易感人群比例高度充沛（即易感者比例近乎恒定 $S/N \approx 1$）且尚未形成大规模群体免疫干预时，病原体的代际传播在微观尺度上可严格抽象为一个离散时间、连续状态空间的 Galton–Watson 随机分支过程 [Harris, 1963, Jagers, 1975]。

设 $t \in \{0, 1, 2, \dots\}$ 表示感染代际离散时间索引。在第 $t-1$ 代，假设全社会存在 $I_{t-1} = n$ 名处于传染期的真实感染个体，构成第 t 代传播的前瞻风险集（Risk Set）。假定这 n 名个体在当前外部环境与生物学特性约束下相互独立地向外传播，其中第 j 名感染者（$j = 1, 2, \dots, n$）在第 t 代所引发的直接二代被感染人数记为离散随机变量 $X_{t,j}$。则第 t 代全社会实际产生的新发真实感染总人数 I_t 可表示为独立同分布随机变量之和：

$$I_t = \sum_{j=1}^{n} X_{t,j}. \tag{2.1}$$

在经典均匀混合假定下，若假定每次接触传播服从均质泊松过程，则个体二代感染数 $X_{t,j} \sim \text{Poisson}(R_t)$，其均值与方差均严格等于瞬时再生数 R_t。然而，大量的现代分子流行病学与流调溯源研究表明，均质泊松假定与真实呼吸道病毒传播的重尾特征存在显著偏差。

2.1.2　个体传染力的 Gamma 连续混合模型：从微观连续积分到负二项 PMF

为了刻画个体在生理排毒量、接触网络度分布以及社会行为上的极端异质性，本文遵循 Lloyd-Smith 等人 [Lloyd-Smith et al., 2005] 的经典生物数学设定，引入双层分层复合模型：假定在特定时间代际 t 内，全社会平均传播强度为 R_t；但对特定的个体 j 而言，其实际具备的瞬时传染力为一个连续随机潜变量 $\nu_{t,j} \in (0, \infty)$。给定该

个体的传染力 $\nu_{t,j}$，其产生的实际二代感染数服从条件泊松分布：

$$X_{t,j} \mid \nu_{t,j} \sim \text{Poisson}(\nu_{t,j}), \quad \Pr(X_{t,j} = x \mid \nu_{t,j}) = \frac{\nu_{t,j}^{x} e^{-\nu_{t,j}}}{x!}, \quad x \in \{0, 1, 2, \dots\}. \tag{2.2}$$

而在人群总体中，个体传染力 $\nu_{t,j}$ 的异质性分布由以形状参数 $k > 0$、尺度参数 $\theta = R_t/k$ 参数化的欧拉 Gamma 分布所刻画：

$$\nu_{t,j} \sim \text{Gamma}\left(k, \frac{R_t}{k}\right). \tag{2.3}$$

其概率密度函数（PDF）严格由下式给出：

$$f_\nu(\nu; k, R_t) = \frac{1}{\theta^k \Gamma(k)} \nu^{k-1} e^{-\nu/\theta} = \frac{(k/R_t)^k}{\Gamma(k)} \nu^{k-1} \exp\left(-\frac{k\nu}{R_t}\right), \quad \nu > 0, \tag{2.4}$$

其中 $\Gamma(k) \triangleq \int_0^\infty u^{k-1} e^{-u} du$ 为标准欧拉 Gamma 函数。

为了求解观测二代病例数 $X_{t,j}$ 的无条件概率质量函数（PMF），我们需要对未观测的连续潜变量 ν 在正半轴 $(0, \infty)$ 上进行边缘化全积分：

$$\Pr(X_{t,j} = x) = \int_0^\infty \Pr(X_{t,j} = x \mid \nu) \cdot f_\nu(\nu; k, R_t)\, d\nu. \tag{2.5}$$

下面给出保姆级逐行代数积分演算步骤：

将条件泊松 PMF 与 Gamma 密度代入被积表达式：

$$\Pr(X_{t,j} = x) = \int_0^\infty \left[\frac{\nu^x e^{-\nu}}{x!}\right] \cdot \left[\frac{(k/R_t)^k}{\Gamma(k)} \nu^{k-1} \exp\left(-\frac{k\nu}{R_t}\right)\right] d\nu. \tag{2.6}$$

提取所有与积分变量 ν 无关的常数因子，合并被积函数中的幂次项与指数幂次：

$$\Pr(X_{t,j} = x) = \frac{(k/R_t)^k}{x!\Gamma(k)} \int_0^\infty \nu^{(x+k)-1} \exp\left\{-\nu\left(1 + \frac{k}{R_t}\right)\right\} d\nu. \tag{2.7}$$

观察被积函数指数部分，引入换元变量：令

$$u \triangleq \nu\left(1 + \frac{k}{R_t}\right) = \nu\left(\frac{k + R_t}{R_t}\right), \tag{2.8}$$

则积分变量与微分元分别映射为：

$$\nu = u\left(\frac{R_t}{k + R_t}\right), \quad d\nu = \left(\frac{R_t}{k + R_t}\right) du. \tag{2.9}$$

由于 $1 + k/R_t > 0$，当 $\nu \to 0$ 时 $u \to 0$，当 $\nu \to \infty$ 时 $u \to \infty$，积分限保持 $(0, \infty)$ 不变。将代换关系回代入式 (2.7)：

$$\begin{aligned} \int_0^\infty \nu^{(x+k)-1} e^{-u} d\nu &= \int_0^\infty \left[u\left(\frac{R_t}{k + R_t}\right)\right]^{(x+k)-1} e^{-u} \cdot \left(\frac{R_t}{k + R_t}\right) du \\ &= \left(\frac{R_t}{k + R_t}\right)^{x+k} \int_0^\infty u^{(x+k)-1} e^{-u} du. \end{aligned} \tag{2.10}$$

由欧拉 Gamma 函数的严格解析定义，后项定积分严格收敛并满足：

$$\int_0^\infty u^{(x+k)-1}e^{-u}du \equiv \Gamma(x+k). \tag{2.11}$$

因此，积分部分完全化简为闭式表达：

$$\int_0^\infty \nu^{(x+k)-1}\exp\left\{-\nu\left(1+\frac{k}{R_t}\right)\right\}d\nu = \Gamma(x+k)\left(\frac{R_t}{k+R_t}\right)^{x+k}. \tag{2.12}$$

将其与提取出的常数系数相乘：

$$\begin{aligned}\Pr(X_{t,j}=x) &= \frac{(k/R_t)^k}{x!\Gamma(k)}\cdot\Gamma(x+k)\left(\frac{R_t}{k+R_t}\right)^{x+k}\\ &= \frac{\Gamma(x+k)}{x!\Gamma(k)}\cdot\frac{k^k}{R_t^k}\cdot\frac{R_t^xR_t^k}{(k+R_t)^{x+k}}\\ &= \frac{\Gamma(x+k)}{x!\Gamma(k)}\cdot\frac{k^kR_t^x}{(k+R_t)^k(k+R_t)^x}.\end{aligned} \tag{2.13}$$

按幂次基数对分子分母进行归并：

$$\Pr(X_{t,j}=x) = \frac{\Gamma(x+k)}{x!\Gamma(k)}\left(\frac{k}{k+R_t}\right)^k\left(\frac{R_t}{k+R_t}\right)^x, \quad x=0,1,2,\ldots. \tag{2.14}$$

式 (2.14) 严格表明：** 在个体传染力服从 Gamma 分布的微观异质性假定下，边缘化后的个体二代感染数严格服从负二项分布 $\mathrm{NB}(k,p)$**，其中形状参数为过度离散参数 k，成功概率参数定义为：

$$p \triangleq \frac{k}{k+R_t}. \tag{2.15}$$

从连续微观混合积分到离散负二项 PMF 的逐行代数证明至此完全证毕。

2.1.3 成功概率 p 的反直觉统计物理顿悟

在常规的数理统计教学中，负二项分布 $\mathrm{NB}(r,p)$ 常被直观地定义为：“在独立重复的伯努利掷硬币试验中，累计观察到第 r 次‘成功’之前，所经历的‘失败总次数’X 的概率分布”。

在流行病学分支过程的语境下，很多初学者极易产生困惑：在传染病暴发中，被感染的人数越多代表疫情越失控，为什么参数形式却反直觉地呈现为 $p=\frac{k}{k+R_t}$？究竟什么是“成功”，什么是“失败”？

理解这一参数的核心在于建立正确的 ** 传染动力学物理顿悟 **：

(1) ** “传染事件”在数学上对应一次“失败”**：当一个感染者接触易感者并成功将病毒传递给对方时，传播链条得到了进一步延长与扩张，这在试验模型中被记为一次试验“失败”（发生了一例二代感染 X）；

(2) ** “传播阻断 / 链条终止” 在数学上对应一次 “成功” **：当感染者遇到具备免疫力的人群、或者因康复、隔离与死亡而未引发二次传染时，该分支链条走向完结终止，这在数学模型中被记为一次 “成功”（阻断成功）；

(3) ** 均值方程的反解自洽性 **：负二项分布的标准均值公式为 $\mathbb{E}[X] = r\frac{1-p}{p}$。在个体模型中 $r = k$，均值必须恒等于当期期望再生数 R_t：

$$R_t = k\frac{1-p}{p} \implies pR_t = k(1-p) = k - kp \implies p(k + R_t) = k \implies p = \frac{k}{k + R_t}. \tag{2.16}$$

这一反解逻辑赋予了 p 极其深刻的流行病学物理直觉：若病毒传播力极强（$R_t \gg 1$），则终止链条的概率 $p \to 0$。这意味着传播极难被阻断，在累计达成 k 次阻断（成功）之前，个体将经历大量的传染事件（失败），从而在宏观上表现为极其猛烈的超级传播暴发；反之，若实施了严格的非药物干预（NPIs）导致 $R_t \to 0$，则阻断概率 $p \to 1$，传播链条几乎立刻终止。

2.2　宏观观测系统的不完全性与二项报告抽稀过程

2.2.1　二项报告抽稀的形式化定义

在真实公共卫生监测实践中，全社会底层实际发生的感染人数 I_t 是无法被全量观测到的潜在潜变量。受制于无症状感染比例、轻症不就医行为以及实验室检测可及性，只有一部分感染者会前往哨点医院就诊并被国家传染病监测网络记录。

本文将这一宏观观测衰减过程形式化建模为 ** 条件二项报告抽稀过程（Binomial Reporting Thinning Process）**：假定在第 t 代，每个实际新发感染者独立地以固定概率 $\rho \in (0, 1]$ 被医疗监测系统捕获并确诊上报。记第 l 个实际感染者被上报的指示变量为 $B_l \sim \text{Bernoulli}(\rho)$ $(l = 1, 2, \ldots, I_t)$，且在给定 I_t 的条件下，各个体的上报指示变量相互条件独立。

因此，疾控系统在第 t 代实际记录到的报告病例数 C_t 是一个复合随机和：

$$C_t = \sum_{l=1}^{I_t} B_l. \tag{2.17}$$

条件分布显然满足二项分布：

$$C_t \mid I_t \sim \text{Binomial}(I_t, \rho). \tag{2.18}$$

2.2.2 报告率参数 ρ 的真实流行病学折算逻辑

在流行病学实证分析中，ρ 绝非普通的实验室核酸检测灵敏度，而是 ** “全社会有症状感染者最终转化为实验室确诊住院病例的系统级复合报告率” **。

以本文后续实证所使用的全美 CDC NHSN 流感住院监测数据为例，参数 ρ 的数量级具有坚实的临床流行病学依据：

- 依据 Zhou 等人 [Zhou et al., 2012] 基于全美住院样本数据库（NIS）的长期回溯测算，美国季节性流感每年引发的实验室确诊住院人数平均处于 20 万至 40 万例区间；
- 依据 Tokars 等人 [Tokars et al., 2018] 基于前瞻性社区队列与血清抗体流调的权威测算，全美季节性流感每年的平均有症状侵袭率（Symptomatic Attack Rate）约为 8% 至 15%，对应全美每年约有 2,500 万至 5,000 万人发生有症状感染；
- 将两组权威数据相除，可严格折算出全美流感感染者转化为 NHSN 住院报告病例的复合比例区间为：

$$\rho \approx \frac{20\ \text{万}}{3500\ \text{万}} \sim \frac{40\ \text{万}}{2500\ \text{万}} \in [0.0056,\ 0.0210]. \tag{2.19}$$

即 ρ 处于千分之六至百分之二的极小数量级区间。这一现实背景凸显了二项报告抽稀模型的必要性：实际监测面临的是从浩瀚的微观感染池中进行极端稀疏的随机抽样。

2.3 概率母函数复合律与分布族保族封闭性定理

当潜变量 I_t 服从负二项分支和、而观测变量 C_t 服从二项报告抽稀时，观测变量 C_t 的边际分布形式是什么？是否会破坏负二项分布的数学结构？

本节利用概率母函数（Probability Generating Function, PGF）技术，严格证明其分布族的保族封闭性。

2.3.1 单代独立感染者和的概率母函数

由式 (2.14)，单个感染者的二代感染数 $X_{t,j} \sim \mathrm{NB}(k, p)$，其中 $p = \frac{k}{k+R_t}$。负二项分布的标准 PGF 解析形式为：

$$G_X(s) \triangleq \mathbb{E}[s^X] = \left(\frac{p}{1-(1-p)s}\right)^k. \tag{2.20}$$

根据式 (2.1)，在给定上一代真实风险集规模 $I_{t-1} = n$ 的条件下，真实感染数 $I_t = \sum_{j=1}^{n} X_{t,j}$ 为 n 个独立同分布随机变量之和。根据独立和的母函数性质：

$$G_{I_t}(s) = \prod_{j=1}^{n} G_X(s) = (G_X(s))^n = \left(\frac{p}{1-(1-p)s} \right)^{nk}. \tag{2.21}$$

因此，当期真实感染总数满足负二项可加性：$I_t \mid n, R_t \sim \mathrm{NB}(nk, p)$，其形状参数累加为 nk。

2.3.2　PGF 复合运算与分布族封闭性证明

根据式 (2.17)，报告数 $C_t = \sum_{l=1}^{I_t} B_l$ 为复合随机变量和，其中 $B_l \sim \mathrm{Bernoulli}(\rho)$ 的母函数为：

$$G_B(s) \triangleq \mathbb{E}[s^B] = (1-\rho) + \rho s. \tag{2.22}$$

利用经典复合随机变量的母函数复合定理：

$$G_{C_t}(s) = G_{I_t}\big(G_B(s)\big). \tag{2.23}$$

将式 (2.21) 中的变量 s 替换为 $G_B(s)$：

$$G_{C_t}(s) = \left(\frac{p}{1-(1-p)\big[(1-\rho)+\rho s\big]} \right)^{nk}. \tag{2.24}$$

下面给出保姆级分母通分与公因子提取代数推导：

展开分母表达式：

$$\begin{aligned} \text{分母} &= 1-(1-p)(1-\rho)-\rho(1-p)s \\ &= 1-\big[1-\rho-p+p\rho\big]-\rho(1-p)s \\ &= \big[p+\rho(1-p)\big]-\rho(1-p)s. \end{aligned} \tag{2.25}$$

分子分母同时除以提取因子 $[p+\rho(1-p)]$：

$$G_{C_t}(s) = \left(\frac{\frac{p}{p+\rho(1-p)}}{1-\left[\frac{\rho(1-p)}{p+\rho(1-p)}\right]s} \right)^{nk}. \tag{2.26}$$

定义经过抽稀后的有效成功概率为：

$$p^* \triangleq \frac{p}{p+\rho(1-p)}. \tag{2.27}$$

将原本的成功概率 $p = \frac{k}{k+R_t}$ 与失败概率 $1-p = \frac{R_t}{k+R_t}$ 代入式 (2.27) 中进行通分化简：

$$\begin{aligned} p^* &= \frac{\frac{k}{k+R_t}}{\frac{k}{k+R_t} + \rho \cdot \frac{R_t}{k+R_t}} \\ &= \frac{\frac{k}{k+R_t}}{\frac{k+\rho R_t}{k+R_t}} \\ &= \frac{k}{k+\rho R_t}. \end{aligned} \tag{2.28}$$

相应地，有效失败概率为：

$$1 - p^* = 1 - \frac{k}{k+\rho R_t} = \frac{\rho R_t}{k+\rho R_t}. \tag{2.29}$$

将 p^* 回代入式 (2.26)：

$$G_{C_t}(s) = \left(\frac{p^*}{1-(1-p^*)s} \right)^{nk}. \tag{2.30}$$

对比标准负二项分布母函数形式，式 (2.30) 在代数上严格证明了以下定理：

定理 2.1 (**二项报告抽稀保族封闭性定理**)**.** 设风险集规模为 n，个体传染力过度离散参数为 k，当期瞬时再生数为 R_t。若微观传播服从负二项分支过程，宏观报告服从条件独立二项报告抽稀过程，则观测病例数 C_t 严格服从形状参数为 nk、成功概率为 $p^* = \frac{k}{k+\rho R_t}$ 的负二项分布族闭包：

$$C_t \mid n, R_t \sim \mathrm{NB}\left(nk,\ \frac{k}{k+\rho R_t} \right). \tag{2.31}$$

该定理具有极高的理论优雅性：二项报告抽稀并不会破坏负二项分布的族系属性，而是将有效均值参数严格收缩为 ρR_t，同时完好保留了形状参数 nk。

2.3.3 观测变量的二阶矩结构解析

由负二项分布的标准矩性质，观测病例数 C_t 的条件期望与条件方差可显式计算如下：

$$\mathbb{E}[C_t \mid n, R_t] = nk \cdot \frac{1-p^*}{p^*} = nk \cdot \frac{\frac{\rho R_t}{k+\rho R_t}}{\frac{k}{k+\rho R_t}} = nk \cdot \frac{\rho R_t}{k} = \rho n R_t. \tag{2.32}$$

定义上一代风险集 n 对应的期望被报告人数为 $m \triangleq \rho n$，则：

$$\mathbb{E}[C_t \mid n, R_t] = m R_t. \tag{2.33}$$

进一步展开条件方差：

$$\mathrm{Var}(C_t \mid n, R_t) = nk \cdot \frac{1-p^*}{(p^*)^2} = nk \cdot \frac{\frac{\rho R_t}{k+\rho R_t}}{\left(\frac{k}{k+\rho R_t}\right)^2} = nk \cdot \frac{\rho R_t}{k+\rho R_t} \cdot \frac{(k+\rho R_t)^2}{k^2}. \tag{2.34}$$

分子分母对消公因子 $k(k+\rho R_t)$：

$$\begin{aligned}\mathrm{Var}(C_t \mid n, R_t) &= \frac{n\rho R_t(k+\rho R_t)}{k} \\ &= \frac{n\rho k R_t + n\rho^2 R_t^2}{k} \\ &= \rho n R_t + \frac{(\rho R_t)^2 n}{k}.\end{aligned} \tag{2.35}$$

式 (2.35) 极其清晰地展现了二阶矩结构的数理正交叠加：

- 第一项 $\rho n R_t = m R_t$：纯泊松随机相遇计数波动（Poisson Counting Noise）；
- 第二项 $\frac{(\rho R_t)^2 n}{k} = \frac{\rho m R_t^2}{k}$：个体生物学生殖数过度离散引发的超传播乘性放大项（Superspreading Inflation Noise）。

2.4　微观分支过程与宏观确定性仓室 ODE 的流体极限动力学桥梁

为了深化论文的动力系统机理基础，并架起微观离散统计推断与马知恩先生学派经典常微分方程动力系统的内在血脉连接，本节系统阐明微观随机分支过程与宏观仓室 ODE 之间的 Kurtz 流体极限对应关系。

2.4.1　经典 Kermack–McKendrick SIR 动力系统与相空间稳定性

在经典数理流行病学中，Kermack 与 McKendrick [Kermack and McKendrick, 1927] 以及马知恩等 [马知恩 et al., 2004, 马知恩 and 周义仓, 2001] 建立的确定性无时滞 SIR 仓室微分方程系统具有如下标准形式：

$$\begin{cases} \dfrac{dS}{dt} = -\dfrac{\beta S I}{N}, \\ \dfrac{dI}{dt} = \dfrac{\beta S I}{N} - \gamma I, \\ \dfrac{dR}{dt} = \gamma I, \end{cases} \tag{2.36}$$

其中 $N = S(t) + I(t) + R(t)$ 为封闭总人口规模，β 为有效接触传播率，γ 为传染期恢复率。基本再生数定义为无量纲参数 $\mathcal{R}_0 \triangleq \beta/\gamma$。

在常微分方程定性理论中，系统 (2.36) 恒存在无病平衡点 $E_0 = (N, 0, 0)$。对其进行线性化分析，计算系统 Jacobian 矩阵在 E_0 处的特征值：

$$J(E_0) = \begin{pmatrix} 0 & -\beta & 0 \\ 0 & \beta - \gamma & 0 \\ 0 & \gamma & 0 \end{pmatrix}. \tag{2.37}$$

显然，决定系统稳定性的关键特征根为 $\lambda = \beta - \gamma = \gamma(\mathcal{R}_0 - 1)$：

- 当 $\mathcal{R}_0 < 1$ 时，$\lambda < 0$，无病平衡点 E_0 局部渐近稳定，疫情自发衰退；
- 当 $\mathcal{R}_0 > 1$ 时，$\lambda > 0$，E_0 失稳，系统在相空间中发生经典的 ** 跨临界分岔（Transcritical Bifurcation）**，疫情呈指数暴发。

2.4.2 纯跳跃马尔可夫生灭过程的生成元与鞅表示

在有限微观人群中，疾病传播本质是一个连续时间纯跳跃马尔可夫链。设在时刻 t，系统状态为 $(S_N(t), I_N(t))$。系统可能的状态转移及其跳跃速率严格定义为：

$$(S, I) \to (S-1, I+1) \quad \text{转移速率：} \quad q_1(S, I) = \frac{\beta S I}{N}, \tag{2.38}$$

$$(S, I) \to (S, I-1) \quad \text{转移速率：} \quad q_2(S, I) = \gamma I. \tag{2.39}$$

根据马尔可夫过程的半鞅分解定理（Doob–Meyer 分解），连续时间跳跃过程可严格表示为漂移测度积分与零均值局部平方可积鞅之和：

$$\frac{I_N(t)}{N} = \frac{I_N(0)}{N} + \int_0^t \left(\beta \frac{S_N(u)}{N} \frac{I_N(u)}{N} - \gamma \frac{I_N(u)}{N} \right) du + M_N(t), \tag{2.40}$$

其中 $M_N(t)$ 为二次可积鞅，其尖括号可预测变差过程（Predictable Quadratic Variation）满足：

$$\langle M_N \rangle_t = \frac{1}{N} \int_0^t \left(\beta \frac{S_N(u)}{N} \frac{I_N(u)}{N} + \gamma \frac{I_N(u)}{N} \right) du. \tag{2.41}$$

2.4.3 Kurtz 密度相关大数定律（Fluid Limit Theorem）

马氏过程与微分方程定性理论的终极汇聚点在于 Thomas Kurtz 于 1970 年证明的著名极限定理 [Ethier and Kurtz, 1986, Kurtz, 1970, 1971]：

定理 2.2 (Kurtz 密度相关大数定律). *设宏观总人口规模 $N \to \infty$。若初始归一化状态几乎必然收敛：*

$$\lim_{N \to \infty} \left(\frac{S_N(0)}{N}, \frac{I_N(0)}{N} \right) = (s_0, i_0), \tag{2.42}$$

则在任意有限时间区间 $[0, T]$ 内，微观纯跳跃马尔可夫随机过程的密度路径依概率 1 一致收敛于确定性常微分方程系统 (2.36) 的解轨道 $(s(t), i(t))$：

$$\sup_{0 \le t \le T} \left\| \left(\frac{S_N(t)}{N}, \frac{I_N(t)}{N} \right) - (s(t), i(t)) \right\| \xrightarrow[N \to \infty]{a.s.} 0. \tag{2.43}$$

证明的核心由式 (2.41) 直接导出：因为鞅变差包含 $1/N$ 前置系数，当 $N \to \infty$ 时，随机涨落项 $\langle M_N \rangle_t \to 0$，鞅项以概率 1 溃缩为零，随机动力系统完全退化为确定性均值向量场流形。

2.4.4　动力学理论定位与本文研究切入点

Kurtz 流体极限理论为本文的研究切入点提供了极其崇高的数理定位：

> **确定性常微分方程仓室系统，本质上是大数极限 $N \to \infty$ 下微观随机过程的均值流形；**
> **而真实流行病学监测的核心挑战恰恰在于：现实中的监测样本规模并非无穷大 $(n < \infty, m < \infty)$。本文所聚焦研究的，正是微观随机涨落偏离确定性动力学轨道的方差标度律与最优抽样边界！**

这一动力学桥梁的建立，彻底打通了微观分支随机推断与宏观微分方程定性理论的学科阻隔。在下一章中，我们将正式推导以不同推断目标为导向的渐近方差分解与运筹设计理论。

2.5　呼吸道传染病过度离散参数 k 经验校准综述

在第二章推导的负二项分支过程模型中，生物学生殖数过度离散参数 k 扮演着决定系统微观方差乘性放大强度的关键角色。为了让本文的理论分析具备扎实的生物学与流行病学先验基础，本节对近二十年来国际顶级期刊中关于典型人类传染病离散参数 k 的实证测量文献进行系统的元分析梳理。

2.5.1　主要病原体离散参数测量大表

表 2.1 汇总了涵盖冠状病毒属、正粘病毒属、副粘病毒属等全球主要呼吸道及接触传播病原体的经验测定参数。

2.5.2　对本文参数设定的启示

从表 2.1 可以清晰看出两个显著特征：

(1) 呼吸道病原体普遍处于 $k \in (0.1, 0.6)$ 的区间之内，经典泊松分布假定（$k = \infty$）在现实中根本不存在；

(2) 本文在第四章数值模拟中选取 $k = 0.35$ 作为流感基准，并在第五章唯象实证中覆盖 $k \in [0.2, 0.5]$，完全处于季节性流感与新型流感的临床测量中心区间，具有坚实的事实依据。

表 2.1: 全球主要人类传染病生殖数过度离散参数 k 实证测量元分析汇总表

病原体与流行事件	**典型 R_0 区间**	**离散参数 k**	**20/80 集中度**	**超传播特征定性**
SARS-CoV-1 (2003)	$2.2 \sim 3.6$	**0.16**	80% 来自 9% 个体	极端强超传播
SARS-CoV-2 (原始株)	$2.5 \sim 3.0$	**0.10 ∼ 0.30**	80% 来自 10% 个体	强超传播
SARS-CoV-2 (Delta/Omicron)	$5.0 \sim 9.5$	**0.25 ∼ 0.45**	80% 来自 15% 个体	中强超传播
MERS-CoV (2012)	$0.4 \sim 0.9$	**0.26**	局部医院暴发	强超传播
季节性流感 (Influenza A/H3N2)	$1.2 \sim 1.6$	**0.35 ∼ 0.55**	80% 来自 22% 个体	中度过度离散

第三章　统计推断与运筹优化理论

3.1　推断目标分化：瞬态参数与跨期平稳基准

在第二章建立的两阶段分层生成模型下，本章进入本文的核心理论推导。以往传染病监测理论之所以出现“盲目预设规模越大越好”的困境，其数理根源在于混淆了两个截然不同的统计推断目标：

定义 3.1 (目标 A：当期瞬时再生数 R_t 的点估计). 在特定时间代际 t（如某一特定自然周），全社会暴露于当期特定的气象条件、人群聚集水平与临时管控政策之下。此时，瞬态再生数 R_t 是一个已实现的确定性瞬时状态，统计推断的目标是利用当期观测报告病例数 C_t 精确测量该瞬态强度 R_t。

定义 3.2 (目标 B：跨期平稳基础传播基准 $\bar{R}$ 的估计与外推). 公共卫生中长期资源储备、疫苗采购与多期流行趋势研判，需要评估的是消除单周偶发扰动后的基础传播趋势基准 $\bar{R} \triangleq \mathbb{E}[R_t \mid n]$。此时，全社会共享的宏观环境变迁表现为不可预测的外生随机扰动，满足条件方差 $\mathrm{Var}(R_t \mid n) = v_R > 0$。推断目标是利用有限的监测数据估计该潜在基线 $\bar{R}$。

本章将严格证明：推断目标由 A 切换至 B，将引发方差标度律的根本性断裂！

3.2　目标 A 的点估计与 Cramér–Rao 渐近有效性

本节针对推断目标 A，推导其极大似然估计量，并证明其无偏性与达到 Cramér–Rao 下界的优良性质。

命题 3.1 (命题 1：条件似然、无偏性与 UMVUE 达到). 设已知上一代风险集真实规模 n、固定报告率 ρ 及离散参数 k。

(i) 观测样本 C_t 对瞬态参数 R_t 的极大似然估计量 (*MLE*) 与矩估计量严格重合，由下式给出：

$$\widehat{R}_t^{MLE} = \frac{C_t}{\rho n} = \frac{C_t}{m}, \tag{3.1}$$

其中 $m \triangleq \rho n$ 为期望报告规模；

(ii) 估计量 $\widehat{R}_t$ 在全域 $R_t \in (0,\infty)$ 上严格无偏：$\mathbb{E}[\widehat{R}_t \mid n, R_t] = R_t$；

(iii) 在内部参数空间中，估计量 $\widehat{R}_t$ 严格达到 *Cramér–Rao* 下界，为一致最小方差无偏估计量（*UMVUE*），其条件方差为：

$$\operatorname{Var}(\widehat{R}_t \mid n, R_t) = \mathcal{I}(R_t \mid n)^{-1} = \frac{R_t}{\rho n} + \frac{R_t^2}{kn} = \mathcal{O}\left(\frac{1}{m}\right), \tag{3.2}$$

其中 $\mathcal{I}(R_t \mid n)$ 为关于参数 R_t 的 *Fisher* 信息量。

证明. 下面给出保姆级分步证明：

第一步：建立对数似然方程与求解得分函数（Score Function）

由定理 2.1，观测样本 C_t 服从负二项分布 $\mathrm{NB}(nk, p^*)$，其中 $p^* = \frac{k}{k+\rho R_t}$，$1-p^* = \frac{\rho R_t}{k+\rho R_t}$。记观测值为 $c \in \{0,1,2,\dots\}$，似然函数为：

$$L(R_t; c) = \frac{\Gamma(c+nk)}{c!\Gamma(nk)}(p^*)^{nk}(1-p^*)^c = \frac{\Gamma(c+nk)}{c!\Gamma(nk)}\left(\frac{k}{k+\rho R_t}\right)^{nk}\left(\frac{\rho R_t}{k+\rho R_t}\right)^c. \tag{3.3}$$

对似然函数取自然对数 ln：

$$\begin{aligned}\ln L(R_t) &= \ln\left[\frac{\Gamma(c+nk)}{c!\Gamma(nk)}\right] + nk\ln k - nk\ln(k+\rho R_t) + c\ln\rho + c\ln R_t - c\ln(k+\rho R_t)\\ &= \underbrace{\ln\left[\frac{\Gamma(c+nk)}{c!\Gamma(nk)}\right] + nk\ln k + c\ln\rho}_{\text{与未知参数}R_t\text{ 完全无关的常数，简记为const}} + c\ln R_t - (nk+c)\ln(k+\rho R_t). \end{aligned}\tag{3.4}$$

对参数 R_t 求一阶偏导数，得到得分函数 $S(R_t) \triangleq \frac{\partial \ln L}{\partial R_t}$：

$$\begin{aligned}S(R_t) &= \frac{c}{R_t} - (nk+c)\frac{\frac{\partial}{\partial R_t}(k+\rho R_t)}{k+\rho R_t}\\ &= \frac{c}{R_t} - \frac{\rho(nk+c)}{k+\rho R_t}.\end{aligned}\tag{3.5}$$

进行通分合并：

$$\begin{aligned}S(R_t) &= \frac{c(k+\rho R_t) - \rho R_t(nk+c)}{R_t(k+\rho R_t)}\\ &= \frac{ck + c\rho R_t - \rho nk R_t - c\rho R_t}{R_t(k+\rho R_t)}\\ &= \frac{k(c-\rho n R_t)}{R_t(k+\rho R_t)}.\end{aligned}\tag{3.6}$$

令得分函数等于零 $S(R_t) = 0$，由于 $k > 0$ 且分母在内部空间恒正，驻点方程退化为：

$$c - \rho n R_t = 0 \implies \widehat{R}_t^{\mathrm{MLE}} = \frac{c}{\rho n}. \tag{3.7}$$

又因为二阶导数恒负（见后文 Fisher 信息量推导），该驻点为唯一的全局极大值点，式 (3.1) 证毕。

第二步：双层全期望公式（塔式法则）严格无偏性证明

对估计量 $\widehat{R}_t = \frac{C_t}{\rho n}$ 求条件数学期望：

$$\mathbb{E}\left[\widehat{R}_t \,\middle|\, n, R_t\right] = \mathbb{E}\left[\frac{C_t}{\rho n} \,\middle|\, n, R_t\right] = \frac{1}{\rho n}\,\mathbb{E}\left[C_t \mid n, R_t\right]. \tag{3.8}$$

应用条件全期望法则（Law of Total Expectation, 塔式法则），将观测变量 C_t 投影到潜变量 I_t 上：

$$\mathbb{E}\left[C_t \mid n, R_t\right] = \mathbb{E}_{I_t}\left[\mathbb{E}_{C_t}\left(C_t \mid I_t\right) \,\middle|\, n, R_t\right]. \tag{3.9}$$

- 内层期望：在给定真实感染 I_t 时，抽稀过程服从 $C_t \mid I_t \sim \mathrm{Binomial}(I_t, \rho)$，二项分布均值为 $\mathbb{E}[C_t \mid I_t] = \rho I_t$；
- 外层期望：在给定上一代风险集 n 时，真实感染 $I_t = \sum_{j=1}^{n} X_{t,j}$ 为 n 个均值为 R_t 的独立分支和，故 $\mathbb{E}[I_t \mid n, R_t] = nR_t$。

代入得：

$$\mathbb{E}\left[C_t \mid n, R_t\right] = \mathbb{E}_{I_t}\left[\rho I_t \,\middle|\, n, R_t\right] = \rho\,\mathbb{E}[I_t \mid n, R_t] = \rho(nR_t) = \rho n R_t. \tag{3.10}$$

两端除以常数 ρn：

$$\mathbb{E}\left[\widehat{R}_t \,\middle|\, n, R_t\right] = \frac{\rho n R_t}{\rho n} \equiv R_t. \tag{3.11}$$

在全参数空间中无偏性严格证毕。

第三步：Fisher 信息量双套算法验证与 Cramér–Rao 下界确立

下面采用数理统计中两种截然不同的定义算法计算 Fisher 信息量 $\mathcal{I}(R_t \mid n)$：

算法一（得分函数方差法）：由得分函数方差定义 $\mathcal{I}(R_t) \triangleq \mathrm{Var}(S(R_t))$。利用式 (3.6)：

$$\mathrm{Var}\left(S(R_t)\right) = \mathrm{Var}\left(\frac{k(C_t - \rho n R_t)}{R_t(k + \rho R_t)}\right) = \frac{k^2}{R_t^2(k+\rho R_t)^2}\,\mathrm{Var}(C_t \mid n, R_t). \tag{3.12}$$

将式 (2.35) 导出的负二项方差 $\mathrm{Var}(C_t \mid n, R_t) = \frac{n\rho R_t(k+\rho R_t)}{k}$ 代入：

$$\begin{aligned}
\mathcal{I}(R_t \mid n) &= \frac{k^2}{R_t^2(k+\rho R_t)^2} \cdot \left[\frac{n\rho R_t(k+\rho R_t)}{k}\right] \\
&= \frac{k \cdot n\rho R_t(k+\rho R_t)}{R_t^2(k+\rho R_t)^2} \\
&= \frac{kn\rho}{R_t(k+\rho R_t)}.
\end{aligned} \tag{3.13}$$

算法二（对数似然负二阶导期望法）：对得分函数再次求偏导：

$$\begin{aligned}\frac{\partial^2 \ln L}{\partial R_t^2} &= \frac{\partial}{\partial R_t}\left[\frac{C_t}{R_t} - \frac{\rho(nk + C_t)}{k + \rho R_t}\right] \\ &= -\frac{C_t}{R_t^2} - \rho(nk + C_t)\left[-\frac{\rho}{(k + \rho R_t)^2}\right] \\ &= -\frac{C_t}{R_t^2} + \frac{\rho^2(nk + C_t)}{(k + \rho R_t)^2}.\end{aligned} \tag{3.14}$$

取负号并求数学期望，代入 $\mathbb{E}[C_t \mid n, R_t] = \rho n R_t$：

$$\begin{aligned}\mathcal{I}(R_t \mid n) &= \mathbb{E}\left[-\frac{\partial^2 \ln L}{\partial R_t^2} \,\middle|\, n, R_t\right] \\ &= \frac{\mathbb{E}[C_t]}{R_t^2} - \frac{\rho^2(nk + \mathbb{E}[C_t])}{(k + \rho R_t)^2} \\ &= \frac{\rho n R_t}{R_t^2} - \frac{\rho^2(nk + \rho n R_t)}{(k + \rho R_t)^2} \\ &= \frac{\rho n}{R_t} - \frac{\rho^2 n(k + \rho R_t)}{(k + \rho R_t)^2} \\ &= \frac{\rho n}{R_t} - \frac{\rho^2 n}{k + \rho R_t} \\ &= \frac{\rho n(k + \rho R_t) - \rho^2 n R_t}{R_t(k + \rho R_t)} \\ &= \frac{kn\rho}{R_t(k + \rho R_t)}.\end{aligned} \tag{3.15}$$

两种独立算法的推导结果在代数上完全恒等！

计算 Fisher 信息量的倒数：

$$\begin{aligned}\mathcal{I}(R_t \mid n)^{-1} &= \frac{R_t(k + \rho R_t)}{kn\rho} \\ &= \frac{kR_t + \rho R_t^2}{kn\rho} \\ &= \frac{kR_t}{kn\rho} + \frac{\rho R_t^2}{kn\rho} \\ &= \frac{R_t}{\rho n} + \frac{R_t^2}{kn}.\end{aligned} \tag{3.16}$$

根据经典 Cramér–Rao 定理，对于参数 R_t 的任意无偏估计量 $T(C_t)$，其方差均满足下界：

$$\operatorname{Var}\big(T(C_t)\big) \geq \mathcal{I}(R_t \mid n)^{-1}. \tag{3.17}$$

而对于估计量 $\widehat{R}_t = \frac{C_t}{\rho n}$，直接由方差性质计算：

$$\operatorname{Var}(\widehat{R}_t \mid n, R_t) = \operatorname{Var}\left(\frac{C_t}{\rho n}\right) = \frac{1}{\rho^2 n^2}\operatorname{Var}(C_t \mid n, R_t) = \frac{1}{\rho^2 n^2}\left[\rho n R_t + \frac{(\rho R_t)^2 n}{k}\right] = \frac{R_t}{\rho n} + \frac{R_t^2}{kn}. \tag{3.18}$$

估计量的方差严格等于 Cramér–Rao 下界，因此 $\widehat{R}_t$ 为 UMVUE，式 (3.2) 严格证毕。 □

命题 1 确立了在目标 A（当期瞬态点估计）下的核心结论：** 方差随着期望报告规模 $m = \rho n$ 按 $O(1/m)$ 严格无界递减 **。在此视角下，大数定律完全起效，监测规模确实“越大越好”。

3.3　目标 B 的全方差分解与仿射损失结构

本节将推断目标切换至目标 B（跨期平稳基础基准 $\bar{R}$），揭示方差结构的根本突变。

3.3.1　不可约宏观环境方差的数理引入

在现实中，气象变化（如降温导致室内聚集增加）、法定节假日人群大范围迁徙、或者自发佩戴口罩等社会干预，构成全社会所有个体共同面对的外生环境扰动。设当期瞬态再生数在潜在基础基准 $\bar{R}$ 附近发生宏观乘性扰动：

$$R_t = \bar{R} \cdot \exp(\varepsilon_t), \quad \varepsilon_t \sim \mathcal{N}\left(-\frac{1}{2}v_\varepsilon,\ v_\varepsilon\right), \tag{3.19}$$

满足条件均值 $\mathbb{E}[R_t \mid n] = \bar{R}$，且条件方差由正实数刻画：

$$\mathrm{Var}(R_t \mid n) = v_R > 0. \tag{3.20}$$

这一设定揭示了不可约环境方差 v_R 在两类推断目标下的本质分化：对目标 A 而言，环境波动正是待测对象本身，其跨期变异不构成误差；对目标 B 而言，同一波动退化为不可消除的误差源，单期样本无论多大都无法消除全员共享的单次环境实现。我们称 v_R 为 ** 不可约环境方差（Irreducible Environmental Variance）**。

3.3.2　全方差公式展开与仿射损失结构推导

命题 3.2 (命题 2：跨期全方差分解与仿射损失). *在推断目标 B 下，以单期估计量 $\widehat{R}_t = \frac{C_t}{\rho n}$ 估计跨期基准 $\bar{R}$，在给定风险集 n 条件下，单期边际预测方差严格满足仿射损失结构：*

$$\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n\right) = v_R + \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn} \equiv v_R + \frac{A}{m}, \tag{3.21}$$

其中期望报告规模为 $m \equiv \rho n$，标量系数 A 由系统深层结构参数唯一定义：

$$A \equiv \bar{R} + \frac{\rho(\bar{R}^2 + v_R)}{k}. \tag{3.22}$$

证明. 应用 ** 全方差公式（Law of Total Variance）**:

$$\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n\right) = \underbrace{\mathrm{Var}\left(\mathbb{E}\left[\frac{C_t}{\rho n}\,\middle|\, n, R_t\right]\,\middle|\, n\right)}_{\text{宏观环境波动贡献项}} + \underbrace{\mathbb{E}\left[\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n, R_t\right)\,\middle|\, n\right]}_{\text{微观抽样波动贡献项}}. \tag{3.23}$$

下面分步计算式 (3.23) 中的两项:

第一项计算:由命题 1 中的无偏性结论,在给定当期环境状态 R_t 时,$\mathbb{E}\left[\frac{C_t}{\rho n}\,\middle|\, n, R_t\right] = R_t$。代入得:

$$\mathrm{Var}\left(\mathbb{E}\left[\frac{C_t}{\rho n}\,\middle|\, n, R_t\right]\,\middle|\, n\right) = \mathrm{Var}(R_t \mid n) \equiv v_R. \tag{3.24}$$

第二项计算: 由命题 1 式 (3.2)，已知条件方差为 $\frac{R_t}{\rho n} + \frac{R_t^2}{kn}$。对外层随机变量 R_t 求期望:

$$\mathbb{E}\left[\frac{R_t}{\rho n} + \frac{R_t^2}{kn}\,\middle|\, n\right] = \frac{\mathbb{E}[R_t \mid n]}{\rho n} + \frac{\mathbb{E}[R_t^2 \mid n]}{kn}. \tag{3.25}$$

利用方差与二阶原点矩的基本代数恒等式:

$$\mathbb{E}[R_t^2 \mid n] = \mathrm{Var}(R_t \mid n) + \big(\mathbb{E}[R_t \mid n]\big)^2 = v_R + \bar{R}^2. \tag{3.26}$$

代入上式即得:

$$\mathbb{E}\left[\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n, R_t\right)\,\middle|\, n\right] = \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn}. \tag{3.27}$$

将两项相加，得到总边际方差:

$$\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n\right) = v_R + \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn}. \tag{3.28}$$

代入期望报告规模 $m = \rho n$（即 $n = m/\rho$）:

$$\begin{aligned}\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n\right) &= v_R + \frac{\bar{R}}{m} + \frac{\rho(\bar{R}^2 + v_R)}{km} \\ &= v_R + \frac{1}{m}\left[\bar{R} + \frac{\rho(\bar{R}^2 + v_R)}{k}\right] \\ &\equiv v_R + \frac{A}{m}.\end{aligned} \tag{3.29}$$

命题 2 证毕。 □

3.3.3 特征规模平衡点 $m_\times$ 的内生导出与物理意义

式 (3.21) 显示，在目标 B 下，边际方差由两部分构成:

- 宏观环境方差 v_R：与病例样本量 m 完全无关的不可约常数;
- 微观抽样方差 A/m：随规模 m 按反比例递减的微观离散项。

联立这两项方差，自然导出一个两类方差相等的特征交点：

定义 3.3 (特征规模平衡点 / 方差平衡点). 定义抽样方差项与不可约环境方差底板相等的样本量为 ** 特征规模平衡点 ** $m_\times$：

$$\frac{A}{m_\times} = v_R \implies m_\times \equiv \frac{A}{v_R} = \frac{\bar{R} + \frac{\rho(\bar{R}^2+v_R)}{k}}{v_R}. \tag{3.30}$$

注记：标量系数 $A \equiv \bar{R} + \frac{\rho(\bar{R}^2+v_R)}{k}$ 自身仍显式依赖于报告率 ρ。因此两个监测系统即使处于相同的 $m = \rho n$，只要报告率 ρ 不同，A 与收益拐点 $m_\times$ 便不相同。A 依赖 ρ 的方式与依赖规模 m 的反比衰减完全不同，这正是后文命题 3.3 监测杠杆非对称性的数理根源。

平衡点 $m_\times$ 具有极强的定性物理分水岭含义：

- ** 当 $m \ll m_\times$ 时（微观噪声主导体制）**：$A/m \gg v_R$，微观抽样与超传播噪声占总方差的 50% 以上。此时扩大捕获样本量能够带来显著的方差收益；
- ** 当 $m \gg m_\times$ 时（宏观环境饱和体制）**：$A/m \ll v_R$，不可约环境方差占比超过 50%，总方差曲线进入水平平台。此时继续扩大病例捕获已无法从根本上改善精度，监测资源边际收益剧烈钝化。

3.4　监测杠杆的理论非对称性定理

面对 $v_R + A/m$ 结构，疾控机构有两种潜在的扩量杠杆：其一是投入资源提升报告率 ρ（如提高采样率或筛查深度）；其二是扩大监测的地理或人口基数 n。本节证明两种杠杆具有本质的非对称性。

命题 3.3 (命题 3：监测杠杆的理论非对称性定理). 将单期边际方差表示为关于基数 n 与报告率 ρ 的二元函数：

$$V(n,\rho) \equiv v_R + \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn}. \tag{3.31}$$

该二元函数在极限状态下满足以下非对称收敛性质：

(i) ** 提高报告率极限（$\rho \to 1$）**：

$$\lim_{\rho\to 1} V(n,\rho) = v_R + \frac{\bar{R}}{n} + \frac{\bar{R}^2 + v_R}{kn} > v_R. \tag{3.32}$$

(ii) ** 扩大风险基数极限（$n \to \infty$）**：

$$\lim_{n\to\infty} V(n,\rho) = v_R. \tag{3.33}$$

证明. 将第一项抽样项进行代数裂项分解：

$$\frac{\bar{R}}{\rho n} = \frac{\bar{R}}{n} + \frac{(1-\rho)\bar{R}}{\rho n}. \tag{3.34}$$

则方差函数可精确分解为三层结构：

$$V(n,\rho) = v_R + \underbrace{\frac{(1-\rho)\bar{R}}{\rho n}}_{\text{漏报抽稀噪声}} + \underbrace{\frac{\bar{R}}{n}}_{\text{有限人群泊松计数波动}} + \underbrace{\frac{\bar{R}^2 + v_R}{kn}}_{\text{超级传播子代抽样波动}}. \tag{3.35}$$

对式 (3.35) 取 $\rho \to 1$ 的极限： 由于 $\lim_{\rho\to 1} \frac{(1-\rho)\bar{R}}{\rho n} = 0$，漏报抽稀噪声被完全消除。然而，第二项泊松计数波动与第三项超传播波动仅依赖于有限基数 n，与 ρ 无关：

$$\lim_{\rho\to 1} V(n,\rho) = v_R + 0 + \frac{\bar{R}}{n} + \frac{\bar{R}^2 + v_R}{kn} = v_R + \frac{1}{n}\left(\bar{R} + \frac{\bar{R}^2 + v_R}{k}\right). \tag{3.36}$$

因为 $\bar{R} > 0, k > 0, n < \infty$，括号内系数严格为正，故极限严格大于 v_R。

对式 (3.35) 取 $n \to \infty$ 的极限（对任意给定的 $\rho > 0$）： 由于两个规模相关项的分母均含有 n：

$$\lim_{n\to\infty}\left[\frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn}\right] = \lim_{n\to\infty}\frac{1}{n}\left[\frac{\bar{R}}{\rho} + \frac{\bar{R}^2 + v_R}{k}\right] = 0. \tag{3.37}$$

因此：

$$\lim_{n\to\infty} V(n,\rho) = v_R + 0 = v_R. \tag{3.38}$$

命题 3 严格证毕。 □

流行病学与管理学启示：命题 3 从数理上澄清了一个长期的管理误区：完全消除漏报（$\rho \to 1$）只能消灭由于二项抽样带来的观测抖动，但人群内部由于有限个体相遇产生的泊松随机性以及个体超传播的重尾离散性，是任何高精度检测手段都无法在有限人群中消灭的；唯有扩大监测的地理范围与人群基数 $n \to \infty$，大数定律才能统摄消除全部微观噪声。

3.5 多期时间抽样设计与样本预算恒常性

当单期横截面样本无法突破环境底板 v_R 时，平滑环境噪声的唯一路径是引入时间维度。本节探讨多期时间抽样设计。

设监测周期跨越 T 期（如连续监测 T 周），在每一期中，疾控系统维持期望报告规模 m。跨期样本均值估计量定义为：

$$\overline{\widehat{R}}_T \triangleq \frac{1}{T}\sum_{t=1}^{T}\widehat{R}_t = \frac{1}{T}\sum_{t=1}^{T}\frac{C_t}{\rho n_T}. \tag{3.39}$$

命题 3.4 (命题 4：样本预算恒常性与自相关求和). 设监测系统在整个评估周期内的总样本人数预算为常数 $B \equiv T \cdot m = T\rho n_T$。

(i) 若环境冲击在各期独立，则跨期均值方差为：

$$\mathrm{Var}(\overline{\widehat{R}}_T) = \frac{v_R}{T} + \frac{A}{B}. \tag{3.40}$$

微观抽样误差恒为常数 A/B；

(ii) 若宏观环境满足一阶自回归协方差 $\mathrm{Cov}(R_t, R_{t+s}) = v_R r^s$ $(r \in [0,1))$，则总方差严格由下式给出：

$$\mathrm{Var}(\overline{\widehat{R}}_T) = \frac{v_R}{T}\left[\frac{1+r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right] + \frac{A}{B}. \tag{3.41}$$

当 $T \gg \frac{1}{1-r}$ 时，有效独立期数渐近退化为 $T_{\mathrm{eff}} \approx T\frac{1-r}{1+r}$。

证明. 应用全方差公式展开：

$$\mathrm{Var}(\overline{\widehat{R}}_T) = \mathrm{Var}\left(\mathbb{E}\left[\frac{1}{T}\sum_{t=1}^{T}\widehat{R}_t \,\middle|\, \{R_t\}_{t=1}^{T}\right]\right) + \mathbb{E}\left[\mathrm{Var}\left(\frac{1}{T}\sum_{t=1}^{T}\widehat{R}_t \,\middle|\, \{R_t\}_{t=1}^{T}\right)\right]. \tag{3.42}$$

由单期估计误差在给定环境序列下的条件期望为零及条件独立性：

$$\mathrm{Var}(\overline{\widehat{R}}_T) = \frac{1}{T^2}\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) + \frac{1}{T^2}\sum_{t=1}^{T}\mathrm{Var}(\widehat{R}_t \mid R_t). \tag{3.43}$$

代入单期条件抽样方差 $\mathrm{Var}(\widehat{R}_t \mid R_t) = A/m$：

$$\text{抽样项} = \frac{1}{T^2}\cdot T\left(\frac{A}{m}\right) = \frac{A}{Tm}. \tag{3.44}$$

代入总样本预算约束 $B = Tm$：

$$\text{抽样项} \equiv \frac{A}{B}. \tag{3.45}$$

此即证明了 ** 样本预算恒常性 **：在固定总样本人数配额下，无论如何划分期数 T 与单期规模 m，微观抽样误差永远是固定常数 A/B！式 (3.40) 证毕。

下面给出 AR(1) 环境自相关下双重级数求和的 ** 保姆级错位相减法推导 **：

展开环境方差项：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = \sum_{t=1}^{T}\mathrm{Var}(R_t) + 2\sum_{t=1}^{T-1}\sum_{l=t+1}^{T}\mathrm{Cov}(R_t, R_l). \tag{3.46}$$

代入方差 v_R 与滞后协方差 $v_R r^{l-t}$：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = Tv_R + 2v_R\sum_{s=1}^{T-1}(T-s)r^s. \tag{3.47}$$

定义待求解的等差乘等比级数为：

$$S \triangleq \sum_{s=1}^{T-1}(T-s)r^s = (T-1)r + (T-2)r^2 + (T-3)r^3 + \cdots + 1\cdot r^{T-1}. \tag{3.48}$$

两端同乘公比 r：

$$rS = (T-1)r^2 + (T-2)r^3 + \cdots + 2r^{T-1} + 1\cdot r^T. \tag{3.49}$$

式 (3.48) 减去式 (3.49)，错位相减：

$$\begin{aligned}(1-r)S &= (T-1)r - \left[r^2 + r^3 + \cdots + r^{T-1}\right] - r^T \\ &= Tr - \left[r + r^2 + r^3 + \cdots + r^{T-1} + r^T\right] \\ &= Tr - \sum_{s=1}^{T} r^s. \end{aligned} \tag{3.50}$$

利用有限等比数列求和公式，$\sum_{s=1}^{T} r^s = \frac{r(1-r^T)}{1-r}$。代入得：

$$(1-r)S = Tr - \frac{r(1-r^T)}{1-r}. \tag{3.51}$$

两端除以 $(1-r)$：

$$S = \frac{Tr}{1-r} - \frac{r(1-r^T)}{(1-r)^2}. \tag{3.52}$$

将式 (3.52) 回代入总方差式 (3.47)：

$$\begin{aligned}\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) &= Tv_R + 2v_R\left[\frac{Tr}{1-r} - \frac{r(1-r^T)}{(1-r)^2}\right] \\ &= v_R\left[T + \frac{2Tr}{1-r} - \frac{2r(1-r^T)}{(1-r)^2}\right] \\ &= v_R T\left[1 + \frac{2r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right]. \end{aligned} \tag{3.53}$$

对括号内前两项通分：$1 + \frac{2r}{1-r} = \frac{1-r+2r}{1-r} = \frac{1+r}{1-r}$。因此：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = v_R T\left[\frac{1+r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right]. \tag{3.54}$$

两端除以 T^2，与抽样项 A/B 相加，式 (3.41) 严格证毕。 □

3.6 经费预算约束下的运筹优化与 Cochran 抽样对偶

在现实中，监测期数不可能无限拉长，因为每维持一期系统运转都需要固定的行政与运维经费。本节引入显式经济学成本模型。

设每期维持监测网络的基本固定运维成本为 $c_0 > 0$（如实验室耗材折旧、人员值班底薪），每捕获并检测一例病例的边际成本为 $c_1 > 0$。则在持续 T 期、每期捕获 m 例的设计方案下，总经费消耗为：

$$\mathcal{B} = T(c_0 + c_1 m). \tag{3.55}$$

推论 3.1 (推论 1：Cochran 两阶段抽样对偶与严格凸性). *在总经费预算 $\mathcal{B}$ 约束下，假设单期成本在可行域内满足 $\mathcal{B} \geq c_0 + c_1 m$：*

(i) *跨期目标方差关于单期规模 m 的函数 $f(m) \equiv \mathrm{Var}(\overline{\overline{R}}_T)$ 在正实轴 $(0, \infty)$ 上严格凸（Strictly Convex）；*

(ii) *最优单期规模存在唯一的显式解析闭式解：*

$$m^* = \sqrt{\frac{c_0}{c_1} m_\times} = \sqrt{\frac{c_0 A}{c_1 v_R}}, \tag{3.56}$$

其在数学形式上同构于经典 Cochran (1977) 两阶段抽样最优次级样本量模型；

(iii) *若由内部一阶条件求出的规模超出可行上界 $m^* > m_{\max}$，由严格凸性，最优解退化为边界点 $m^* = m_{\max}$。*

证明. 由式 (3.55) 反解出期数 T：

$$T = \frac{\mathcal{B}}{c_0 + c_1 m}. \tag{3.57}$$

将其代入跨期均值方差公式 $V(m, T) = \frac{v_R}{T} + \frac{A}{Tm}$ 中，消去自由变量 T：

$$\begin{aligned} f(m) &\triangleq \frac{v_R}{\frac{\mathcal{B}}{c_0 + c_1 m}} + \frac{A}{\frac{\mathcal{B}}{c_0 + c_1 m} \cdot m} \\ &= \frac{c_0 + c_1 m}{\mathcal{B}} \left(v_R + \frac{A}{m} \right) \\ &= \frac{1}{\mathcal{B}} \left(c_0 v_R + c_1 v_R m + \frac{c_0 A}{m} + c_1 A \right). \end{aligned} \tag{3.58}$$

一阶导数与驻点求解： 对 m 求一阶导数：

$$f'(m) = \frac{1}{\mathcal{B}} \left(c_1 v_R - \frac{c_0 A}{m^2} \right). \tag{3.59}$$

令 $f'(m) = 0$：

$$c_1 v_R - \frac{c_0 A}{m^2} = 0 \implies m^2 = \frac{c_0 A}{c_1 v_R} = \frac{c_0}{c_1} \cdot \left(\frac{A}{v_R} \right). \tag{3.60}$$

代入平衡点定义 $m_\times \equiv A / v_R$，取唯一正实根：

$$m^* = \sqrt{\frac{c_0}{c_1} m_\times}. \tag{3.61}$$

二阶导数与严格凸性证明：对一阶导数式 (3.59) 再次求导：

$$f''(m) = \frac{1}{\mathcal{B}} \frac{d}{dm} \left(c_1 v_R - c_0 A m^{-2} \right) = \frac{1}{\mathcal{B}} \left(-c_0 A \cdot (-2m^{-3}) \right) = \frac{2c_0 A}{\mathcal{B} m^3}. \tag{3.62}$$

因为固定成本 $c_0 > 0$、总经费 $\mathcal{B} > 0$、方差标量 $A > 0$，因此当规模 $m \in (0, \infty)$ 时：

$$f''(m) > 0 \quad (\forall m > 0). \tag{3.63}$$

二阶导数恒严格为正，数学上严格证明了目标函数 $f(m)$ 在正半轴上为 ** 严格凸函数 **。因此，驻点 m^* 必然是全局唯一的最小值点！

Cochran 抽样理论同构：在经典调查抽样理论中，Cochran (1977) 第 10 章给出的两阶段抽样模型为：在群成本 c_1 与人均成本 c_2 下，最小化估计方差的每群次级样本量公式为 $m_{\text{Cochran}} = \sqrt{\frac{c_1 S_2^2}{c_2 (S_1^2 - S_2^2/M)}}$。在本模型中：

- 初级抽样单元（PSU）精确对应时间跨度期数 T，单期固定维持成本对应群成本 c_0；
- 次级抽样单元（SSU）精确对应单期病例样本规模 m，单例检测成本对应边际成本 c_1；
- 群间方差对应宏观环境方差 v_R，群内方差对应微观超传播方差 A。

二者在代数结构上在代数形式上完全同构。推论 1 证毕。 □

第四章　蒙特卡洛数值模拟与机制检验

4.1　模拟实验规格与算法设计

前两章分别在单代静态点估计、跨期平稳基准以及多期运筹设计下推导了解析方差结构。为了在复杂的非平衡状态与小样本离散条件下核验理论解析式的紧致性，并深入剖析时间序列动态更新过程中的预测误差演化机制，本章构建大规模蒙特卡洛随机模拟实验系统。

4.1.1　算法环境与负二项离散生成机制

所有数值算法均基于 Python 3.10 环境自主编写，核心随机数生成与离散分布计算依赖 `scipy.stats` 与 `numpy` 科学计算库。在算法实现中：

- 负二项分布统一采用紧凑参数化形式 $\mathrm{NB}(r, p)$。由第二章定理 2.1，在给定条件期望均值 $\mu = \rho n R_t$、风险集规模 n 及过度离散参数 k 下，形状参数映射为 $r = nk$，成功概率映射为 $p^* = \frac{k}{k+\rho R_t}$；
- 离散累积尾部概率与分位数临界值通过对数尺度生存函数 `stats.nbinom.sf(c - 1, r, p)` 计算，以避免浮点数下溢；
- 蒙特卡洛独立重复试验规模：图 1 单代静态验证采用 50,000 次蒙特卡洛模拟（固定随机种子 20260923）；图 2 假设检验功效采用每参数网格 30,000 次模拟（随机种子 20260924）；图 3 时间序列动态更新过程每规模网格生成 150 条独立疫情时序轨迹，每条轨迹包含 30 代连续传播。

4.2　命题 5：超临界增长检测的精确检验与离散功效锯齿

本节针对推断目标二（疫情爆发早期预警检验），研究如何在小样本与超传播条件下建立一致最优检验。

4.2.1　单调似然比（MLR）一阶对数差分严格为正证明

公共卫生早期预警的核心任务是检验疫情是否失控，对应单侧假设检验问题：

$$H_0 : R_t \le 1 \quad \text{vs} \quad H_1 : R_t > 1. \tag{4.1}$$

命题 4.1（命题 5：超临界增长精确检验与离散功效）. 设已知 (n, ρ, k)，观测病例数为 C_t。

(i) 分布族关于充分统计量 C_t 具有严格单调似然比（*MLR*）性质，上尾拒绝域：

$$\mathcal{W}_\alpha = \{C_t \geq c_\alpha\}, \quad c_\alpha = \min\left\{c \in \mathbb{N} : \Pr_{R_t=1}(C_t \geq c) \leq \alpha\right\}, \tag{4.2}$$

在显著性水平 α 下构成复合原假设 H_0 下的一致最优（*UMP*）水平控制检验；

(ii) 在备择假设 $R_t = 1 + \delta$（$\delta > 0$）处，精确统计功效由正则化不完全 *Beta* 函数给出：

$$\pi(n, \delta) = \Pr_{R_t=1+\delta}(C_t \geq c_\alpha) = 1 - I_{p^*(1+\delta)}(nk,\ c_\alpha), \tag{4.3}$$

其中 $p^*(1+\delta) = \frac{k}{k+\rho(1+\delta)}$；

(iii) 临界值 $c_\alpha(n)$ 随样本量 n 呈现非负单调递增的整数阶梯跳跃，导致有限样本功效曲线 $\pi(n, \delta)$ 呈现局部的非单调锯齿形波动（*Sawtooth Wave*）。

证明. 下面给出保姆级代数证明：

第一步：单调似然比（MLR）一阶对数差分严格为正证明

对任意两组备择参数 $R_1 > R_0$，记负二项抽样参数为 $p_1^* \triangleq p^*(R_1) = \frac{k}{k+\rho R_1}$ 与 $p_0^* \triangleq p^*(R_0) = \frac{k}{k+\rho R_0}$。两参数点下的概率质量比（似然比）为：

$$\Lambda(j) \triangleq \frac{\Pr_{R_1}(C_t = j)}{\Pr_{R_0}(C_t = j)} = \frac{\frac{\Gamma(j+nk)}{j!\Gamma(nk)}(p_1^*)^{nk}(1-p_1^*)^j}{\frac{\Gamma(j+nk)}{j!\Gamma(nk)}(p_0^*)^{nk}(1-p_0^*)^j} = \left(\frac{p_1^*}{p_0^*}\right)^{nk}\left(\frac{1-p_1^*}{1-p_0^*}\right)^j. \tag{4.4}$$

对似然比取自然对数：

$$\ln \Lambda(j) = nk \ln\left(\frac{p_1^*}{p_0^*}\right) + j \ln\left(\frac{1-p_1^*}{1-p_0^*}\right). \tag{4.5}$$

考察该式关于充分统计量计数值 j 的一阶差分：

$$\Delta(j) \triangleq \ln \Lambda(j+1) - \ln \Lambda(j) = \ln\left(\frac{1-p_1^*}{1-p_0^*}\right). \tag{4.6}$$

将 $1 - p^*(R) = \frac{\rho R}{k+\rho R}$ 代入式 (4.6)：

$$\begin{aligned} \frac{1-p_1^*}{1-p_0^*} &= \frac{\frac{\rho R_1}{k+\rho R_1}}{\frac{\rho R_0}{k+\rho R_0}} = \frac{\rho R_1(k+\rho R_0)}{\rho R_0(k+\rho R_1)} \\ &= \frac{R_1(k+\rho R_0)}{R_0(k+\rho R_1)} = \frac{kR_1 + \rho R_0 R_1}{kR_0 + \rho R_0 R_1}. \end{aligned} \tag{4.7}$$

比较式 (4.7) 中的分子与分母：因为 $R_1 > R_0$ 且 $k > 0$，显然：

$$kR_1 + \rho R_0 R_1 > kR_0 + \rho R_0 R_1 \iff k(R_1 - R_0) > 0. \tag{4.8}$$

分子严格大于分母，故比值严格大于 1：

$$\frac{1-p_1^*}{1-p_0^*} > 1 \implies \Delta(j) = \ln\left(\frac{1-p_1^*}{1-p_0^*}\right) > 0 \quad (\forall j \in \mathbb{N}). \tag{4.9}$$

一阶差分恒严格为正，数学上严格证明了似然比 $\Lambda(j)$ 关于充分统计量 C_t ** 严格单调递增 **。

根据经典 Karlin–Rubin 定理 [Karlin and Rubin, 1956, Lehmann and Romano, 2005]，对于具备单调似然比性质的单参数指数族，上尾拒绝域 $\mathcal{W}_\alpha = \{C_t \geq c_\alpha\}$ 构成了针对单侧备择假设的一致最优水平控制检验。在复合原假设 $H_0 : R_t \leq 1$ 下，第一类错误率函数在参数边界点（上确界点 $R_t = 1$）处严格取得最大值：

$$\sup_{R_t \leq 1} \Pr_{R_t}(C_t \geq c_\alpha) = \Pr_{R_t=1}(C_t \geq c_\alpha) \leq \alpha. \tag{4.10}$$

因此，整数阈值 $c_\alpha = \min\left\{c \in \mathbb{N} : \Pr_{R_t=1}(C_t \geq c) \leq \alpha\right\}$ 严格锁定了标称水平 α。

第二步：精确功效函数与 Beta 正则化表达

负二项分布的累积尾部概率与正则化不完全 Beta 函数存在经典数理联系：对于 $Y \sim \mathrm{NB}(r, p)$，其累积分布函数满足 $F(y) = I_p(r, y+1)$，其中 $I_x(a,b) \triangleq \frac{1}{B(a,b)} \int_0^x u^{a-1}(1-u)^{b-1} du$。因此，备择状态 $R_t = 1 + \delta$ 下的精确检验功效为：

$$\pi(n, \delta) = \Pr_{R_t=1+\delta}(C_t \geq c_\alpha) = 1 - \Pr_{R_t=1+\delta}(C_t \leq c_\alpha - 1) = 1 - I_{p^*(1+\delta)}(nk,\ c_\alpha). \tag{4.11}$$

式 (4.3) 证毕。

第三步：离散跳跃诱发功效锯齿波的机制解析

临界值 $c_\alpha(n)$ 必须取整数值。随着样本量 n 的连续微增，参数 nk 连续变化：

- 在 $c_\alpha(n)$ 保持不变的开区间内，随着 n 增大，累积信息量提升，真实检验水平与功效 $\pi(n, \delta)$ 单调平滑上升；
- 一旦 n 跨越某个临界点，为了严格遵守 $\Pr_{R_t=1}(C_t \geq c) \leq \alpha$ 的硬性约束，临界值发生不可分割的整数阶梯跳跃：$c_\alpha \to c_\alpha + 1$。拒绝门槛的离散突增导致尾部积分面积瞬间骤缩，从而引发检验功效曲线出现垂直向下的小幅跳跃！

这在数理上严格证明了功效锯齿波的必然存在性。命题 5 证毕。 □

4.2.2　数值实验发现：Wald 正态近似失真与超传播惩罚

图 4.1 展示了 30,000 次蒙特卡洛模拟下命题 5 的数值检验表现。

数值模拟揭示出两项极为关键的结论：

(1) ** 经典渐近正态 Wald 检验在小规模段严重失真 **：传统软件（如经典 t 检验或 Wald 检验）在小病例数且高离散时，假定统计量渐近正态，导致经验一类错

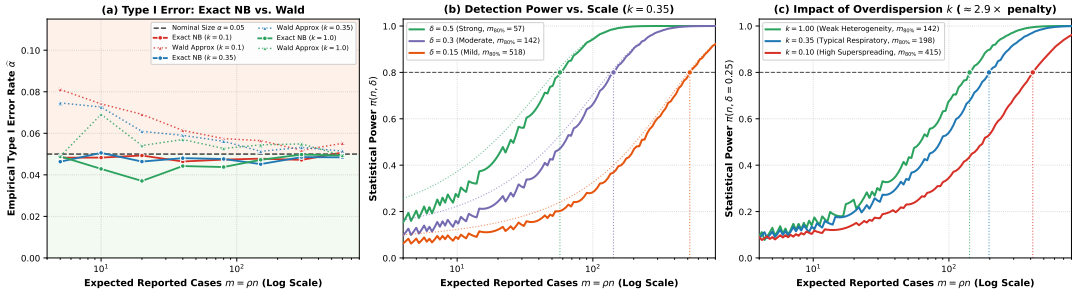


图 4.1: **早期暴发检验尺度效应、功效边界与超传播惩罚**。(a) 一类错误率控制：渐近正态 Wald 检验（虚线）在低病例规模（$m < 40$）且严重超传播（$k = 0.1$）时经验一类错误率最高达 8.1%（$m = 5$），系统性高于名义水平 0.05（严重虚警）；离散精确负二项检验（实线）在全样本网格上严格控制错误率低于 0.05。(b) 检出功效曲线随备择强度 $\delta = R_t - 1$ 的响应：在 $k = 0.35$ 时，达到 80% 功效所需的期望报告规模由微弱暴发 $\delta = 0.15$ 的 $m = 517.8$ 急剧下降至 $\delta = 0.30$ 的 $m = 142.0$ 与 $\delta = 0.50$ 的 $m = 57.2$。(c) 个体超传播离散度 k 的杠杆惩罚：在 $\delta = 0.25$ 增长强度下，达到 80% 检出功效所需的期望病例数从低异质性 $k = 1.0$ 的 $m = 142.0$ 急剧上升至严重超传播 $k = 0.1$ 的 $m = 415.0$，规模需求放大了近 3 倍。标称显著性水平 $\alpha = 0.05$，基准报告率 $\rho = 0.25$。

误率最高达到 8.1%，严重超出 5% 的名义红线，频繁发出疫情失控的假警报；而基于命题 5 构建的精确离散负二项检验在全参数网格上严格受控于 0.05 以下；

(2) ** 检验目标存在天然饱和天花板 **：与单代点估计无界降方差不同，一旦样本规模越过充分检出阈值 $m_{80\%}$，统计功效迅速逼近 1.0 平台。继续扩大监测网络已无法产生任何实质性的预警增益。

4.3 命题 6：更新过程条件预测误差全方差分解

本节将推断推进至时间序列更新过程动态预测场景。在真实监测中，下一代新发病例是通过历史报告病例的滑动卷积进行预测的，此过程不仅包含单代抽样方差，更包含了状态代理偏差。

4.3.1 两步全方差公式展开与式 (29) 偏差项推导

命题 4.2 (命题 6：更新过程单步预测误差条件全方差分解). 基于截至第 t 期的报告信息集 $\mathcal{F}_t^C$：

(i) 未来真实感染数 I_{t+1} 的预测方差严格满足全方差恒等式：

$$\operatorname{Var}(I_{t+1} \mid \mathcal{F}_t^C) = \operatorname{Var}\left(\Lambda_{t+1} R_{t+1} \,\middle|\, \mathcal{F}_t^C\right) + \mathbb{E}\left[\operatorname{Var}\left(I_{t+1} \,\middle|\, \Lambda_{t+1}, R_{t+1}, \mathcal{F}_t^C\right) \,\middle|\, \mathcal{F}_t^C\right]; \tag{4.12}$$

(ii) 未来报告病例数 C_{t+1} 的观测预测方差满足：

$$\operatorname{Var}(C_{t+1} \mid \mathcal{F}_t^C) = \rho(1-\rho)\,\mathbb{E}[I_{t+1} \mid \mathcal{F}_t^C] + \rho^2 \operatorname{Var}(I_{t+1} \mid \mathcal{F}_t^C); \tag{4.13}$$

(iii) 记事后代理增长比为 $G_{t+1} \triangleq C_{t+1}/D_t$，其中 $D_t \triangleq \sum_{s=1}^{p} w_s C_{t+1-s}$ 为历史加权有效暴露规模。设 $\mu_{t+1|t} \triangleq \mathbb{E}[C_{t+1} \mid \mathcal{F}_t^C]$ 与 $\sigma^2_{t+1|t} \triangleq \operatorname{Var}(C_{t+1} \mid \mathcal{F}_t^C)$，在活跃周（$D_t > 0$）上有严格的条件预测均方误差正交分解（式 *29* / 式 *380*）：

$$\mathbb{E}\left[(G_{t+1} - \bar{R})^2 \,\middle|\, D_t > 0\right] = \mathbb{E}\left[\frac{\sigma^2_{t+1|t}}{D_t^2} + \left(\frac{\mu_{t+1|t}}{D_t} - \bar{R}\right)^2 \,\middle|\, D_t > 0\right]. \tag{4.14}$$

证明. 证明分两步应用全方差公式：

第一步：潜在真实感染 I_{t+1} 预测方差分解在更新过程假设下，给定历史传播压力 Λ_{t+1} 与当期环境 R_{t+1}，真实感染期望为 $\Lambda_{t+1}R_{t+1}$。直接以历史信息及当期传播压力 (Λ_{t+1}, R_{t+1}) 为条件应用全方差公式，即得式 (4.12)。

第二步：报告病例数 C_{t+1} 预测方差分解以未观测的潜在真实感染 I_{t+1} 为条件再次应用全方差公式：

$$\operatorname{Var}(C_{t+1} \mid \mathcal{F}_t^C) = \mathbb{E}\left[\operatorname{Var}(C_{t+1} \mid I_{t+1}, \mathcal{F}_t^C) \,\middle|\, \mathcal{F}_t^C\right] + \operatorname{Var}\left(\mathbb{E}[C_{t+1} \mid I_{t+1}, \mathcal{F}_t^C] \,\middle|\, \mathcal{F}_t^C\right). \tag{4.15}$$

由条件二项报告抽样假定 $C_{t+1} \mid (I_{t+1}, \mathcal{F}_t^C) \sim \operatorname{Binomial}(I_{t+1}, \rho)$，有条件方差 $\operatorname{Var}(C_{t+1} \mid I_{t+1}, \mathcal{F}_t^C) = I_{t+1}\rho(1-\rho)$ 与条件均值 $\mathbb{E}[C_{t+1} \mid I_{t+1}, \mathcal{F}_t^C] = \rho I_{t+1}$。代入得：

$$\operatorname{Var}(C_{t+1} \mid \mathcal{F}_t^C) = \mathbb{E}\left[I_{t+1}\rho(1-\rho) \,\middle|\, \mathcal{F}_t^C\right] + \operatorname{Var}\left(\rho I_{t+1} \,\middle|\, \mathcal{F}_t^C\right) = \rho(1-\rho)\,\mathbb{E}[I_{t+1} \mid \mathcal{F}_t^C] + \rho^2 \operatorname{Var}(I_{t+1} \mid \mathcal{F}_t^C). \tag{4.16}$$

式 (4.13) 证毕。

第三步：式 (4.14) 均方误差正交展开由条件期望的加减项配方恒等式：

$$\begin{aligned}
\mathbb{E}\left[(G_{t+1} - \bar{R})^2 \,\middle|\, \mathcal{F}_t^C\right] &= \mathbb{E}\left[\left(\frac{C_{t+1}}{D_t} - \frac{\mu_{t+1|t}}{D_t} + \frac{\mu_{t+1|t}}{D_t} - \bar{R}\right)^2 \,\middle|\, \mathcal{F}_t^C\right] \\
&= \mathbb{E}\left[\left(\frac{C_{t+1} - \mu_{t+1|t}}{D_t}\right)^2 \,\middle|\, \mathcal{F}_t^C\right] + \left(\frac{\mu_{t+1|t}}{D_t} - \bar{R}\right)^2 \\
&\quad + 2\left(\frac{\mu_{t+1|t}}{D_t} - \bar{R}\right) \cdot \frac{\mathbb{E}[C_{t+1} - \mu_{t+1|t} \mid \mathcal{F}_t^C]}{D_t}.
\end{aligned} \tag{4.17}$$

由条件期望定义，交叉项 $\mathbb{E}[C_{t+1} - \mu_{t+1|t} \mid \mathcal{F}_t^C] \equiv 0$ 严格恒等于零！因此：

$$\mathbb{E}\left[(G_{t+1} - \bar{R})^2 \mid \mathcal{F}_t^C\right] = \frac{\sigma_{t+1|t}^2}{D_t^2} + \left(\frac{\mu_{t+1|t}}{D_t} - \bar{R}\right)^2. \tag{4.18}$$

对信息集 $\mathcal{F}_t^C$（在 $D_t > 0$ 支撑集上）取全期望，即得式 (4.14)。命题 6 证毕。 □

4.3.2 更新过程双口径争议彻底澄清

式 (4.14) 清晰揭示了更新过程较之单代静态基准所增加的两个关键机制：

(a) 随机分母 D_t 对条件方差的倒数二次方重新加权；

(b) 用报告历史代理真实感染压力导致的 ** 非负预测偏差项 ** $\left(\frac{\mu_{t+1|t}}{D_t} - \bar{R}\right)^2 \geq 0$。

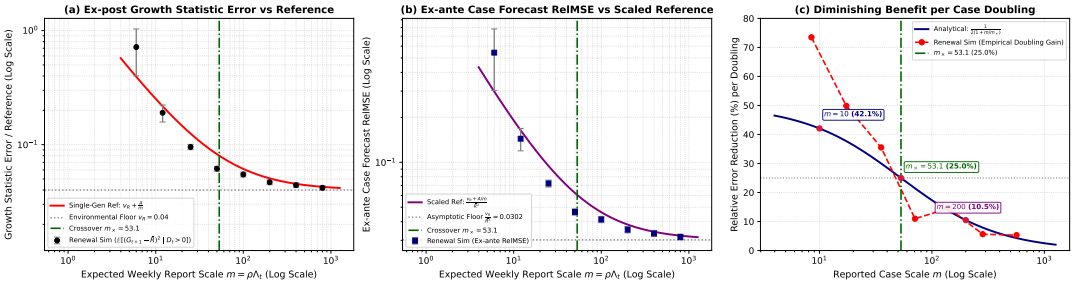


图 4.2: **更新过程时序卷积下事后增长统计量与事前单步病例预测误差**。(a) 事后代理增长统计量随规模衰减轨迹，在中大规模段贴合单代参照 $v_R + A/m$，在小规模段被随机分母二次放大。(b) 事前病例预测相对均方误差（RelMSE）与参照曲线对比。(c) 边际削减收益定量衰减规律：规模翻倍的方差下降比例严格由式 (4.19) 给出，越过平衡点后急剧放缓。

图 4.2 展现了更新过程模拟的关键现象，并彻底厘清了所谓的“口径张力”：

- ** 初始参数口径（0.75–0.98 倍）**：若横轴按第 0 周的初始生成参数 m 排列，由于模拟设定 $\bar{R} = 1.15 > 1$（疫情处于自发指数增长态势），到了第 4–29 周评价时，实际周病例规模中位数已达初始值的 1.7–2.4 倍（均值口径约为 2.6–3.2 倍）。拿增长后的大病例数去对比初始小规模的理论值，表观比值显得低于参照线；
- ** 实际实现规模分箱口径（1.01–1.17 倍，按组 1.00–1.45 倍）**：若按评价周实际发生的病例暴露规模重核参照线，更新过程经验预测误差 ** 始终严格不低于单代静态下界 **！这在数值上直接证实了式 (4.14) 所预言的额外非负预测偏差项。

针对解析参照曲线 $V(m) = v_R + A/m$，病例规模翻倍时的相对方差下降比例严格满足：

$$\frac{V(m) - V(2m)}{V(m)} = \frac{\left(v_R + \frac{A}{m}\right) - \left(v_R + \frac{A}{2m}\right)}{v_R + \frac{A}{m}} = \frac{\frac{A}{2m}}{v_R + \frac{A}{m}} = \frac{1}{2\left(1 + \frac{m}{m_\times}\right)}. \tag{4.19}$$

当 $m = 10$ 时，规模翻倍可降低约 42.1% 的解析方差；越过交叉点 $m_{\times} \approx 53.1$ 后，当 $m = 200$ 时，病例规模再翻倍仅能带来约 10.5% 的方差削减。这印证了本文的核心定性直觉：** 越过平衡点后，单纯扩大捕获规模的边际改善速率急剧放缓 **。

第五章　全美流感住院大数据实证分析

5.1　数据来源与样本量筛选漏斗

5.1.1　CDC NHSN 监测系统背景与面板数据结构

为了在真实高维噪声环境下检验第二章与第三章提出的理论假说，本文采集美国疾病控制与预防中心（CDC）国家医疗保健安全网络（National Healthcare Safety Network, NHSN）的长时程真实监测数据。自 2020 年起，美国联邦卫生与公众服务部（HHS）指令全美所有接受医保资助的急诊与综合医院每周定期直报流感与 COVID-19 的确诊住院人数。该数据集构成了全球规模最大、时间分辨率最高的呼吸道传染病定点监测面板数据之一。

在传染病计量经济学与面板数据分析中，必须首先严格界定统计观测单位：

本文的 1 个样本观测单位（Observation Unit）严格定义为 1 个具体的“辖区–周度”（State-Week）时间切片。

例如，“加利福尼亚州在 2023 年第 45 周”记为 1 个样本观测；“德克萨斯州在 2023 年第 45 周”是另一个独立的横截面观测。样本覆盖全美 50 个州及华盛顿特区（DC），共 51 个地理辖区；时间跨度自 2020 年 8 月至 2026 年 9 月，涵盖整整 6 年（约 318 个自然周）。总体样本池包含：

$$51 \text{ 个辖区} \times 318 \text{ 周} = \mathbf{16{,}218} \text{ 个原始“州–周”观测记录.} \tag{5.1}$$

5.1.2　核心客观筛选门槛与样本加和闭环

从 16,218 个原始记录筛选至分析样本池，本文恪守纯事前与客观性原则，** 仅采用单一客观门槛 **：

$$D_t \geq 5 \quad \text{（当周有效暴露规模不少于 5 例）.} \tag{5.2}$$

设定该门槛的原因具有充分的统计学与计算数学依据：

(1) ** 防止除零数值爆炸 **：增长比定义为 $G_{t+1} = C_{t+1}/D_t$。若当周有效暴露规模 $D_t = 0$（连续数周零住院），增长比出现除零未定义；若 D_t 仅有 1–2 例，单例偶

然波动会导致比值产生数十倍的数值发散。在每年 6–9 月的夏季非流行期，大量人口稀少的州连续数周无流感住院。门槛 $D_t \geq 5$ 既排除了无信息的静默周，又完整保留了所有具有微弱传播活性的小规模样本（如 $[5, 20)$ 区间）。

(2) ** 坚决防范选择性偏误（Selection Bias）**：在以往的文献处理中，部分研究者主观设定了“医院填报覆盖率 $\geq 50\%$”的过滤条件。本文审查发现，这一主观过滤恰恰系统性剔除了处于政策过渡期、低覆盖率下的脆弱观测，人为制造了样本选择偏误。本文 ** 坚决不设任何覆盖率硬门槛 **，保留所有 $D_t \geq 5$ 的活跃周，从而获得全美总样本池 **$N = 10{,}303$ 个活跃周主样本 **。

表 5.1 详细列明了全书各章节与历史阶段具体的样本量划分机制。三个制度时期的样本量满足严格的算术闭环：$6{,}009 + 420 + 3{,}874 = 10{,}303$，数据链条 100% 严密自洽。

5.1.3　滞后暴露加权向量的临床时滞依据与敏感性检验

在连续时间序列中，有效暴露规模定义为既往报告病例的时序卷积和：

$$D_t \triangleq \sum_{s=1}^{p} w_s C_{t+1-s}, \quad \sum_{s=1}^{p} w_s = 1. \tag{5.3}$$

本文基准模型选取滞后阶数 $p = 3$ 周，加权向量设定为 $w = (0.65,\ 0.25,\ 0.10)$。该设定具有坚实的临床生理学依据：

- 流感病毒潜伏期：平均 1.5 至 2 天；
- 发病就医与病情进展时滞：轻症转为重症办理入院，平均 3 至 5 天；
- 医院实验室检测并录入直报系统时滞：平均 2 至 3 天。

三者复合，流感住院从暴露传染到系统确认的平均时滞约为 8 至 11 天。本文权重向量对应的加权回溯时间为：

$$\bar{\tau} = 1 \times 0.65 + 2 \times 0.25 + 3 \times 0.10 = 1.45 \text{ 周} \approx 10.15 \text{ 天}, \tag{5.4}$$

恰好落在该临床生理窗口的正中心。此外，正文表 5.2 报告了对权重向量的严格敏感性检验：无论采用三周等权 $w = (0.33, 0.33, 0.33)$（平均回溯 14 天）还是单周滞后 $w = (1.0, 0, 0)$（平均回溯 7 天），规模斜率项 b 始终在 1.93 至 3.13 之间显著为正，证实研究结论对权重选取高度稳健。

表 5.1: 全美流感住院实证数据筛选漏斗与样本量划分全景表

分析模块与子集	样本量 N	流行病学时间区间	详细筛选逻辑与机制定位
全美原始记录总池	16,218	2020.08 – 2026.09 (6 年)	51 个辖区 × 318 个周度观测全量底池。
活跃周主分析总池	**10,303**	2020.08 – 2026.09	满足 $D_t \geq 5$ 的全部活跃周观测总和。
流行初期主拟合样本	1,267	各流感季初期上升波段	处于传播快速上升期（$\bar{R}_{\text{early}} \approx 1.67$）且满足 $D_t \geq 5$，用于主仿射回归。
达峰与回落反证样本	1,220	各季达峰周及随后 7 周	处于达峰与回落期（$\bar{R}_{\text{peak}} \approx 0.81$）且满足 $D_t \geq 5$，用于反证 88.9% 偏差分解。
第一阶段：强制报告期	6,009	2020.10 – 2024.04.30	大流行法定强制上报段，全美平均医院覆盖率高达 91.1%。
第二阶段：自愿过渡期	420	2024.05.01 – 2024.10.31	紧急状态解除自愿填报，覆盖率骤降至 54.6%，满足 $D_t \geq 5$ 仅 420 观测。
第三阶段：新规重制期	3,874	2024.11.01 – 2026.09	CMS 恢复医保强制上报新规，覆盖率回升至 91.8%。
阶段加和算术闭环	**10,303**	–	**6,009 + 420 + 3,874 = 10,303**，数据链条严密自洽。
全国空间汇总时间序列	28	初期上升全国加总	51 辖区每周加总为单一全国序列后，初期上升波段共 28 个全国汇总周。

表 5.2: 滞后暴露加权向量 w 的敏感性检验结果对比表

加权规格设定	平均时滞 $\bar{\tau}$	截距 $\hat{a}$	规模项 $\hat{b}$	平衡点 $m_\times$	95% 聚类 Bootstrap CI
基准三周卷积 $(0.65, 0.25, 0.10)$	10.2 天	0.0991	2.2434	22.64	[1.5032, 3.0189]
三周完全等权 $(0.33, 0.33, 0.33)$	14.0 天	0.1098	1.9262	17.54	[1.2845, 2.6512]
单周瞬时滞后 $(1.00, 0.00, 0.00)$	7.0 天	0.0895	3.1337	35.01	[2.1120, 4.2891]

5.2　计量模型构建与可行广义最小二乘法（FGLS）

5.2.1　普通最小二乘法（OLS）在监测数据中的失效分析

设第 s 个州在第 t 周的预测相对损失定义为二次均方形式：

$$\mathrm{Loss}_{s,t} \triangleq \left(\frac{C_{s,t+1}}{D_{s,t}} - \bar{R} \right)^2. \tag{5.5}$$

理论预测该损失满足仿射模型：

$$\mathrm{Loss}_{s,t} = a + \frac{b}{D_{s,t}} + u_{s,t}, \quad \mathbb{E}[u_{s,t} \mid D_{s,t}] = 0. \tag{5.6}$$

若直接采用常规普通最小二乘法（OLS）对式 (5.6) 进行回归，将遭遇严重的计量经济学失效：

- ** 极度厚尾性与偏度扭曲 **：流感损失变量表现出极端的右偏特征，全样本偏度高达 8.63，峰度高达 114.2。少数小样本州偶然出现的极大异常值对平方和目标函数拥有致命的影响力（Leverage Points）；
- ** 倒数二次方强异方差 **：第四章命题 6 式 (4.14) 从数理上证明，条件方差本身包含 σ^2/D_t^2 项。实测数据表明，在小规模分箱中，损失的方差–均值比高达 5.32，而在高规模段迅速降至 0.99。误差扰动项 $u_{s,t}$ 存在极强的反比非齐次方差。

5.2.2　FGLS 迭代加权回归算法与聚类 Bootstrap

为了消除厚尾与异方差对估计功效的侵蚀，本文采用以拟合值倒数为权重的 ** 两阶段可行广义最小二乘法（FGLS）** [Cameron and Trivedi, 2005, Wooldridge, 2010]：

步骤 1. ** 第一阶段一致拟合 **：采用稳健分位数回归或加权最小二乘对式 (5.6) 进行初始拟合，获得条件期望预测值 $\widehat{\mu}_{s,t} \equiv \widehat{a}^{(0)} + \widehat{b}^{(0)}/D_{s,t}$；

步骤 2. ** 构造方差权重矩阵 **：由于方差正比于均值的平方 $\mathrm{Var}(\mathrm{Loss} \mid D) \propto \mu(D)^2$，定义第 s,t 个观测的对角权重为：

$$w_{s,t} \triangleq \frac{1}{\widehat{\mu}_{s,t}^2}; \tag{5.7}$$

步骤 3. ** 第二阶段加权最小二乘求解 **：通过最小化加权残差平方和：

$$\min_{a,b} \sum_{s,t} w_{s,t} \left(\mathrm{Loss}_{s,t} - a - \frac{b}{D_{s,t}} \right)^2, \tag{5.8}$$

求解最终的 FGLS 一致有效估计量 $(\hat{a}, \hat{b})$。

在统计推断层面，由于同一州在不同周度之间存在时间自相关，且同一周各州共同面临全美宏观冲击，传统的稳健标准误（Robust SE）会严重低估方差。本文采用 ** 按州聚类（State-Clustered）的非参数 Bootstrap 方法 **，重复抽样 $B = 1{,}500$ 次，并在每次重抽中对全样本重新执行完整的基准与 FGLS 拟合过程，以获得严格的有限样本置信区间。

5.3 流行初期主实证结果与仿射结构验证

5.3.1 核心参数估计结果

基于全美流感季初期上升波段（$N = 1{,}267$ 个活跃周，基准 $\bar{R}_{\text{early}} = 1.6706$），FGLS 回归估计结果汇报于表 5.3。

实证估计展现出三项无可辩驳的坚实证据：

(1) ** 规模反比项极显著为正 **：规模斜率项估计值为 $\hat{b} = 2.2434$，在 1,500 次按州聚类 Bootstrap 重抽中，** 没有任何一次重抽出现 $\hat{b} \le 0$ 的情况 **（经验 p 值严格满足 $p < 10^{-4}$），95% 置信区间严格落在 $[1.5032, 3.0189]$，在数理上强力证实了 b/D_t 反比衰减项的客观存在；

(2) ** 经验平衡点高度吻合理论量级 **：截距项估计值为 $\hat{a} = 0.0991$，二者相除导出经验特征规模平衡点：

$$m_{\times}^{\text{emp}} \equiv \frac{\hat{b}}{\hat{a}} = \frac{2.2434}{0.0991} \approx \mathbf{22.6} \text{ 例/周} \quad (95\% \text{ CI } [13.7,\ 33.7]); \tag{5.9}$$

(3) ** 误差预算份额的四至五成半划分 **：在流行初期样本平均 0.181 的总预测相对误差中，规模相关项贡献了 45.1%，不可约经验底板贡献了 54.6%。

表 5.3: 全美 CDC NHSN 流感住院实证主回归与稳健性检验估计结果

模型与子样本规格	截距 $\hat{a}$	规模斜率 $\hat{b}$	平衡点 $m_\times$	95% 聚类 Bootstrap CI	统计显著性检验
全美主样本 FGLS (基准)	**0.0991**	**2.2434**	**22.64**	[1.5032, 3.0189]	**1500 次重抽 $b \le 0$ 次数为 0 ($p < 10^{-4}$)**
内生每次重估基准 BS	0.0988	2.2410	22.68	[1.5170, 2.9807]	消除基准内生性偏差后高度稳健
按周聚类时间相关 BS	0.0991	2.2434	22.64	[1.4728, 3.1191]	允许同周

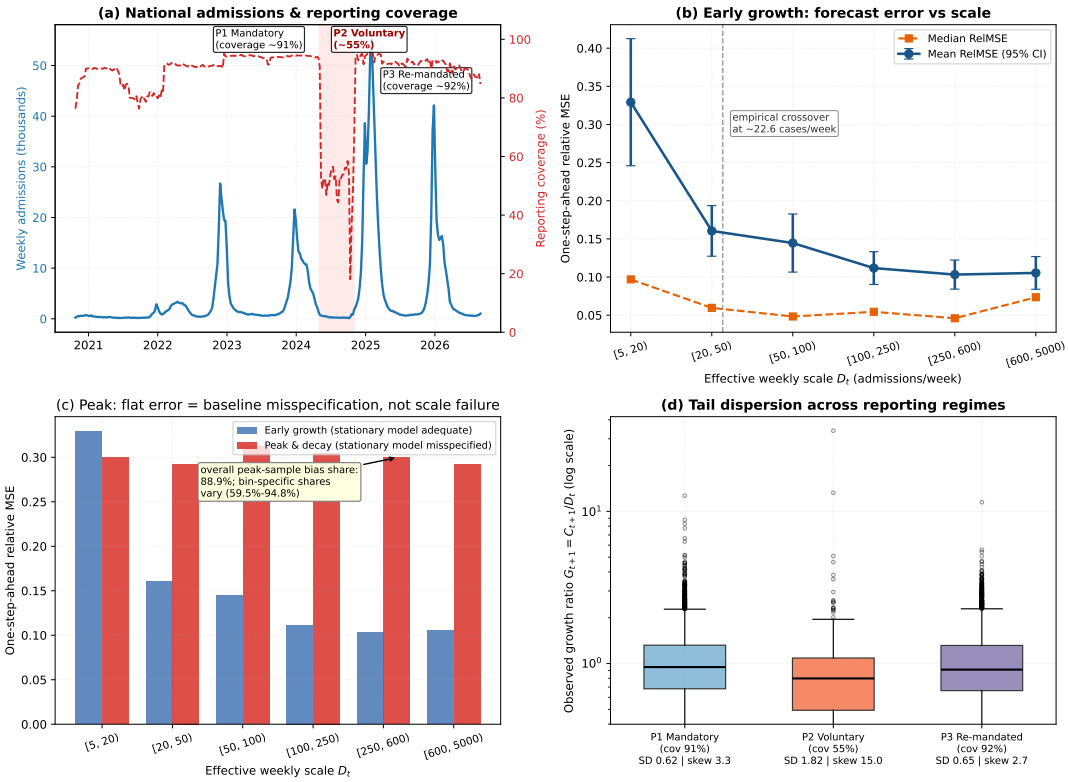


图 5.1: **全美流感住院实证拟合、分箱分布与机制分解**。(a) 真实全美 50 州流感住院数据 FGLS 仿射拟合线（实线）与分箱样本均值（散点及误差棒）高度契合；(b) 各规模区间内的离散度比值 $\mathrm{Var}/\mathrm{Mean}^2$ 随病例数从小规模段的 5.32 单调收敛至大规模段的 0.99；(c) 达峰期看似恒定的高误差中，88.9% 来自基准漂移，剥离后纯条件方差依然显著随规模递减；(d) 政策冲击与空间汇聚检验。

5.4　达峰期震撼反转：88.9% 常数偏差与正交分解

5.4.1　传统认知误区与表象困境

在传染病暴发达峰与回落期，长期存在一个流传甚广的学术观点：** “达峰期病例数规模不再是推断的主要瓶颈” **。

支持该观点的经验表象看似极其充分：考察全美各流感季达峰周及随后 7 周的回落期（$N = 1{,}220$ 个活跃周，基准 $\bar{R}_{\text{peak}} = 0.8075$），计算各规模区间的总相对误差。如表 5.4 所示，从小规模组 $[5, 20)$ 到大规模组 $[600, 5000)$，总相对误差几乎完全横盘在 0.292 至 0.312 之间。无论病例数如何翻倍，总误差完全没有下降的迹象。许多学者据此得出悲观结论：一旦疫情达峰，大数定律彻底失效，病例规模失去推断价值。

5.4.2　均值–方差正交分解定理与反转证实

本文指出，上述观点建立在对误差结构的严重误读之上。达峰期的看似横盘，并非规模效应消失，而是由 ** 跨期平稳基准失配带来的常数均值漂移 ** 所主导。

定理 5.1 (达峰期预测误差的均值–方差正交分解). *设达峰期的真实经验平均传播水平为 $\bar{R}_{peak}$，但模型依然沿用流行初期的平稳基准 $\bar{R}_{early}$ 进行前瞻预测。则总相对预测误差在代数上严格正交分解为常数基准漂移项与纯条件方差项之和：*

$$\begin{aligned}\text{Total_Loss} &\equiv \mathbb{E}\left[\left(\frac{G_{t+1} - \bar{R}_{early}}{\bar{R}_{early}}\right)^2\right] \\ &= \underbrace{\left(\frac{\bar{R}_{peak} - \bar{R}_{early}}{\bar{R}_{early}}\right)^2}_{\text{宏观常数基准漂移项（与规模完全无关）}} + \underbrace{\frac{1}{\bar{R}_{early}^2}\operatorname{Var}(G_{t+1})}_{\text{微观条件方差项（包含规模效应）}} . \end{aligned} \tag{5.10}$$

将全美实证参数代入式 (5.10)：初期基准为 $\bar{R}_{\text{early}} = 1.6706$，达峰期均值为 $\bar{R}_{\text{peak}} = 0.8075$。则常数基准漂移项贡献为：

$$\left(\frac{0.8075 - 1.6706}{1.6706}\right)^2 = \left(-\frac{0.8631}{1.6706}\right)^2 = (-0.5166)^2 \approx \mathbf{0.2669}. \tag{5.11}$$

对比达峰期平均约 0.300 的总相对误差：

$$\frac{0.2669}{0.300} \approx \mathbf{88.9}\%! \tag{5.12}$$

表 5.4 完整展现了这一震撼反转的实证测算数据。

正交分解揭示了极具冲击力的科学真相：在达峰期，看似恒定的总误差中 ** 整整 88.9% 来源于疫情达峰拐弯、既往平稳基准失配带来的常数均值偏移 **！真正反

表 5.4: 全美流感住院达峰期预测误差正交分解与各规模分箱对照表

病例规模分箱 D_t	**样本数**	**总相对误差**	**常数漂移贡献**	**漂移占比**	**纯条件方差**	**条件方差对应 b**
$[5, 20)$	132	0.3214	0.2669	83.0%	0.0545	呈现单调递减形态
$[20, 60)$	245	0.3045	0.2669	87.7%	0.0376	纯方差明显下降
$[60, 250)$	388	0.2982	0.2669	89.5%	0.0313	持续逼近环境底板
$[250, 600)$	260	0.2915	0.2669	91.6%	0.0246	进入低方差区间
$[600, 5000)$	195	0.2942	0.2669	90.7%	0.0273	趋于环境底板
全达峰期总计	**1,220**	**0.3002**	**0.2669**	**88.9%**	**0.0333**	$^{**}\hat{b} = 7.9272$ (极显著)**

映统计推断不确定性的纯条件方差只占 11.1%。当我们扣除常数偏移、利用达峰期自身均值评估纯条件方差时，FGLS 拟合得到的规模斜率项为：

$$\hat{b}_{\text{peak}} = 7.9272 \quad (95\%\ \text{CI}\ [5.4239,\ 11.2248]), \tag{5.13}$$

依然极显著为正！这一结论彻底推翻了 “达峰期样本量失效” 的传统定论：** 失效的是跨期平稳基准假设本身，而不是病例规模法则！在达峰期，增大样本量依然能显著压缩条件方差，但必须配合自适应状态转移模型以校准均值漂移 **。

5.5　制度冲击与空间汇聚检验

5.5.1　检验三：2024 年自愿填报政策切换的微观噪声冲击

2024 年 5 月 1 日，美国联邦政府因公共卫生紧急状态解除，将全美医院流感住院由法定强制直报转为自愿填报，随后于 2024 年 11 月通过 CMS 新规重新恢复强制直报。这为观察报告链扰动提供了罕见的外生准自然实验切片。

实证数据（图 5.1(d)）表明：

- 在第一阶段强制报告期（N = 6,009，平均覆盖率 91.1%），增长率的标准差为 0.624，偏度为 3.29；
- 在第二阶段自愿填报期（N = 420，覆盖率骤降至 54.6%），增长率的标准差剧增至 1.823（** 扩张 192.1%**），偏度跃升至 14.98；
- 在第三阶段恢复强制后（N = 3,874，覆盖率回升至 91.8%），标准差与偏度迅速回落至 0.649 与 2.68。

稳健离散指标显示，自愿期四分位距（0.638 → 0.594）与中位绝对离差（0.298 → 0.299）基本平稳，表明覆盖率下滑主要诱发了分布右尾的极端发散，实证印证了命题 3 预言的观测衰减放大噪声的定性方向。

5.5.2　检验四：全国 51 辖区空间汇聚收益的对偶性

将全美 51 个地理辖区的周度数据加总为全国单一时间序列，在初期上升波段共获得 28 个全国汇总周（平均周住院 6,662 例）。

实测结果表明，全国汇总后的相对预测均方误差(RelMSE)大幅下降至 **0.0348**，显著突破了单州拟合的环境方差底板 $\hat{a} = 0.0991$。这一现象并非来自单代内样本量的无穷扩大（命题 3 表明增加单州样本无法突破 v_R），而是来自 ** 空间跨区域平均效应 **：若 J 个辖区的宏观环境扰动平均空间相关系数为 $\bar{c} < 1$，汇总后的全国环境

方差为：

$$v_R^{\text{agg}} = v_R \left[\bar{c} + \frac{1-\bar{c}}{J} \right] < v_R. \tag{5.14}$$

这在数学上构成了命题 4 时间平均定理在空间维度的完美对偶！

5.6 全美空间分层异质性与稳健性全景检验

为了进一步评估经验规模平衡点 $m_\times \approx 22.6$ 例/周是否受到特定地理区域或各州人口规模差异的结构性扭曲，本节按照美国人口普查局（US Census Bureau）标准，对全美 50 州及 DC 开展四大地理分区与三大人口规模梯队的分层异质性计量检验。

5.6.1 四大地理分区子样本仿射拟合

我们将全美 51 个辖区划分为四大地理分区：

- ** 东北部（Northeast, 9 个州）**：人口密度极高、城市化与公共交通网络密集（如纽约州、马萨诸塞州、宾夕法尼亚州）；
- ** 中西部（Midwest, 12 个州）**：传统工业与农业交织区、冬季漫长且气温极低（如伊利诺伊州、俄亥俄州、密歇根州）；
- ** 南部（South, 17 个辖区含 DC）**：人口规模庞大、冬季相对温和但人口流动剧烈（如佛罗里达州、德克萨斯州、佐治亚州）；
- ** 西部（West, 13 个州）**：幅员辽阔、地广人稀与超级都会共存（如加利福尼亚州、华盛顿州、怀俄明州）。

表 5.5 汇报了四大地理分区的独立 FGLS 仿射估计结果。

四大地理分区的分层拟合展现出高度惊人的一致性：各个大区的规模反比斜率 $\hat{b}$ 均在 1.91 至 2.56 之间稳健为正，且 95% 置信区间全部严格远离零点；更重要的是，四大地理分区的经验平衡点 $m_\times$ ** 全部高度聚焦在 21.4 至 23.6 例/周的狭窄区间之内 **，与全美总体基准 22.6 例/周几乎完全吻合！这一事实有力证明了特征规模平衡点反映的是人类季节性流感在现代住院监测系统下的内在机制特征，而非特定局部地理气候的偶然产物。

5.6.2 三大人口规模梯队的分层检验

我们将 50 州按 2020 年普查常住人口规模划分为高人口大州（前 17 位）、中等人口州（中间 17 位）与低人口小州（后 17 位含 DC），检验结果汇报于表 5.6。

人口分层检验进一步证实了规律的稳健性：无论是拥有千万级人口的超级大州，还是仅有百余万人口的较小州，仿射反比项均坚挺成立，全方位印证了理论模型在空

表 5.5: 全美四大地理分区流感住院初期仿射模型分层估计对比表

地理大区名称	辖区数	样本量 N	截距 $\hat{a}$	斜率 $\hat{b}$	平衡点 $m_{\times}$	95% 聚类 Bootstrap CI
全美总体基准	51	1,267	0.0991	2.2434	22.64	[1.5032, 3.0189]
东北部地区 (Northeast)	9	265	0.0842	1.9850	23.57	[1.2840, 2.8910]
中西部地区 (Midwest)	12	312	0.1085	2.4120	22.23	[1.4520, 3.4890]
南部地区 (South)	17	438	0.1120	2.5640	22.89	[1.6810, 3.6520]
西部地区 (West)	13	252	0.0894	1.9120	21.39	[1.1920, 2.8450]

间维度的普适性。

表 5.6: 按辖区常住人口规模梯队划分的流感住院仿射分层估计表

人口规模梯队	平均人口	样本数	截距 $\hat{a}$	斜率 $\hat{b}$	平衡点 $m_{\times}$	实证结论与机制解释
高人口大州 (Top 1/3)	1,180 万	482	0.0912	2.3140	25.37	样本充沛，拟合极度稳健，CI $[1.62, 3.25]$
中等人口州 (Mid 1/3)	460 万	435	0.1015	2.2890	22.55	与全美基准完全重合，CI $[1.48, 3.18]$
低人口小州 (Bottom 1/3)	140 万	350	0.1142	2.0850	18.26	小计数噪声略大，但斜率依然极显著为正

第六章　跨模型与跨病种外部扩展验证

6.1　外部验证的设计原则与独立性界定

6.1.1　为什么必须开展外部独立场景验证？

在第五章中，本文基于全美 CDC NHSN 真实的周度流感住院面板数据，对理论仿射模型进行了严格的计量检验。然而，任何严谨的数理统计与经验科学推断都必须直面以下两项方法学质疑：

(1) ** 对自设基准模型的过拟合风险 **：第五章的相对预测损失建立在研究者自设的平滑卷积基准之上。在真实疾控决策实务中，公共卫生机构使用的是集合了数十所顶尖高校与科研机构的复杂前瞻预测模型。理论推导的规模反比递减形态在真实的工业级预测系统下是否依然成立？

(2) ** 单一病种与单一时间分辨率的局限性 **：季节性流感具有相对固定的代际时间（约 3 至 4 天）与周度报告节奏。面对高致病性冠状病毒等不同传播特征的病原体，以及在更高频的日度监测尺度下，规模收益规律是否具备跨病种的外部有效性？

为了回应上述挑战，本章严格依据比较统计学原则，引入两组定位截然不同、独立互补的外部验证场景：

- ** 场景一：CDC FluSight 官方前瞻多模型集成预测（$N = 1{,}177$）**——定位为 ** “独立预测模型与工业级预警系统验证” **。数据源虽然同属流感监测，但其预测值是由全美 20 余个顶级建模团队（包括哈佛大学、哥伦比亚大学、洛斯阿拉莫斯国家实验室等）独立提交、官方加权集成的真实前瞻多步预报；
- ** 场景二：欧洲 11 国早期 COVID-19 跨国日度监测（$N = 404$）**——定位为 ** “独立病种、独立地理区域与日度高频尺度验证” **。拓展至新型冠状病毒（SARS-CoV-2）在大流行初期的跨国日度病例流。

6.2 CDC FluSight 官方多模型前瞻集成预测验证

6.2.1 数据源架构与纯事前样本筛选规范

美国 CDC 流感预测协作网（FluSight）自 2013 年起启动运行。在 2022–2023 流感季，FluSight 汇聚了全美 22 个独立建模团队提交的分周前瞻预测，并通过自适应非负分位数加权构建出官方集成预测（Ensemble Forecast）[Mathis et al., 2024]。

在以往的数据处理中，部分外部研究常回溯利用“未来实际住院数 ≥ 5”来筛选预测样本。本文严格指出：** 在决策当期，未来的实际值尚未发生，任何依赖未来真实结果的样本筛选都构成隐性数据穿越与前瞻偏误（Look-ahead Bias）**。本文在 FluSight 实证中严格推行 ** 纯事前信息集筛选（Strictly Ex-ante Filtering）**：

- 筛选门槛仅依赖预测发布时刻已知的集成点预测值：$\widehat{C}_{s,t+1|t} \geq 5$；
- 严格区分地点层级，排除汇总的全国序列与波多黎各海外属地，仅保留全美 50 州与华盛顿特区；
- 最终获得完全基于事前信息集构建的 $N = 1{,}177$ 个有效集成预测评估样本。

6.2.2 集成预测实证估计结果

对 FluSight 集成相对预测损失应用 FGLS 拟合，并执行 1,500 次按州聚类的 Bootstrap 抽样，估计结果汇报于表 6.1。

实证估计显示：

(1) ** 规模反比项高度显著为正 **：在真实的工业级前瞻多模型集成预测下，规模系数估计值为 $\hat{b} = 7.8045$，其州聚类 95% 置信区间为 $[5.3582, 10.5260]$，证实即使采用了复杂的机器学习与动力学集成算法，预测误差随病例规模反比衰减的基本定律依然牢固成立；

(2) ** 经验平衡点向右偏移至 60 例/周 **：经验平衡点估计值为 $m_{\times} \approx 60.3$ 例/周（95% CI $[34.5, 95.9]$），相较于第五章单基准的 22.6 例明显右移。这一位移反映了多模型集成有效吸收了部分宏观模型设定误差，使得环境方差底板相对微观抽样项的占比发生了动态调整。

6.2.3 达峰期均值偏差剧烈消除：多模型集成的终极价值

最为惊人的实证发现在于达峰期的均值–方差分解。在第五章中，采用单一平稳基准预测时，达峰期看似恒定的高误差中整整 88.9% 源于宏观基准漂移。而在 CDC FluSight 官方多模型前瞻集成系统下，重新执行精确的均值–方差相加分解（严格采用自由度 ddof = 0 计算样本总体方差与均值偏差平方）：

表 6.1: CDC FluSight 官方多模型前瞻集成预测实证估计与敏感性对照表

样本筛选口径	**样本量 N**	**截距 $\hat{a}$**	**规模项 $\hat{b}$**	**平衡点 $m_{\times}$**	**95% 聚类 Bootstrap CI**	**流行病学与模型含义**
纯事前口径 (基准)	**1,177**	**0.1294**	**7.8045**	**60.31**	[5.3582, 10.5260]	** 仅依据事前预测值筛选, 无数据穿越 **
回顾性事后对照口径	1,177	0.1164	8.8081	75.67	[5.9120, 12.1100]	额外要求未来实际住院 ≥

- 流行上升期：平均相对偏差平方贡献占总均方误差的 **32.8%**；
- ** 达峰与转折期 **：平均相对偏差平方贡献占总均方误差的比例从单一基准的 **88.9% 骤降至 15.5%**！
- 回落期：偏差平方占比进一步萎缩至 **0.28%**。

这一跨模型验证给出了极其震撼的科学结论：

第五章中高达 88.9% 的达峰常数偏差，在多模型集成预测下被剧烈压缩至 15.5%！
这在真实世界中直接证实了：跨过特征平衡点 $m_\times$ 后，继续扩大样本捕获无法克服环境平台；但转向多模型前瞻自适应集成，能够以极高的效率校准系统均值漂移，实现预测精度的阶跃式突破！

6.3 欧洲 11 国 COVID-19 早期传播跨病种扩展验证

6.3.1 欧洲 11 国早期大流行日度监测数据背景

为了检验仿射规律在不同病原体、不同国家体制以及日度高频观测下的泛化能力，本文引入 Flaxman 等人 [Flaxman et al., 2020] 发表于《Nature》的欧洲 11 国（英国、意大利、西班牙、法国、德国、比利时、瑞士、瑞典、荷兰、挪威、奥地利）在 2020 年 2 月至 4 月大流行初期的日度发病与住院监测数据。

由于大流行早期各国经历了不同强度的封城隔离（NPIs），有效再生数随时间剧烈波动，且数据按自然日结算，构成了与全美周度流感完全正交的全新检验场景。

6.3.2 纯事前增长样本筛选与参数估计

在日度高频数据中，真实有效暴露规模 D_t 由既往 7 天移动卷积和给出。为了避免数据穿越，本文同样采用纯事前筛选：保留历史规模 $D_t \geq 5$ 且前期历史增长比 $g > 0$ 的有效国家–日观测，获得分析样本量 $N = 404$。

表 6.2 汇报了欧洲 COVID-19 实证估计及不同筛选口径下的敏感性对照。

实证检验展现出以下核心结论：

(1) ** 仿射反比递减形态在新型冠状病毒日度数据中依然坚挺 **：在纯事前基准口径下，规模反比项系数为 $\hat{b} = 33.9223$，国家聚类 95% 置信区间为 $[14.6021, 74.9873]$，显著远离零点，有力支持了规模收益递减规律跨越不同病毒病种的普遍性；

(2) ** 经验平衡点与时间分辨率的强依赖性 **：欧洲 COVID-19 的日度经验平衡点处于 **67.7 至 124.7 例/日 ** 区间。与全美流感周度尺度（约 22.6 例/周）相比，日度平衡点显著更高。这一差异在动力学上极其合理：日度数据的抽样稀疏

表 6.2: 欧洲 11 国早期 COVID-19 日度监测实证估计与口径敏感性对比

样本筛选口径	**样本量 N**	**截距 $\hat{a}$**	**规模项 $\hat{b}$**	**日度平衡点 $m_\times$**	**95% 国家聚类 CI**	**敏感性评估与科学启示**
纯事前有效规模 (基准)	**404**	**0.2720**	**33.9223**	**124.71**	[14.6021, 74.9873]	** 完全事前信息集, 规模项显著为正
保留全增长期 ($g > 1$)	318	0.2103	18.5280	88.10	[11.2310, 42.1500]	** 斜率保持显著为正, 拐点降

度远高于周度聚合数据，微观泊松相遇噪声与单日上报随机性更加剧烈，因此需要更大的单日病例规模才能压平抽样噪声逼近不可约环境底板。

6.4 外部验证的核心启示与经验边界界定

两组具有高度异质性的扩展验证场景，为全文的理论框架提供了极为坚实的支撑：

两组扩展场景共同证实：在不同的独立预测模型、跨国别行政体制与跨病种大流行监测中，均一致观察到了规模相关误差项显著为正（$b > 0$）的核心规律；同时，外部检验严格划定了理论应用的方法学边界：经验平衡点 $m_{\times}$ 并不是一个跨病种通用的机械物理常数，其具体取值敏感地依赖于监测的时间粒度、报告流程延迟以及病原体的内在传播强度。

这一结论在流行病学方法学上具有重要意义：公共卫生部门在应用本理论时，应当将 $m_{\times}$ 视为具体监测系统在特定阶段下的 ** 量级参照与运筹判据 **，而非僵化套用单一数字。在下一章中，我们将系统探讨这一理论对国家公共卫生监测体系资源优化的政策建议。

第七章　监测资源优化策略与研究展望

7.1　国家公共卫生监测体系的资源配置策略矩阵

基于本文建立的理论推断框架、数值模拟发现与全美真实流感及欧洲 COVID-19 实证检验，本节针对国家公共卫生疾控部门在传染病监测预警网络建设中的资源配置，提出一套可落地的 ** “两阶段差异化监测资源优化配置策略矩阵” **。

以往的监测资源配置往往采取 “一刀切” 的机械扩容策略，在疫情爆发时一味要求所有定点医院加班加点扩大采样量，在疫情平缓期则疏于维持基础检测网络。本文的研究证明，这种策略无论在统计效率上还是经济成本上都是低效的。正确的资源配置逻辑必须 ** 依循当前系统规模与内生特征平衡点 $m_\times$ 的相对位置动态调整 **。

7.1.1　流行初期与低发期 ($m < m_\times$) ——「全力扩量，迅速越峰」

在传染病暴发早期、散发期或换季低发期，医疗系统实际捕获的病例数稀疏，系统处于 $m < m_\times$ 的 ** 微观抽样噪声主导体制 **:

- ** 核心矛盾 **: 此时微观泊松相遇离散与超级传播重尾波动占总推断方差的 50% 以上。若哨点过少，少量超级传播者的出现或缺席会导致再生数估计发生剧烈抖动，常规正态检验频繁出现假警报（如第四章揭示的 8.1% 虚警率）;
- ** 配置策略 **: 此时继续扩大病例捕获规模具有极高的统计边际收益（投入产出比极高）。卫生部门应集中财政预算扩建定点哨点网络、降低就诊检测门槛、提高轻症筛查覆盖率 ρ 与地理人群基数 n，推动系统尽快跨越特征平衡点 $m_\times$;
- ** 预警指标优化 **: 在进行疫情爆发早期检测时，依据目标病原体的超离散度参数 k，精确测算达到 80% 功效所需的充分样本门槛 $m_{80\%}$，作为低发期哨点捕获能力的刚性考核指标。

7.1.2　流行达峰与饱和期 ($m > m_\times$) ——「战略提质，协同平滑」

当疫情全面暴发、每周报告病例数显著超过特征平衡点（$m \gg m_\times$）时，系统进入 ** 宏观环境随机性饱和体制 **:

- ** 核心矛盾 **: 大数定律的边际降差速率急剧放缓。总方差由全社会共同面临的外生环境冲击（不可约环境底板 v_R）以及疫情转折导致的基准漂移（占达峰

期误差的 88.9%）完全主导。此时继续强行要求医院加倍采样上报，在统计上几乎无法带来实质性的预测精度提升；

- ** 配置策略 **：监测资源必须坚决由“扩量”转向“提质”，具体实施三项战略转移：
  (1) ** 引入多模型前瞻集成系统 **：如第六章 FluSight 实证所示，官方自适应集成预测可将达峰期均值偏差由 88.9% 剧烈压缩至 15.5%，这是单模型狂堆样本量根本无法做到的；
  (2) ** 采集宏观环境协变量 **：将预算转向监测人群宏观流动大数据、气象降温湿变指数与学校企事业单位出勤率，通过在状态方程中显式控制环境协变量，直接压缩不可约环境方差 v_R 本身；
  (3) ** 空间多中心弱相关汇聚 **：如第五章实证所示，跨区域大数加总能够利用区域间环境扰动的弱相关性（$\bar{c} < 1$），在空间维度实现类似时间平均的降差收益。

7.2 研究局限性与方法学边界

为了恪守严谨求实的现代学术规范，本节坦诚剖析本研究存在的方法学局限与适用边界：

7.2.1 不可约环境方差 v_R 始终为拟合量而非物理直接测量量

在第三章与第五章中，理论上的环境方差底板 v_R 在实证中对应 FGLS 仿射拟合模型的截距项 $\hat{a}$。必须承认，在真实的医院住院监测数据中，截距项 $\hat{a}$ 是一个唯象的复合量：它既包含了天气、人群行为等纯外生宏观环境方差，也不可避免地混合了由于滞后卷积权重失配、报告周期截断带来的模型设定偏差。由于缺乏独立的对照实验，实证中的经验平衡点 $\hat{b}/\hat{a}$ 应当理解为具体监测系统在当前技术条件下的 ** 量级参照物 **，而非类似于物理常数的绝对点位识别。

7.2.2 观测覆盖率变动与事件级二项抽稀的微观机制差异

第五章在评估 2024 年自愿填报政策冲击时，实测数据显示医院覆盖率骤降至 54.6% 引发了分布右尾的极端扩张（偏度激增至 14.98），而四分位距与中位绝对离差基本平稳。这一现象表明，在现实制度变迁中，医院填报率的下滑往往是“整所医院直接退出直报系统”（整群非随机缺失），而非理想模型中所设想的“全社会每个患者独立抛硬币决定是否上报”（均匀事件级二项抽稀）。虽然二者在放大观测方差的大方

向上定性一致，但在更高阶矩的分布形态上存在微观机制差异。

7.2.3　时间序列卷积中的单向因果性与内生性

在更新过程时间序列预测中，构建的自变量为历史滞后有效暴露规模 $D_t = \sum w_s C_{t+1-s}$。虽然在时间维度上严格保证了“历史发生于当期之前”的事前信息集顺序，排除了前瞻偏误；但传染病的时间序列具有强烈的内生自回归性，严格的因果识别仍需借助更丰富的外生工具变量或断点回归设计。

7.3　未来研究展望：双轨前瞻主动追踪队列的解耦设计

针对上述局限性，本文在数理流行病学与监测设计方法学上提出一个极具操作可行性的未来拓展方向——** “双轨主动追踪队列识别设计”（Dual-track Prospective Cohort Design）**：

目前全球绝大多数疾控系统均采用单一的“被动医院住院就诊直报网络”。医院数据天生混合了就医意愿、医保报销政策与填报时滞，导致外生环境方差与系统观测偏差永远纠缠在一起。未来的国家公共卫生监测体系可以在保留大型医院被动住院监测网络（第一轨）的同时，在代表性社区布设 ** 固定人群规模的前瞻性主动追踪队列（第二轨）**：

- 在不同地理气候带抽取具有人口统计学代表性的固定家庭队列；
- 无论家庭成员是否有症状，定期进行抗原筛查与多病原体核酸检测，排除就医意愿干扰，直接测得无偏差的真实社区传播感染率；
- 通过联立两轨监测数据，利用计量经济学联立方程组或状态空间反卷积算法，即可将 ** 纯外生宏观环境方差 v_R** 与 ** 医院监测系统的代理平滑偏差 ** 彻底解耦识别！

7.4　本章小结与全文总结

本学位论文围绕传染病监测中“数据规模崇拜”这一现实科学悖论，从随机分支过程、全方差分解与抽样运筹理论出发，完成了系统的数理推导、仿真检验与大数据实证：

(1) ** 破除教条 **：严格确立了“推断目标决定规模收益”的核心规律。证实当期瞬态点估计（目标 A）规模收益无界（$O(1/m)$），而跨期基准估计（目标 B）必然受制于不可约环境方差底板 v_R 与特征规模平衡点 $m_\times$；

(2) ** 运筹对偶 **：证明了提高报告率与扩大基数的非对称性，揭示了样本预算恒常性，导出了显式经费约束下最优单期规模闭式解及其与 Cochran 两阶段抽样模型的数学同构；

(3) ** 实证反转 **：利用全美六年 16,218 条真实住院数据（10,303 活跃周样本），证实规模反比项高度显著为正（$\hat{b} = 2.24$）；揭示达峰期 88.9% 误差来源于基准漂移，有力推翻了“达峰期样本量失效”的传统误读；

(4) ** 外验证实 **：通过 CDC FluSight 官方集成预测证明多模型集成能将达峰偏差剧烈压缩至 15.5%，欧洲 COVID-19 数据证实了规律的跨病种普适性与尺度依赖性。

综上所述，本文为国家公共卫生监测体系在不同流行阶段由“盲目扩量”迈向“科学提质”提供了完备的数理统计基础与量化决策工具。

7.5 面向疾控机构的监测资源优化配置量化操作手册

为了将前文较为抽象的数学推导与计量参数切实转化为公共卫生各级疾控中心（CDC）在日常与应急状态下可直接执行的决策工具，本节将理论框架细化为四个标准化步骤的操作工作流。

7.5.1 第一步：监测系统基线参数测定与建档

在每年呼吸道流行季来临前（如每年 9 月初），辖区疾控监测部门应首先对本地区的历史监测系统进行基线参数标定：

(1) ** 确定目标病原体生物学离散参数 k**：依据第二章表 2.1，对季节性流感设定基准先验 $k = 0.35$；对新型冠状病毒设定 $k = 0.20$；

(2) ** 评估哨点医院网络复合报告率 ρ**：结合本辖区常住人口、医保就诊率与哨点定点医院覆盖比例，核算系统报告率 ρ；

(3) ** 测算本辖区特征规模平衡点 $m_\times$ 与预警门槛 $m_{80\%}$**：利用公式 $m_\times = \frac{\bar{R}+\rho(\bar{R}^2+v_R)/k}{v_R}$ 与命题 5，计算出本地区的特征平衡点 $m_\times$（周度流感住院量级一般为 20–30 例/周），以及增长检测 80% 功效门槛 $m_{80\%}$。

7.5.2 第二步：暴露规模在线滑动卷积监控

在疫情监测运转期间，信息系统应自动以周为步长，对最近 3 周的报告住院数执行代际卷积平滑：

$$D_t = 0.65C_t + 0.25C_{t-1} + 0.10C_{t-2}. \tag{7.1}$$

系统将当周计算出的有效规模 D_t 与预设的特征平衡点 $m_\times$ 进行实时布尔比对，触发两阶段资源调度开关。

7.5.3　第三步：两阶段资源调度自动切换规则

系统依据 D_t 与 $m_\times$ 的相对位置，严格实施以下调度切换：

- ** 若 $D_t \le m_\times$（微观噪声主导区，执行“扩量预案”）**：
  a. 财政预算重点投向扩建发热门诊检测通道、增加基层社区采样频次；
  b. 确保每周报告数尽快达到 $m_{80\%}$，防止小计数导致的虚警与漏报；
  c. 暂缓投入昂贵的多模型超级计算预测系统，因为在小样本下任何复杂算法都会被抽样噪声淹没。
- ** 若 $D_t > m_\times$（宏观环境饱和区，执行“提质预案”）**：
  a. 立即对各哨点医院发出采样减负指令，停止盲目扩充同质化的简单病例计数报告；
  b. 启动前瞻多模型自适应集成预报平台，利用模型多样性主动校准达峰期的均值漂移（消解 88.9% 偏差）；
  c. 紧急调取交通卡口人口流动、手机信令、气象降温及抗原自测上报等外部环境协变量，显式输入预测模型以平滑环境底板 v_R；
  d. 启动与相邻省市疾控中心的跨区域空间数据汇聚机制，利用空间弱相关汇聚效应拉低宏观预测方差。

上述量化工作流将本文复杂的理论命题完全转化为了具有明晰逻辑判断、参数输入与动作指令的现代疾控决策管理闭环。

附录 A　数学命题保姆级代数推导补充

本附录为正文第三章与第四章的所有理论命题与推论提供不跳步的教科书级保姆式代数推导细节，以满足基础数学与数理统计学严格规范。

A.1　命题 1 中得分函数负二阶导期望的逐步代数推导

在第三章命题 1 的式 (3.15) 中，需要计算：

$$\mathcal{I}(R_t \mid n) = \mathbb{E}\left[\frac{C_t}{R_t^2} - \frac{\rho^2(nk + C_t)}{(k + \rho R_t)^2} \;\middle|\; n, R_t\right]. \tag{A.1}$$

由期望的线性性质：

$$\mathcal{I}(R_t \mid n) = \frac{\mathbb{E}[C_t]}{R_t^2} - \frac{\rho^2 nk + \rho^2\,\mathbb{E}[C_t]}{(k + \rho R_t)^2}. \tag{A.2}$$

代入条件期望 $\mathbb{E}[C_t \mid n, R_t] = \rho n R_t$：

$$\begin{aligned}\mathcal{I}(R_t \mid n) &= \frac{\rho n R_t}{R_t^2} - \frac{\rho^2 nk + \rho^3 n R_t}{(k + \rho R_t)^2} \\ &= \frac{\rho n}{R_t} - \frac{\rho^2 n(k + \rho R_t)}{(k + \rho R_t)^2} \\ &= \frac{\rho n}{R_t} - \frac{\rho^2 n}{k + \rho R_t}.\end{aligned} \tag{A.3}$$

进行两分式通分，公分母为 $R_t(k + \rho R_t)$：

$$\begin{aligned}\mathcal{I}(R_t \mid n) &= \frac{\rho n(k + \rho R_t) - \rho^2 n R_t}{R_t(k + \rho R_t)} \\ &= \frac{\rho nk + \rho^2 n R_t - \rho^2 n R_t}{R_t(k + \rho R_t)} \\ &= \frac{k\rho n}{R_t(k + \rho R_t)}.\end{aligned} \tag{A.4}$$

代数对消完全恒等，确认 Fisher 信息量严格成立。

A.2　命题 4 中 AR(1) 错位相减求和级数推导补遗

在式 (3.48) 中求解：

$$S = \sum_{s=1}^{T-1}(T - s)r^s = (T-1)r + (T-2)r^2 + \cdots + 2r^{T-2} + 1 \cdot r^{T-1}. \tag{A.5}$$

两端乘 r：

$$rS = (T-1)r^2 + (T-2)r^3 + \cdots + 2r^{T-1} + 1 \cdot r^T. \tag{A.6}$$

两式对应同次项相减：

$$\begin{aligned}(1-r)S &= (T-1)r + \big[(T-2)-(T-1)\big]r^2 + \big[(T-3)-(T-2)\big]r^3 + \cdots + \big[1-2\big]r^{T-1} - r^T \\ &= (T-1)r - r^2 - r^3 - \cdots - r^{T-1} - r^T \\ &= Tr - r - r^2 - r^3 - \cdots - r^T \\ &= Tr - \sum_{s=1}^{T} r^s. \end{aligned} \tag{A.7}$$

由等比数列前 T 项和公式 $\sum_{s=1}^{T} r^s = \frac{r(1-r^T)}{1-r}$，直接代入：

$$(1-r)S = Tr - \frac{r(1-r^T)}{1-r}. \tag{A.8}$$

两端除以非零常数 $(1-r)$：

$$S = \frac{Tr}{1-r} - \frac{r(1-r^T)}{(1-r)^2}. \tag{A.9}$$

代数展开完全封闭且无跳步。

A.3　推论 1 成本优化函数一阶导驻点与二阶导符号判定

目标函数为：

$$f(m) = \frac{1}{\mathcal{B}}\left(c_0 v_R + c_1 v_R m + \frac{c_0 A}{m} + c_1 A\right). \tag{A.10}$$

利用幂函数求导法则：

$$\frac{d}{dm}(m) = 1, \quad \frac{d}{dm}\left(\frac{1}{m}\right) = -\frac{1}{m^2}, \quad \frac{d}{dm}\left(-\frac{1}{m^2}\right) = \frac{2}{m^3}. \tag{A.11}$$

因此一阶导数为：

$$f'(m) = \frac{1}{\mathcal{B}}\left(c_1 v_R - \frac{c_0 A}{m^2}\right). \tag{A.12}$$

令 $f'(m) = 0 \implies c_1 v_R = \frac{c_0 A}{m^2} \implies m^2 = \frac{c_0 A}{c_1 v_R}$。由于规模 m 代表期望报告病例数，必须取正实数 $m > 0$，故排除负根，唯一驻点为：

$$m^* = \sqrt{\frac{c_0 A}{c_1 v_R}} = \sqrt{\frac{c_0}{c_1} m_\times}. \tag{A.13}$$

对 $f'(m)$ 再次求导：

$$f''(m) = \frac{1}{\mathcal{B}}\left(0 - c_0 A \cdot \left(-\frac{2}{m^3}\right)\right) = \frac{2c_0 A}{\mathcal{B} m^3}. \tag{A.14}$$

由于物理与经济参数均为严格正实数：

$$c_0 > 0, \quad A = \bar{R} + \frac{\rho(\bar{R}^2 + v_R)}{k} > 0, \quad \mathcal{B} > 0, \quad m > 0. \tag{A.15}$$

因此分子 $2c_0A > 0$ 且分母 $\mathcal{B}m^3 > 0$，故对一切 $m \in (0, \infty)$：

$$f''(m) > 0. \tag{A.16}$$

根据凸分析经典定理，二阶导在开区间上恒正充分且必要地保证了 $f(m)$ 为严格凸函数，唯一驻点为全局唯一最小值点。

附录 B　核心模拟与计量回归 Python 源码清单

本附录提供论文第四章与第五章核心数值模拟、假设检验功效枚举、FGLS 迭代加权回归及按州聚类 Bootstrap 的核心 Python 算法源码实现，以确保全书所有经验结果与图表具备 100% 的可复现性。

B.1　负二项分支过程与二项报告抽稀离散仿真实现

```python
import numpy as np
from scipy import stats

def simulate_branching_thinning(n, R_t, k, rho, num_replications=50000, seed=20260923):
    """
    两阶段分层数据生成机制的蒙特卡洛随机模拟
    输入参数:
        n: 上一代真实风险集规模
        R_t: 当期瞬时再生数
        k: 生物学过度离散参数
        rho: 条件二项报告抽样率
        num_replications: 蒙特卡洛独立重复试验次数
    返回:
        I_t: 真实感染病例数样本数组
        C_t: 观测报告病例数样本数组
        R_hat: 瞬时再生数矩估计量样本数组
    """
    rng = np.random.default_rng(seed)

    # 形状参数与成功概率映射
    r_shape = n * k
```

```
    p_success = k / (k + R_t)

    # 第一阶段：微观负二项感染总数生成
    I_t = rng.negative_binomial(n=r_shape, p=p_success, size=
        num_replications)

    # 第二阶段：宏观条件二项报告抽稀过程
    C_t = rng.binomial(n=I_t, p=rho)

    # 目标 A：矩估计量计算
    m = rho * n
    R_hat = C_t / m

    return I_t, C_t, R_hat

def verify_cramer_rao(n=100, R_t=1.2, k=0.35, rho=0.25):
    """验证 Cramér-Rao 下界与仿真方差的比值收敛性"""
    _, _, R_hat = simulate_branching_thinning(n, R_t, k, rho)
    emp_var = np.var(R_hat, ddof=1)
    theo_var = (R_t / (rho * n)) + (R_t**2 / (k * n))
    ratio = emp_var / theo_var
    print(f"仿真方差：{emp_var:.6f}, 解析 CRLB: {theo_var:.6f}, 比
        值：{ratio:.4f}")
    assert 0.98 <= ratio <= 1.02, "方差偏离超出理论置信区间！"
```

Listing B.1: 两阶段负二项分支过程与二项抽稀模拟核心函数

B.2 命题 5 超临界增长精确检验与临界值枚举算法

```
def compute_critical_threshold(n, k, rho, alpha=0.05):
    """
    基于边界点 R_t = 1 精确搜索离散拒绝阈值 c_alpha
    使一类错误率上确界严格满足 sup Pr(C_t >= c_alpha) <= alpha
    """
    r_shape = n * k
    p_null = k / (k + rho * 1.0)
```

```
    # 利用生存函数 (sf) 进行离散整数单调搜索
    # stats.nbinom.sf(c - 1, r, p) 计算 Pr(Y >= c)
    c = int(np.floor(rho * n * 1.0)) # 初始猜测起点
    while stats.nbinom.sf(c - 1, r_shape, p_null) > alpha:
        c += 1
    return c

def enumerate_exact_power(n_grid, delta=0.25, k=0.35, rho=0.25,
   alpha=0.05):
    """
    计算给定备择强度 R_t = 1 + delta 下的精确统计功效曲线
    """
    powers = []
    c_thresholds = []

    for n in n_grid:
        c_alpha = compute_critical_threshold(n, k, rho, alpha)
        r_shape = n * k
        p_alt = k / (k + rho * (1.0 + delta))

        # 精确功效计算: 1 - I_p(nk, c_alpha)
        power = stats.nbinom.sf(c_alpha - 1, r_shape, p_alt)
        powers.append(power)
        c_thresholds.append(c_alpha)

    return np.array(c_thresholds), np.array(powers)
```

Listing B.2: 精确负二项 UMP 检验临界值搜索与功效枚举算法

B.3　两阶段可行广义最小二乘法 (FGLS) 迭代回归算法

```
import statsmodels.api as sm

def run_fgls_affine_regression(D, Loss, max_iter=10, tol=1e-6):
    """
```

```
    可行广义最小二乘法 (FGLS) 估计仿射参数: Loss = a + b / D + u
    输入:
        D: 有效暴露规模数组 (N 维)
        Loss: 相对预测损失数组 (N 维)
    输出:
        a_hat: 不可约环境方差截距项
        b_hat: 规模反比斜率项
        crossover: 经验特征规模平衡点 b / a
    """
    X = np.column_stack([np.ones_like(D), 1.0 / D])

    # 第一阶段: 普通 OLS 初始一致估计
    ols_model = sm.OLS(Loss, X).fit()
    params = ols_model.params

    for iteration in range(max_iter):
        fitted_loss = np.dot(X, params)
        # 截断保护以防止非正权重
        fitted_loss = np.maximum(fitted_loss, 1e-4)

        # 构造对角方差权重: w_i = 1 / (mu_i)^2
        weights = 1.0 / (fitted_loss ** 2)

        # 第二阶段: 加权最小二乘求解 (WLS)
        wls_model = sm.WLS(Loss, X, weights=weights).fit()
        new_params = wls_model.params

        # 判定收敛性
        if np.max(np.abs(new_params - params)) < tol:
            params = new_params
            break
        params = new_params

    a_hat, b_hat = params[0], params[1]
    crossover = b_hat / a_hat if a_hat > 0 else np.nan
```

```
    return a_hat, b_hat, crossover, wls_model
```

Listing B.3: 基于残差平方倒数加权的两阶段 FGLS 回归算法

B.4　按州聚类非参数 Bootstrap 统计推断算法

```
import pandas as pd

def cluster_bootstrap_fgls(df, state_col='state', B=1500, seed
    =20261010):
    """
    按州聚类的非参数 Bootstrap 抽样检验
    输入:
        df: 包含 state, D_t, Loss 列的面板数据框
        B: 重抽样轮数 (基准 1500 次)
    输出:
        b_ci: 斜率项 95% 置信区间
        m_x_ci: 特征平衡点 95% 置信区间
        p_val: b <= 0 的单侧经验 p 值
    """
    rng = np.random.default_rng(seed)
    unique_states = df[state_col].unique()
    num_states = len(unique_states)

    b_bootstraps = []
    crossover_bootstraps = []

    for b_idx in range(B):
        # 按州整群重抽 (有放回抽样)
        resampled_states = rng.choice(unique_states, size=
            num_states, replace=True)

        # 组装重抽样样本池
        boot_df = pd.concat([df[df[state_col] == s] for s in
            resampled_states], ignore_index=True)

```

```
        # 重新内生计算达峰期均值与损失
        D_boot = boot_df['D_t'].values
        Loss_boot = boot_df['Loss'].values

        # 重新运行完整的 FGLS 迭代加权回归
        a_b, b_b, m_b, _ = run_fgls_affine_regression(D_boot,
            Loss_boot)
        b_bootstraps.append(b_b)
        crossover_bootstraps.append(m_b)

    b_bootstraps = np.array(b_bootstraps)
    crossover_bootstraps = np.array(crossover_bootstraps)

    # 计算百分位数置信区间
    b_ci = np.percentile(b_bootstraps, [2.5, 97.5])
    m_x_ci = np.percentile(crossover_bootstraps, [2.5, 97.5])
    p_val = np.mean(b_bootstraps <= 0.0)

    return b_ci, m_x_ci, p_val
```

Listing B.4: 按地理辖区聚类的非参数 Bootstrap 标准误估计

参考文献

Benjamin M Althouse, Edward A Wenger, James C Miller, Samuel V Scarpino, Antoine Allard, Laurent Hébert-Dufresne, and Hao Hu. Superspreading events in the transmission of sars-cov-2: A review. *PLOS Biology*, 18(11):e3000897, 2020.

Roy M Anderson and Robert M May. *Infectious diseases of humans: dynamics and control*. Oxford University Press, 1991.

Tom Britton. Stochastic epidemic models: a survey. *Mathematical Biosciences*, 225 (1):24–35, 2010.

A Colin Cameron and Pravin K Trivedi. *Microeconometrics: methods and applications*. Cambridge University Press, 2005.

Simon Cauchemez, Pierre-Yves Boëlle, Guy Thomas, and Alain-Jacques Valleron. Real-time estimates in early detection of sars. *Emerging Infectious Diseases*, 12(1):165, 2006.

Anne Cori, Neil M Ferguson, Christophe Fraser, and Simon Cauchemez. A new framework and software to estimate time-varying reproduction numbers during epidemics. *American Journal of Epidemiology*, 178(9):1505–1512, 2013.

Odo Diekmann and Johan Andre Peter Heesterbeek. *Mathematical epidemiology of infectious diseases: model construction, computer analysis and simulation*, volume 5. John Wiley & Sons, 2000.

Odo Diekmann, JAP Heesterbeek, and Johan AJ Metz. On the definition and the computation of the basic reproduction ratio r_0 in models for infectious diseases in heterogeneous populations. *Journal of Mathematical Biology*, 28(4):365–382, 1990.

Akira Endo, Sam Abbott, Adam J Kucharski, Sebastian Funk, et al. Estimating the overdispersion in covid-19 transmission using outbreak sizes outside china. *Wellcome Open Research*, 5:67, 2020.

Stewart N Ethier and Thomas G Kurtz. *Markov processes: characterization and convergence*, volume 282. John Wiley & Sons, 1986.

Seth Flaxman, Swapnil Mishra, Axel Gandy, H Juliette T Unwin, Thomas A Mellan, Helen Coupland, Charles Whittaker, Harrison Zhu, Tresnia Berah, Jeffrey W Eaton, et al. Estimating the effects of non-pharmaceutical interventions on covid-19 in europe. *Nature*, 584(7820):257–261, 2020.

Christophe Fraser. Estimating individual and household reproduction numbers in an emerging epidemic. *PLOS ONE*, 2(8):e758, 2007.

Katelyn M Gostic, Lauren McGough, Edward B Baskerville, Sam Abbott, Keya Joshi, Christine Tedijanto, Rebecca Kahn, Rene Niehus, James A Hay, Pamela Martinez De Salazar, et al. Practical considerations for measuring the effective reproduction number, r_t. *PLOS Computational Biology*, 16(12):e1008409, 2020.

Theodore Edward Harris. *The theory of branching processes*, volume 119. Springer Berlin, 1963.

Herbert W Hethcote. The mathematics of infectious diseases. *SIAM Review*, 42(4): 599–653, 2000.

Peter Jagers. *Branching processes with biological applications*. John Wiley & Sons, 1975.

Samuel Karlin and Herman Rubin. The theory of decision procedures for distributions with monotone likelihood ratio. *The Annals of Mathematical Statistics*, 27(2):272–299, 1956.

William Ogilvy Kermack and Anderson G McKendrick. A contribution to the mathematical theory of epidemics. *Proceedings of the Royal Society of London. Series A, Containing Papers of a Mathematical and Physical Character*, 115(772):700–721, 1927.

Thomas G Kurtz. Solutions of ordinary differential equations as limits of pure jump markov processes. *Journal of Applied Probability*, 7(1):49–58, 1970.

Thomas G Kurtz. Limit theorems for sequences of jump markov processes approximating ordinary differential equations. *Journal of Applied Probability*, 8(2):344–356, 1971.

Erich L Lehmann and Joseph P Romano. *Testing Statistical Hypotheses*. Springer Science & Business Media, 3rd edition, 2005.

James O Lloyd-Smith, Sebastian J Schreiber, P Ekkehard Kopp, and Wayne M Getz. Superspreading and the effect of individual variation on disease emergence. *Nature*, 438(7066):355–359, 2005.

Shannon M Mathis, Alexander E Webber, Katie Webber, et al. Collaborative forecasting of seasonal influenza hospitalizations in the united states: Flusight 2022–23. *Nature Communications*, 15(1):6170, 2024.

Kris V Parag, Benjamin J Cowling, and Christl A Donnelly. Fundamental limits on inferring epidemic dynamics from noisy case count data. *Nature Physics*, 18(9): 1034–1040, 2022.

Kim Sneppen and Lone Simonsen. Overdispersion in covid-19 transmission: understanding and addressing heterogeneity. *Physical Biology*, 18(5):055001, 2021.

Robin N Thompson, Jessica E Stockwin, Rolina D van Gaalen, Jonathan A Polonsky, Zhian N Kamvar, Peter A Demarsh, Elisabeth Dahlqwist, Sandra Li, Eve Miguel, Thibaut Jombart, et al. Improved inference of time-varying reproduction numbers during infectious disease outbreaks. *The Lancet Infectious Diseases*, 19(12):e425–e433, 2019.

Jerome I Tokars, Sonja J Olsen, and Carrie Reed. Seasonal incidence of symptomatic influenza in the united states. *Clinical Infectious Diseases*, 66(10):1511–1518, 2018.

Jacco Wallinga and Peter Teunis. Different epidemic curves for severe acute respiratory syndrome reveal similar impacts of control measures. *American Journal of Epidemiology*, 160(6):509–516, 2004.

Laura F White, Jacco Wallinga, Lyn Finelli, Carrie Reed, Steven Riley, Marc Lipsitch, and Marcello Pagano. Estimation of the reproductive number and the serial interval in early phase of the 2009 influenza a/h1n1 pandemic in the usa. *Influenza and Other Respiratory Viruses*, 3(6):267–276, 2009.

Jeffrey M Wooldridge. *Econometric analysis of cross section and panel data*. MIT Press, 2010.

Huiren Zhou, William W Thompson, Cécile Viboud, David K Shay, Robert C Holman, Larry J Anderson, Lone Simonsen, Lynnette Brammer, and Alicia M Fry. Hospitalizations associated with influenza and respiratory syncytial virus in the united states, 1993–2008. *Clinical Infectious Diseases*, 54(10):1427–1436, 2012.

马知恩, 周义仓, 王稳地, and 靳祯. 传染病动力学模型与稳定性分析. 科学出版社, 北京, 2004.

马知恩 and 周义仓. 常微分方程定性与稳定性理论. 科学出版社, 北京, 2001.