论文深读与理论推导详解：《疫情监测中的病例规模收益边界：估计目标、环境随机性与外部验证》

论文全案理论推导详解 · sympy 数值核验 · 技术审计意见

目录

1 导读前言：应用统计研究生的“论文通透心法” 3

2 第一部分：宏观全景地图——这篇论文究竟讲了一个什么故事？ 3

2.1 1.1 一个违背直觉的现实科学矛盾 . . . 3

2.2 1.2 论文的核心破局点：“推断目标决定规模收益” . . . 4

2.3 1.3 内生平衡点 $m_\times$ 的物理意义 . . . 4

3 第二部分：全篇核心参数全景深度字典与流行病学物理直觉 4

3.1 2.1 全篇核心参数速查总表 . . . 5

3.2 2.2 核心参数的深度流行病学物理剖析 . . . 5

3.2.1 (1) 超传播参数 k 的生物学本质 . . . 5

3.2.2 (2) 报告抽样率 ρ 的折算逻辑 . . . 5

3.2.3 (3) 滞后卷积权重 $w = (0.65, 0.25, 0.10)$ 的依据 . . . 6

4 第三部分：数学命题教学级逐行拆解与深入证明（保姆级代数展开） 6

4.1 3.1 命题 1 前置：Gamma–Poisson 混合积分逐行展开与“成功概率” p 的物理本质 . 6

4.1.1 3.1.0 成功概率 p 的反直觉物理顿悟 . . . 6

4.1.2 3.1.1 Gamma–Poisson 连续混合积分逐行演算 . . . 7

4.2 3.2 命题 1：条件似然、得分函数、无偏性与 Cramér–Rao 下界 . . . 7

4.2.1 3.2.1 PGF 复合律保族性逐行推导 . . . 7

4.2.2 3.2.2 负二项方差公式化简 . . . 8

4.2.3 3.2.3 对数似然与得分函数求解 . . . 8

4.2.4 3.2.4 无偏性验证（双层全期望展开） . . . 9

4.2.5 3.2.5 Fisher 信息量与 Cramér–Rao 下界确立 . . . 9

4.3 3.3 命题 2：跨期基础水平的边际方差分解与仿射式推导 . . . 9

4.4 3.4 命题 4 与推论 1：AR(1) 错位相减级数求和与 Cochran 对偶证明 . . . 10

4.4.1 3.4.1 AR(1) 双重协方差级数求和的错位相减法展开 . . . 10

4.4.2 3.4.2 推论 1 成本优化一阶导与二阶导完整展开 . . . 10

4.5 3.5 命题 5：单调似然比（MLR）一阶差分严格为正证明 11

5 第四部分：数值模拟的深层设计与三幅图的精读密码 11

5.1 4.1 图 1（理论方差分解与 50,000 次蒙特卡洛验证） 11

5.2 4.2 图 2（增长检测功效与 Wald 检验失真） 11

5.3 4.3 图 3（更新过程时序卷积与单步预测误差的双口径解密） 12

6 第五部分：全美流感真实数据实证全景复盘 12

6.1 5.1 实证中的样本量 N 是什么？怎么一步步筛选出来的？ 12

6.1.1 (1) N 的统计学定义：观测单位是“州—周（State-Week）” 12

6.1.2 (2) 总样本池的来源：16,218 个原始记录 12

6.1.3 (3) 核心客观筛选门槛：$D_t \geq 5$（全美总有效样本 $N = 10,303$） 12

6.1.4 (4) 各章节具体的 N 划分机制全景表 13

6.2 5.2 为什么必须用 FGLS（可行广义最小二乘法）？ 13

6.3 5.3 核心实证估计结果 13

6.4 5.4 达峰期震撼反转：88.9% 偏差 vs 15.5% 集成预测 13

6.5 5.5 欧洲 11 国 COVID-19 跨病种验证 14

7 第六部分：硕士中期答辩高频质询 Q&A 宝典（11 问 11 答） 14

7.0.1 Q1: 你的研究与现有的 EpiEstim (Cori) 和 Parag 的信息论下界有什么本质区别？ 14

7.0.2 Q2: 为什么一定要用负二项分支过程？用经典的泊松过程不行吗？ 14

7.0.3 Q3: 理论上的 $m_\times = A/v_R$ 与实证拟合得到的 $b/a \approx 22.6$ 能否直接画等号？ . 15

7.0.4 Q4: 你在局限性里提到 v_R 始终是拟合量而非测量量，如果让你来测，在实务中怎么才能把它测出来？ 15

7.0.5 Q5: 为什么推论 1 里的最优单期规模公式会和 Cochran 的两阶段抽样同构？ 15

7.0.6 Q6: 实证中为什么用 FGLS 而不用我们最熟悉的普通最小二乘法 (OLS)？ . . 15

7.0.7 Q7: 达峰期看似误差恒定在 0.3 左右，你凭什么说病例规模在达峰期依然有用？ 15

7.0.8 Q8: 滞后暴露权重取 $w = (0.65, 0.25, 0.10)$ 的依据是什么？换一组权重结论还成立吗？ 15

7.0.9 Q9: 为什么命题 3 说提高报告率 ρ 存在无法消除的方差下界？现实中疾控提高检测率没有意义吗？ 16

7.0.10 Q10: 这篇论文对国家公共卫生监测体系的建设，到底能提供什么实际建议？ 16

7.0.11 Q11：你在实证里的样本量 N 是怎么确定的？有没有主观挑选样本或偷看未来数据？ 16

- **英文标题（原文）**：Boundaries of Surveillance Scale Returns in Epidemic Monitoring: Estimation Targets, Environmental Stochasticity, and External Validation
- **来源仓库**：https://github.com/wangchi2068/case-count-inference-bottleneck （最新定稿 commit `80e7d39`，2026 年 10 月 10 日）
- **深读依据**：仓库内权威定稿正文 `paper/main.tex`（28 页）、理论附录 A.1–A.6、全美 NHSN 流感实证、CDC FluSight 前瞻集成验证与欧洲 11 国 COVID-19 扩展实验。
- **阅读对象**：应用统计专业硕士（MAS）及生物数学/动力学建模方向研究生。旨在不仅讲清公式“是什么”，更深度拆解“为什么这样推”、“直觉怎么理解”、“参数怎么设定与文献依据”、“实证样本量 N 是什么与怎么选的”以及“评委可能怎么问”。

---

1 导读前言：应用统计研究生的“论文通透心法”

阅读或答辩这篇论文时，首先要建立一个宏观全局认知：**本文是一篇高度典范的应用统计学顶刊风格论文**。它的行文与论证结构高度精密，由四根核心支柱环环相扣而成：

1. **微观概率论支柱**：从经典生灭分支过程（Galton–Watson 过程）出发，引入生物学超传播机制（Gamma 混合泊松分布，即负二项分布）与宏观观测不完全性（二项报告抽样过程），建立了双层随机生成机制；
2. **渐近统计推断支柱**：利用概率母函数（PGF）复合律证明了分布族闭包，计算得分函数与 Fisher 信息矩阵，严格证明了一致最小方差无偏估计（UMVUE）并达到 Cramér–Rao 下界；
3. **运筹与抽样设计支柱**：将理论方差分解与流行病学监测资源预算结合，推导了时间与样本规模的二维权衡闭式解，在数学形式上同构于经典两阶段抽样模型（Cochran 费用分配模型）的深刻对偶；
4. **经验计量与实证支柱**：不满足于纯理论推导，而是采集全美 CDC NHSN 长达六年、涵盖 50 州及 DC 的 16,218 条真实住院周度记录，采用可行广义最小二乘法（FGLS）与聚类 Bootstrap 检验，破除了达峰期“样本量失效”的传统误读，并扩展至 CDC FluSight 与欧洲 COVID-19 多场景。

读懂这篇论文的秘诀在于：**时刻牢记“推断目标决定规模收益”这一灵魂红线**。

---

2 第一部分：宏观全景地图——这篇论文究竟讲了一个什么故事？

2.1 1.1 一个违背直觉的现实科学矛盾

在公共卫生监测实践与常规统计直觉中，人们往往预设：**“数据越多越好，样本量越大越准”**。大数定律告诉我们，只要不断扩大哨点医院覆盖面、增加报告确诊人数（即增大病例规模 m），随机

噪声就会被迅速平均掉，估计精度就能无界提升。

然而，在应对流感大流行、COVID-19 等真实传染病爆发时，全球疾控机构频繁面临一个极其尴尬的困境：

- 为什么在疫情高峰期，即便每周捕获上万例患者，模型的短期预测误差依然居高不下？
- 为什么在投入巨资扩展检测网络后，对未来趋势的判断却很快遭遇“平台瓶颈”，再怎么加倍收集病例，预测精度的改善也极其微弱？

既有文献的局限：以往学者通常笼统地将这种现象归咎于“漏报太多”、“数据质量差”或“模型设定错误”。近年来 Parag 等人（Nature Physics, 2022）利用信息论推导了带噪疫情曲线的信息极限，但其核心结论依然是：信息量随病例数近似线性增长。这仍未回答：**究竟在什么时候，病例规模不再是推断的主要瓶颈？**

2.2 1.2 论文的核心破局点：“推断目标决定规模收益”

本文最惊艳的洞见，在于指出以往文献混淆了**两个截然不同的统计推断目标**：

- **目标 A（当期传播参数 R_t）**：估计特定当周环境下的瞬时传染数。此时，环境扰动是我们要测量的“信号”。定理证明：测量方差随期望报告规模 m 按 $O(1/m)$ 严格单调趋零！在此目标下，大数定律完全成立，样本确实越大越好。
- **目标 B（跨期平均基准 $\bar{R}$）**：估计消除单周偶然波动后的潜在基础趋势。此时，宏观气象、节假日人群流动等不可预测的环境扰动成了“噪声”。定理证明：单期横截面样本再大，也只能观测到该期环境的一次实现，因而必然残留一个**不可约环境方差下限** v_R！总方差呈现仿射结构：

$$\mathrm{Var} = v_R + \frac{A}{m}$$

2.3 1.3 内生平衡点 $m_\times$ 的物理意义

将上述两项方差联立，自然导出了一个不可逆转的临界规模：

$$m_\times \equiv \frac{A}{v_R}$$

- **当 $m \ll m_\times$ 时（微观噪声主导区）**：抽样方差远远大于环境方差，此时扩大病例捕获能够带来极其显著的方差下降（投入产出比极高）；
- **当 $m \gg m_\times$ 时（宏观环境饱和区）**：不可约环境方差占比超过 50%，误差曲线进入水平平台。此时继续依靠扩大病例报告数已无法改善预测精度，监测资源必须由“扩量”转向“提质”（控制环境协变量与推进多模型集成）。

---

3 第二部分：全篇核心参数全景深度字典与流行病学物理直觉

为了彻底搞懂论文的推导与实证，消除“参数天书感”，本部分系统梳理全篇 20 个核心数学与流行病学参数。

3.1 2.1 全篇核心参数速查总表

符号	参数中文名称	数学类型与定义域	流行病学/物理含义
R_t	当期瞬时再生数 / 传播强度	连续标量 $(0,\infty)$	给定当期环境下，平均每个感染者引发的二代数（目标 A）
$\bar{R}$	跨期平均传播基准	连续标量 $(0,\infty)$	消除单周偶然波动后的基线水平（目标 B）
k	生物学过度离散参数	连续标量 $(0,\infty)$	刻画传染力异质性（超传播强度）；$k\to 0$ 极端厚尾，$k\to\infty$
ρ	报告抽样率 / 报告率	连续比例 $(0,1]$	潜在真实感染者被医疗系统检测并上报的概率
n	上一代真实风险集规模	正整数 $\mathbb{N}_+$	上一传播代社会上真实存在的感染人数（潜变量）
m	期望报告规模	连续标量 $(0,\infty)$	$m=\rho n$，上一代风险集对应的期望被报告人数
C_t	观测报告病例数	非负整数 $\mathbb{N}$	医院或疾控系统实际记录到的报告计数（观测随机变量）
I_t	当期真实新发感染总数	非负整数 $\mathbb{N}$	当期全社会实际发生的新感染总人数（潜变量）
v_R	不可约环境方差	连续标量 $(0,\infty)$	天气、人群聚集、社会干预对全员的共同乘性扰动方差
A	规模相关方差标量系数	连续标量 $(0,\infty)$	$A\equiv\bar{R}+\frac{\rho(\bar{R}^2+v_R)}{k}$，微观抽样与超传播方差的综合系数
$m_\times$	特征规模平衡点 / 阈值	连续标量 $(0,\infty)$	抽样方差与环境方差相等的特征规模，$m_\times\equiv A/v_R$
D_t	有效暴露病例规模	连续标量 $(0,\infty)$	既往报告住院数的时序卷积平滑加权和，增长比分母
w	滞后暴露加权向量	离散向量 $\sum w_s=1$	传染代际分布与就诊确诊填报时滞的复合卷积权重
G_{t+1}	周度病例增长比	连续标量 $(0,\infty)$	下周新发报告数与当期有效暴露规模的比值 C_{t+1}/D_t
B	总病例人数预算	连续标量 $(0,\infty)$	命题 4 中各期期望被报告人数之和，$B=T\cdot m=T\rho n_T$
$\mathcal{B}$	总经费预算	货币标量 $(0,\infty)$	推论 1 中系统总运作经费预算，$\mathcal{B}=T(c_0+c_1 m)$
r	一阶环境自相关系数	连续标量 $[0,1)$	宏观环境冲击在相邻周度之间的自回归相关系数
T_{eff}	有效独立期数	连续标量 $(0,\infty)$	自相关折减后的等效独立期数，$T_{\text{eff}}\approx T\frac{1-r}{1+r}$
c_α	增长判定离散临界值	非负整数 $\mathbb{N}$	单侧假设检验 $H_0:R_t\le 1$ 在显著性水平 α 下的整数拒绝阈值
a,b	仿射损失模型拟合参数	连续标量	实证模型 $\text{Loss}=a+b/D_t+u$ 的截距与斜率

3.2 2.2 核心参数的深度流行病学物理剖析

3.2.1 (1) 超传播参数 k 的生物学本质

在负二项分支模型中，方差公式为 $\text{Var}(X)=R_t+\frac{R_t^2}{k}$。

- 第一项 R_t 是纯 Poisson 计数方差（哪怕所有人传染力完全相同，随机相遇也会产生的泊松噪声）；
- 第二项 R_t^2/k 是个体生物学生殖数异质性方差。
- **文献依据**：Lloyd-Smith 等人（Nature, 2005）对全球 8 种传染病的历史流调数据进行了元分析，发现 SARS 的 $k\approx 0.16$，麻疹 $k\approx 0.1$（强超传播），而流感 $k\approx 0.3\sim 0.5$（中度超传播）。本文数值模拟选取 $k=0.35$ 作为流感基准，并在实证唯象分析中覆盖 $k\in[0.2,0.5]$，完全建立在真实流行病学基石之上。

3.2.2 (2) 报告抽样率 ρ 的折算逻辑

在流感住院实证中，ρ 不是普通的核酸阳性检出率，而是 **“全社会有症状感染者最终转化为实验室确诊住院病例的复合比例”**。

- **文献依据**：
- Zhou 等（2012）测算全美流感年均住院负担约为 20 万 ~ 40 万例；
- Tokars 等（2018）基于血清抗体流调测算全美季节性流感平均有症状侵袭率（Symptomatic Attack Rate）约为 8% ~ 15%（即约 2500 万 ~ 5000 万有症状感染）；
- 两者相除：$\rho \approx \frac{20\text{万}}{3500\text{万}} \sim \frac{40\text{万}}{2500\text{万}} \in [0.0056, 0.021]$（千分之六至百分之二）。
- 这一极端小概率抽样特性，完美契合了二项报告抽样模型的物理现实。

3.2.3 (3) 滞后卷积权重 $w = (0.65, 0.25, 0.10)$ 的依据

流感病程由三段时滞复合而成：

1. **潜伏期**：感染到出现症状，平均 1.5 ~ 2 天；
2. **就诊时滞**：发病轻症到病情恶化办理入院，平均 3 ~ 5 天；
3. **填报确认时滞**：医院实验室检测并录入 CDC NHSN 系统，平均 2 ~ 3 天。

三者相加，流感住院的复合时滞为 8 ~ 11 天。权重向量加权时间为：

$$\bar{\tau} = 1 \times 0.65 + 2 \times 0.25 + 3 \times 0.10 = 1.45 \text{ 周} \approx 10.2 \text{ 天}$$

正好落在该临床生理窗口的正中心。此外，正文表 1 证明无论是单周滞后（7 天）还是三周等权（14 天），斜率 b 均高度显著为正，结论对权重选择完全稳健。

---

4 第三部分：数学命题教学级逐行拆解与深入证明（保姆级代数展开）

本部分面向数学与统计学严格标准，将附录与正文中的每一个定理进行保姆级代数展开，绝不跳步。

4.1 3.1 命题 1 前置：Gamma–Poisson 混合积分逐行展开与“成功概率” p 的物理本质

4.1.1 3.1.0 成功概率 p 的反直觉物理顿悟

在负二项分布 $\text{NB}(k, p)$ 的抛硬币定义中：

- 我们不断试验，直到累计看到第 k 次“成功”为止；
- 在此之前所经历的“失败总次数” X 服从负二项分布。
- **在传染病模型中**：
- **传染给一个人 $\Longrightarrow$ 数学上记为一次“失败”！**
- **传染链条中断（未传染）$\Longrightarrow$ 数学上记为一次“成功”！**
- 均值公式反解：

$$R_t = k\frac{1-p}{p} \implies pR_t = k - kp \implies p(k + R_t) = k \implies p = \frac{k}{k + R_t}$$

- **物理直觉**：病毒传染力越强（R_t 越大），“中断传染（成功）”的概率 p 越接近 0，于是在链条中断前就会发生大量的“传染事件（失败）”，造成超级暴发！

4.1.2 3.1.1 Gamma–Poisson 连续混合积分逐行演算

设个体传染力 $\nu \sim \text{Gamma}(k, \theta)$，其中形状参数为 k，尺度参数 $\theta = R_t/k$。概率密度为：

$$f_\nu(\nu) = \frac{1}{\theta^k \Gamma(k)} \nu^{k-1} e^{-\nu/\theta} = \frac{(k/R_t)^k}{\Gamma(k)} \nu^{k-1} e^{-k\nu/R_t}$$

给定个体传染力 ν，二代感染数条件服从泊松分布：$\Pr(X = x \mid \nu) = \frac{\nu^x e^{-\nu}}{x!}$。

对潜变量 ν 在 $(0, \infty)$ 上求全积分（边缘化）：

$$\Pr(X = x) = \int_0^\infty \frac{\nu^x e^{-\nu}}{x!} \cdot \frac{(k/R_t)^k}{\Gamma(k)} \nu^{k-1} e^{-k\nu/R_t} d\nu$$

提取所有不含积分变量 ν 的常数项，合并被积函数中的幂次与指数：

$$= \frac{(k/R_t)^k}{x!\Gamma(k)} \int_0^\infty \nu^{(x+k)-1} \exp\left\{-\nu\left(1 + \frac{k}{R_t}\right)\right\} d\nu$$

做变量代换：令 $u = \nu\left(1 + \frac{k}{R_t}\right) = \nu\frac{k+R_t}{R_t}$，则 $\nu = u\frac{R_t}{k+R_t}$，微元 $d\nu = \frac{R_t}{k+R_t} du$。

代入积分中：

$$\int_0^\infty \nu^{(x+k)-1} e^{-u} \frac{R_t}{k+R_t} du = \left(\frac{R_t}{k+R_t}\right)^{x+k} \int_0^\infty u^{(x+k)-1} e^{-u} du$$

由欧拉 Gamma 函数严格积分定义：$\int_0^\infty u^{(x+k)-1} e^{-u} du = \Gamma(x+k)!$

代回原式展开：

$$\Pr(X = x) = \frac{(k/R_t)^k}{x!\Gamma(k)} \cdot \left(\frac{R_t}{k+R_t}\right)^{x+k} \cdot \Gamma(x+k) = \frac{\Gamma(x+k)}{x!\Gamma(k)} \cdot \frac{k^k R_t^x}{(k+R_t)^{x+k}}$$

按幂次项拆分组合：

$$= \frac{\Gamma(x+k)}{x!\Gamma(k)} \cdot \left(\frac{k}{k+R_t}\right)^k \left(\frac{R_t}{k+R_t}\right)^x$$

令 $p \triangleq \frac{k}{k+R_t}$，则 $1 - p = 1 - \frac{k}{k+R_t} = \frac{R_t}{k+R_t}$。

代入即得：

$$\Pr(X = x) = \frac{\Gamma(x+k)}{x!\Gamma(k)} p^k (1-p)^x \equiv \text{NB}(k, p)$$

从微观连续混合积分到离散负二项 PMF 逐行证毕！

4.2 3.2 命题 1：条件似然、得分函数、无偏性与 Cramér–Rao 下界

4.2.1 3.2.1 PGF 复合律保族性逐行推导

每个感染者独立以概率 ρ 上报，报告数 $C_t = \sum_{j=1}^{I_t} B_j$，其中 $B_j \sim \text{Bernoulli}(\rho)$，其 PGF 为 $G_B(s) = (1-\rho) + \rho s$。

上一代 n 个人产生的感染总数 $I_t \sim \mathrm{NB}(nk, p)$，其 PGF 为：

$$G_{I_t}(s) = \left(\frac{p}{1-(1-p)s}\right)^{nk}$$

利用复合随机和 PGF 复合定理 $G_{C_t}(s) = G_{I_t}(G_B(s))$：

$$G_{C_t}(s) = \left(\frac{p}{1-(1-p)[(1-\rho)+\rho s]}\right)^{nk}$$

将分母完全展开：

$$1-(1-p)(1-\rho)-\rho(1-p)s = 1-(1-\rho-p+p\rho)-\rho(1-p)s = [p+\rho(1-p)]-\rho(1-p)s$$

分子分母同时除以提取因子 $[p+\rho(1-p)]$：

$$G_{C_t}(s) = \left(\frac{\frac{p}{p+\rho(1-p)}}{1-\frac{\rho(1-p)}{p+\rho(1-p)}s}\right)^{nk}$$

定义新成功概率 $p^* \triangleq \frac{p}{p+\rho(1-p)}$。代入 $p = \frac{k}{k+R_t}$ 与 $1-p = \frac{R_t}{k+R_t}$：

$$p^* = \frac{\frac{k}{k+R_t}}{\frac{k}{k+R_t}+\rho\frac{R_t}{k+R_t}} = \frac{k}{k+\rho R_t}$$

对比负二项标准 PGF 形式，直接证明了：**观测值** $C_t \mid n, R_t \sim \mathrm{NB}(nk, p^*)$ **严格保族封闭！**

4.2.2 3.2.2 负二项方差公式化简

由负二项分布方差公式，形状参数为 nk，成功概率为 p^*：

$$\mathrm{Var}(C_t \mid n, R_t) = \frac{nk(1-p^*)}{(p^*)^2} = nk \cdot \frac{\frac{\rho R_t}{k+\rho R_t}}{\left(\frac{k}{k+\rho R_t}\right)^2} = nk \cdot \frac{\rho R_t}{k+\rho R_t} \cdot \frac{(k+\rho R_t)^2}{k^2}$$

分子分母对消 $k(k+\rho R_t)$：

$$= \frac{n\rho R_t(k+\rho R_t)}{k} = \frac{nk\rho R_t + n\rho^2 R_t^2}{k} = \rho n R_t + \frac{(\rho R_t)^2 n}{k}$$

清晰展示了泊松方差 $\rho n R_t$ 与个体超传播方差 $\frac{(\rho R_t)^2 n}{k}$ 的代数叠加！

4.2.3 3.2.3 对数似然与得分函数求解

$$\ln L(R_t) = \mathrm{const} - (nk + C_t)\ln(k+\rho R_t) + C_t \ln R_t$$

对 R_t 求偏导：

$$S(R_t) = \frac{\partial \ln L}{\partial R_t} = -\frac{\rho(nk+C_t)}{k+\rho R_t} + \frac{C_t}{R_t} = \frac{-\rho R_t(nk+C_t) + C_t(k+\rho R_t)}{R_t(k+\rho R_t)} = \frac{k(C_t - \rho n R_t)}{R_t(k+\rho R_t)}$$

令 $S(R_t)=0$，解得唯一极大似然估计量 $\widehat{R}_t^{\mathrm{MLE}}=\frac{C_t}{\rho n}$。

4.2.4 3.2.4 无偏性验证（双层全期望展开）

利用双层全期望公式：

$$\mathbb{E}[\widehat{R}_t \mid n,R_t]=\frac{1}{\rho n}\mathbb{E}[C_t \mid n,R_t]=\frac{1}{\rho n}\mathbb{E}_{I_t}\Big(\mathbb{E}_{C_t}[C_t \mid I_t]\,\Big|\,n,R_t\Big)$$

- 内层：二项报告抽样均值 $\mathbb{E}[C_t \mid I_t]=\rho I_t$；
- 外层：独立分支和均值 $\mathbb{E}[I_t \mid n,R_t]=\mathbb{E}\left[\sum_{i=1}^{n}X_{i,t}\right]=nR_t$；

代入：

$$\mathbb{E}[\widehat{R}_t \mid n,R_t]=\frac{1}{\rho n}\cdot\rho(nR_t)=R_t \quad (\text{严格无偏！})$$

4.2.5 3.2.5 Fisher 信息量与 Cramér–Rao 下界确立

$$\mathcal{I}(R_t \mid n)=\mathrm{Var}(S(R_t))=\frac{k^2\,\mathrm{Var}(C_t)}{R_t^2(k+\rho R_t)^2}=\frac{k^2\cdot\frac{n\rho R_t(k+\rho R_t)}{k}}{R_t^2(k+\rho R_t)^2}=\frac{k\rho n}{R_t(k+\rho R_t)}=\frac{n}{\frac{R_t}{\rho}+\frac{R_t^2}{k}}$$

取倒数得下界：

$$\mathcal{I}^{-1}=\frac{R_t}{\rho n}+\frac{R_t^2}{kn}\equiv\mathrm{Var}(\widehat{R}_t \mid n,R_t)$$

无偏估计量方差达到 Cramér–Rao 下界，确立其为 UMVUE!

4.3 3.3 命题 2：跨期基础水平的边际方差分解与仿射式推导

应用全方差公式：

$$\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\,n\right)=\mathrm{Var}\left(\mathbb{E}\left[\frac{C_t}{\rho n}\,\middle|\,n,R_t\right]\,\middle|\,n\right)+\mathbb{E}\left[\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\,n,R_t\right)\,\middle|\,n\right]$$

- 第一项：由无偏性，$\mathbb{E}\left[\frac{C_t}{\rho n}\,\middle|\,n,R_t\right]=R_t$，故方差为 $\mathrm{Var}(R_t \mid n)=v_R$；
- 第二项：代入命题 1 条件方差：

$$\mathbb{E}\left[\frac{R_t}{\rho n}+\frac{R_t^2}{kn}\,\middle|\,n\right]=\frac{\mathbb{E}[R_t \mid n]}{\rho n}+\frac{\mathbb{E}[R_t^2 \mid n]}{kn}$$

代入二阶矩恒等式 $\mathbb{E}[R_t^2 \mid n]=\mathrm{Var}(R_t)+(\mathbb{E}[R_t])^2=v_R+\bar{R}^2$：

$$=\frac{\bar{R}}{\rho n}+\frac{\bar{R}^2+v_R}{kn}$$

两项相加，整理为仿射结构：

$$\mathrm{Var} = v_R + \frac{1}{\rho n}\left[\bar{R} + \frac{\rho(\bar{R}^2 + v_R)}{k}\right] \equiv v_R + \frac{A}{m}$$

其中令 $m = \rho n$，标量系数 $A \equiv \bar{R} + \frac{\rho(\bar{R}^2+v_R)}{k}$。

4.4 3.4 命题 4 与推论 1：AR(1) 错位相减级数求和与 Cochran 对偶证明

4.4.1 3.4.1 AR(1) 双重协方差级数求和的错位相减法展开

在 AR(1) 自相关下，要求解级数：

$$S \triangleq \sum_{s=1}^{T-1}(T-s)r^s = (T-1)r + (T-2)r^2 + \cdots + 1\cdot r^{T-1}$$

两端同乘公比 r：

$$rS = (T-1)r^2 + (T-2)r^3 + \cdots + 1\cdot r^T$$

两式相减：

$$(1-r)S = (T-1)r - \left[r^2 + r^3 + \cdots + r^{T-1}\right] - r^T = Tr - \sum_{s=1}^{T} r^s = Tr - \frac{r(1-r^T)}{1-r}$$

两端除以 $(1-r)$：

$$S = \frac{Tr}{1-r} - \frac{r(1-r^T)}{(1-r)^2}$$

代入环境总方差：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = Tv_R + 2v_R S = Tv_R + 2v_R\left[\frac{Tr}{1-r} - \frac{r(1-r^T)}{(1-r)^2}\right] = v_R T\left[1 + \frac{2r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right]$$

通分化简括号内前两项：$1 + \frac{2r}{1-r} = \frac{1-r+2r}{1-r} = \frac{1+r}{1-r}$：

$$= v_R T\left[\frac{1+r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right]$$

两端除以 T^2，严格导出命题 4(ii) 式 (16)！

4.4.2 3.4.2 推论 1 成本优化一阶导与二阶导完整展开

目标函数代入 $T = \frac{\mathcal{B}}{c_0 + c_1 m}$：

$$f(m) = \frac{c_0 + c_1 m}{\mathcal{B}}\left(v_R + \frac{A}{m}\right) = \frac{1}{\mathcal{B}}\left[c_0 v_R + c_1 v_R m + \frac{c_0 A}{m} + c_1 A\right]$$

一阶导数：

$$f'(m) = \frac{1}{\mathcal{B}}\left[c_1 v_R - \frac{c_0 A}{m^2}\right] = 0 \implies m^2 = \frac{c_0 A}{c_1 v_R} = \frac{c_0}{c_1} m_\times \implies m^* = \sqrt{\frac{c_0}{c_1} m_\times}$$

二阶导数：

$$f''(m) = \frac{1}{\mathcal{B}} \frac{d}{dm}\left(c_1 v_R - c_0 A m^{-2}\right) = \frac{2 c_0 A}{\mathcal{B} m^3} > 0 \quad \text{（严格凸函数，唯一全局极小值点！）}$$

4.5　3.5 命题 5：单调似然比（MLR）一阶差分严格为正证明

对任意备择强度 $R_1 > R_0$，似然比对数形式为：

$$\ln \frac{\Pr_{R_1}(C_t = j)}{\Pr_{R_0}(C_t = j)} = nk \ln \frac{p^*(R_1)}{p^*(R_0)} + j \ln \frac{1 - p^*(R_1)}{1 - p^*(R_0)}$$

计算对计数值 j 的一阶差分：

$$\Delta(j) \triangleq \ln \frac{\Pr_{R_1}(j+1)}{\Pr_{R_0}(j+1)} - \ln \frac{\Pr_{R_1}(j)}{\Pr_{R_0}(j)} = \ln \frac{1 - p^*(R_1)}{1 - p^*(R_0)}$$

代入 $1 - p^*(R) = \frac{\rho R}{k + \rho R}$：

$$\frac{1 - p^*(R_1)}{1 - p^*(R_0)} = \frac{\frac{\rho R_1}{k + \rho R_1}}{\frac{\rho R_0}{k + \rho R_0}} = \frac{R_1(k + \rho R_0)}{R_0(k + \rho R_1)} = \frac{k R_1 + \rho R_0 R_1}{k R_0 + \rho R_0 R_1}$$

由于 $R_1 > R_0$，显然分子 $k R_1 + \rho R_0 R_1 > k R_0 + \rho R_0 R_1$ 分母，该比值严格大于 1！

取自然对数后，一阶差分 $\Delta(j) > 0$ 恒成立！

证明了似然比关于充分统计量 C_t **严格单调递增**，Karlin–Rubin 定理严格适用！

5　第四部分：数值模拟的深层设计与三幅图的精读密码

5.1　4.1 图 1（理论方差分解与 50,000 次蒙特卡洛验证）

- **双对数坐标轴下的两条轨迹**：
- 蓝色曲线（估计当期 R_t）：斜率为 -1 的直线，随 m 增大单调趋零；
- 红色曲线（估计跨期 $\bar{R}$）：小样本时沿 -1 斜率下降，越过交叉点 $m_\times = 53.1$ 后，迅速弯曲变平，严丝合缝贴在水平渐近虚线 $v_R = 0.04$ 上；
- 散点与解析解比值处于 0.988–1.017 之间，证明理论代数推导 100% 紧致正确。

5.2　4.2 图 2（增长检测功效与 Wald 检验失真）

- 虚线（Wald 检验）：在小样本且强超传播（$k = 0.1$）时，实际一类错误率最高达到 8.1%（严重虚警）；

- 实线（离散精确负二项检验）：全域严格受控于 0.05 以下；
- 超传播的代价：达到 80% 功效所需的病例数，从轻度超传播（$k = 1.0$）的 142 例激增至重度超传播（$k = 0.1$）的 415 例，暴增近 3 倍！

5.3　4.3 图 3（更新过程时序卷积与单步预测误差的双口径解密）

- **为什么初始参数看是 0.75–0.98 倍？**模拟横轴标示的是第 0 周的初始规模 m。因为 $\bar{R} = 1.15 > 1$（疫情自发增长），到了第 4–29 周评估时，实际病例数自发增长至初始值的 1.7–2.4 倍（中位数口径，均值口径约 2.6–3.2 倍）！拿增长后的大病例数对比初始小规模理论值，表观比值自然偏低；
- **为什么实际规模看是不低于下界的 1.01–1.17 倍（按组 1.00–1.45 倍）？**按实际发生规模重核参照线，经验预测误差**严格不低于单代静态下界**，直接证实了式 (29) 预言的额外预测偏差项 $(\mu/D - \bar{R})^2 \geq 0$！

6　第五部分：全美流感真实数据实证全景复盘

6.1　5.1 实证中的样本量 N 是什么？怎么一步步筛选出来的？

很多读者在查阅实证表格时常有疑问："表 1 的 $N = 1267$ 是什么？表 3 的 $N = 1220$ 又是什么？为什么三个阶段加起来又是 10,303？这些 N 到底代表什么，又是怎么筛选出来的？"

本节彻底讲透实证中样本量 N 的统计学定义与严格筛选漏斗：

6.1.1　(1) N 的统计学定义：观测单位是"州—周（State-Week）"

在传染病面板数据（Panel Data）中，**1 个观测不是 1 个人，也不是 1 个州，而是 1 个具体的"辖区—周度"时间切片**！

例如："加利福尼亚州在 2023 年第 45 周"记为 1 个样本观测；"德克萨斯州在 2023 年第 45 周"是另 1 个观测。

6.1.2　(2) 总样本池的来源：16,218 个原始记录

- 全美 50 个州加上华盛顿特区（DC），共 51 个地理辖区；
- 样本时间跨度从 2020 年 8 月至 2026 年 9 月，涵盖整整 6 年（约 318 个自然周）；
- 51 个辖区 $\times$ 318 周 $= \mathbf{16,218}$ 个原始"州—周"观测记录。

6.1.3　(3) 核心客观筛选门槛：$D_t \geq 5$（全美总有效样本 $N = 10,303$）

从 16,218 个记录筛选到 10,303 个主分析样本，依据单一客观规则：

- **门槛规则**：当周有效暴露规模 $D_t \geq 5$（加权暴露住院数不少于 5 例）；
- **为什么必须设为 5？**

增长比定义为 $G_{t+1} = C_{t+1}/D_t$。若 $D_t = 0$（连续多周零病例）或 D_t 仅有 1–2 例，增长比会出现

剧烈的除零数值爆炸；在夏季非流行期，很多州连续数周无流感住院。设定 $D_t \geq 5$，既排除了无信息的静默周，又完整保留了真实的小规模样本（如 $[5, 20)$ 组）。

- **坚决避免选择性偏误（不设覆盖率门槛）**：

主分析**不设任何医院填报覆盖率硬门槛**（没有像早期做法那样要求覆盖率 $\geq 50\%$），防止系统性剔除低覆盖率的脆弱观测。最终获得 $N = 10,303$ **个活跃周主样本**。

6.1.4 (4) 各章节具体的 N 划分机制全景表

章节与分析模块	样本量 N	详细筛选逻辑与流行病学阶段界定
全美主分析总池	10,303	满足 $D_t \geq 5$ 的全部活跃州—周观测总和。
流行初期主拟合（表 1）	1,267	各流感季初期疫情上升波段（$\bar{R}_{\text{early}} \approx 1.67$）中满足 $D_t \geq 5$ 的记录。主回
达峰与回落反证（表 3）	1,220	全美各季达峰周及随后 7 周回落期（$\bar{R}_{\text{peak}} \approx 0.81$）满足 $D_t \geq 5$ 的记录。
前过渡高覆盖期（第一阶段）	6,009	2020 年 10 月至 2024 年 4 月 30 日（合并大流行初期与法定强制段），平
自愿过渡期（第二阶段）	420	2024 年 5 月至 10 月（紧急状态解除），夏季低发加自愿填报，仅 420 个
CMS 新规重制期（第三阶段）	3,874	2024 年 11 月至 2026 年 9 月，恢复医保强制上报，覆盖率回升至 91.8%。
阶段加和算术闭环	10,303	$6,009 + 420 + 3,874 = 10,303$，数据链条 100% 严密闭环！
全国空间汇总序列	28	51 辖区数据加总为全国单一时间序列后，初期上升波段共 28 个全国汇总
CDC FluSight 外部验证	1,177	CDC 官方多模型前瞻预测（2022–23 季），按纯事前预测值 $\widehat{Y} \geq 5$ 筛选的
欧洲 COVID-19 外部验证	404	欧洲 11 国早期暴发序列（2020 年 2–4 月），按事前历史规模 $D_t \geq 5, g >$

6.2 5.2 为什么必须用 FGLS（可行广义最小二乘法）？

- 普通 OLS 假定误差项具有同方差；
- 但实测发现：残差具有极端厚尾（偏度高达 8.63），且小规模组的方差–均值比高达 5.32，大规模组收缩至 0.99，存在剧烈的反比非齐次方差；
- 必须采用以拟合值平方倒数 $1/\hat{\mu}^2$ 加权的 FGLS，并配合 1,500 次按州聚类的 Bootstrap 估计标准误。

6.3 5.3 核心实证估计结果

- 规模斜率项 $\hat{b} = 2.2434$（95% CI $[1.50, 3.02]$），**1,500 次 Bootstrap 重抽无一次小于等于零**（$p < 10^{-4}$），强力证实了 b/D_t 递减项的真实存在；
- 经验拟合截距 $\hat{a} = 0.0991$；经验平衡点 $m_{\times}^{\text{emp}} = \hat{b}/\hat{a} \approx 22.6$ 例/周；
- **误差份额分解**：在流行初期平均 0.181 的总误差中，规模相关项占 45.1%，不可约经验下限占 54.6%（四至五成半）。

6.4 5.4 达峰期震撼反转：88.9% 偏差 vs 15.5% 集成预测

- **表象与传统误读**：在达峰期，各规模组的总相对误差恒定在 0.292–0.312，看起来不管怎么增大病例规模，误差完全不下降。很多人据此宣称“达峰期病例数失效了”。
- **论文的数学正交分解**：

$$\text{总误差} = \underbrace{\left(\frac{\bar{R}_{\text{peak}} - \bar{R}_{\text{early}}}{\bar{R}_{\text{early}}}\right)^2}_{\text{常数基准偏移项（占 88.9\%）}} + \underbrace{\text{条件方差项（占 11.1\%）}}_{\text{规模效应仍显著为正！}}$$

- 达峰期看似恒定的高误差，**整整 88.9% 是因为疫情达峰转向、历史平稳基准失灵导致的常数漂移**！
- 剥离常数漂移后，达峰期内部的纯条件方差依然显著随规模递减（$\hat{b} = 7.9272$）；
- **外部验证的终极呼应**：

在引入 CDC FluSight 官方真实多模型前瞻集成预测后，**达峰期的均值偏差占比从静态单模型的 88.9% 骤降至 15.5%**！

直接在实证上回答了：跨过规模平衡点后，单纯扩充样本量已经边际递减，必须依靠多模型自适应集成来消除均值漂移。

6.5 5.5 欧洲 11 国 COVID-19 跨病种验证

- 引入欧洲 11 国早期日度发病监测数据（$N = 404$）；
- 纯事前口径拟合得 $\hat{b} = 33.92$（95% CI $[14.60, 74.9873]$），显著为正，经验平衡点为 124.7 例/天；
- 证明了规模递减规律跨病种、跨地域的高度稳健性，同时证实特征平衡点随时间分辨率和监测尺度变动。

---

7 第六部分：硕士中期答辩高频质询 Q&A 宝典（11 问 11 答）

本部分专为数学系、应用统计系教授评委的刁钻提问量身定制，掌握这 11 个回答，答辩即可稳操胜券。

7.0.1 Q1: 你的研究与现有的 EpiEstim (Cori) 和 Parag 的信息论下界有什么本质区别？

> **答**：Cori 等人的 EpiEstim 解决的是“如何在滑动窗口下估计时变再生数”，Parag 等人的研究确立了“以当期瞬态参数 R_t 为目标时信息量随病例数线性增长”的物理极限。

> 本文的本质区别在于**推断目标的切换**：我们证明，一旦将推断目标由当期瞬态参数 R_t 切换为跨期基础水平 $\bar{R}$，由于单期横截面样本无法消除全员共享的外生宏观环境扰动，方差标度律发生根本改变，出现不可约环境方差下限 v_R 与特征规模平衡点 $m_\times$。本文填补的是从“单期推断”跨越到“监测资源运筹设计”的理论空白。

7.0.2 Q2: 为什么一定要用负二项分支过程？用经典的泊松过程不行吗？

> **答**：传染病学中普遍存在极强的超传播现象（Lloyd-Smith 等 2005），约 20% 的感染者引发 80% 的传播。

> 泊松分布强加了方差等于均值（$k \to \infty$），这在数学上会严重低估小计数阶段的重尾抽样风险，人为低估达到指定功效所需的样本量需求（如图 2 所示，强超传播下样本量需求暴增 3 倍）。引入负二项分布不仅具有流行病学真实性，更在数理上通过 PGF 复合运算保证了二项抽样下的分布族封闭性，为全方差分解提供了优雅的解析基准。

7.0.3 Q3: 理论上的 $m_\times = A/v_R$ 与实证拟合得到的 $b/a \approx 22.6$ 能否直接画等号？

> **答**：不能直接等同，实证比值是理论平衡点的**经验映射物与量级参照**。

> 理论上的 $m_\times$ 是在单代已知参数下的解析临界点；而实证中的 $a = 0.0991$ 与 $b = 2.2434$ 是在真实流感周度时间序列中对 D_t 进行仿射拟合的参数，其中 a 既包含了宏观环境波动，也吸收了滞后卷积平滑失配的常数偏差。实证的核心价值在于**验证了理论预测的仿射递减与平台收敛形状**，而非点位精确物理测量。

7.0.4 Q4: 你在局限性里提到 v_R 始终是拟合量而非测量量，如果让你来测，在实务中怎么才能把它测出来？

> **答**：正如我们在第 6.2 节方法学展望中所提出的，未来可以通过**“双轨监测体系”**实现纯外生环境方差 v_R 的解耦测度：

> 目前的医院住院监测混合了就医行为与填报时滞；如果能在代表性社区布设固定人群的前瞻性主动追踪队列（如定期家庭采样），直接测得无就医行为干扰的真实社区传播强度，就能将外生宏观环境方差 v_R 与监测系统的代理平滑偏差完全分离识别。

7.0.5 Q5: 为什么推论 1 里的最优单期规模公式会和 Cochran 的两阶段抽样同构？

> **答**：这体现了数理统计深层的对偶之美。

> 在时间序列监测中，期数 T 本质上就是初级抽样单元（PSU），单期捕获病例数 m 就是次级抽样单元（SSU）。固定维持成本 c_0 发生于每一期，边际采集成本 c_1 发生于每个病例。这与 Cochran (1977) 调查抽样中“在有限预算下权衡抽取多少个群（群成本 c_0）与每群调查多少人（人均成本 c_1）”的数学优化模型完全同构，二阶导数 $\frac{2c_0A}{\mathcal{B}m^3} > 0$ 严格保证了最优解的全局唯一性。

7.0.6 Q6: 实证中为什么用 FGLS 而不用我们最熟悉的普通最小二乘法 (OLS)？

> **答**：因为真实监测数据的残差具有极强的异方差与厚尾性。

> 流感住院损失的偏度高达 8.63，小规模段的方差–均值比高达 5.32，大规模段收缩至 0.99，表现出剧烈的反比非齐次方差。如果使用普通 OLS，小样本段的极大极端值会过度主导回归线，估计功效损失极大；FGLS 通过一阶拟合残差平方倒数进行迭代加权，在大样本下达到最优线性无偏估计（BLUE）。

7.0.7 Q7: 达峰期看似误差恒定在 0.3 左右，你凭什么说病例规模在达峰期依然有用？

> **答**：凭严格的**均值–方差正交代数分解**。

> 我们证明了达峰期看似恒定的高误差中，整整 88.9% 来源于疫情转折导致的常数基准漂移 $(\bar{R}_{\text{peak}} - \bar{R}_{\text{early}})^2/\bar{R}^2_{\text{early}} = 0.2669$。真正反映推断波动的纯条件方差只占 11.1%。当我们使用达峰期自身均值剥离常数漂移后，规模相关项系数 $\hat{b} = 7.9272$ 依然高度显著为正。失效的是跨期平稳性假设，而不是病例规模本身。

7.0.8 Q8: 滞后暴露权重取 $w = (0.65, 0.25, 0.10)$ 的依据是什么？换一组权重结论还成立吗？

> **答**：有两个依据：第一，加权平均回溯时间为 1.45 周（约 10.2 天），与流感临床从感染、潜伏（1–2 天）、发病就诊（3–5 天）到填报确认的复合特征时滞（约 10 天）完全吻合；

> 第二，正文第 5.1 节进行了严格的权重敏感性检验：无论换用单周滞后（7 天）还是三周等权（14 天），规模斜率 b 始终在 1.9 到 3.1 之间，聚类 Bootstrap 置信区间严格远离零点，1,500 次重抽无一次小于零，核心科学结论对权重设定高度稳健。

7.0.9 Q9：为什么命题 3 说提高报告率 ρ 存在无法消除的方差下界？现实中疾控提高检测率没有意义吗？

> **答**：提高报告率具有显著价值，但它的作用机制具有局限性。

> 全方差公式严格表明：提高报告率 $\rho \to 1$ 只能消除由于漏报产生的纯二项抽样方差 $\frac{(1-\rho)\bar{R}}{\rho n}$，但它无法消除人群中固有的微观计数随机性 $\frac{\bar{R}}{n}$，更无法消除个体超级传播引发的子代抽样方差 $\frac{\bar{R}^2+v_R}{kn}$。唯有扩大地理或人群基数 n，通过大数定律才能同时压低所有微观随机性。

7.0.10 Q10：这篇论文对国家公共卫生监测体系的建设，到底能提供什么实际建议？

> **答**：给出了两阶段“差异化资源配置”判据：

> 1. **在疫情初期与低发期（$m < m_\times$）**：系统处于微观噪声主导区，此时应集中资源扩建哨点、扩大病例捕获，能够迅速跨过平衡点，获得显著的方差收益；

> 2. **在疫情高峰期与常态化监测期（$m > m_\times$）**：系统跨过特征平衡点进入饱和区，此时继续单纯追求捕获更多病例已边际收益递减，监测资源应当果断由“扩量”转向“提质”——即转向引入多模型前瞻集成预测，并补充气象、人群流动等外部环境协变量以解释不可约环境方差。

7.0.11 Q11：你在实证里的样本量 N 是怎么确定的？有没有主观挑选样本或偷看未来数据？

> **答**：实证中的 N 指的是“州—周”观测记录数。全美 51 辖区在 6 年内共有 16,218 个原始记录。我们采用单一、客观且纯事前的活跃周筛选门槛：$D_t \geq 5$，以过滤无流感病例时的除零数值爆炸，由此获得全美总样本池 10,303 个活跃观测。

> 在具体分析中：主拟合选取各季初期上升阶段（$N = 1,267$），达峰期选取转折周及随后回落周（$N = 1,220$）；三个报告制度期的样本量分别为 $6,009$、420 和 $3,874$，三者加和严格等于 $10,303$，数据链条绝对自洽；全部筛选仅依赖当期及既往已知数据，绝不利用未来信息；同时不设覆盖率门槛，确保不会因人为筛选引入选择性偏误。