论文深读与理论推导详解：《疫情监测中的病例规模收益边界：估计目标、环境随机性与外部验证》

论文全案理论推导详解 · sympy 数值核验 · 技术审计意见

目录

1 导读前言：应用统计研究生的“论文通透心法” 3

2 第一部分：宏观全景地图——这篇论文究竟讲了一个什么故事？ 3

2.1 1.1 一个违背直觉的现实科学矛盾 . . . 3

2.2 1.2 论文的核心破局点：“推断目标决定规模收益” . . . 4

2.3 1.3 内生平衡点 $m_\times$ 的物理意义 . . . 4

3 第二部分：核心概念与流行病学物理直觉通识 4

3.1 2.1 超传播与离散参数 k . . . 4

3.2 2.2 报告抽样率 ρ . . . 5

3.3 2.3 不可约环境方差 v_R . . . 5

3.4 2.4 有效暴露病例规模 D_t 与权重向量 w . . . 5

4 第三部分：数学命题教学级逐行拆解与深入证明 5

4.1 3.1 命题 1：条件似然、Fisher 信息与 Cramér–Rao 下界 . . . 5

4.1.1 3.1.1 定理陈述 . . . 5

4.1.2 3.1.2 逐步严密代数推导 . . . 5

4.2 3.2 命题 2：跨期基础水平的边际方差分解 . . . 8

4.2.1 3.2.1 核心问题与数学表述 . . . 8

4.2.2 3.2.2 逐步严密代数推导 . . . 8

4.3 3.3 命题 3：监测杠杆的理论非对称性 . . . 8

4.3.1 3.3.1 定理陈述与公卫意义 . . . 8

4.3.2 3.3.2 分步极限证明 . . . 9

4.4 3.4 命题 4 与推论 1：成本预算与监测设计运筹优化 . . . 9

4.4.1 3.4.1 命题 4（多期时间平均与 AR(1) 修正） . . . 9

4.4.2 3.4.2 推论 1（成本约束下的闭式解与 Cochran 对偶） . . . 10

4.5 3.5 命题 5：当期超临界增长判定的精确检验与离散功效锯齿 . . . 10

4.5.1 3.5.1 检验构建与单调似然比（MLR） . . . 10

4.5.2 3.5.2 为什么功效曲线呈现锯齿状（Sawtooth Wave）？ 11

5 第四部分：数值模拟的深层设计与三幅图的精读密码 11

5.1 4.1 图 1（理论方差分解与 50,000 次蒙特卡洛验证） 11

5.2 4.2 图 2（增长检测功效与 Wald 检验失真） 11

5.3 4.3 图 3（更新过程时序卷积与单步预测误差的双口径解密） 11

6 第五部分：全美流感真实数据实证全景复盘 12

6.1 5.1 数据资产与计量模型设定 12

6.2 5.2 核心实证估计结果 12

6.3 5.3 达峰期震撼反转：88.9% 偏差 vs 15.5% 集成预测 12

6.4 5.4 欧洲 11 国 COVID-19 跨病种验证 13

7 第六部分：硕士中期答辩高频质询 Q&A 宝典（10 问 10 答） 13

7.0.1 Q1: 你的研究与现有的 EpiEstim (Cori) 和 Parag 的信息论下界有什么本质区别？ 13

7.0.2 Q2: 为什么一定要用负二项分支过程？用经典的泊松过程不行吗？ 13

7.0.3 Q3: 理论上的 $m_\times = A/v_R$ 与实证拟合得到的 $b/a \approx 22.6$ 能否直接画等号？ . 13

7.0.4 Q4: 你在局限性里提到 v_R 始终是拟合量而非测量量，如果让你来测，在实务中怎么才能把它测出来？ 14

7.0.5 Q5: 为什么推论 1 里的最优单期规模公式会和 Cochran 的两阶段抽样同构？ 14

7.0.6 Q6: 实证中为什么用 FGLS 而不用我们最熟悉的普通最小二乘法 (OLS)？ . . 14

7.0.7 Q7: 达峰期看似误差恒定在 0.3 左右，你凭什么说病例规模在达峰期依然有用？ 14

7.0.8 Q8: 滞后暴露权重取 $w = (0.65, 0.25, 0.10)$ 的依据是什么？换一组权重结论还成立吗？ 14

7.0.9 Q9: 为什么命题 3 说提高报告率 ρ 存在无法消除的方差下界？现实中疾控提高检测率没有意义吗？ 14

7.0.10 Q10: 这篇论文对国家公共卫生监测体系的建设，到底能提供什么实际建议？ 15

- **英文标题（原文）**: Boundaries of Surveillance Scale Returns in Epidemic Monitoring: Estimation Targets, Environmental Stochasticity, and External Validation
- **来源仓库**：https://github.com/wangchi2068/case-count-inference-bottleneck （最新定稿 commit `80e7d39`，2026 年 10 月 10 日）
- **深读依据**：仓库内权威定稿正文 `paper/main.tex`（28 页）、理论附录 A.1–A.6、全美 NHSN 流感实证、CDC FluSight 前瞻集成验证与欧洲 11 国 COVID-19 扩展实验。

- **阅读定位**：面向应用统计专业硕士（MAS）及生物数学/动力学建模方向研究生的**全景教学级研读长文与答辩通透指南**。旨在不仅解释公式“是什么”，更深度拆解“为什么这样推”、“直觉怎么理解”、“实证说明了什么”以及“评委可能怎么问”。

---

1 导读前言：应用统计研究生的“论文通透心法”

阅读或答辩这篇论文时，首先要建立一个宏观全局认知：**本文是一篇高度典范的应用统计学顶刊风格论文**。它的行文与论证结构高度精密，由四根核心支柱环环相扣而成：

1. **微观概率论支柱**：从经典生灭分支过程（Galton–Watson 过程）出发，引入生物学超传播机制（Gamma 混合泊松分布，即负二项分布）与宏观观测不完全性（二项报告抽样过程），建立了双层随机生成机制；
2. **渐近统计推断支柱**：利用概率母函数（PGF）复合律证明了分布族闭包，计算得分函数与 Fisher 信息矩阵，严格证明了一致最小方差无偏估计（UMVUE）并达到 Cramér–Rao 下界；
3. **运筹与抽样设计支柱**：将理论方差分解与流行病学监测资源预算结合，推导了时间与样本规模的二维权衡闭式解，在数学形式上同构于经典两阶段抽样模型（Cochran 费用分配模型）的深刻对偶；
4. **经验计量与实证支柱**：不满足于纯理论推导，而是采集全美 CDC NHSN 长达六年、涵盖 50 州及 DC 的 16,218 条真实住院周度记录，采用可行广义最小二乘法（FGLS）与聚类 Bootstrap 检验，破除了达峰期“样本量失效”的传统误读，并扩展至 CDC FluSight 与欧洲 COVID-19 多场景。

读懂这篇论文的秘诀在于：**时刻牢记“推断目标决定规模收益”这一灵魂红线**。

---

2 第一部分：宏观全景地图——这篇论文究竟讲了一个什么故事？

2.1 1.1 一个违背直觉的现实科学矛盾

在公共卫生监测实践与常规统计直觉中，人们往往预设：**“数据越多越好，样本量越大越准”**。大数定律告诉我们，只要不断扩大哨点医院覆盖面、增加报告确诊人数（即增大病例规模 m），随机噪声就会被迅速平均掉，估计精度就能无界提升。

然而，在应对流感大流行、COVID-19 等真实传染病爆发时，全球疾控机构频繁面临一个极其尴尬的困境：

- 为什么在疫情高峰期，即便每周捕获上万例患者，模型的短期预测误差依然居高不下？
- 为什么在投入数亿元扩展检测网络后，对未来趋势的判断却很快遭遇“平台瓶颈”，再怎么加倍收集病例，预测精度的改善也极其微弱？

既有文献的局限：以往学者通常笼统地将这种现象归咎于“漏报太多”、“数据质量差”或“模型设定错误”。近年来 Parag 等人（Nature Physics, 2022）利用信息论推导了带噪疫情曲线的信息

极限，但其核心结论依然是：信息量随病例数近似线性增长。这仍未回答：**究竟在什么时候，病例规模不再是推断的主要瓶颈？**

2.2　1.2 论文的核心破局点："推断目标决定规模收益"

本文最惊艳的洞见，在于指出以往文献混淆了**两个截然不同的统计推断目标**：

- **目标 A（当期传播参数 R_t）**：估计特定当周环境下的瞬时传染数。此时，环境扰动是我们要测量的"信号"。定理证明：测量方差随期望报告规模 m 按 $O(1/m)$ 严格单调趋零！在此目标下，大数定律完全成立，样本确实越大越好。
- **目标 B（跨期平均基准 $\bar{R}$）**：估计消除单周偶然波动后的潜在基础趋势。此时，宏观气象、节假日人群流动等不可预测的环境扰动成了"噪声"。定理证明：单期横截面样本再大，也只能观测到该期环境的一次实现，因而必然残留一个**不可约环境方差下限** v_R！总方差呈现仿射结构：

$$\mathrm{Var} = v_R + \frac{A}{m}$$

2.3　1.3 内生平衡点 $m_\times$ 的物理意义

将上述两项方差联立，自然导出了一个不可逆转的临界规模：

$$m_\times \equiv \frac{A}{v_R}$$

- **当 $m \ll m_\times$ 时（微观噪声主导区）**：抽样方差远远大于环境方差，此时扩大病例捕获能够带来极其显著的方差下降（投入产出比极高）；
- **当 $m \gg m_\times$ 时（宏观环境饱和区）**：不可约环境方差占比超过 50%，误差曲线进入水平平台。此时继续依靠扩大病例报告数已无法改善预测精度，监测资源必须由"扩量"转向"提质"（控制环境协变量与推进多模型集成）。

3　第二部分：核心概念与流行病学物理直觉通识

在深入代数推导之前，必须彻底理解论文中反复出现的几个关键符号的物理内涵：

3.1　2.1 超传播与离散参数 k

- **流行病学现象**：传染病传播具有极强的个体异质性，即"二八定律"——20% 的感染者引发了 80% 的二代传播（超传播事件，Superspreading）。
- **数学建模**：个体的次级感染数服从负二项分布 $\mathrm{NB}(k, p)$，方差为 $R_t + R_t^2/k$。
- **参数 k 的物理直觉**：
- $k \in (0, \infty)$ 是生物学过度离散参数；
- 当 $k \to \infty$ 时，方差退化为均值 R_t，退化为经典泊松分布（所有个体传染力均匀）；
- 当 $k \to 0$ 时，异质性极强，极少数"超级传播者"引发超级暴发，分布具有极严重的厚尾特征。

3.2　2.2 报告抽样率 ρ

- **物理含义**：真实感染者中，最终被医疗系统检测并上报的概率。
- **观测机制**：潜在感染者独立以概率 ρ 被医院确诊上报，构成二项报告抽样过程 $C_t \mid I_t \sim \text{Binomial}(I_t, \rho)$。

3.3　2.3 不可约环境方差 v_R

- **物理含义**：外部宏观气象、人群自发聚集、交通政策变动等对整个地区所有感染者的“共同乘性冲击”。
- **不可约性**：无论你在当地测了 100 人还是 10 万人，由于他们处于同一个客观天气与社会环境中，单周横截面数据无法通过大数定律平均消除这一共同外生扰动。

3.4　2.4 有效暴露病例规模 D_t 与权重向量 w

- **为什么不直接用上周病例数？**流感病程具有持续性，前几天甚至两周前的住院患者依然具有传染风险，且就医确诊存在延迟。
- **数学卷积**：$D_t = \sum_{s=1}^{3} w_s C_{t+1-s}$，采用 3 周回溯卷积核 $w = (0.65, 0.25, 0.10)$。
- **加权平均回溯时滞**：$\bar{\tau} = 1 \times 0.65 + 2 \times 0.25 + 3 \times 0.10 = 1.45$ 周 ≈ 10.2 天。这与流感临床从感染、发病到住院填报的复合特征时滞（约 10 天）完全吻合。

4　第三部分：数学命题教学级逐行拆解与深入证明

本部分面向数学与统计学严格标准，将附录与正文中的每一个定理进行保姆级代数展开，绝不跳步。

4.1　3.1 命题 1：条件似然、Fisher 信息与 Cramér–Rao 下界

4.1.1　3.1.1 定理陈述

设已知上一代风险集真实规模 n、固定报告率 ρ 及离散参数 k：

1. 观测报告数 $C_t \mid n, R_t \sim \text{NB}$ (均值 $= \rho n R_t$, 形状参数 $= nk$)；
2. 矩估计量 $\widehat{R}_t = \frac{C_t}{\rho n}$ 恰为极大似然估计（MLE）；
3. 在内部参数空间 $R_t \in (0, \infty)$ 上，估计量 $\widehat{R}_t$ 严格无偏，且方差严格达到 Cramér–Rao 下界：

$$\text{Var}(\widehat{R}_t \mid n, R_t) = \mathcal{I}(R_t \mid n)^{-1} = \frac{R_t}{\rho n} + \frac{R_t^2}{kn}$$

4.1.2　3.1.2 逐步严密代数推导

第一步：单感染者的概率母函数（PGF）

个体二代感染数 $X_{i,t} \sim \text{NB}(k, p)$，其中成功概率 $p = \frac{k}{k+R_t}$。

负二项分布的标准 PGF 形式为：

$$G_X(s) \equiv \mathbb{E}[s^X] = \left(\frac{p}{1-(1-p)s} \right)^k$$

第二步：n 名独立感染者求和

当期真实新发感染总数 $I_t = \sum_{i=1}^{n} X_{i,t}$。由条件独立性，独立随机变量和的 PGF 等于各自 PGF 之积：

$$G_{I_t}(s) = \prod_{i=1}^{n} G_X(s) = \left(\frac{p}{1-(1-p)s} \right)^{nk}$$

因此，$I_t \mid n, R_t \sim \mathrm{NB}(nk, p)$，形状参数累加为 nk。

第三步：二项报告抽样下的 PGF 复合运算

每个感染者独立以概率 ρ 上报，则报告数可表示为复合随机和 $C_t = \sum_{j=1}^{I_t} B_j$，其中 $B_j \sim \mathrm{Bernoulli}(\rho)$。

伯努利分布的 PGF 为 $G_B(s) = (1-\rho) + \rho s$。

利用复合随机变量的 PGF 复合律 $G_{C_t}(s) = G_{I_t}(G_B(s))$：

$$G_{C_t}(s) = \left(\frac{p}{1-(1-p)[(1-\rho)+\rho s]} \right)^{nk}$$

展开分母：

$$1-(1-p)(1-\rho)-\rho(1-p)s = [p+\rho(1-p)] - \rho(1-p)s$$

分子分母同除以 $[p+\rho(1-p)]$：

$$G_{C_t}(s) = \left(\frac{\frac{p}{p+\rho(1-p)}}{1-\frac{\rho(1-p)}{p+\rho(1-p)}s} \right)^{nk}$$

定义新的成功概率 $p^* \triangleq \frac{p}{p+\rho(1-p)}$。将 $p = \frac{k}{k+R_t}$ 及 $1-p = \frac{R_t}{k+R_t}$ 代入：

$$p^* = \frac{\frac{k}{k+R_t}}{\frac{k}{k+R_t} + \rho\frac{R_t}{k+R_t}} = \frac{k}{k+\rho R_t}$$

对比负二项标准 PGF 形式，直接证明了：**观测值 C_t 严格服从负二项分布**：

$$C_t \mid n, R_t \sim \mathrm{NB}\left(\text{形状参数} = nk,\ \text{成功概率} = \frac{k}{k+\rho R_t} \right)$$

条件期望为 $\mathbb{E}[C_t] = nk\frac{1-p^*}{p^*} = \rho n R_t$。

第四步：对数似然方程与极值解

观测样本 C_t 的概率质量函数为：

$$\Pr(C_t) = \frac{\Gamma(C_t+nk)}{C_t!\Gamma(nk)}(p^*)^{nk}(1-p^*)^{C_t} = \mathrm{const} \cdot \left(\frac{k}{k+\rho R_t} \right)^{nk} \left(\frac{\rho R_t}{k+\rho R_t} \right)^{C_t}$$

取对数得到对数似然函数：

$$\ln L(R_t) = \text{const} - (nk + C_t)\ln(k + \rho R_t) + C_t \ln R_t$$

对参数 R_t 求一阶导数（得分函数 Score Function）：

$$S(R_t) \triangleq \frac{\partial \ln L}{\partial R_t} = -\frac{\rho(nk + C_t)}{k + \rho R_t} + \frac{C_t}{R_t}$$

通分展开：

$$S(R_t) = \frac{-\rho R_t(nk + C_t) + C_t(k + \rho R_t)}{R_t(k + \rho R_t)} = \frac{-\rho n R_t k - \rho R_t C_t + C_t k + \rho R_t C_t}{R_t(k + \rho R_t)} = \frac{k(C_t - \rho n R_t)}{R_t(k + \rho R_t)}$$

令得分函数为零 $S(R_t) = 0$，解得唯一驻点：

$$\widehat{R}_t^{\text{MLE}} = \frac{C_t}{\rho n}$$

第五步：无偏性验证

在内部参数空间 $R_t \in (0, \infty)$ 上：

$$\mathbb{E}[\widehat{R}_t \mid n, R_t] = \mathbb{E}\left[\frac{C_t}{\rho n} \,\middle|\, n, R_t\right] = \frac{\mathbb{E}[C_t \mid n, R_t]}{\rho n} = \frac{\rho n R_t}{\rho n} = R_t$$

估计量严格无偏。

第六步：Fisher 信息量与 Cramér–Rao 下界验证

利用得分函数的方差计算 Fisher 信息量：

$$\mathcal{I}(R_t \mid n) = \text{Var}(S(R_t)) = \text{Var}\left(\frac{k(C_t - \rho n R_t)}{R_t(k + \rho R_t)}\right) = \frac{k^2}{R_t^2(k + \rho R_t)^2}\,\text{Var}(C_t \mid n, R_t)$$

将负二项条件方差 $\text{Var}(C_t \mid n, R_t) = \rho n R_t + \frac{(\rho R_t)^2 n}{k} = \frac{\rho n R_t(k + \rho R_t)}{k}$ 代入：

$$\mathcal{I}(R_t \mid n) = \frac{k^2}{R_t^2(k + \rho R_t)^2} \cdot \frac{\rho n R_t(k + \rho R_t)}{k} = \frac{k \rho n}{R_t(k + \rho R_t)} = \frac{n}{\frac{R_t}{\rho} + \frac{R_t^2}{k}}$$

计算其倒数：

$$\mathcal{I}(R_t \mid n)^{-1} = \frac{1}{n}\left(\frac{R_t}{\rho} + \frac{R_t^2}{k}\right) = \frac{R_t}{\rho n} + \frac{R_t^2}{kn}$$

而估计量 $\widehat{R}_t$ 的真实抽样方差为：

$$\text{Var}(\widehat{R}_t \mid n, R_t) = \text{Var}\left(\frac{C_t}{\rho n}\right) = \frac{1}{\rho^2 n^2}\,\text{Var}(C_t) = \frac{1}{\rho^2 n^2}\left[\rho n R_t + \frac{\rho^2 n R_t^2}{k}\right] = \frac{R_t}{\rho n} + \frac{R_t^2}{kn}$$

二者严格代数相等！

结论证毕：该估计量在有限样本下严格达到信息矩阵下界，为一致最小方差无偏估计（UMVUE）。

4.2　3.2 命题 2：跨期基础水平的边际方差分解

4.2.1　3.2.1 核心问题与数学表述

若目标不是当期具体的 R_t，而是跨周平稳的潜在基准 $\bar{R} = \mathbb{E}[R_t \mid n]$，且环境存在真实波动 $\mathrm{Var}(R_t \mid n) = v_R > 0$。问：使用单期估计量 $\frac{C_t}{\rho n}$ 估计 $\bar{R}$ 的边际方差是多少?

4.2.2　3.2.2 逐步严密代数推导

应用**全方差公式（Law of Total Variance）**：

$$\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n\right) = \underbrace{\mathrm{Var}\left(\mathbb{E}\left[\frac{C_t}{\rho n}\,\middle|\, n, R_t\right]\,\middle|\, n\right)}_{\text{宏观环境项}} + \underbrace{\mathbb{E}\left[\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n, R_t\right)\,\middle|\, n\right]}_{\text{微观抽样项}}$$

第一项（环境项展开）：

由命题 1 的条件无偏性，$\mathbb{E}\left[\frac{C_t}{\rho n}\,\middle|\, n, R_t\right] = R_t$。因此：

$$\mathrm{Var}(R_t \mid n) = v_R$$

第二项（微观抽样项展开）：

代入命题 1 导出的条件方差公式：

$$\mathbb{E}\left[\frac{R_t}{\rho n} + \frac{R_t^2}{kn}\,\middle|\, n\right] = \frac{\mathbb{E}[R_t \mid n]}{\rho n} + \frac{\mathbb{E}[R_t^2 \mid n]}{kn}$$

利用方差与二阶矩基本关系：$\mathbb{E}[R_t^2 \mid n] = (\mathbb{E}[R_t \mid n])^2 + \mathrm{Var}(R_t \mid n) = \bar{R}^2 + v_R$。

代入得：

$$\frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn}$$

两项相加，得到定稿核心方差公式（式 7）：

$$\mathrm{Var}\left(\frac{C_t}{\rho n}\,\middle|\, n\right) = v_R + \frac{\bar{R}}{\rho n} + \frac{\bar{R}^2 + v_R}{kn} = v_R + \frac{1}{m}\left[\bar{R} + \frac{\rho(\bar{R}^2 + v_R)}{k}\right] \equiv v_R + \frac{A}{m}$$

其中令 $m = \rho n$ 为期望报告规模，定义标量系数 $A \triangleq \bar{R} + \frac{\rho(\bar{R}^2 + v_R)}{k}$。

4.3　3.3 命题 3：监测杠杆的理论非对称性

4.3.1　3.3.1 定理陈述与公卫意义

将方差中的抽样项展开：

$$\frac{\bar{R}}{\rho n} = \frac{\bar{R}}{n} + \frac{(1-\rho)\bar{R}}{\rho n}$$

因此总方差为：

$$V(n,\rho)=v_R+\underbrace{\frac{(1-\rho)\bar{R}}{\rho n}}_{\text{漏报抽样方差}}+\underbrace{\frac{\bar{R}}{n}}_{\text{完全报告计数方差}}+\underbrace{\frac{\bar{R}^2+v_R}{kn}}_{\text{超传播固有方差}}$$

4.3.2　3.3.2 分步极限证明

- **极限一（提高报告率 $\rho\to 1$）**：

$$\lim_{\rho\to 1}V(n,\rho)=v_R+0+\frac{\bar{R}}{n}+\frac{\bar{R}^2+v_R}{kn}=v_R+\frac{1}{n}\left(\bar{R}+\frac{\bar{R}^2+v_R}{k}\right)>v_R$$

物理含义：即便疾控中心投入无限资源把报告率提高到 100%（$\rho=1$），漏报方差虽然消除了，但人群内部固有的计数方差和个体超级传播带来的内在抽样方差依然存在！估计方差存在严格大于 v_R 的刚性下界。

- **极限二（扩大人群覆盖基数 $n\to\infty$）**：

对任意固定的 $\rho\in(0,1]$：

$$\lim_{n\to\infty}V(n,\rho)=v_R+\lim_{n\to\infty}\left[\frac{\bar{R}}{\rho n}+\frac{\bar{R}^2+v_R}{kn}\right]=v_R+0+0=v_R$$

物理含义：唯有扩大人群捕获基数 n，通过大数定律才能将微观层面的所有抽样波动彻底压平，收敛到不可约环境方差下限 v_R。

4.4　3.4 命题 4 与推论 1：成本预算与监测设计运筹优化

4.4.1　3.4.1 命题 4（多期时间平均与 AR(1) 修正）

设总样本输入规模预算为 $B=T\cdot m=T\rho n_T$。设计方案为 $\mathcal{D}_T=(T,n_T)$。

对跨期样本均值 $\overline{\widehat{R}}_T=\frac{1}{T}\sum_{t=1}^{T}\widehat{R}_t$ 求方差：

$$\mathrm{Var}(\overline{\widehat{R}}_T)=\frac{1}{T^2}\mathrm{Var}\left(\sum_{t=1}^{T}R_t\right)+\frac{1}{T^2}\sum_{t=1}^{T}\mathrm{Var}(\widehat{R}_t\mid R_t)=\frac{1}{T^2}\mathrm{Var}\left(\sum_{t=1}^{T}R_t\right)+\frac{1}{T^2}\cdot T\frac{A}{m}$$

代入 $Tm=B$：

$$\text{第二项（抽样项）}=\frac{A}{Tm}=\frac{A}{B}\quad\text{（恒为常数！）}$$

惊人结论：在固定总样本预算下，无论你分多少期，抽样误差项永远是常数 A/B！

要想降低总方差，**唯一的方法是拉长期数 T 去压制第一项（环境项）**！

- 独立环境下：第一项为 $\frac{v_R}{T}$，方差以 $O(1/T)$ 严格递减；
- AR(1) 自相关环境下（相关系数 r）：

$$\mathrm{Var}\left(\sum_{t=1}^{T} R_t\right) = Tv_R + 2v_R \sum_{s=1}^{T-1}(T-s)r^s = v_R T\left[\frac{1+r}{1-r} - \frac{2r(1-r^T)}{T(1-r)^2}\right]$$

当观测期远大于环境自相关记忆时长（$T \gg \frac{1}{1-r}$）时，有效独立期数退化为 $T_{\mathrm{eff}} \approx T\frac{1-r}{1+r}$。

4.4.2　3.4.2 推论 1（成本约束下的闭式解与 Cochran 对偶）

设每期固定运转维持成本为 c_0，每报告一例边际成本为 c_1。总经费预算为 $\mathcal{B} = T(c_0 + c_1 m)$。

代入 $T = \frac{\mathcal{B}}{c_0 + c_1 m}$ 到目标方差函数：

$$f(m) = \mathrm{Var}(\overline{\widehat{R}}_T) = \frac{v_R}{\frac{\mathcal{B}}{c_0+c_1 m}} + \frac{A}{\frac{\mathcal{B}}{c_0+c_1 m}m} = \frac{c_0 + c_1 m}{\mathcal{B}}\left(v_R + \frac{A}{m}\right) = \frac{1}{\mathcal{B}}\left[c_0 v_R + c_1 v_R m + \frac{c_0 A}{m} + c_1 A\right]$$

求一阶导数：

$$f'(m) = \frac{1}{\mathcal{B}}\left[c_1 v_R - \frac{c_0 A}{m^2}\right] = 0 \implies m^2 = \frac{c_0 A}{c_1 v_R} = \frac{c_0}{c_1} m_\times \implies m^* = \sqrt{\frac{c_0}{c_1} m_\times}$$

求二阶导数：

$$f''(m) = \frac{2c_0 A}{\mathcal{B} m^3} > 0 \quad (\text{对一切} m > 0 \text{ 恒正，函数严格凸！})$$

学术高度：这在数学结构上与抽样调查鼻祖 Cochran (1977) 第 10 章的两阶段抽样最优次级样本量公式完全同构！初级抽样单元对应期数 T，次级抽样单元对应单期病例 m。

4.5　3.5 命题 5：当期超临界增长判定的精确检验与离散功效锯齿

4.5.1　3.5.1 检验构建与单调似然比（MLR）

单侧假设检验：$H_0 : R_t \le 1 \quad \text{vs} \quad H_1 : R_t > 1$。

对任意 $R_1 > R_0$，似然比为：

$$\frac{\Pr_{R_1}(C_t = j)}{\Pr_{R_0}(C_t = j)} = \left(\frac{p^*(R_1)}{p^*(R_0)}\right)^{nk}\left(\frac{1-p^*(R_1)}{1-p^*(R_0)}\right)^{j}$$

由于 $1 - p^*(R) = \frac{\rho R}{k + \rho R}$ 关于 R 严格单调递增，底数 $\frac{1-p^*(R_1)}{1-p^*(R_0)} > 1$。

因此，似然比关于充分统计量 C_t **严格单调递增**（满足 MLR 性质）。

由经典统计推断理论（Karlin–Rubin 定理），上尾拒绝域 $\{C_t \ge c_\alpha\}$ 在复合原假设下，一类错误率严格在上确界点（边界点 $R_t = 1$）达到最大：

$$\sup_{R_t \le 1} \Pr_{R_t}(C_t \ge c_\alpha) = \Pr_{R_t = 1}(C_t \ge c_\alpha) \le \alpha$$

离散临界值由 $c_\alpha = \min\{c \in \mathbb{N} : \Pr_{R_t=1}(C_t \ge c) \le \alpha\}$ 唯一确定。

4.5.2　3.5.2 为什么功效曲线呈现锯齿状（Sawtooth Wave）？

因为观测计数 C_t 只能取整数，临界值 $c_\alpha(n)$ 随样本量 n 呈阶梯状跳变：

- 当 n 在某个区间连续微增时，临界值 c_α 保持不变，由于样本量变大，功效连续上升；
- 一旦 n 跨过某个临界点，为了控制显著性水平 α，c_α 突然跳跃到 $c_\alpha + 1$，拒绝门槛突然拔高，导致统计功效瞬间出现向下跳跃！
- 这解释了图 2 模拟中为什么连续增加病例数，功效曲线会出现特有的锯齿波动，证实了离散枚举求解最小样本量的必要性。

5　第四部分：数值模拟的深层设计与三幅图的精读密码

5.1　4.1 图 1（理论方差分解与 50,000 次蒙特卡洛验证）

- **验证目的**：直接在无时序延迟的单代分支模型下，用 50,000 次完全随机模拟，核验命题 1 与命题 2 的代数解析式是否准确无误。
- **图面精读**：
- 蓝色曲线（估计当期 R_t）：在双对数坐标轴下是一条斜率为 -1 的直线，随着 m 增大一路单调趋于零；
- 红色曲线（估计跨期 $\bar{R}$）：在小样本时沿 -1 斜率下降，越过交叉点 $m_\times = 53.1$ 后，迅速弯曲变平，严丝合缝地贴在水平渐近虚线 $v_R = 0.04$ 上；
- 散点（仿真值）与实线（解析解）比值处于 0.988–1.017 之间，证明理论代数推导 100% 紧致正确。

5.2　4.2 图 2（增长检测功效与 Wald 检验失真）

- **验证目的**：检验常规渐近正态 Wald 检验在传染病暴发早期小计数时的失效，并展示超传播对样本量需求的惩罚。
- **图面精读**：
- 虚线（Wald 检验）：在小样本且强超传播（$k = 0.1$）时，实际一类错误率最高达到 8.1%（严重虚警）；
- 实线（离散精确负二项检验）：全域严格压在 0.05 以下；
- 超传播的代价：达到 80% 功效所需的病例数，从轻度超传播（$k = 1.0$）的 142 例激增至重度超传播（$k = 0.1$）的 415 例，暴增近 3 倍！

5.3　4.3 图 3（更新过程时序卷积与单步预测误差的双口径解密）

- **核心争议与双口径彻底搞通**：
- **为什么按初始规模看是 0.75–0.98 倍？**模拟生成时横轴标示的是第 0 周的初始规模 m。因为设定了 $\bar{R} = 1.15 > 1$（疫情处于增长态势），到了第 4–29 周评估时，实际的周病例数已经自发增长到了初始值的 1.7–2.4 倍（中位数口径）！拿增长后的大病例数去对比初始小规模的理论值，表观比值自然显得略低；

- **为什么按实际规模看是不低于下界的 1.01–1.17 倍（按组 1.00–1.45 倍）？**只要按照评价周实际发生的病例暴露规模重核参照线，经验预测误差就**严格不低于单代静态下界**！
- **理论大获全胜**：这直接印证了命题 6 和式 (29) 的条件分解定理——更新过程因为只能用历史报告代替真实感染压力，必然叠合一个非负的预测偏差项 $(\mu/D - \bar{R})^2 \geq 0$！

6　第五部分：全美流感真实数据实证全景复盘

6.1　5.1 数据资产与计量模型设定

- **真实数据源**：美国 CDC NHSN 系统 50 个州加华盛顿特区自 2020 年 8 月至 2026 年 9 月共 16,218 条周度住院记录；
- **有效样本筛选**：$D_t \geq 5$（活跃周门槛），保留 10,303 个有效州周观测；
- **计量模型**：根据式 (7) 仿射理论形式，建立模型 $\text{Loss}_{s,t} = a + \frac{b}{D_{s,t}} + u_{s,t}$；
- **为什么必须用 FGLS（可行广义最小二乘法）？**
- 普通 OLS 假定误差项具有同方差；
- 但实测发现：残差具有极端厚尾（偏度高达 8.63），且小规模组的方差–均值比高达 5.32，大规模组收缩至 0.99，存在剧烈的反比非齐次方差；
- 必须采用以拟合值平方倒数 $1/\hat{\mu}^2$ 加权的 FGLS，并配合 1,500 次按州聚类的 Bootstrap 估计标准误。

6.2　5.2 核心实证估计结果

- 规模斜率项 $\hat{b} = 2.2434$（95% CI $[1.50, 3.02]$），**1,500 次 Bootstrap 重抽无一次小于等于零**（$p < 10^{-4}$），强力证实了 b/D_t 递减项的真实存在；
- 经验拟合截距 $\hat{a} = 0.0991$；经验平衡点 $m_{\times}^{\text{emp}} = \hat{b}/\hat{a} \approx 22.6$ 例/周；
- **误差份额分解**：在流行初期平均 0.181 的总误差中，规模相关项占 45.1%，不可约经验下限占 54.6%（四至五成半）。

6.3　5.3 达峰期震撼反转：88.9% 偏差 vs 15.5% 集成预测

- **表象与传统误读**：在达峰期，各规模组的总相对误差恒定在 0.292–0.312，看起来不管怎么增大病例规模，误差完全不下降。很多人据此宣称“达峰期病例数失效了”。
- **论文的数学正交分解**：

$$\text{总误差} = \underbrace{\left(\frac{\bar{R}_{\text{peak}} - \bar{R}_{\text{early}}}{\bar{R}_{\text{early}}}\right)^2}_{\text{常数基准偏移项（占 88.9\%）}} + \underbrace{\text{条件方差项（占 11.1\%）}}_{\text{规模效应仍显著为正！}}$$

- 达峰期看似恒定的高误差，**整整 88.9% 是因为疫情达峰转向、历史平稳基准失灵导致的常数漂移**！
- 剥离常数漂移后，达峰期内部的纯条件方差依然显著随规模递减（$\hat{b} = 7.9272$）；
- **外部验证的终极呼应**：

在引入 CDC FluSight 官方真实多模型前瞻集成预测后，**达峰期的均值偏差占比从静态单模型的 88.9% 骤降至 15.5%**！

直接在实证上回答了：跨过规模平衡点后，单纯扩充样本量已经边际递减，必须依靠多模型自适应集成来消除均值漂移。

6.4 5.4 欧洲 11 国 COVID-19 跨病种验证

- 引入欧洲 11 国早期日度发病监测数据（$N = 404$）；
- 纯事前口径拟合得 $\hat{b} = 33.92$（95% CI $[14.60, 74.99]$），显著为正，经验平衡点为 124.7 例/天；
- 证明了规模递减规律跨病种、跨地域的高度稳健性，同时证实特征平衡点随时间分辨率和监测尺度变动。

---

7 第六部分：硕士中期答辩高频质询 Q&A 宝典（10 问 10 答）

本部分专为数学系、应用统计系教授评委的刁钻提问量身定制，掌握这 10 个回答，答辩即可稳操胜券。

7.0.1 Q1: 你的研究与现有的 EpiEstim (Cori) 和 Parag 的信息论下界有什么本质区别？

> **答**：Cori 等人的 EpiEstim 解决的是“如何在滑动窗口下估计时变再生数”，Parag 等人的研究确立了“以当期瞬态参数 R_t 为目标时信息量随病例数线性增长”的物理极限。

> 本文的本质区别在于**推断目标的切换**：我们证明，一旦将推断目标由当期瞬态参数 R_t 切换为跨期基础水平 $\bar{R}$，由于单期横截面样本无法消除全员共享的外生宏观环境扰动，方差标度律发生根本改变，出现不可约环境方差下限 v_R 与特征规模平衡点 $m_\times$。本文填补的是从“单期推断”跨越到“监测资源运筹设计”的理论空白。

7.0.2 Q2: 为什么一定要用负二项分支过程？用经典的泊松过程不行吗？

> **答**：传染病学中普遍存在极强的超传播现象（Lloyd-Smith 等 2005），约 20% 的感染者引发 80% 的传播。

> 泊松分布强加了方差等于均值（$k \to \infty$），这在数学上会严重低估小计数阶段的重尾抽样风险，人为低估达到指定功效所需的样本量需求（如图 2 所示，强超传播下样本量需求暴增 3 倍）。引入负二项分布不仅具有流行病学真实性，更在数理上通过 PGF 复合运算保证了二项抽样下的分布族封闭性，为全方差分解提供了优雅的解析基准。

7.0.3 Q3: 理论上的 $m_\times = A/v_R$ 与实证拟合得到的 $b/a \approx 22.6$ 能否直接画等号？

> **答**：不能直接等同，实证比值是理论平衡点的**经验映射物与量级参照**。

> 理论上的 $m_\times$ 是在单代已知参数下的解析临界点；而实证中的 $a = 0.0991$ 与 $b = 2.2434$ 是在真实流感周度时间序列中对 D_t 进行仿射拟合的参数，其中 a 既包含了宏观环境波动，也吸收了滞后卷积平滑失配的常数偏差。实证的核心价值在于**验证了理论预测的仿射递减与平台收敛形状**，而非点位精确物理测量。

7.0.4 Q4: 你在局限性里提到 v_R 始终是拟合量而非测量量，如果让你来测，在实务中怎么才能把它测出来？

> **答**：正如我们在第 6.2 节方法学展望中所提出的，未来可以通过**“双轨监测体系”**实现纯外生环境方差 v_R 的解耦测度：

> 目前的医院住院监测混合了就医行为与填报时滞；如果能在代表性社区布设固定人群的前瞻性主动追踪队列（如定期家庭采样），直接测得无就医行为干扰的真实社区传播强度，就能将外生宏观环境方差 v_R 与监测系统的代理平滑偏差完全分离识别。

7.0.5 Q5: 为什么推论 1 里的最优单期规模公式会和 Cochran 的两阶段抽样同构？

> **答**：这体现了数理统计深层的对偶之美。

> 在时间序列监测中，期数 T 本质上就是初级抽样单元（PSU），单期捕获病例数 m 就是次级抽样单元（SSU）。固定维持成本 c_0 发生于每一期，边际采集成本 c_1 发生于每个病例。这与 Cochran (1977) 调查抽样中“在有限预算下权衡抽取多少个群（群成本 c_0）与每群调查多少人（人均成本 c_1）”的数学优化模型完全同构，二阶导数 $\frac{2c_0A}{\mathcal{B}m^3} > 0$ 严格保证了最优解的全局唯一性。

7.0.6 Q6: 实证中为什么用 FGLS 而不用我们最熟悉的普通最小二乘法 (OLS)？

> **答**：因为真实监测数据的残差具有极强的异方差与厚尾性。

> 流感住院损失的偏度高达 8.63，小规模段的方差–均值比高达 5.32，大规模段收缩至 0.99，表现出剧烈的反比非齐次方差。如果使用普通 OLS，小样本段的极大极端值会过度主导回归线，估计功效损失极大；FGLS 通过一阶拟合残差平方倒数进行迭代加权，在大样本下达到最优线性无偏估计（BLUE）。

7.0.7 Q7: 达峰期看似误差恒定在 0.3 左右，你凭什么说病例规模在达峰期依然有用？

> **答**：凭严格的**均值–方差正交代数分解**。

> 我们证明了达峰期看似恒定的高误差中，整整 88.9% 来源于疫情转折导致的常数基准漂移 $(\bar{R}_{\text{peak}} - \bar{R}_{\text{early}})^2/\bar{R}^2_{\text{early}} = 0.2669$。真正反映推断波动的纯条件方差只占 11.1%。当我们使用达峰期自身均值剥离常数漂移后，规模相关项系数 $\hat{b} = 7.9272$ 依然高度显著为正。失效的是跨期平稳性假设，而不是病例规模本身。

7.0.8 Q8: 滞后暴露权重取 $w = (0.65, 0.25, 0.10)$ 的依据是什么？换一组权重结论还成立吗？

> **答**：有两个依据：第一，加权平均回溯时间为 1.45 周（约 10.2 天），与流感临床从感染、潜伏（1–2 天）、发病就诊（3–5 天）到填报确认的复合特征时滞（约 10 天）完全吻合；

> 第二，正文第 5.1 节进行了严格的权重敏感性检验：无论换用单周滞后（7 天）还是三周等权（14 天），规模斜率 b 始终在 1.9 到 3.1 之间，聚类 Bootstrap 置信区间严格远离零点，1,500 次重抽无一次小于零，核心科学结论对权重设定高度稳健。

7.0.9 Q9: 为什么命题 3 说提高报告率 ρ 存在无法消除的方差下界？现实中疾控提高检测率没有意义吗？

> **答**：提高报告率具有显著价值，但它的作用机制具有局限性。

> 全方差公式严格表明：提高报告率 $\rho \to 1$ 只能消除由于漏报产生的纯二项抽样方差 $\frac{(1-\rho)\bar{R}}{\rho n}$，但它无法消除人群中固有的微观计数随机性 $\frac{\bar{R}}{n}$，更无法消除个体超级传播引发的子代抽样方差 $\frac{\bar{R}^2+v_R}{kn}$。唯有扩大地理或人群基数 n，通过大数定律才能同时压低所有微观随机性。

7.0.10 Q10：这篇论文对国家公共卫生监测体系的建设，到底能提供什么实际建议？

> **答**：给出了两阶段“差异化资源配置”判据：

> 1. **在疫情初期与低发期（$m < m_\times$）**：系统处于微观噪声主导区，此时应集中资源扩建哨点、扩大病例捕获，能够迅速跨过平衡点，获得显著的方差收益；

> 2. **在疫情高峰期与常态化监测期（$m > m_\times$）**：系统跨过特征平衡点进入饱和区，此时继续单纯追求捕获更多病例已边际收益递减，监测资源应当果断由“扩量”转向“提质”——即转向引入多模型前瞻集成预测，并补充气象、人群流动等外部环境协变量以解释不可约环境方差。